선택한 토큰과 처리한 위치를 구별하기

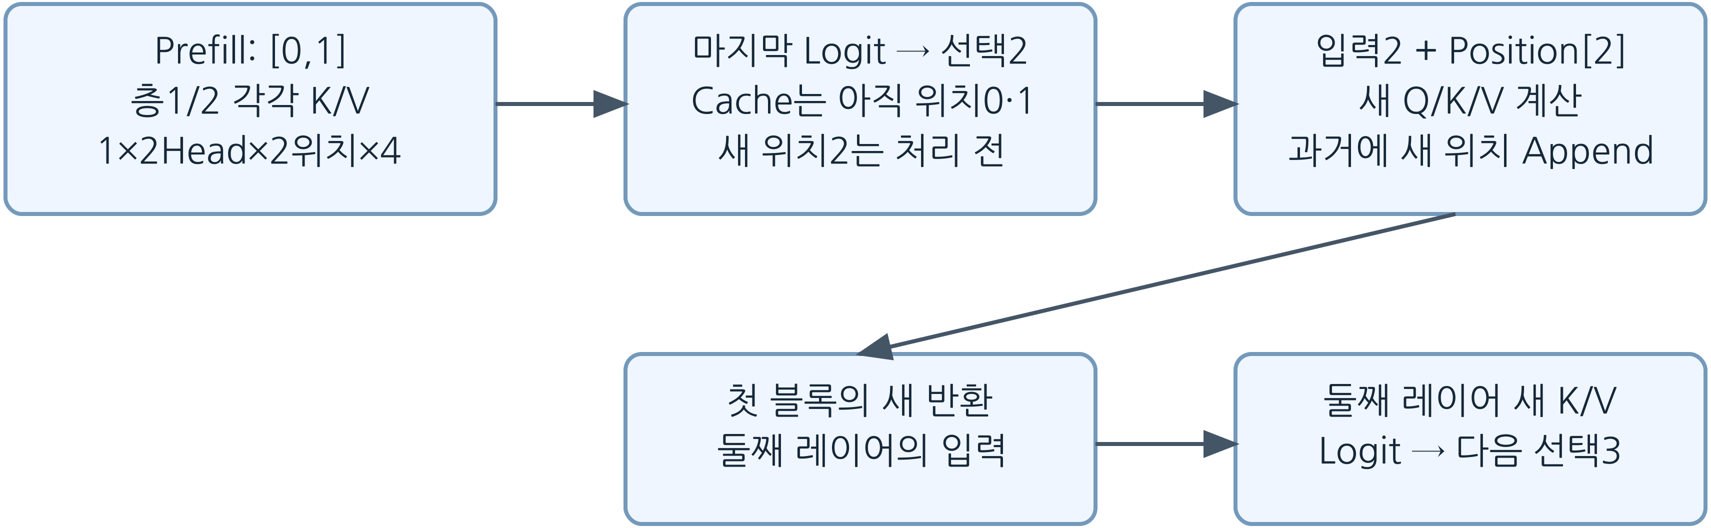
Prefill: [0,1]
층1/2 각각 K/V
1×2Head×2위치×4
마지막 Logit → 선택2
Cache는 아직 위치0·1
새 위치2는 처리 전
입력2 + Position[2]
새 Q/K/V 계산
과거에 새 위치 Append
첫 블록의 새 반환
둘째 레이어의 입력
둘째 레이어 새 K/V
Logit → 다음 선택3

둘째 레이어는 첫 레이어 K/V를 복사하지 않음
Full/Incremental은 같은 Token·원위치·모델·Causal 조건에서 비교