비용을 줄이는 서로 다른 세 지점

KV Cache
과거 표현/투영 재계산 감소
원 Full 계수 정의 유지
새 Query의 과거 읽기 유지

Local Causal
허용15쌍 → 9쌍
먼 직접 연결6개 생략
남긴 열의 Softmax 재정규화

별도 특징 Kernel
과거 제공 집합 유지
계수 정의 변경
직접 합 = S/z 인자 합

Full / Local / Kernel의 출력은 이 실험에서 서로 다름
좌표 곱셈 셈과 CPU/GPU 시간·모델 성능은 별도 검증