제 10 장. Attention 과 Transformer — 상세 해설

AI Knowledge Book

목차

해설서를 읽는 방법 3
10.1 필요한 정보를 어떻게 골라 가져오는가? — 해설 4
독립 연습 해설 5
심화 해설 10
이해 확인 해설 12
10.2 점수·비율·출력의 상세 해설 13
10.3 어떤 정보는 왜 읽지 못하게 해야 하는가? — 해설 21
10.4 같은 입력과 다른 입력에서 정보를 가져오는 방식 — 해설 30
10.5 여러 Head 를 독립적으로 계산하고 결합하기 — 해설 40
10.6 위치와 순서를 Attention 에 반영하기 — 해설 50
10.7 Attention 출력을 Transformer 블록으로 연결하기 — 해설 60
10.8 Encoder 와 Decoder 의 정보 요구 및 구조 선택 — 해설 71
10.9 다음 토큰 계산과 KV Cache 재사용 83
10.10 Efficient Attention 의 비용과 정보 경로 — 상세 해설 97
10.11 전체 모델 구현과 종합 적용 — 해설 106

해설서를 읽는 방법

본문의 유제와 독립 연습을 먼저 풀고, 입력·중간 표현·반환을 적은 계산 기록과 해설을 비교하자. 숫자가 다르면 처음 달라진 출처·축·허용 관계를 찾는다. 구조 설계 문제는 정보 요구를 충족하는 여러 답을 인정하며 각 해설의 조건과 판정 기준을 확인한다. 문제로 돌아가는 링크는 본권의 같은 문항을 가리킨다. 절별 목차에서 필요한 해설을 찾거나, 마지막 절의 종합 Checkpoint 에서 여러 연산을 함께 복습할 수 있다.

10.1 필요한 정보를 어떻게 골라 가져오는가? — 해설

본문의 질문에 먼저 답하고 자기 계산을 남긴 뒤 아래 풀이와 비교하자. 답이 다르면 출처·합할 축·성립 조건 중 어느 부분이 다른지 찾는다. 각 풀이 끝의 복습 안내로 돌아가 필요한 정의와 예제를 다시 읽을 수 있다. 여러 답이 가능한 구성·제안 문제에서는 예시와 같은 수를 썼는지가 아니라 요구 조건을 만족하고 근거를 설명했는지를 확인한다.

유제 10.1.1 해설 받는 사람을 표현하려는 요청

각 기여는 $0.2[2,0]=[0.4,0]$, $0.2[0,4]=[0,0.8]$, $0.6[2,4]=[1.2,2.4]$ 다. 따라서 출력은 $[1.6,3.2]$ 다. 앞 요청의 $[0.8,3.2]$ 와 비교하면 첫 좌표는 0.8 증가하고 둘째 좌표는 같다.

비율 0.4 를 둘째 값에서 셋째 값으로 옮겼다고 읽을 수 있다. 변화는 $0.4([2,4]-[0,4])=[0.8,0]$ 다. 둘째·셋째 값의 둘째 좌표가 둘 다 4 여서 그 좌표에서는 어디에 비율을 더 주는지와 무관하게 같은 총합을 얻는다. 두 요청이 달라졌다고 모든 출력 좌표가 달라지는 것은 아니다.

좌표별로 직접 더하거나 두 출력의 차이식을 쓰는 방법을 모두 허용한다. 비율만 다르다는 이유로 출력 전체가 달라져야 한다고 답했다면 값의 좌표도 확인하지 않은 것이다. 복습: 예제 10.1.1, 예제 10.1.3.

유제 10.1.2 해설 주어진 규칙의 적용 조건

점수 합은 $2+0+2=4$ 이므로 비율은 $[0.5,0,0.5]$ 다. 출력은 $0.5[2,0]+0[0,4]+0.5[2,4]=[1,0]+[0,0]+[1,2]=[2,2]$ 다. 이 교육용 규칙에서는 점수 0 이 비율 0 이 된다. 뒤에서 배우는 softmax 의 점수 0 을 같은 방식으로 읽어서는 안 된다.

$[-1,2,-1]$ 은 합이 0 이어서 나눗셈이 정의되지 않고 음수 점수도 있다. 이번 규칙의 '비음수·행 합 양수' 조건을 충족하지 않는다. 합 0 만 지적해도 적용 불가는 설명되지만, 비음수 조건까지 별도로 확인해야 다른 입력에서도 검사할 수 있다. 임의로 분모에 작은 수를 더해 계산하는 답은 주어진 규칙의 풀이가 아니다. 복습: 예제 10.1.2, 정의 10.1.1.

유제 10.1.3 해설 가중치가 같아도 출력이 다른 경우

첫 값의 차이는 $[7,0]-[2,0]=[5,0]$ 이다. 그 값의 비율은 0.2 이므로 출력 차이는 $0.2[5,0]=[1,0]$ 이다. 원래 출력 $[0.8,3.2]$ 에 더하면 $[1.8,3.2]$ 다. 전체 계산으로도 $0.2[7,0]+0.6[0,4]+0.2[2,4]=[1.4,0]+[0,2.4]+[0.4,0.8]$ 로 확인된다.

가중치가 같다는 것은 같은 비율로 보낸다는 뜻이지 보내는 내용이 같다는 뜻이 아니다. 출력은 비율과 값 둘 다에 의존한다. 값의 변화량을 그대로 더해 $[5.8,3.2]$ 로 답했다면 20% 만 전달한다는 조건을 놓쳤다. 복습: 예제 10.1.3, 정의 10.1.2.

유제 10.1.4 해설 두 점 사이에서 가능한 출력

출력은 $(1-t)[1,3]+t[5,1]=[1+4t,3-2t]$ 다. $[3,2]$ 의 첫 좌표는 $1+4t=3$ 에서 $t=0.5$ 를 요구하고 둘째 좌표도 $3-2(0.5)=2$ 로 맞다. 비율 $[0.5,0.5]$ 이며 비음수·합 1 도 만족한다.

$[3,3]$ 은 첫 좌표에서 $t=0.5$, 둘째 좌표에서 $t=0$ 을 요구한다. 같은 비율을 벡터 전체에 곱해야 하므로 불가능하다. 두 좌표를 별도의 비율로 섞으면 정의한 가중 집계와 다른 연산이 된다. 직선식 $y=3-(x-1)/2$ 로 대조하는 방법도 허용한다. 좌표별 범위 $1\le x\le 5, 1\le y\le 3$ 는 필요조건이지만 충분조건은 아니다. 복습: 정리 10.1.1, 예제 10.1.4.

유제 10.1.5 해설 잘못 옮긴 값 찾기

원래 출력은 $0.1[1,0]+0.7[0,2]+0.2[3,1]=[0.7,1.6]$ 이다. 새 값 행이 $[3,1],[1,0],[0,2]$ 인데 원래 비율을 그대로 쓰면 $[0.3,0.1]+[0.7,0]+[0,0.4]=[1,0.5]$ 다.

새 출처 순서는 3,1,2 이므로 비율도 $[0.2,0.1,0.7]$ 로 옮긴다. 각 열의 출처는 셋째·첫째·둘째다. 그러면 $[0.6,0.2]+[0.1,0]+[0,1.4]=[0.7,1.6]$ 으로 원래 출력이 보존된다. 출처별 기여 벡터를 표로 나열한 답도 허용한다. 순열을 모든 배열에 같은 축으로 무작정 적용하는 답은 부정확하다. A 에서는 제공 위치 열, V 에서는 제공 위치 행을 옮긴다. 복습: 정리 10.1.2, 예제 10.1.5.

독립 연습 해설

연습문제 10.1.1 해설 출력 좌표의 기여 비교

기여는 순서대로 $[0.6,2.4]$, $[1.5,0]$, $[-0.2,0.2]$ 다. 합은 $[1.9,2.6]$ 이다. 첫 좌표의 가장 큰 양의 기여는 둘째 위치의 1.5 다. 가장 큰 가중치 0.6 을 받은 첫 위치보다 크다. 둘째 값의 첫 좌표 5 가 첫 값의 첫 좌표 1 보다 커서 계수 차이를 넘어선다.

셋째 위치는 첫 좌표에 음수로 기여한다. 이를 '중요하지 않다' 며 버리면 첫 출력이 2.1 이 되어 틀린다. 좌표 기여 비교는 수치 비교이며 언어적 중요성의 증명이 아니다. 각 좌표를 별도 합으로 계산해도 된다. 복습: 예제 10.1.1의 비율과 기여 비중 구분.

연습문제 10.1.2 해설 요청마다 주어진 점수를 비율로 바꾸기

첫 행의 합은 8, 둘째 행의 합은 4 다. 따라서

$$A=\begin{bmatrix}0 & 0.25 & 0.75\\ 0.75 & 0.25 & 0\end{bmatrix}.$$

첫 출력은 $0[2,1]+0.25[0,3]+0.75[4,-1]=[0,0]+[0,0.75]+[3,-0.75]=[3,0]$ 이다. 둘째 출력은 $0.75[2,1]+0.25[0,3]+0[4,-1]=[1.5,0.75]+[0,0.75]=[1.5,1.5]$ 이다. 출력 행렬의 첫 행이 첫 요청, 둘째 행이 둘째 요청에 대응한다.

둘째 좌표에서 양·음의 기여가 상쇄되어 0 이 되어도 값들이 모두 0 이었다는 뜻은 아니다. 분수 1/4, 3/4 로 계산해도 같다. 모든 점수를 합한 12 로 나누는 것은 요청별 비율이 아니다. 복습: 예제 10.1.2, 정의 10.1.3.

연습문제 10.1.3 해설 전체를 다시 계산하지 않고 변화 예측

원래 기여는 $[1,1]$, $[1.5,0]$, $[0,1]$ 이므로 $o=[2.5,2]$ 다. 둘째 값 변화는 $[8,-2]-[6,0]=[2,-2]$ 이고 비율 0.25 를 곱하면 $\Delta o=[0.5,-0.5]$ 다. 새 출력은 $[3,1.5]$ 다. 전체를 다시 더하면 $[1,1]+[2,-0.5]+[0,1]$ 로 같다.

이 차이식은 비율이 고정된 경우에 성립한다. 실제 입력 변화로 키까지 바뀌어 비율이 달라지면 다른 위치들의 기여도 달라질 수 있다. '값은 점수에 절대로 영향을 주지 않는다' 로 무조건 일반화하지 말고 이번 계산 경로와 고정 조건을 밝혀야 한다. 복습: 예제 10.1.3, '실제 모델에서는 Q/K/V 를 어떻게 만들까?'.

연습문제 10.1.4 해설 같은 출력 좌표와 다른 출력 좌표

새 비율은 $[0.4-\delta, 0.4+\delta, 0.2]$ 다. 첫째에서 둘째로 옮긴다는 방향과 비음수 조건에서 $0 \le \delta \le 0.4$ 다. 합은 항상 1 이고 다른 비율도 비음수다. 변화는 $\delta([4,5]-[1,5]) = [3\delta, 0]$ 이므로 둘째 좌표는 보존된다.

원래 출력은 $[0.4+1.6+0.4, 2+2-0.2] = [2.4, 3.8]$ 이다. $\delta = 0.1$ 이면 $[2.7, 3.8]$ 다. 역방향 이동까지 허용하면 $-0.4 \le \delta \le 0.4$ 이지만 문제는 첫째에서 둘째로의 이동을 지정했으므로 기본 답은 비음수 구간이다. '합만 1 이면 된다' 며 $\delta = 0.5$ 를 허용하면 첫 비율이 음수가 된다. 복습: 예제 10.1.3, 정의 10.1.1.

연습문제 10.1.5 해설 값의 폭을 늘리기

A 는 2×3, V 는 3×3, O 는 2×3 이다. 첫 출력은 $0.5[1,0,2] + 0.5[3,4,0] = [2,2,1]$ 이다. 둘째 출력은 $0.25[3,4,0] + 0.75[0,2,6] = [0.75, 2.5, 4.5]$ 이다. 출력의 세 좌표는 값의 세 좌표를 이어 받는다.

비교 점수가 이미 주어졌으므로 Q/K 의 한 좌표 폭과 값의 세 좌표 폭 사이에 집계 차원의 충돌이 없다. 내적 비교를 선택한다면 Q 와 K 의 폭끼리는 맞아야 하지만 V 의 폭까지 같아야 하는 것은 아니다. 값 폭을 제공 위치 수와 혼동하면 이번 둘 다 3 인 우연에 가려진다. 제공 위치 수를 4 로 바꿔도 값 폭은 3 일 수 있다. 복습: 정의 10.1.3, 정의 10.1.2.

연습문제 10.1.6 해설 목표 출력의 비율 찾기

출력 식은 $[4a_2, 2a_3]$ 다. $[1,1]$ 에는 $a_2 = 1/4$, $a_3 = 1/2$ 가 필요하고 합 조건에서 $a_1 = 1/4$ 다. 모두 비음수다. 대입하면 $[1,1]$ 을 얻는다.

$[3,1]$ 은 $a_2 = 3/4$, $a_3 = 1/2$ 를 요구하여 $a_1 = -1/4$ 다. 정규화된 비음수 집계로는 불가능하다. 두 좌표는 각각 $[0,4]$, $[0,2]$ 범위에 있지만 합 조건을 만족하는 공동 비율이 없다. 가능한 영역은 $x \ge 0, y \ge 0, x/4 + y/2 \le 1$ 이다. 영역의 식으로 답해도 허용한다. 음수 계수를 찾아놓고 '식의 해가 있으므로 가능' 이라고 답한 경우에는 어떤 종류의 계수를 허용했는지 다시 확인한다. 복습: 예제 10.1.4, 정리 10.1.1.

연습문제 10.1.7 해설 합 1 조건을 빠뜨린 코드의 반례

한 답은 값 $[1], [2]$, 계수 $[1,1]$ 이다. 둘 다 양수이고 계수도 비음수지만 출력은 $[3]$ 으로 최댓값 2 를 넘는다. 다른 양수 값과 합 1 이 아닌 비음수 계수로 범위를 벗어나게 만든 답도 허용한다. 계수 합이 1 이 아니어도 우연히 범위 안에 있을 수 있으므로, 반드시 실제로 범위를 벗어나는 수를 제시해야 반례다.

범위 증명에서 얻는 것은 $L \sum_j a_j \le o \le U \sum_j a_j$ 다. 이를 $L \le o \le U$ 로 바꾸는 마지막 단계에 합 1 이 필요하다. 음수 계수 반례를 내면 비음수 조건까지 바꾸어 원래 주장의 실패를 정확히 검증하지 못한다. 복습: 정리 10.1.1의 증명과 실패 사례.

연습문제 10.1.8 해설 어떤 양이 바뀌는가?

(가) 값만 바꾸면 비교 입력과 변환 규칙은 같으므로 가중치는 반드시 불변이다. 출력은 바뀔 수 있다. 변경된 값이 가중치 0 을 받거나 변화가 0 이면 출력이 같을 수도 있다.

(나) 질의만 바꾸면 키와의 적합도 점수가 바뀔 수 있어 가중치도 바뀔 수 있다. 값은 그대로지만 비율이 달라져 출력도 바뀔 수 있다. 비교 함수가 두 질의에 같은 점수를 주거나 값들이 모두 같으면 변화가 출력에 나타나지 않을 수 있다.

(다) 키 하나만 바꾸면 그 키의 점수가 바뀔 수 있다. 같은 행의 합으로 정규화하는 규칙에서는 분모도 달라져 다른 키의 비율까지 바뀔 수 있다. 따라서 가중치와 출력 모두 바뀔 수 있다. 다른 비교·변환 규칙에서는 변화 범위를 그 규칙에 맞춰 확인한다.

분류와 함께 '가능' 과 '필연' 을 구별한 근거가 있어야 한다. '질의가 변하면 모든 출력이 반드시 변한다' 는 답은 동일한 값들을 집계하는 반례로 고칠 수 있다. 복습: 정의 10.1.2, 예제 10.1.3.

연습문제 10.1.9 해설 크기는 맞지만 출처가 틀린 집계

원래 올바른 출력은 $0.2 \times 10 + 0.5 \times 20 + 0.3 \times 100 = 2 + 10 + 30 = 42$ 다. 정렬된 값 [100], [10], [20] 에 원래 비율을 곱한 출력은 $20 + 5 + 6 = 31$ 이다. 올바른 새 비율은 C/A/B 에 해당하는 $[0.3, 0.2, 0.5]$ 로, $30 + 2 + 10 = 42$ 다.

각 값과 비율에 같은 출처 이름을 붙여 대조하면 배열 크기를 바꾸지 않고 오류를 찾는다. 0.3 을 C 에 주었다는 비교 결과를 값 A 에 적용하는 것이 핵심 오류다. 배열 전체를 같은 축으로 정렬할 수 없다는 점도 주의한다. 비율 행에서는 열, 값 표에서는 행이 출처 축이다. 복습: 예제 10.1.5, 정리 10.1.2.

연습문제 10.1.10 해설 요청 축과 제공 위치 축의 혼동

잘못된 $A = S/8$ 의 각 행 합은 0.5 다. 잘못된 출력은 첫 요청 $1/8 \times 2 + 3/8 \times 6 = 2.5$, 둘째 요청 $3/8 \times 2 + 1/8 \times 6 = 1.5$ 다.

각 행 합은 원래 4 이므로 정상 비율은 [1/4, 3/4], [3/4, 1/4] 이고 행 합은 각각 1 이다. 정상 출력은 [5], [3] 다. 잘못된 표에서는 각 요청에 배정된 비율을 절반씩 줄였다. 전체 합이 1 이면 두 요청을 합친 비율만 맞을 뿐 각 요청이 자기 제공 위치 사이에서 100% 를 배분한다는 조건은 충족하지 않는다.

'전체 표도 확률표다' 라는 설명으로 요청별 집계 규칙을 대체할 수 없다. 여기서는 각 행이 별도의 요청이다. NumPy 에서는 `scores.sum(axis=1, keepdims=True)` 가 대응 분모다. 복습: 예제 10.1.2, 'NumPy 로 행과 출처를 확인하기'.

연습문제 10.1.11 해설 원소별 곱을 집계로 착각한 구현 수정

`A * V` 는 $\begin{bmatrix} 0.5 & 0 \\ 0 & 2 \end{bmatrix}$ 를 만든다. 같은 인덱스 셀끼리 곱하고 다른 제공 위치의 기여를 더하지 않는다. 수정은 `correct = A @ V` 다. 결과는 $\begin{bmatrix} 0.5 & 3 \\ 1 & 2 \end{bmatrix}$ 이다.

첫 행은 $0.25[2, 0] + 0.75[0, 4] = [0.5, 3]$ 다. 두 번째 행도 $0.5[2, 0] + 0.5[0, 4] = [1, 2]$ 다. 이번에는 요청 수·제공 위치 수·값 폭이 모두 2 여서 모양 오류가 발생하지 않는다. 모양이 같은 것이 의미가 같은 연산의 증거는 아니다. 각 출력 셀에서 제공 위치를 합하는지 확인해야 한다. `np.matmul(A,V)` 도 같은 답으로 허용한다. 복습: 정의 10.1.3.

연습문제 10.1.12 해설 출처별 기여를 반환하는 함수 만들기

다음은 한 구현이다. 본문의 `aggregate` 와 같은 입력 검사 뒤 기여 배열을 만든다.

solution_code.py | learning-source/solution_code.py | Python | L1-L14 (14 줄)
source revision: section-source-v0.1

```python
""" 출처별 기여를 반환하는 독립 연습의 한 풀이."""
import numpy as np
from aggregate import aggregate


def with_contributions(weights, values):
    # 입력 검사를 재사용하고, 출처별 중간값을 별도로 만든다.
    expected = aggregate(weights, values)
    weights = np.asarray(weights, dtype=float)
    values = np.asarray(values, dtype=float)
    parts = weights[:, :, None] * values[None, :, :]
    output = parts.sum(axis=1)
    assert np.allclose(output, expected)
    return parts, output
```

`weights[:, :, None]` 은 `(m,n,1)`, `values[None, :, :]` 는 `(1,n,d)` 다. 곱하면 각 요청의 각 출처 비율이 그 출처의 모든 좌표에 곱해져 `(m,n,d)` 가 된다. `axis=1` 은 가운데 제공 위치 축을 더한다. `axis=2` 를 더하면 값 좌표를 없애 버려 원하는 출력과 다르다.

예제의 둘째 요청·셋째 제공 위치는 0.6 과 $[2, 4]$ 이므로 `C[1,2]=[1.2,2.4]` 다. 둘째 요청 전체를 합하면 `O[1]=[1.6,3.2]` 다. 반복문 구현이나 `np.einsum` 도 동일한 축·기여를 반환하면 허용한다. 함수가 출력만 계산하고 출처별 기여를 반환하지 않으면 수행 요구 일부가 빠진다. 복습: 정의 10.1.3, ‘NumPy 로 행과 출처를 확인하기’.

연습문제 10.1.13 해설 가중치가 달라도 같은 출력

예를 들어 $a = [0, 1, 0]$, $b = [0.5, 0, 0.5]$ 다. 둘 다 비음수·합 1 이고, 첫 출력은 $0 + 1 + 0 = 1$, 둘째는 $0 + 0 + 1 = 1$ 이다. 서로 다른 비율을 만들었다고 확인하는 단계도 필요하다.

모든 답은 $a_2 + 2a_3 = 1$ 과 합 1 을 만족하면 된다. 이를 풀면 $a_1 = a_3 = t$, $a_2 = 1 - 2t$, $0 \le t \le 0.5$ 다. 서로 다른 두 t 를 고르면 다양한 답을 얻는다. 출력이 같다는 것은 합친 수가 같다는 뜻이며 경로의 각 비율까지 같음을 뜻하지 않는다. 값 전체의 복원 문제와도 구분한다. 여기서는 값은 알고 있고 가중치를 모른다. 복습: ‘합친 출력으로 원래 자료를 모두 알 수 있을까?’.

연습문제 10.1.14 해설 공통 이동이 출력에 미치는 영향 증명

새 출력은

$$o' = \sum_j a_j (v_j + c) = \sum_j a_j v_j + \left(\sum_j a_j \right) c = o + c$$

다. 분배법칙으로 두 합을 나누고, 위치에 따라 변하지 않는 c 를 두 번째 합에서 밖으로 꺼냈다. 합 1 조건이 마지막에 쓰였다. 비음수는 이 등식에 필요하지 않다. 음수 계수가 있어도 합 1 이면 등식은 성립한다.

일반적인 합을 s 라 두면 $o' = o + sc$ 다. 합이 2 이면 $o' = o + 2c$ 다. 예를 들어 값 1 과 2, 계수 1 과 1, 공통 이동 $c = 1$ 이면 원래 출력 3, 새 출력 $2 + 3 = 5$ 다. $o + c = 4$ 가 아니다. 반례는 합이 1 이 아닌 경우 이동 효과가 달라짐을 보인다. 벡터의 각 좌표로 같은 증명을 써도 허용한다. 복습: 정의 10.1.1, 정리 10.1.1의 조건 사용법.

연습문제 10.1.15 해설 대응 보존 증명의 조건 평가

(가) 는 같은 제공 위치를 나타내는 A 의 열과 V 의 행을 함께 옮기므로 출력이 보존된다. 정리 10.1.2의 합 변수 재명명 증명이 적용된다. 요청 행을 옮기는 것은 출력의 행 순서를 바꾸므로 제공 위치 순열과 다른 동작이다.

(나) 는 일반적으로 보존되지 않는다. 두 값 0 과 2 에 비율 $[0.75, 0.25]$ 를 주면 출력 0.5 다. 값만 2,0 으로 바꾸면 1.5 다. 동일한 비율의 경우나 동일한 값의 경우에는 우연히 같을 수 있지만 일반 보장은 아니다.

(다) 는 고정된 가중치와 값이라는 조건을 벗어난다. 토큰 순서가 바뀌면 위치와 앞뒤 문맥을 포함한 표현, 비교 점수, 접근 조건 등이 달라질 수 있다. 출력 불변을 이 정리로 보장할 수 없다. 수정 문장은 “고정된 가중치의 제공 위치 열과 고정된 값의 제공 위치 행을 같은 순열로 재배열하면 집계 출력이 보존된다” 면 충분하다. (다) 의 실제 Attention 구조를 완성할 필요는 없다. 복습: 정리 10.1.2의 적용 범위.

연습문제 10.1.16 해설 출력과 비율을 알아도 값이 복원되지 않는 경우

조건은 $0.25v_1 + 0.75v_2 = 3$, 즉 $v_1 + 3v_2 = 12$ 다. 예를 들어 $(v_1, v_2) = (0, 4)$ 와 $(6, 2)$ 는 각각 $0 + 3 = 3$, $1.5 + 1.5 = 3$ 을 만든다. 스칼라 값 쌍을 서로 다르게 만들고 두 대입을 확인하면 다른 답도 허용한다.

$v_2 = t$ 를 자유롭게 고르면 $v_1 = 12 - 3t$ 다. 두 미지수에 독립된 식 하나라 여러 쌍이 남는다. v_2 를 추가로 알고 있으면 $v_1 = 12 - 3v_2$ 가 정해지고, v_1 을 알고 있어도 $v_2 = (12 - v_1)/3$ 이 정해진다. 비율이 양수라는 조건 덕분에 해당 나눗셈이 가능하다. ‘비율까지 알면 언제나 복원’ 이라는 답은 식의 수를 확인하지 않은 것이다. 복습: ‘합친 출력으로 원래 자료를 모두 알 수 있을까?’, 심화문제 10.1.2.

연습문제 10.1.17 해설 가중치와 설명을 혼동한 보고서 수정

기여는 $0.9[0, 0] = [0, 0]$, $0.1[10, 0] = [1, 0]$ 이고 출력은 $[1, 0]$ 이다. 첫 위치가 받은 계수 0.9 는 관찰된 사실이다. 그러나 출력의 첫 좌표의 수치 기여는 0 이므로 ‘출력 90% 가 첫 위치에서 왔다’ 는 말은 이 예에서 틀리다. 둘째 좌표는 모두 0 이므로 0 을 분모로 비중을 계산할 수도 없다.

한 수정 예는 “이 요청은 첫 위치에 가중치 0.9 를 배정했지만, 주어진 값의 수치 기여는 0 이었다. 이 집계 결과만으로 첫 단어가 모델 정답의 원인이라고 결론 내릴 수 없다” 다. 계산에서 확인한 계수·기여와 실제 의미·최종 원인의 추론을 구분하면 표현은 달라도 된다. ‘첫 단어는 절대로 원인이 아니다’ 라고 바꾸는 것도 근거를 넘어선다. 여기서 확인한 것은 이 집계의 수치이며 전체 모델의 모든 경로는 관찰하지 않았다. 복습: ‘높은 가중치를 의미나 인과적 설명으로 단정하지 않기’.

연습문제 10.1.18 해설 센서 자료를 요청별로 가져오기

(가) 비율은 $[0.75, 0.25, 0]$, $[0, 0.25, 0.75]$ 다. 첫 출력은 $0.75[10, 1] + 0.25[20, 0] = [7.5, 0.75] + [5, 0] = [12.5, 0.75]$ 다. 둘째 출력은 $0.25[20, 0] + 0.75[30, 1] = [5, 0] + [22.5, 0.75] = [27.5, 0.75]$ 다. 같은 센서 값을 읽지만 첫 요청은 낮은 측정값 쪽, 둘째는 높은 측정값 쪽에 큰 비율을 주었다. 둘째 좌표는 같아도 첫 좌표는 다르다.

(나) 비율을 $[a, b, c]$ 라 놓으면 $a + b + c = 1$, $10a + 20b + 30c = 25$, $a + c = 0.5$ 다. 마지막 식과 합 조건에서 $b = 0.5$ 다. 측정값 식은 $10a + 30c = 15$ 이고 $a = 0.5 - c$ 를 넣으면 $5 + 20c = 15$ 이므로 $c = 0.5$, $a = 0$ 이다. 비율 $[0, 0.5, 0.5]$ 는 비음수·합 1 이며 $[25, 0.5]$ 를 만든다. 좌표별로 별도 비율을 고를 필요가 없다.

(다) 값의 둘째 좌표는 교육용 품질 표시일 뿐 확률 모델을 주지 않았다. 0.5 는 가중 평균된 표시이며 측정의 정확성 확률 50% 를 보장하지 않는다. 비교용 키에는 센서의 위치·측정 시점·요청 대상과의 거리 등을 둘 수 있고, 값에는 보정 측정값과 전달할 품질 표시를 둘 수 있다. 이는 한 설계 예다. 요청과의 비교에 적절한 정보와 실제 전달할 내용의 역할을 분명히 설명하면 다른 제안도 허용한다. 목표를 만족하는 비율은 구했지만 그 비율을 실제 Q/K 에서 학습할 수 있음을 증명한 것은 아니다. 복습: 정의 10.1.2, 예제 10.1.4, 가중치 해석의 한계.

심화 해설

심화문제 10.1.1 해설 서로 다른 값을 동시에 바꿔도 보존되는 집계

변화량은 $a_1 h + a_2(v_2' - v_2)$ 다. 이를 0 으로 만들려면 $v_2' = v_2 - (a_1/a_2)h$ 로 두면 된다. 대입하면 $a_1 h - a_1 h = 0$ 이므로 다른 값들의 기여와 함께 전체 출력이 그대로다. 값 벡터에 비음수 제약은 없으므로 이 조정은 임의의 벡터 h 에 가능하다.

$a_2 = 0$ 이면 둘째 값을 아무리 바꾸어도 그 위치가 출력에 기여하지 않는다. 보존하려면 $a_1 h = 0$ 이어야 한다. 처음의 $a_1 > 0$ 을 유지하면 $h = 0$ 만 가능하다. $a_1 = 0$ 까지 허용한 별도 경우라면 두 값의 변화 모두 관찰되지 않는다. 0 으로 나누는 식을 그대로 적용할 수 없다. 이 조정은 같은 출력에 서로 다른 원래 값들이 대응하는 구체적인 원인이다. 복습: 예제 10.1.3, 정보 손실 설명.

심화문제 10.1.2 해설 두 요청이 있으면 복원되는 작은 사례

식은 $3v_1 + v_2 = 8$, $v_1 + 3v_2 = 16$ 이다. 첫 식에서 $v_2 = 8 - 3v_1$ 을 둘째에 넣으면 $v_1 + 24 - 9v_1 = 16$ 이므로 $v_1 = 1$, $v_2 = 5$ 다. 원래 비율에 대입하면 $0.75 + 1.25 = 2$, $0.25 + 3.75 = 4$ 로 맞다. 두 식을 더하고 빼서 합 6·차이 -4 를 구해도 된다.

두 요청 모두 $[0.5, 0.5]$ 이면 두 식이 같은 $v_1 + v_2 = 6$ 이다. $(0, 6)$, $(1, 5)$ 등 무수한 쌍이 가능하다. 요청 수가 둘이라고 반드시 독립된 정보 둘을 얻는 것은 아니다. 올바른 문장은 “하나의 집계 출력만으로 여러 미지의 값을 일반적으로 유일하게 복원할 수 없으며, 여러 출력과 알려진 비율이 충분히 독립된 조건을 주면 복원이 가능한 경우도 있다” 다. 이 심화는 선형대수의 연립식·가역성으로 이어진다. 복습: 연습문제 10.1.16, 정의 10.1.3.

심화문제 10.1.3 해설 비율의 작은 변화가 출력에 미치는 범위

$d_j = a_j - b_j$ 로 두면 두 행의 합이 모두 1 이어서 $\sum_j d_j = 0$ 이다. $d_j > 0$ 인 항의 합을 P, $d_j < 0$ 인 항의 절댓값 합을 N 이라 하면 $P = N$ 이다. 절댓값 합은 $P + N = 2P$ 이므로 $P = N = \varepsilon$ 다.

출력 차이 $D = \sum_j d_j v_j$ 에서 양수 항은 εL 과 εU 사이이고, 음수 항은 $-\varepsilon U$ 와 $-\varepsilon L$ 사이다. 음수 계수에 곱할 때 부등호 방향이 뒤집히는 점에 주의하자. 둘을 합하면

$$-\varepsilon(U - L) \le D \le \varepsilon(U - L)$$

이다. 따라서 $|D| \le \varepsilon(U - L)$ 다. 다른 증명은 $c = (L + U)/2$ 를 빼서 $D = \sum_j d_j (v_j - c)$ 로 만들고 삼각 부등식과 $|v_j - c| \le (U - L)/2$ 를 쓰는 것이다. $\sum_j d_j = 0$ 이라 공통 상수 항이 없어지는 원리는 연습문제 10.1.14와 연결된다.

두 값 L, U 에 대해 $b = [1, 0]$, $a = [1 - \varepsilon, \varepsilon]$, $0 \le \varepsilon \le 1$ 이면 출력 차이는 $\varepsilon(U - L)$ 여서 등호를 만든다. $L = U$ 이면 어떤 비율 변화에도 출력 차이는 0 이다. 출력의 수치 변화에 관한 정리이며 언어 의미·모델 정답의 안정성을 바로 보장하지 않는다. 복습: 정리 10.1.1, 예제 10.1.3.

이해 확인 해설

다음 다섯 해설은 본문의 같은 제목을 가진 질문에 대응한다. 독립 연습 18 문항에 포함하지 않는다. 먼저 자기 답과 이유를 적은 뒤 비교하고, 필요한 본문 위치로 돌아가 보자.

두 요청

같은 세 값 벡터를 그대로 두면 요청 문장만 바꾸어도 단순 평균의 결과는 같다. 평균은 $(v_1 + v_2 + v_3)/3$ 이고 식에 요청을 나타내는 양이 없기 때문이다. 요청별로 다른 집계를 원하면 비율을 정하는 단계가 요청에 의존해야 한다. 이는 평균의 산술 오류가 아니라 선택 기능의 한계다. '요청이 다르면 평균도 달라진다' 고 답했다면 무엇을 고정한 계산인지 다시 확인하자. 질문으로 돌아가기. 복습: 본문의 '평균과 한 위치의 복사로는 무엇이 부족할까?'.

내용을 바꾼 경우

가중치는 바뀌지 않는다. q_i, 모든 k_j, 점수 변환 규칙이 고정되어 있고 비교 단계가 v_2 를 읽지 않기 때문이다. 출력은 달라질 수 있다. 변화량은 $a_{i2}\Delta v_2$ 여서 비율이 0 이거나 값의 변화가 0 이면 그대로일 수도 있다.

실제 모델의 원래 입력을 바꾸면 키와 값이 함께 바뀔 수 있다. 따라서 위 결론은 값을 따로 바꾼 조건 아래의 결론이며 '입력을 바꾸어도 가중치는 언제나 같다' 로 확장할 수 없다. 질문으로 돌아가기. 복습: 정의 10.1.2, 예제 10.1.3.

크기

A 는 4×5, V 는 5×3, O 는 4×3 이다. A 의 행은 네 요청, 열은 다섯 제공 위치다. V 의 행은 같은 다섯 제공 위치, 열은 세 값 좌표다. 곱에서 제공 위치를 합하므로 출력의 행은 요청마다 하나, 열은 값 좌표마다 하나로 남는다. 다섯 값을 읽었다고 출력이 다섯 행이 되는 것은 아니다. 질문으로 돌아가기. 복습: 정의 10.1.3.

합 1 만 확인하면 되는가?

아니다. $[-0.5, 1.5]$ 의 합은 1 이지만 첫 계수가 음수여서 볼록결합의 비음수 조건을 만족하지 않는다. 조건을 검사할 때 합 1 과 비음수를 각각 확인해야 한다. 예를 들어 값 0 과 2 에 이 계수를 곱하면 출력 3 으로 두 값 사이를 벗어난다. 같은 값 두 개라 우연히 범위 안에 놓이더라도 계수가 볼록결합의 조건을 만족하는 것은 아니다. 질문으로 돌아가기. 복습: 정의 10.1.1, 정리 10.1.1.

세 문장

같은 주장이 아니다. 첫째는 위치가 받은 계수이므로 가중치 표에서 확인한다. 둘째는 해당 출력 좌표의 수치 기여이므로 가중치와 값의 그 좌표를 곱해 확인한다. 계수가 0.8 이어도 값 좌표가 2 면 기여는 1.6 이다. 셋째는 최종 결과의 원인에 관한 주장으로, 계수나 기여 하나만으로 입증하지 못한다. 모델의 다른 경로와 실제 변화 실험 등을 함께 살펴야 한다.

관찰한 계수·집계의 수치·언어적 의미와 인과성은 필요한 근거가 다르다. '가중치가 크니 정답의 원인이다' 라고 답했다면 주장 범위를 넘어선 것이다. 질문으로 돌아가기. 복습: 본문의 '높은 가중치를 의미나 인과적 설명으로 단정하지 않기'.

10.2 점수·비율·출력의 상세 해설

먼저 직접 계산하고 풀이와 비교하자. 점수가 틀렸다면 내적의 같은 좌표 곱을, 비율이 틀렸다면 scale·지수·한 행의 분모를, 출력이 틀렸다면 값의 출처와 집계 축을 각각 확인한다. 약값은 여섯 자리로 표시하며 중간 계산에서는 더 정밀한 값을 유지한다. 해설의 문제 참조는 본문으로 연결된다.

유제 해설

유제 10.2.1 해설

K^{T} 는 2×3 이고 출력 점수표는 2×3 이다. 첫 질의에서 첫 키는 $2 \cdot 1 + (-1) \cdot 2 = 0$, 둘째 키는 $2(-1) + (-1)0 = -2$, 셋째 키는 $2 \cdot 2 + (-1) \cdot 1 = 3$ 이다. 둘째 질의에서는 $1 + 2 = 3$, $-1 + 0 = -1$, $2 + 1 = 3$ 이다. 따라서 $D = \begin{bmatrix} 0 & -2 & 3 \\ 3 & -1 & 3 \end{bmatrix}$ 다.

첫 셀의 0 은 같은 좌표 곱의 상쇄다. 그 위치를 빼는 지시가 아니다. scale 뒤에도 0 이지만 지수는 $e^0 = 1$ 이고, 유한 점수의 한 행 분모는 양수이므로 계수는 양수다. 내적과 집계 비율을 곧바로 동일시한 오답이다. 정의 10.2.1과 예제 10.2.3를 연결해 복습하자.

유제 10.2.2 해설

평균 0 과 쌍 안 독립성으로 $E[q_r k_r] = 0$ 이고, $E[(q_r k_r)^2] = E[q_r^2]E[k_r^2] = 4 \cdot 9 = 36$ 이다. 한 곱의 분산은 36 이다. 곱 항들이 독립이므로 내적 분산은 $16 \cdot 36 = 576$, 표준편차는 24 다. 분모 $\sqrt{16} = 4$ 는 분산을 16 으로 나누어 $576/16 = 36$ 을 남긴다.

이 확률 모형에서 분산 1 이 목적이라면 분모 24 가 필요하다. 본문 scale 은 비교 폭만 보고 정한 4 이며 표본 분산을 측정하여 자동으로 24 를 선택하는 방식이 아니다. 한 성분의 분산과 여러 항의 합 분산을 혼동하면 36 또는 576 을 분모로 쓰는 오답이 나온다. 분모는 표준편차라는 점을 정리 10.2.1의 마지막 단계에서 확인하자.

유제 10.2.3 해설

점수 $[0, \ln 2, \ln 3]$ 를 쓰면 지수가 $[1, 2, 3]$, 합이 6 이므로 요구 비율을 얻는다. $[\ln(1/6), \ln(1/3), \ln(1/2)]$ 도 지수의 합이 1 인 다른 답이다. 두 답은 공통 상수 $-\ln 6$ 만큼 다르다.

유한 c 를 더하면 지수에 e^c 가 공통으로 곱해지고, 분자·분모에서 약분된다. 따라서 무수히 많은 점수 답이 있다. 반면 $[0, 1/2, 1/2]$ 에는 정확한 0 이 포함된다. 유한 실수 점수의 지수는 모두 양수이므로 만들 수 없다. 극한으로 접근하는 것과 유한 점수에서 정확히 얻는 것은 구별한다. 정리 10.2.2가 복습 위치다.

유제 10.2.4 해설

$\sqrt{9} = 3$ 이므로 조정 점수는 $[1, 0]$ 이다. 조정 전 비율은 $[e^3/(e^3+1), 1/(e^3+1)] \approx [0.952574, 0.047426]$, 조정 후는 $[e/(e+1), 1/(e+1)] \approx [0.731059, 0.268941]$ 이다.

출력은 첫 계수 a 를 쓰면 $2a + 8(1-a) = 8 - 6a$ 다. 따라서 전후 약 2.284555, 3.613649 다. 첫 값이 여전히 더 큰 계수를 받지만 둘째 큰 값의 기여가 늘었다. 순위만 기록하면 이 차이를 놓친다. 값 폭을 2 로 늘려도 비교 폭 9 는 그대로이므로 분모는 3 이다. 새 값 좌표는 집계 출력의 폭을 늘릴 뿐 점수 공식에 들어가지 않는다. 예제 10.2.4를 복습하자.

유제 10.2.5 해설

$c = \sqrt{2}\ln 2$ 라 쓰면 $D = \begin{bmatrix} c & 0 \\ 0 & c \end{bmatrix}$, $S = \begin{bmatrix} \ln 2 & 0 \\ 0 & \ln 2 \end{bmatrix}$ 다. 두 지수 행은 $[2,1]$, $[1,2]$ 이며 각각 합이 3 이다. 따라서

$$A = \begin{bmatrix} 2/3 & 1/3 \\ 1/3 & 2/3 \end{bmatrix}, \qquad O = \begin{bmatrix} 2 & 3 & 5 \\ 1 & 6 & 4 \end{bmatrix}.$$

Q, K, D, S, A 는 여기서 모두 2×2 이지만 역할은 다르다. V, O 는 2×3 이다. 첫 출력의 셋째 좌표는 $(2/3)6 + (1/3)3 = 4 + 1 = 5$, 둘째는 $(1/3)6 + (2/3)3 = 2 + 2 = 4$ 다. 출처별 기여는 같은 좌표끼리 합한다. V 폭 3 으로 scale 하면 $\ln 2$ 가 되지 않으므로 요구한 정수 지수 비율이 사라진다. 정의 10.2.4와 예제 10.2.5에서 두 폭을 다시 구별하자.

유제 10.2.6 해설

float64 에서 이 세 직접 지수는 모두 0 으로 underflow 될 수 있다. 분모도 0 이므로 나눗셈은 정상 비율을 만들지 못한다. 최대값 -1000 을 빼면 $[0, -1, -2]$ 이며 지수의 비는 $[1, e^{-1}, e^{-2}]$ 다. 가중치는 약 $[0.665241, 0.244728, 0.090031]$ 이다.

점수를 모두 1000 올리면 바로 $[0, -1, -2]$ 가 된다. 정리 10.2.2에 의해 같은 답이다. 각 점수가 음수라는 사실보다 공통 기준과 차이를 구별하는 것이 핵심이다. 0 으로 underflow 된 직접 지수를 '작은 확률이므로 무시해도 된다' 고 처리하면 세 항이 모두 사라지는 문제를 놓친다. 예제 10.2.6의 최대값 이동을 복습하자.

독립 연습 해설

연습문제 10.2.1 해설

첫 키의 좌표별 곱은 $[2, -2, 0]$ 로 합 0, 둘째는 $[0, 2, 6]$ 으로 합 8 이다. $d_k = 3$ 이므로 $D = [0, 8]$, $S = [0, 8/\sqrt{3}] \approx [0, 4.618802]$ 다. $t = e^{8/\sqrt{3}}$ 라 쓰면 $A = [1/(1+t), t/(1+t)] \approx [0.009768, 0.990232]$ 다.

출력은 $4/(1+t) + 10t/(1+t) = 10 - 6/(1+t) \approx 9.941391$ 다. 첫 위치 기여는 $4/(1+t) \approx 0.039073$ 로 0 이 아니다. Q `(1,3)`, K `(2,3)`, D/S/A `(1,2)`, V `(2,1)`, O `(1,1)` 이다. 점수 0 을 가중치 0 으로 바꾸거나, 비교 폭을 키 수 2 로 착각한 답을 이 계산이 구별한다. 정의 10.2.1·예제 10.2.3로 돌아가자.

연습문제 10.2.2 해설

$d_k = 1$ 이라 scale 이 바꾸는 것이 없다. $D = S = \begin{bmatrix} 0 & \ln 2 & \ln 4 \\ 0 & -\ln 2 & -\ln 4 \end{bmatrix}$ 다. 첫 지수 행은 $[1, 2, 4]$ 로 합 7, 둘째는 $[1, 1/2, 1/4]$ 로 합 7/4 다. 따라서

$$A = \begin{bmatrix} 1/7 & 2/7 & 4/7 \\ 4/7 & 2/7 & 1/7 \end{bmatrix}, \qquad O = \begin{bmatrix} 5 & 6 \\ 5 & 3 \end{bmatrix}.$$

첫 출력은 $[7(1+4)/7, 7(2+4)/7]$, 둘째는 $[7(4+1)/7, 7(2+1)/7]$ 다. Q `(2,1)`, K `(3,1)`, V `(3,2)`, 중간 `(2,3)`, O `(2,2)` 다. 점수 부호가 바뀌었지만 비율은 음수가 되지 않는다. 이 예에서는 역수 지수의 정규

화로 순서가 뒤집혔다. Softmax 는 일반적인 선형 함수가 아니므로 $\mathrm{softmax}(-s) = -\mathrm{softmax}(s)$ 는 틀리다. 정의 10.2.3를 복습하자.

연습문제 10.2.3 해설

(가) 는 가능하다. 비교 폭 8 을 공유하고 키·값의 제공 위치 수가 6 으로 같다. 분모는 $\sqrt{8}$ 이고 D/A 는 `(4,6)`, O 는 `(4,3)` 이다. (나) 는 Q 폭 8 과 K 폭 3 이 다르므로 내적을 정의할 수 없다. 자유로운 값 폭은 V 의 두 번째 축에 해당하며 K 의 비교 폭까지 자유로운 것은 아니다. (다) 는 내적은 가능하지만 A 의 제공 축 길이 6 과 V 의 행 길이 5 가 달라 집계할 수 없다.

여기서는 shape 의 세 역할을 모두 검사해야 한다. 받는 수와 제공 수가 다르다는 것 자체는 문제없다. 값 폭과 비교 폭이 다르다는 것도 문제없다. 정의 10.2.4의 네 양수 정수와 두 대응 조건을 복습하자.

연습문제 10.2.4 해설

올바른 분모 2 에서는 점수가 $[\ln 3, 0]$ 이고 지수 비 $[3, 1]$ 로 가중치 $[3/4, 1/4]$, 출력 3 이다. 잘못된 분모 4 에서는 $[(\ln 3)/2, 0]$ 이고 지수 $[\sqrt{3}, 1]$ 이다. 가중치는 $[\sqrt{3}/(\sqrt{3}+1), 1/(\sqrt{3}+1)] \approx [0.633975, 0.366025]$, 출력 $12/(1+\sqrt{3}) \approx 4.392305$ 다.

두 경우 첫 점수가 더 크지만 선택의 집중도가 다르다. argmax 나 순위만 같다는 검사로 연속 비율 연산을 검증할 수 없다. 분산 1 모형에서 d_k 로 나눈 점수의 분산이 $1/d_k$ 가 된다는 본문 설명과도 연결된다. 정의 10.2.2·예제 10.2.4를 복습하자.

연습문제 10.2.5 해설

전후 지수는 $[1, 2, 3]$ 와 $[1, 4, 3]$ 이다. 따라서 가중치는 $[1/6, 1/3, 1/2]$ 에서 $[1/8, 1/2, 3/8]$ 로 바뀐다. 첫째/셋째 비는 둘 다 1/3 이다. 바꾸지 않은 두 점수의 차이는 유지되므로 두 계수의 비도 유지된다. 하지만 늘어난 둘째 지수가 공통 분모를 6 에서 8 로 키웠으므로 첫째와 셋째 위치의 개별 계수는 모두 줄었다.

‘한 점수만 바꾸었으니 한 가중치만 바뀐다’ 는 오개념을 교정한다. 한 계수의 변화와 한 쌍의 비 변화는 다르다. 정리 10.2.2의 비 식과 정의의 전체 행 분모를 함께 보자.

연습문제 10.2.6 해설

행 i 의 새 분자·분모는 $e^{S_{ij}} e^{c_i}$ 와 $e^{c_i} \sum_{\ell} e^{S_{i\ell}}$ 다. 행마다 상수가 다르더라도 같은 행 안에서 약분되어 모든 A_{ij} 가 보존된다. 중요한 것은 모든 **제공 열에 같은 행 상수**가 적용된다는 조건이다.

열별 상수 반례로 한 행 $[0, 0]$ 에 $[0, \ln 3]$ 을 더하자. 비율 $[1/2, 1/2]$ 가 $[1/4, 3/4]$ 로 바뀐다. ‘상수를 더하면 언제나 불변’ 이라는 표현에는 적용 축이 빠져 있다. 행별 증명은 벡터 식으로 써도 허용한다. 정리 10.2.2와 축 설명을 복습하자.

연습문제 10.2.7 해설

한 곱의 평균은 0 이며 분산은 같은 좌표의 두 분산을 곱한다. 세 곱의 분산은 $1 \cdot 9 = 9, 4 \cdot 1 = 4, 9 \cdot 4 = 36$ 이다. 전 성분 독립성으로 교차 공분산이 0 이라 내적 평균은 0, 분산은 $9 + 4 + 36 = 49$ 다. $\sqrt{3}$ 로 나누면 분산은 49/3 다.

평균 0 만으로 $E[q_r k_r] = E[q_r]E[k_r]$ 를 쓰는 것은 불가하다. 예를 들어 두 변수가 같은 부호 변수 U 이면 각 평균은 0 이지만 곱은 1 이다. 이 문제에는 독립성이 명시되어 있어 분해를 사용할 수 있다. 분산들을 먼저 모두 더한 뒤 곱하면 서로 다른 좌표 조합까지 넣는 오류다. 정리 10.2.1의 한 곱 → 합 순서를 복습하자.

연습문제 10.2.8 해설

$E[U] = 0, \mathrm{Var}(U) = 1$ 이다. 그러나 $qk = U^2 = 1$ 은 상수여서 평균 1, 분산 0 이다. q 와 k 가 서로 독립이라는 가정이 깨졌다. $d_k = 1$ 이라고 해서 다른 가정이 자동으로 충족되는 것은 아니다.

본문 좌표 의존성 반례에서는 q 와 k 두 벡터는 서로 독립이지만 각 벡터의 좌표가 반복되었다. 이번에는 좌표가 하나라 교차 좌표가 없고, 비교하는 쌍 자체가 의존한다. 모두 '상관이 있다' 고만 쓰면 어느 증명 단계가 깨졌는지 설명하지 못한다. 정리 10.2.1의 $E[q_r k_r]$ 분해와 교차 공분산 제거를 별도로 확인하자.

연습문제 10.2.9 해설

$a_1 = (1 + e^{-\Delta})^{-1}$ 를 미분하면 $a_1' = e^{-\Delta}/(1 + e^{-\Delta})^2$ 이고 이는 $a_1(1 - a_1)$ 이다. $\Delta = 0$ 이면 $a_1 = 1/2$, 미분은 1/4 다. $\Delta = \ln 99$ 이면 $e^{-\Delta} = 1/99$, $a_1 = 99/100$, 미분은 $99/10000 = 0.0099$ 다.

허용되는 수정은 "이 점수 차이에서는 비율이 작은 점수 변화에 덜 민감하며, 비율을 통과하는 한 학습 경로의 미분이 작다" 다. 모델 전체에는 값·다른 질의·다른 Head·residual·손실의 경로도 있다. 이 계산만으로 전체 학습 불가능을 결론 내릴 수 없다. 반대로 작은 미분이 전혀 중요하지 않다고 단정하는 것도 과도하다. 본문의 미분 도출로 복습하자.

연습문제 10.2.10 해설

$s_j = \ln a_j + c$ 이면 $e^{s_j} = e^c a_j$ 다. 가중치 합이 1 이므로 분모는 e^c, 따라서 비율은 정확히 a_j 다. 모든 a_j 가 양수이므로 로그가 유한하다.

역으로 s 가 a 를 만든다면 $e^{s_j - s_t} = a_j/a_t$ 에서 $s_j - s_t = \ln a_j - \ln a_t$ 다. 고정 기준 위치 t 를 잡으면 $s_j - \ln a_j = s_t - \ln a_t = c$ 로 모든 위치에서 같다. 따라서 해는 공통 상수만큼만 다르다. n=1 에서도 임의 점수가 비율 1 을 만들며 같은 표현이 성립한다. 0 계수를 포함하면 유한 로그가 없어지는 조건도 명시해야 한다. 이는 점수 복원이며 Q/K 의 표현 가능성은 별도다. 정리 10.2.2를 복습하자.

연습문제 10.2.11 해설

열 최대값은 $[0, \ln 3]$ 이다. 이를 빼면 첫 행 $[0, 0]$, 둘째 $[0, -\ln 3]$ 가 된다. 지수 행별 정규화의 결과는 $[[1/2, 1/2], [3/4, 1/4]]$ 다. 올바른 $[[1/4, 3/4], [1/2, 1/2]]$ 와 다르다. 각 행에 서로 다른 열 상수를 빼서 점수 차이를 바꾸었다.

전체 최대값 $\ln 3$ 하나를 빼는 경우는 모든 셀에 같은 상수라 행별 비율이 보존된다. 그러나 한 행의 최대값보다 훨씬 큰 다른 행 최대값을 빼면, 그 행의 지수들이 모두 underflow 될 수 있다. 예를 들어 행이 $[1000, 1001]$ 와 $[-1000, -1001]$ 이면 전체 최대값 이동 뒤 둘째 행은 극히 작은 지수 둘을 갖는다. 따라서 실수에서의 동등성과 각 행의 적어도 한 지수를 1 로 남기는 수치적 장점을 구별한다. 본문의 '최대값을 빼도 답은 같고 지수는 작아진다' 를 복습하자.

연습문제 10.2.12 해설

정상 계수 [1/4, 3/4], [1/2, 1/2] 로 출력은 2/4 + 30/4 = 8, 1 + 5 = 6 이다. 전체 지수 합은 6 이라 잘못된 두 행은 [1/6, 3/6], [1/6, 1/6] 이고 출력은 32/6 = 16/3, 12/6 = 2 다. 정상 출력의 2/3, 1/3 배다. 이는 각 행 지수 합 4 와 2 를 전체 합 6 으로 나눈 축소율이다.

한 행에 c 를 더하면 그 행의 지수 합에 e^c 가 곱해져 전체 분모가 바뀐다. 변경하지 않은 행도 같은 전체 분모를 사용하므로 출력이 달라질 수 있다. 행별 정규화의 독립성에는 이런 경로가 없다. 본문의 질의별 비율 설명을 복습하자.

연습문제 10.2.13 해설

`e.sum(axis=1)` 의 shape 는 `(2,)` 다. `(2,3)` 과 나누면 마지막 축에서 3 과 2 가 맞지 않아 broadcasting 오류가 생긴다. `(2,2)` 입력에서는 오류 없이 **열마다** 다른 분모가 적용되어 더 위험하다. 한 행의 분모를 `(m,1)` 로 유지해야 한다.

큰 점수는 지수 연산부터 overflow 될 수 있으므로 `keepdims=True` 만 붙여서는 해결되지 않는다. 다음처럼 실제 소스 함수를 사용한다. `from scoring import softmax_rows` 다음 `A = softmax_rows(S)` 다. 그 함수의 최대값·분모 두 곳 모두 `axis=1, keepdims=True` 를 사용한다. [[1000, 1001, 999]] 에서 결과는 약 [[0.244728, 0.665241, 0.090031]] 이고 행 합은 부동소수점 허용오차 안에서 1 이다. 다른 구현도 동일 행별 식·유한성·결과를 지키면 허용된다. 예제 10.2.6과 실제 함수 발췌를 복습하자.

연습문제 10.2.14 해설

비교 폭은 1 이며 점수는 $[0, \ln 3]$ 다. A 는 [1/4, 3/4] 이고 정상 O 는 $(1/4)[10, 0] + (3/4)[0, 2] = [2.5, 1.5]$ 로 `(1,2)` 다. $AK = [(3/4)\ln 3] \approx [0.823959]$ 는 `(1,1)` 이며 키의 비교 좌표를 집계했다. 요구된 값 내용이 아니다.

V 폭도 1 이면 잘못된 출력의 shape 가 정상과 같을 수 있다. 예를 들어 V 가 [10], [2] 인 정상 출력 4 와 AK 의 약 0.823959 는 크기는 같고 값이 다르다. 따라서 검사에는 전달 내용의 생성원과 실제 수치 대조도 필요하다. 정의 10.2.4를 복습하자.

연습문제 10.2.15 해설

원래 계수는 [1/4, 3/4] 여서 출력은 8 이다. 키만 뒤집으면 점수 $[\ln 3, 0]$, 계수 [3/4, 1/4] 가 원래 값 [2], [10] 에 붙어 출력은 1.5 + 2.5 = 4 다. 키·값을 함께 뒤집으면 같은 새 계수가 [10], [2] 에 붙어 7.5 + 0.5 = 8 이 된다.

고정된 자료의 대응 순열은 점수·A 의 열과 V 의 행을 함께 옮긴다. 합의 항 순서만 달라져 같은 출력이다. 실제 문장 순서를 바꾸면 위치 표현·여러 레이어 계산에 따라 Q/K/V 내용 자체가 바뀔 수 있으므로 이 대수적 보존을 그대로 적용하지 않는다. 정리 10.1.2와 앞 절의 순열 반례를 복습하자.

연습문제 10.2.16 해설

한 구현은 실제 해설 소스의 다음 함수다. 입력 검사를 포함한 전체 계산을 먼저 부르고, A 와 V 사이에 새 축을 넣어 각 출처의 기여를 보존한다.

solution_scoring.py | learning-source/solution_scoring.py | Python | L1-L10 (10 줄)
source revision: scoring-source-v0.1

```python
""" 독립 문제의 좌표별 기여와 두 확률비 요구를 구현한다."""
import numpy as np
from scoring import scaled_dot_product


def with_contributions(q, k, v):
    dots, scores, a, o = scaled_dot_product(q, k, v)
    # 질의·제공 위치·값 좌표의 세 축을 남긴다.
    c = a[:, :, None] * np.asarray(v)[None, :, :]
    return dots, scores, a, c, o
```

`a[:,:,None]` 은 `(m,n,1)`, `v[None,:,:]` 는 `(1,n,d_v)` 다. 곱 C 는 `(m,n,d_v)` 이고 `C.sum(axis=1)` 이 O 다. 유제 입력에서 둘째 요청·첫 출처·셋째 좌표의 기여는 $(1/3)6 = 2$, 둘째 출처 기여는 $(2/3)3 = 2$, 합은 4 다. 따라서 `C[1,0,2]=2`, `C[1,1,2]=2`, `O[1,2]=4` 다. 반복문이나 `einsum` 도 같은 축·기여를 반환하면 허용한다. 단순 O 만 반환하면 요구한 출처별 배열이 빠진다. 예제 10.2.5의 기여 전개가 복습 위치다.

연습문제 10.2.17 해설

(가) V 는 점수 경로에 들어가지 않으므로 A 는 반드시 보존된다. O 는 달라질 수 있다. 예를 들어 값 모두에 공통 벡터를 더하면 O 에도 그 벡터가 더해진다. 값 변화가 상쇄되면 O 가 우연히 보존될 수도 있으므로 '반드시 변한다' 는 답은 틀리다.

(나) 새 점수는 $S'_{ij} = S_{ij} + (q_i \cdot b)/\sqrt{d_k}$ 다. 추가 항은 같은 질의 행의 모든 키에서 같으므로 A 가 보존된다. V 도 고정이라 O 도 보존된다. 질의마다 추가 항이 달라도 행별 불변성에는 문제가 없다.

(다) 점수는 2 배가 된다. 반례로 원래 점수 $[0, \ln 2]$ 의 A 는 $[1/3, 2/3]$ 지만 2 배 뒤는 $[1/5, 4/5]$ 다. V 가 $[0], [1]$ 이면 O 도 달라진다. 모든 값이 같거나 모든 점수가 같으면 보존될 수 있지만 '반드시' 는 아니다. 정리 10.2.2의 덧셈과 곱셈 구별을 복습하자.

연습문제 10.2.18 해설

둘째 계수는 $1/(e^M + 1) > 0$ 이고 출력은 $10/(e^M + 1) > 0$ 이다. 유한 M 으로 정확한 0 을 얻을 수 없다. $1/(e^M + 1) \le 10^{-3}$ 은 $e^M \ge 999$, 즉 $M \ge \ln 999 \approx 6.906755$ 와 동치다. 이때 출력은 0.01 이하가 되지만 여전히 양수다.

작은 계수도 큰 값·여러 층·다른 경로에서 효과가 남을 수 있다. 부동소수점에서 underflow 로 0 이 보이더라도 정밀도와 점수에 따른 현상이어서 접근 정책을 보장하지 않는다. 정확한 차단 요구는 mask 와 같은 별도 허용 규칙으로 표현해야 한다. 다음 절로 이어지는 질문이지 현재 확률비 조건의 다른 이름이 아니다. 정의 10.2.3와 안정성 예제를 복습하자.

연습문제 10.2.19 해설

셋째 키가 0 벡터라 점수 $s_3 = 0$ 이고 $s_1 = q_1/\sqrt{2}$, $s_2 = q_2/\sqrt{2}$ 다. 정리의 비 식에서 요구 비 r_1, r_2 를 만들려면 $q = [\sqrt{2}\ln r_1, \sqrt{2}\ln r_2]$ 로 정하면 된다. 두 질의는 $[\sqrt{2}\ln 2, 0]$, $[0, \sqrt{2}\ln 3]$ 다.

$$D = \begin{bmatrix} \sqrt{2}\ln 2 & 0 & 0 \\ 0 & \sqrt{2}\ln 3 & 0 \end{bmatrix}, \quad S = \begin{bmatrix} \ln 2 & 0 & 0 \\ 0 & \ln 3 & 0 \end{bmatrix}, \quad A = \begin{bmatrix} 1/2 & 1/4 & 1/4 \\ 1/5 & 3/5 & 1/5 \end{bmatrix}.$$

따라서 출력은 첫 요청 $5+5+10=20$, 둘째 요청 $2+12+8=22$ 다. Q `(2,2)`, K `(3,2)`, V `(3,1)`, 중간 `(2,3)`, O `(2,1)` 이다. 요구된 비율을 대수적으로 구성했을 뿐 실제 센서 오차 분포·손실·학습·최적성을 제시한 것은 아니다. 교육 수치에서 '최적' 을 결론 내리지 말자. 정리 10.2.2·정의 10.2.4를 복습하자.

연습문제 10.2.20 해설

가능한 한 입력을 제시한다. $Q=\begin{bmatrix}1&0\\0&1\end{bmatrix}$, $K=\begin{bmatrix}0&0\\\sqrt{2}\ln 3&0\end{bmatrix}$, $V=\begin{bmatrix}2&0&4\\10&8&0\end{bmatrix}$ 다. 정상 점수는 $[[0,\ln 3],[0,0]]$, A 는 $[[1/4,3/4],[1/2,1/2]]$, O 는 $[[8,6,1],[6,4,2]]$ 다.

열별 정규화는 A 를 $[[1/2,3/4],[1/2,1/4]]$ 로 바꾸므로 행 합부터 실패하며 O 는 $[[8.5,6,2],[3.5,2,2]]$ 다. 전체 정규화도 본문 축소율 때문에 실패한다. $d_v=3$ 으로 scale 하면 첫 점수 차이는 $\sqrt{2/3}\ln 3$ 으로 달라진다. 첫 계수는 $1/[1+3^{\sqrt{2/3}}]$ 가 되어 정상 1/4 와 다르다. AK 는 `(2,2)` 이고 O 의 `(2,3)` 과 다르며 값 내용도 사용하지 않는다.

축 오류를 잡기 위해 비대칭 점수, scale 오류를 잡기 위해 $d_k\neq d_v$, 역할 오류를 잡기 위해 K 와 V 의 다른 내용·폭을 선택했다. 별도 입력 셋을 구성해도 같은 결함을 실제 수치로 드러내면 허용한다. 유한 테스트는 해당 사례의 증거이며 모든 입력의 정확성 증명은 아니다. 도출·구현 검토와 경계 입력 검사를 함께 사용한다.

심화문제 해설

심화문제 10.2.1 해설

벡터 독립성으로 $E[q_rk_r]=E[q_r]E[k_r]=0$ 이라 내적 평균이 0 이다. 제곱을 펼치면

$$E[(q^{\top}k)^2]=\sum_{r,s}E[q_rq_sk_rk_s]=\sum_{r,s}E[q_rq_s]E[k_rk_s]=\sum_{r,s}(C_q)_{rs}(C_k)_{rs}.$$

벡터 안 독립성은 사용하지 않는다. q 전체와 k 전체의 독립성이 두 묶음의 기댓값을 분해한다. 유한 이차 적률은 각 $E[q_rq_s]$ 등의 유한성을 보장하며, 독립 벡터 곱의 이차 적률도 유한하다. 평균 0 이므로 이 값이 분산이다.

공분산 행렬은 대칭이다. 따라서 $\operatorname{tr}(C_qC_k)=\sum_r\sum_s(C_q)_{rs}(C_k)_{sr}$ 에서 두 번째 행렬의 첨자를 뒤집어 앞 합과 같음을 얻는다. $C_q=C_k=I_d$ 이면 대각의 d 개 1 만 남아 분산 d 다. 두 좌표 반복 예에서는 각각 $\begin{bmatrix}1&1\\1&1\end{bmatrix}$ 이고 곱의 대각이 2,2 라 trace 4 다. $\sqrt{2}$ 로 나눈 뒤 분산 2 도 일치한다. 성분 분산만 기록하면 비대각 공분산 효과를 놓친다. 정리 10.2.1의 교차항을 복습하자.

심화문제 10.2.2 해설

고정 V 의 유한 합을 미분하여

$$\frac{\partial o}{\partial s_t}=\sum_j v_ja_j(\delta_{jt}-a_t)=a_tv_t-a_t\sum_j a_jv_j=a_t(v_t-o)$$

를 얻는다. 한 점수를 올리는 효과는 해당 값을 더 보내는 것과 다른 모든 값의 비율을 줄이는 것이 합쳐진 결과다. $v_1=0,v_2=10$, 점수 둘 다 0 이면 $a_1=a_2=1/2,o=5$ 다. 첫 점수 미분은 $(1/2)(0-5)=-2.5$,

둘째는 $(1/2)(10-5)=2.5$ 다. 이 두 미분의 합이 0 인 것은 공통 점수 이동이 출력을 바꾸지 않기 때문이다.

$s_t = D_t/\sqrt{d_k}$ 라면 연쇄법칙으로 $\partial o/\partial D_t = a_t(v_t - o)/\sqrt{d_k}$ 다. 비교 입력 변수를 정확히 써야 한다. 모든 값이 v 이면 $o = v$ 이고 각 미분이 0 이다. A 가 변화할 수 있어도 V 가 그 차이를 출력에 남기지 않기 때문이다. 이 식은 값 고정 조건을 썼으며, 원래 입력을 바꿀 때 V 자체가 변하는 효과는 별도로 더해야 한다. 본문의 미분과 예제 10.2.5의 기여를 복습하자.

심화문제 10.2.3 해설

(가) $s = [q_1/\sqrt{2}, q_2/\sqrt{2}, 0]$ 다. $q = [\sqrt{2}\ln(a_1/a_3), \sqrt{2}\ln(a_2/a_3)]$ 이면 지수는 $[a_1/a_3, a_2/a_3, 1]$ 이고 합이 $1/a_3$ 이라 요구한 a 를 얻는다. 양수 조건이 로그의 유한성을 보장한다.

(나) 스칼라 키에서 $d_k = 1$ 이고 점수는 $[q, 2q, 0]$ 다. 따라서 $a_1/a_3 = e^q$, $a_2/a_3 = e^{2q} = (a_1/a_3)^2$ 여야 한다. 역으로 이 등식이 성립하는 양수·합 1 비율이면 $q = \ln(a_1/a_3)$ 로 구성할 수 있어 충분조건이기도 하다.

(다) 목표에서 $a_1/a_3 = 1/3$, $a_2/a_3 = 2/3$ 다. 두 좌표 키에서는 $[\sqrt{2}\ln(1/3), \sqrt{2}\ln(2/3)]$ 로 가능하다. 스칼라 키는 $(1/3)^2 = 1/9 \neq 2/3$ 이므로 불가능하다. 점수 해가 존재해도 고정 키의 내적이 점수 차이를 자유롭게 만들 수 있는 것은 아니다. 이는 키 구성의 대수적 제약이며, 실제 모델이 학습으로 모든 과제에 충분한 표현을 얻는다는 보장으로 확대하지 않는다. 연습문제 10.2.10의 점수 복원과 구별하자.

이해 확인 해설

두 합 축 식 (10.2.1)은 질의 i·키 j 를 고정하고 비교 좌표 r 을 합한다. O_{it} 는 질의 i·값 좌표 t 를 고정하고 제공 위치 j 의 기여를 합한다. r 의 길이는 d_k, j 의 길이는 n 이다. 두 합이 모두 행렬곱에 들어가더라도 축 의미는 다르다. 질문으로 돌아가 말로 설명해 보자.

나누는 수 분모는 $\sqrt{64} = 8$ 이다. D/S/A 는 3×5, O 는 3×12 다. 3 은 질의 수, 5 는 제공 위치 수, 64 는 비교 폭, 12 는 전달 값 폭이다. 값 폭으로 나누는 오답은 점수 경로와 집계 경로를 혼동한다. 질문으로 돌아가자.

같은 비와 같은 가중치 원래 지수 $[1, 2]$ 의 가중치는 $[1/3, 2/3]$ 다. 새 지수 $[1, 2, 1]$ 의 가중치는 $[1/4, 1/2, 1/4]$ 다. 앞 두 비는 모두 1:2 지만 개별 계수는 줄었다. 비는 공통 분모를 약분하고, 개별 계수는 분모 크기의 영향을 받는다. 질문과 정리 10.2.2를 복습하자.

차단인가 반올림인가? 점수 0 은 지수 1 이므로 유한 점수의 계수가 양수다. 기계적 0 은 underflow 등 수치 표현의 결과이고, 정책상 접근 금지는 허용 위치 집합을 지정한 조건이다. 서로 다른 이유로 나타난 수를 같은 정책으로 읽을 수 없다. 질문과 안정성 예제를 복습하자.

어떤 요청이 바뀌는가? 행별 Softmax 에서는 둘째 행의 공통 이동도 약분되어 두 행 모두 불변이다. 특히 첫 행은 둘째 점수에 접근하지 않는다. 전체 정규화에서는 분모 $Z_1 + Z_2$ 가 $Z_1 + e^c Z_2$ 로 바뀌어 c 가 0 이 아니면 첫 계수 행도 달라진다. 질문에서 실제 분모를 써 보자.

10.3 어떤 정보는 왜 읽지 못하게 해야 하는가? — 해설

먼저 자기 답에서 입력–대상 대응, 배열 번호와 원래 위치, 허용 분모, 실제 값의 출처를 확인하자. 출력만 다르면 중간 A 와 J 를 비교하고, 출력이 같더라도 잘못 열린 경로가 없는지 검사한다. 구성·설계 문제에서는 같은 숫자나 코드인가보다 주어진 접근 정책과 처리 계약을 만족하는가가 기준이다. 아래 모든 풀이에서 True/1 은 허용이며 배열 번호는 0 부터 센다.

유제 해설

유제 10.3.1 해설 네 번째 입력을 추가하면

각 대상은 $[y_1, y_2, y_3, y_4]$ 다. 질의 0/1/2/3 의 허용 원래 위치는 각각 $\{0\}, \{0,1\}, \{0,1,2\}, \{0,1,2,3\}$ 이다. 키가 같은 순서라 배열 열 집합도 같다. 따라서

$$B = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 1 \end{bmatrix}.$$

행 2 는 대상 위치 3 의 y_3 를 예측한다. 위치 2 의 y_2 는 입력에 이미 주어진 내용이므로 허용하고, 위치 3 의 y_3 는 정답이므로 닫는다. 현재 입력 위치와 예측 대상 위치를 하나로 합치면 대각선까지 닫거나 정답을 여는 오류가 생긴다. 표로 먼저 대응을 쓴 답도 허용한다. 복습: 예제 10.3.1, 정의 10.3.2.

유제 10.3.2 해설 분모를 직접 줄여 보기

전체 지수는 $[2,1,5]$, 분모 8, A 는 $[1/4, 1/8, 5/8]$ 다. 각 기여는 $3/4, 9/8, 150/8$ 이므로 출력은 $165/8 = 20.625$ 다. J 가 $\{0,1\}$ 이면 분모 3, A 는 $[2/3, 1/3, 0]$, 출력은 $2+3=5$ 다.

차단 전 A 에만 Mask 를 곱하면 $[1/4, 1/8, 0]$ 이며 합은 3/8 이다. 출력도 $3/4 + 9/8 = 15/8 = 1.875$ 로, 정상 출력 5 에 허용 질량 3/8 을 곱한 값이다. 허용된 위치끼리 비율 2:1 은 유지되지만 총 비율이 1 이 아니므로 정의한 정규화된 집계가 아니다. 다시 3/8 로 나누면 실수 수학에서 정상 A 를 얻지만, 본문의 구현은 처음부터 허용 열만 계산한다. 복습: 정의 10.3.3, 예제 10.3.2.

유제 10.3.3 해설 Causal 과 패딩을 동시에 적용하기

결합 Mask 는 $[[1,0,0,0],[1,1,0,0],[1,1,0,0],[1,1,0,0]]$ 다. 마지막 두 키는 실제 내용이 아니어서 어느 행에서도 닫힌다. 모든 행을 계산하면 점수가 0 이므로 A 는 첫 행 $[1,0,0,0]$, 나머지 세 행 $[1/2,1/2,0,0]$ 이다. 출력은 $[4,8,8,8]^\top$ 이다. 여기에 적용한 열 제약은 Causal/Key padding 결합이다. 위치 제약 없이 Key padding 만 적용하면 네 행 모두 두 실제 키를 반씩 읽어 $[8,8,8,8]^\top$ 이다.

유효 질의 $[1,1,0,0]$ 를 결합 Mask 와 함께 전달하면 마지막 두 A 행을 0 으로 두어 출력은 $[4,8,0,0]^\top$ 이다. 이 두 A 행은 합 0 이라 확률분포가 아니다. 패딩 질의는 사용하지 않을 출력의 계약으로 처리했다. Key padding 만으로 패딩 질의가 0 이 된다고 답했다면 열과 행의 역할을 혼동한 것이다. 복습: 정의 10.3.4, 예제 10.3.3. 문제의 'Key padding 만' 과 결합 정책의 차이를 자신의 표에 명시하자.

유제 10.3.4 해설 비어 있는 실제 요청

위치 0 요청에서 키 1/2 는 모두 미래이고, 위치 1 요청에서는 키 1 만 허용이다. 따라서 B 는 $[[0,0],[1,0]]$ 다. 두 요청 모두 유효하므로 첫 행에서 오류가 난다. 위치 0 에 해당하는 허용 BOS 키/값을 키 목록에 추가하면 그 행은 BOS 를 읽고 둘째 행은 BOS 와 위치 1 을 읽는다. 금지된 위치 1 을 첫 행에서 대신 열면 정답을 읽으므로 해결이 아니다.

다른 선택으로 빈 허용 집합에 0 을 반환하는 별도 계약을 정할 수는 있다. 그러나 이는 원래 정규화된 Attention 의 정의를 바꾸며, 후속 연산이 0/빈 정보 상태를 어떻게 사용할지까지 결정해야 한다. 유효 예측이므로 임의로 패딩 질의라고 표시하여 생략하는 답도 부적절하다. 이 문제는 가능한 설계 대안을 비교하는 것이며 없는 과거 정보를 Mask 만으로 새로 만들 수 없다. 복습: 예제 10.3.4와 본문의 빈행 설명.

유제 10.3.5 해설 또 다른 배열 순서

질의 행 0 의 원래 위치는 1, 입력은 y_1, 대상은 y_2 다. 키 열 0/1/2 의 원래 위치는 1/2/0 이므로 허용 열은 $\{0,2\}$, 원래 위치 집합은 $\{0,1\}$ 이다. 질의 행 1 은 원래 위치 0 의 BOS 로 y_1 을 예측하므로 열 2 만 허용이다. 올바른 B 는 $[[1,0,1],[0,0,1]]$ 이다.

잘못된 행 0 $[1,0,0]$ 은 미래를 열지 않았지만 BOS 열 2 를 잃었다. 잘못된 행 1 $[1,1,0]$ 은 원래 위치 1 의 정답 y_1 과 위치 2 의 더 먼 미래 y_2 를 읽고, 필요한 BOS 열 2 를 놓쳤다. 누출 쌍은 $(1,0),(1,1)$, 누락 쌍은 $(0,2),(1,2)$ 다. 미래 열만 지우면 첫 행과 둘째 행 모두 필요한 과거가 복구되지 않는다. 복습: 예제 10.3.5와 위치 함수 정의.

유제 10.3.6 해설 두 변경의 전달 범위

가중치는 고정이다. 한 값의 변화 Δv 는 그 열의 계수만큼 각 출력에 전달된다. (가) 원래 위치 2 의 계수는 $[0,0,1/2]^{\mathsf{T}}$ 이므로 출력 변화는 $[[0,0],[0,0],[3,-3]]$ 다. y_1/y_2 의 예측에서는 미래, y_3 의 예측에서는 이미 입력된 y_2 의 내용이다.

(나) 원래 위치 0 의 계수는 $[1,1/3,1/6]^{\mathsf{T}}$ 이므로 변화는 $[[6,-6],[2,-2],[1,-1]]$ 다. BOS 는 세 요청에 모두 허용되어 변화를 전달한다. 배열 전체를 다시 곱하여 대조해도 된다. 미래 변경 불변성은 모든 행 불변이 아니라 해당 미래를 허용하지 않는 행의 불변성이다. K 도 함께 변하면 A 를 다시 계산해야 하므로 이 값 변화 공식만으로 모든 행을 계산할 수 없다. 복습: 정리 10.3.1, 예제 10.3.6.

독립 연습 해설

연습문제 10.3.1 해설 다섯 입력의 읽기 목록

대상은 $[a,b,c,d,e]$ 이고 대상 위치는 1–5 다. 질의 p 의 허용 원래 위치는 $\{0,\dots,p\}$ 이므로 각 행은 길이 p+1 의 1 뒤에 남은 0 을 붙인다.

$$B = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 1 & 1 \end{bmatrix}.$$

마지막 입력 d 는 위치 4 이고 그 행의 정답은 위치 5 의 e 다. 따라서 d 는 정답이 아니라 허용된 현재 입력이다. 마지막 행까지 d 를 닫으면 알려진 접두 정보를 불필요하게 버린다. 입력/대상 표를 먼저 쓴 뒤 Mask 를 쓰는 전략이 삼각형 외우기보다 다른 배열 순서에도 적용된다. 복습: 예제 10.3.1, 유제 10.3.1.

연습문제 10.3.2 해설 대각선을 허용했는데 정답이 보인다

잘못된 행 1 의 입력은 y_2, 예측 대상도 y_2 다. 대각선 $B_{11} = 1$ 을 통해 $y_2 \to k_1, v_1 \to A_{11}, o_1 \to y_2$ 예측 경로가 열린다. 더구나 질의 자체도 y_2 에서 만들어졌다면 값을 닫아도 $y_2 \to q_1 \to$ 점수/예측이라는 경로가 남는다.

입력을 $[\text{BOS}, y_1, y_2]$, 대상을 $[y_1, y_2, y_3]$ 로 바꾸고 원래 입력 위치 0/1/2 기준의 아래 삼각형을 적용한다. 행 1 은 BOS 와 y_1 을 읽어 y_2 를 예측하므로 필요한 과거는 보존된다. 정답 shift 는 실제 Q/K/V 생성 입력에도 적용되어야 한다. 대각선 차단만으로 잘못된 입력의 질의 내용을 바꿀 수는 없다. 복습: 예제 10.3.1, 정리 10.3.2.

연습문제 10.3.3 해설 두 요청과 일부만 남긴 키

대상 위치는 행 0 에서 5, 행 1 에서 2 다. 행 0 은 키 위치 3/0/1 을 읽으므로 배열 열 $\{0, 1, 3\}$, 원래 위치 $\{0, 1, 3\}$ 이다. 행 1 은 키 위치 0/1 만 읽으므로 배열 열 $\{1, 3\}$, 원래 위치 $\{0, 1\}$ 이다. B 는 $[[1, 1, 0, 1], [0, 1, 0, 1]]$ 이다.

두 집합의 숫자가 첫 행에서 우연히 같아도 의미는 다르다. 위치 2/4 의 과거는 키 목록에 없으므로 이 Mask 가 그 내용을 되살릴 수는 없다. m 과 n 의 일치가 아니라 각 질의와 각 키 한 쌍의 원래 위치 비교가 필요하기 때문에 직사각형에도 같은 식을 사용한다. 복습: 정의 10.3.1, 정의 10.3.2.

연습문제 10.3.4 해설 왼쪽 패딩과 재배열

위치 0 요청은 실제 키 위치 0 의 열 2 만 허용하므로 $[0, 0, 1, 0]$ 다. 위치 2 요청은 실제 위치 2/0/1 의 열 1/2/3 을 허용하므로 $[0, 1, 1, 1]$ 이다. 결합 B 는 이 두 행이다.

열 0 의 -1 은 임시 표지일 뿐 실제 내용이 없다. 위치 비교만 사용하면 $-1 \le 0$ 과 $-1 \le 2$ 가 참이라 두 행 모두 이 패딩 열을 읽게 된다. 패딩 유효성 조건이 독립적으로 필요하다. 재배열과 왼쪽 패딩의 도형을 외울 필요 없이 두 조건을 셀마다 AND 하면 된다. 복습: 정의 10.3.4, 예제 10.3.4.

연습문제 10.3.5 해설 점수 순위와 접근 권한

차단 전 지수는 $[1, 2, 7]$, 분모 10, A 는 $[1/10, 1/5, 7/10]$ 다. 출력은 $3/10 + 18/10 + 630/10 = 651/10 = 65.1$ 이다. 차단 후 분모 3, A 는 $[1/3, 2/3, 0]$, 출력은 $1 + 6 = 7$ 이다.

가장 큰 점수는 현재 Q/K 좌표에서 비교가 잘 맞았다는 수치다. 그 위치가 미래 정답이나 패딩이면 읽을 권한은 없다. 낮은 점수의 과거도 허용 정책에 속하면 정규화 대상에 남긴다. 비교 순위와 허용 관계는 다른 입력/역할이다. 복습: 정의 10.3.1, 예제 10.3.2.

연습문제 10.3.6 해설 값만 0 으로 만든 경우

A 는 원래 $[1/10, 1/5, 7/10]$ 이고, 마지막 값 0 을 곱하면 출력은 $0.3 + 1.8 = 2.1$ 이다. 정상 Mask 의 7 보다 작다. 값만 0 으로 만들면 실제 두 출처의 총 비율 3/10 이 남는다.

마지막 점수를 $\ln 70$ 으로 바꾸면 분모는 73, 허용 두 계수는 $[1/73, 2/73]$ 가 된다. 출력은 $21/73 \approx 0.287671$ 로 바뀐다. 마지막 V 를 0 으로 두어도 그 K 가 분모를 바꿔 출력에 영향을 준다. 누출 진단에는 값 경로뿐 아니라 키 → 정규화 경로도 포함한다. 복습: 예제 10.3.3, 정리 10.3.1.

연습문제 10.3.7 해설 Softmax 뒤에 곱한 Mask

전체 A 는 $[1/8, 3/8, 1/2]$ 다. 곱한 뒤 $[1/8, 3/8, 0]$, 합은 $1/2$, 출력은 $2/8 + 30/8 = 4$ 다. 이를 합 $1/2$ 로 나누면 $[1/4, 3/4, 0]$, 출력 8 로 정상 결과와 같다.

일반적으로 전체 분모를 Z, 허용 지수 합을 $Z_J > 0$ 라 놓으면 Mask 를 곱한 계수의 합은 Z_J/Z 다. 허용 열에서 $(e^{s_j}/Z)/(Z_J/Z) = e^{s_j}/Z_J$ 이므로 실수 수학에서는 동등하다. 그러나 차단 점수가 매우 커서 허용 계수들이 먼저 underflow 하여 모두 0 이면 계산한 합도 0 이다. 뒤의 재정규화가 0/0 을 복구하지 못한다. 허용 최대/분모를 처음부터 사용하자. 복습: 정의 10.3.3, 본문 구현.

연습문제 10.3.8 해설 유한 음수는 정확한 차단인가?

둘째 계수는 $e^{-C}/(1 + e^{-C}) = 1/(e^C + 1) > 0$, 출력은 $10^6/(e^C + 1) > 0$ 다. $10^6/(e^C + 1) \le 10^{-3}$ 은 $e^C + 1 \ge 10^9$, 즉 $C \ge \ln(10^9 - 1) \approx 20.723266$ 과 같다. 작은 기여의 기준은 정할 수 있어도 유한 C 로 정확한 0 을 만들지는 못한다.

n 개 키를 모두 같은 유한 음수 $-C$ 로 덮으면 각 지수는 같아서 계수는 1/n 이다. 최대값을 빼면 점수들이 모두 0 이 되는 것으로도 알 수 있다. '전부 차단' 대신 '전부 동일하게 허용' 이 되어 버린다. 부동소수점 underflow 를 접근 정책으로 이용하지 말고 명시적인 허용 집합과 빈행 계약을 사용해야 한다. 복습: 정의 10.3.3, 본문 빈행 설명.

연습문제 10.3.9 해설 최대값을 어느 집합에서 구할까?

전체 최대 10^6 을 빼면 허용 점수는 $[-10^6, 1-10^6]$ 다. float64 에서 두 지수는 모두 0 으로 underflow 할 수 있고 허용 분모 0 으로 실패한다. 허용 최대 1 을 빼면 허용 지수 $[e^{-1}, 1]$, 비율은 $[1/(1+e), e/(1+e), 0] \approx [0.268941, 0.731059, 0]$ 다.

실수 수학에서는 임의의 공통 상수 이동이 약분되어 동등하다. 기계에서는 지수로 표현하기 전에 매우 작은 수가 0 이 될 수 있다. 허용 최대를 선택하면 적어도 한 허용 지수 1 을 보존한다. 허용되지 않은 큰 점수는 계산 안정화의 기준에도 필요 없다. 복습: 본문 구현와 앞 절 안정화 설명.

연습문제 10.3.10 해설 두 종류의 잘못된 열

행 0 에서 잘못 연 열은 0(원래 위치 2), 빠진 열은 1(위치 0) 이다. 행 1 에서는 잘못 연 열 0, 빠진 열 2(위치 1) 다. 행 2 에서는 모든 키를 읽어도 되므로 두 목록이 모두 비었다. 따라서 쌍 목록은 extra=$[(0,0),(1,0)]$, missing=$[(0,1),(1,2)]$ 다.

올바른 B 는 $[[0,1,0],[0,1,1],[1,1,1]]$ 이다. BOS 만 열면 모든 행이 $[0,1,0]$ 이다. 행 1 은 위치 1 을 잃고, 행 2 는 위치 1 과 2 를 잃는다. 누출을 막는 조건과 가능한 모든 접두 입력을 유지하는 조건을 각각 확인해야 한다. 그림에 잘못 연 빨간 경로와 복구할 과거 경로를 함께 표시해도 좋다. 복습: 예제 10.3.5.

연습문제 10.3.11 해설 Mask 는 옳고 값의 순서는 틀리다

허용 키 지수는 열 1 의 1, 열 2 의 2 이므로 A 는 $[0, 1/3, 2/3]$ 다. 잘못된 V $[2, 0, 12]^\top$ 에 곱하면 출력은 8 이다. 열 2 는 키 metadata 로는 위치 1 이지만 실제 값은 위치 2 의 12 다. 따라서 정답 y_2 의 내용이 $v_{j=2} \to o$ 로 들어온다. 열 0 의 키를 닫아도 다른 열에 붙은 미래 값이 열린다.

정상 재배열 V 는 $[12, 2, 0]^\top$ 이고 출력은 2/3 이다. K 의 행, V 의 행, 원래 위치, key_valid 모두 동일 제공자의 순열로 옮긴다. 이미 계산한 S/A 가 있다면 제공 열도 함께 옮긴다. Q 행은 요청 순서가 그대로면 바꾸지 않는다. 크기만 맞는 배열곱으로 출처의 정확성을 확인할 수 없다. 복습: 예제 10.3.5와 앞 절 대응 순열.

연습문제 10.3.12 해설 불변 검사와 양성 대조

원래 위치 2 는 요청 위치 0/1 에서 미래다. 이 두 행의 Q 와 허용 K/V 가 그대로이므로 정리 10.3.1에 따라 출력 $[2, 0]$, $[2/3, 4]$ 를 유지한다. 위치 2 의 요청은 그 입력을 읽어 위치 3 을 예측하므로 반드시 보존된다는 주장을 할 수 없다. 임의의 변화가 우연히 같은 출력을 만들 수는 있지만 정책상 차단된 경로는 아니다.

원래 위치 1 의 V 를 $[0, 9]$ 로 바꾸면 그 변화 $[0, 3]$ 에 A 열 $[0, 2/3, 1/3]^\top$ 를 곱한다. 출력 변화는 $[[0, 0], [0, 2], [0, 1]]$ 이다. 전체 출력은 $[[2, 0], [2/3, 6], [19/3, 9]]$ 가 된다. 상수 0 구현은 미래 변경 불변은 통과하지만 이 정상 기준 출력/과거 변화 검사에서 실패한다. 복습: 예제 10.3.6.

연습문제 10.3.13 해설 마지막 층 전에 누출된 경우

마지막 허용 집합은 위치 0 하나이므로 계수 1, 출력은 $h_0 = t$ 다. t=5 이면 5, t=9 이면 9 다. 경로는 첫 입력 위치 2→ 첫 층 위치 0 표현 → 마지막 층 허용 값 위치 0→ 출력이다.

마지막 층은 원래 위치 기준으로 미래 열을 직접 읽지 않았지만 허용 V 가 이미 미래에 의존한다. 첫 층의 위치 0 이 위치 2 를 읽는 경로를 닫고, 초기 입력–대상/Q 생성과 다른 전체 혼합 경로도 확인해야 한다. 마지막 위치 0 까지 닫으면 유효 빈행이 되고 필요한 BOS 도 잃으므로 정상 수리가 아니다. 복습: 정리 10.3.2와 그 앞의 반례.

연습문제 10.3.14 해설 패딩 행과 유효 빈 행

active=$[0, 1]$ 이면 첫 행을 건너뛰고 둘째 행은 열 0 만 읽어 A=$[[0, 0], [1, 0]]$ 다. 첫 행 합 0 은 패딩 요청 생략 계약, 둘째 행 합 1 은 정상 분포다. active=$[1, 1]$ 이면 첫 행을 유효 요청으로 선언하여 빈 허용 집합 오류가 난다.

분모에 작은 양수 ϵ 을 더해 0 을 반환하는 방법은 결과를 정할 수는 있지만 허용 집합 위의 Softmax 를 정의하지 못한다. 비어 있는 집합에서 합 1 을 만족할 계수가 없기 때문이다. 입력 오류를 숨길 위험도 있다. 별도 0 출력 계약이 필요하다면 명시적으로 설계해야 한다. 복습: 예제 10.3.4, 본문 구현.

연습문제 10.3.15 해설 Boolean 규약을 거꾸로 전달한 경우

그대로 allowed 로 전달하면 $[False, True, True]$ 가 되어 열 1/2 를 읽고 열 0 을 닫는다. 원래는 열 0 만 읽어야 했다. Boolean blocked 의 올바른 의미 변환은 `allowed = ~blocked` 로 $[[True, False, False]]$ 다. 정수 배열의 비트 반전은 같은 의미가 아니므로 dtype 도 확인해야 한다.

key padding 이 `(n,)` Boolean True= 차단이면 `~key_padding` 이 키별 허용이다. 먼저 `row = (~key_padding)[None,:]` 로 새 행 축을 만들고 `np.broadcast_to(row, (m,n))` 로 늘린 뒤 필요한 Causal 조건과 AND 한다. 의미 반전과 행 반복이라는 서로 다른 두 변환이다. 함수는 shape 가 점수와 exact 일치해야 하므로 `(n,)` 을 바로 넘기면 거부한다. 복습: 정의 10.3.1, 본문 구현.

연습문제 10.3.16 해설 NumPy 로 실제 위치 비교하기

`qp=np.array([3,0]); kp=np.array([2,0,4,1]); valid=np.array([True,True,True,False])` 를 놓고 `(kp[None,:] <= qp[:,None]) & valid[None,:]` 를 계산한다. qp 를 넓힌 shape 는 `(2,1)`, kp/valid 는 `(1,4)`, 비교는 `(2,4)` 다. 비교 배열은 $[[1,1,0,1],[0,1,0,0]]$, 유효성과 결합한 최종은 $[[1,1,0,0],[0,1,0,0]]$ 다.

행 0·열 1 은 배열 번호로 $1 \le 0$ 이 거짓이지만 실제 위치 $0 \le 3$ 이 참이고 실제 키라 허용해야 한다. 행 1·열 0 은 배열 번호 $0 \le 1$ 이 참이지만 실제 위치 $2 \le 0$ 이 거짓이라 닫아야 한다. 한 셀만 들어도 반례가 되지만 두 방향을 모두 확인하면 누출/과거 손실을 함께 알 수 있다. 복습: 정의 10.3.2와 구현의 위치 비교.

연습문제 10.3.17 해설 누출과 과거 손실을 함께 보고하기

실제 해설 소스는 다음과 같다. 비교 정책의 정본 배열을 다시 만들고 차집합 두 개를 구한다.

solution_masking.py | learning-source/solution_masking.py | Python | L1-L14 (14 줄)
source revision: masking-source-v0.1

```python
""" 독립 연습의 누출 진단과 미래 차단·과거 보존 수정."""
import numpy as np
from masking import causal_allowed


def diagnose_and_repair(query_pos, key_pos, key_valid, wrong):
    correct = causal_allowed(query_pos, key_pos, key_valid)
    wrong = np.asarray(wrong)
    if wrong.dtype != np.bool_ or wrong.shape != correct.shape:
        raise ValueError(" 검사할 Mask 의 규약/크기가 다르다")
    # 잘못 연 경로와 놓친 과거를 각각 (질의 배열 행, 키 배열 열) 로 반환한다.
    extra = np.argwhere(wrong & ~correct)
    missing = np.argwhere(correct & ~wrong)
    return extra, missing, correct
```

`wrong & ~correct` 는 잘못 허용한 쌍, `correct & ~wrong` 는 놓친 쌍이다. `argwhere` 의 두 좌표는 원래 위치가 아니라 배열 행/열이므로 보고할 때 qp/kp 에 대입해 실제 출처를 덧붙이면 좋다. 요구 입력에서 extra 는 $[[0,0],[1,0]]$, missing 은 $[[0,1],[1,2]]$, correct 는 연습문제 10.3.10의 수정 배열이다.

`wrong & correct` 는 과도한 접근만 지운다. 놓친 과거를 열지 못하므로 correct 자체를 반환해야 한다. 다른 구현으로 셀을 순회하여 목록을 만들거나 집합 차를 써도 같은 의미·순서 대응·결과면 허용한다. 복습: 예제 10.3.5, 정의 10.3.1.

연습문제 10.3.18 해설 차단 열의 NaN

부동소수점 연산에서 $0 \cdot \mathrm{NaN}$ 은 NaN 이 될 수 있다. 따라서 `A @ V` 는 $1 \cdot 2 + 0 \cdot \mathrm{NaN}$ 을 포함하여 NaN 을 반환하며 2 를 보장하지 않는다. 수학의 유한 V 조건을 벗어난 입력이다. 본문 함수는 모든 Q/K/V 의 유한성을 먼저 검사하여 ValueError 를 낸다.

다른 계약으로 각 질의의 허용 열만 뽑아 `a[i,cols] @ v[cols]` 를 계산하고 그 허용 V 만 유한성 검사할 수 있다. 그러나 허용된 NaN 은 여전히 거부해야 한다. 차단 K 의 점수 계산도 비유한 값을 만들 수 있으므로 Q/K→S 경로까지 그 계약에 맞추어 선택 계산해야 한다. `nan_to_num` 으로 모든 NaN 을 무조건 0 으로 바꾸면 허용된 잘못된 자료까지 정상값처럼 쓰므로 별도의 근거가 필요하다. 본 실습에서는 명시적인 유한 입력 계약을 유지한다. 복습: 구현 부록과 정리 10.3.1의 조건.

연습문제 10.3.19 해설 바로 앞 두 입력만 읽는 정책

관계는 $p_Q(i) - 1 \le p_K(j) \le p_Q(i)$ 와 실제 키 조건의 결합이다. 주어진 배열에는 실제 키만 있으므로

$$B = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 0 & 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 1 & 1 \end{bmatrix}.$$

점수가 모두 0 이라 허용 키 둘이면 반씩, 첫 행 하나이면 1 이다. 출력은 $[2, 3, 6, 12, 24]^{\mathsf{T}}$ 다. 미래는 모두 닫히지만 위치 2 요청부터는 더 오래된 과거를 일부 버린다. 전체 접두를 모두 허용하라는 요구에는 부적합하고, '바로 앞 두 입력만' 이라는 새 정책에는 정확하다. 정책을 정한 뒤 검사해야 하며 Causal 이라는 말만으로 모든 과거를 반드시 열어야 한다고 일반화하지 않는다. 복습: 정의 10.3.1, 정의 10.3.2.

연습문제 10.3.20 해설 두 시퀀스를 하나의 배열에 넣기

위치만 비교하면 A 의 위치 0 질의가 B 의 위치 0 키 (배열 열 2) 를 읽고, A 의 위치 1 질의는 B 의 위치 0/1 까지 읽는다. 다른 시퀀스의 내용을 섞는다. `same_sequence & causal` 로 결합해야 한다. B 는

$$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 1 \end{bmatrix}$$

이다. 같은 시퀀스 식별자끼리 위치 비교를 적용하면 두 독립 블록이 생긴다. 점수 0 에서 출력은 $[2, 4, 100, 150]^{\mathsf{T}}$ 이다. 실제 구현은 질의/키의 식별자를 각각 `(m,1)/(1,n)` 으로 넓혀 equality 를 계산하고 기존 비교와 AND 하면 된다. key padding 이 있으면 세 번째 조건도 AND 한다. 단일 시퀀스용 함수를 조용히 batch 격리 함수로 취급하지 말자. 복습: 본문 구현의 계약과 정의 10.3.1.

심화문제 해설

심화문제 10.3.1 해설 Mask 를 포함한 출력 미분

J 가 고정되어 있으므로 허용 부분은 일반 Softmax 의 입력 목록을 J 로 바꾼 것이다. $t \in J$ 에서 $Z_J = \sum_{j \in J} e^{s_j}$, $\partial Z_J / \partial s_t = e^{s_t}$ 다. 몫의 미분으로 $\partial A_j / \partial s_t = A_j(\delta_{jt} - A_t)$ 를 얻는다. 유한 합을 미분하면

$$\frac{\partial o}{\partial s_t} = \sum_{j \in J} v_j A_j (\delta_{jt} - A_t) = A_t v_t - A_t \sum_{j \in J} A_j v_j = A_t (v_t - o).$$

$t \notin J$ 이면 허용 분모/분자의 어디에도 s_t 가 없고 차단 계수도 고정 0 이므로 미분은 0 이다. J 가 하나면 A=1, o=v 이므로 자기 미분도 0 이다. 둘 이상이어도 모든 허용 값이 같은 v 이면 o=v 라 출력 미분은 0 이다. 후자의 A 자체는 점수에 따라 달라질 수 있어 첫 경우와 다르다.

실제 토큰 변화는 점수 하나만 바꾸는 조작이 아닐 수 있다. Q 나 허용 K/V 가 바뀌면 연쇄법칙의 다른 항이 생기고, Mask/위치 대응 자체가 변하면 고정 J 미분의 전제도 깨진다. 이 부분 미분 0 만으로 전체 모델 누출 없음은 증명되지 않는다. 복습: 앞 절 Softmax 미분, 정리 10.3.1, 정리 10.3.2.

심화문제 10.3.2 해설 두 층의 가능한 정보 경로

행은 받는 위치, 열은 원래 입력 출처다. 첫 층 B1 은 $[[1,0,0],[1,1,1],[0,0,1]]$, 둘째 B2 는 $[[1,0,0],[1,1,0],[1,1,1]]$ 이다. Boolean 곱은 중간 q 중 어느 하나에서 두 연결이 모두 열리면 참이다. 행 0 은 B1 의 행 0 만 얻어 $[1,0,0]$, 행 1 은 B1 의 행 0 OR 행 1 로 $[1,1,1]$, 행 2 는 세 행 OR 로 $[1,1,1]$ 이다. 따라서

$$C = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}.$$

둘째 위치 1 의 미래 경로는 입력 2→ 첫 층 위치 1→ 둘째 층 위치 1 이다. 각 행의 수치 계수가 양수인 일반적인 집계라면 전달 가능한 구조적 경로다. 첫 층을 전체 Causal $[[1,0,0],[1,1,0],[1,1,1]]$ 로 고치면 둘째 층과의 Boolean 합성도 같은 아래 삼각형이 된다. 위치 1 은 입력 0/1 을 보존하고 2 를 읽지 않는다. 기존 R1 에서 누락된 위치 2 의 과거 0/1 도 복구한다.

가능 경로의 존재는 특정 입력에서 출력 변화가 반드시 0 이 아니라는 증명이 아니다. 값이 같거나 변화가 상쇄되거나 후속 사상이 해당 방향을 없앨 수 있다. 반대로 경로가 없다는 결론도 질의·residual·다른 경로가 문제의 관계 밖에 있다면 전체 모델로 확대할 수 없다. 이 문제는 제공 관계의 두 단계 가능성을 계산한 것이며, 전체 의존성 증명은 모든 경로와 초기 가정이 필요하다. 복습: 정리 10.3.2.

심화문제 10.3.3 해설 전체 미래 차단 실험을 설계하기

한 설계는 입력 위치 p 의 출력으로 대상 p+1 을 예측하는 모델에서, 위치 0–p 입력과 그 위치 metadata/패딩을 고정하고 p+1 이후 실제 토큰만 바꾸는 것이다. p 를 여러 값으로 택하고 길이·왼쪽/오른쪽 패딩·키 재배열도 별도 변형한다. 평가 시 dropout 을 끄거나 난수를 동일하게 고정하여 입력 변화와 무작위 변화를 혼동하지 않는다.

각 층에서 위치 p 와 허용 과거의 Q/K/V, B, S 의 허용 셀, A, O, 후속 표현과 최종 예측 값을 수집한다. 마지막 O 만 달라졌는지 보는 대신 최초로 달라진 허용 표현을 찾아 경로를 거슬러 올라간다. 입력–대상 이동이 없으면 Q 자체에서 정답이 들어올 수 있고, V 만 재배열되었으면 허용 열의 출처가 틀리며, 첫 층이 미래를 읽었으면 다음 층의 허용 과거 K/V 가 이미 달라진다. 서로 다른 원인을 다른 중간값에서 진단한다.

정상 기준을 독립 계산과 대조하고, 영향이 상쇄되지 않게 구성한 허용 과거 변경으로 기대 출력 변화를 검사한다. 모든 출력을 상수로 만드는 결함을 배제하는 데 필요하다. 부동소수점 비교의 허용오차를 사전 정하고 동일 연산의 완전 불변 여부와 근사 수치 일치를 구별한다. 작은 테스트의 통과는 그 입력

들에서 관찰한 결과다. 일반 보장에는 정리 10.3.2의 초기 의존성·각 층의 정책·위치별 연산·다른 경로 부재를 코드/설계에서 확인해야 한다.

자기평가 기준은 (1) 예측 대상과 허용 입력을 정확히 지정했는가, (2) 미래만 바꾸고 난수 등 교란을 고정했는가, (3) 미래 경로와 과거 보존을 둘 다 검사했는가, (4) 중간값으로 세 오류를 구별할 수 있는가, (5) 테스트의 한계를 설명했는가다. 실제 사용자 학습효과나 원고의 교육적 충분함은 이 기술 실험으로 측정되지 않으며 독립 리뷰·인간 편집·독자 연구의 다른 증거가 필요하다. 비슷한 계획이라도 이 요구를 근거로 만족하면 허용한다.

이해 확인 해설

대각선의 의미 옳지 않다. 입력 위치 p 에서 대상 p+1 을 예측하므로 대각선은 이미 주어진 현재 입력을 읽는다. 대상을 같은 위치에 잘못 놓았거나 Q 에 정답을 직접 넣었으면 다른 오류다. 질문과 예제 10.3.1의 대응 표를 복습하자.

작은 점수와 차단 둘째 비율은 $1/(e^{20}+1) \approx 2.061154 \times 10^{-9}$ 다. 값이 10^{12} 이면 기여는 약 2061.154 로 작다고 단정할 수 없다. 둘째 열을 허용 집합에서 제외하면 계수 0 으로 직접 경로를 닫는다. 큰 값과 여러 경로를 고려하지 않은 '작은 비율 = 접근 금지' 는 틀리다. 질문, 정의 10.3.3를 복습하자.

손실만 지우면 해결되지 않는다. 제외한 것은 패딩 질의 → 그 행의 손실이라는 경로다. 패딩 키/값 → 유효 질의의 A/O→ 유효 손실 경로는 남는다. Key padding 열 차단과 Query padding/손실 제외는 별도 역할이다. 질문, 예제 10.3.3로 돌아가자.

한 행만 계산하면 네 키 모두 원래 위치 5 이하의 실제 키라면 허용이다. 배열 행 0 은 요청 목록에서의 위치일 뿐 원래 위치 5 라는 사실을 대체하지 않는다. 올바른 Mask 는 $[[1,1,1,1]]$ 다. 질문, 정의 10.3.2를 복습하자.

마지막 층의 0 말할 수 없다. 허용된 과거 K/V 나 Q 가 이미 미래에 의존하면 마지막 열 차단을 우회한다. 예를 들어 입력 2→ 첫 층 위치 0→ 마지막 허용 위치 0→ 출력이라는 경로가 있다. 초기 입력과 모든 층에서 과거 의존성이 보존되고 다른 혼합 경로가 없어야 귀납 보장을 적용할 수 있다. 질문, 정리 10.3.2와 반례를 복습하자.

10.4 같은 입력과 다른 입력에서 정보를 가져오는 방식 — 해설

먼저 자기 답의 화살표를 확인하자. Q 가 나온 집합의 위치 수가 출력 행 수이며, K/V 가 나온 집합의 위치 수는 집계에서 합하는 축이다. 정확한 수치뿐 아니라 어느 표현을 보강하는지 설명할 수 있어야 한다. 수치가 다르면 투영 → 점수 → 허용 열 → 분모 → 좌표별 합 순서로 비교하자. 설계 문제의 사상은 유일하지 않으며, 주어진 요구·shape·접근 정책·반환 계약을 만족하는 대안을 허용한다.

유제 해설

유제 10.4.1 해설 투영 폭을 바꾸면

Q, K 는 3×2 이고 $V = X[2,3]^{\mathsf{T}} = [2,3,5]^{\mathsf{T}}$ 는 3×1 이다. Q/K/B 를 바꾸지 않았으므로 S/A 는 그대로 3×3 이다. O 는 3×1 이다. 첫 출력은 $(2 \cdot 2 + 1 \cdot 3 + 2 \cdot 5)/5 = 17/5$, 나머지는 $(2 + 9 + 15)/7 = 26/7$, $(4 + 9 + 30)/11 = 43/11$ 이다.

두 좌표 V 의 좌표들을 더한 값이 새 V 이므로, 기존 O 의 두 좌표를 더해도 이 답을 검산할 수 있다. 비교 폭과 값 폭을 같다고 적었다면 두 곱 QK^{T} 와 AV 의 소거 축을 따로 그려 보자. 복습: 정의 10.4.1, 정리 10.4.1.

유제 10.4.2 해설 한 행을 끝까지 검산하기

$q_1 = [0,1]$ 의 내적은 $[0, \sqrt{2}\ln 3, \sqrt{2}\ln 3]$ 이다. $\sqrt{2}$ 로 나누면 $[0, \ln 3, \ln 3]$, 지수는 $[1,3,3]$, 분모 7 이므로 $A_1 = [1/7, 3/7, 3/7]$ 이다. 값의 기여는

$$\tfrac{1}{7}[2,0] = [2/7, 0], \quad \tfrac{3}{7}[0,3] = [0, 9/7], \quad \tfrac{3}{7}[2,3] = [6/7, 9/7].$$

합은 $o_1 = [8/7, 18/7]$ 이다. 다른 위치 2 가 둘째 좌표에 9/7 를 더했다. 위치 0 은 비율이 0 이 아니어도 해당 값의 둘째 좌표가 0 이라 그 좌표에는 0 을 더한다. '읽을 수 있음', '계수가 양수임', '특정 좌표의 기여가 0 이 아님' 을 서로 바꾸어 말하지 말자. 복습: 예제 10.4.2, 예제 10.4.3.

유제 10.4.3 해설 값을 바꾸는 실험과 입력을 바꾸는 실험

$A_{02} = 2/5, A_{12} = 3/7$ 이므로 $\Delta o_0 = [2, -2]$, $\Delta o_1 = [15/7, -15/7]$ 다. 변경 후 출력은 각각 $[18/5, -1/5]$, $[23/7, 3/7]$ 이다. 이는 Q/K/B 고정 상태에서 투영 후 값만 바꾼 실험이다.

X 의 행 2 자체를 바꾸면 $k_2 = x_2 W_K, v_2 = x_2 W_V$ 가 함께 달라질 수 있고, 위치 2 의 질의 q_2 도 달라질 수 있다. 그러면 새 A 를 계산해야 한다. 예를 들어 x_2 의 첫 좌표를 늘리면 첫 요청에 대한 열 2 의 점수가 변하므로 위 고정 계수를 곱한 값만으로 전체 변화를 구할 수 없다. 복습: 정리 10.4.2와 본문의 제공자 변경 실험.

유제 10.4.4 해설 패딩은 어느 축을 닫는가?

Key padding 만 적용하면 B 의 모든 행은 $[1,1,0]$ 이다. 유효 요청 0 의 지수는 $[2,1]$ 이므로 A 행은 $[2/3, 1/3, 0]$, 출력은 $[4/3, 1]$ 이다. 요청 1 은 $[1,3]$ 으로 $[1/4, 3/4, 0]$, 출력 $[1/2, 9/4]$ 다. active=$[True, True, False]$ 를 적용하면

$$A = \begin{bmatrix} 2/3 & 1/3 & 0 \\ 1/4 & 3/4 & 0 \\ 0 & 0 & 0 \end{bmatrix}, \quad O = \begin{bmatrix} 4/3 & 1 \\ 1/2 & 9/4 \\ 0 & 0 \end{bmatrix}.$$

마지막 0 행은 정규화한 확률분포가 아니라 사용하지 않는 요청의 별도 반환 계약이다. Causal 까지 결합하면 요청 0 은 열 0 만 허용하여 출력 $[2, 0]$ 으로 바뀌고, 요청 1 은 기존 두 열을 계속 읽으므로 그대로다. 열 차단과 행 비활성을 섞었다면 10.3 의 패딩 예제를 복습하자. 복습: 예제 10.4.4.

유제 10.4.5 해설 같은 폭이어야 하는 것은 무엇인가?

$W_Q : 3 \times 2$, $W_K : 4 \times 2$, $W_V : 4 \times 5$ 다. 따라서 $Q : 2 \times 2$, $K : 3 \times 2$, $V : 3 \times 5$, $S/A : 2 \times 3$, $O : 2 \times 5$ 다. K/V 를 만드는 입력은 Z 라 그 입력 폭 4 가 W 의 첫 축이어야 한다. 3×2 는 Z 의 위치 수 3 을 입력 폭과 혼동한 제안이다.

O 를 H 의 폭 3 에 맞추려면 $R : 5 \times 3$ 을 두어 $OR : 2 \times 3$ 으로 만든 뒤 H 와 더할 수 있다. 다른 비선형 사상도 입력/출력 shape 와 갱신 계약을 명시하면 가능한 설계지만, 본문의 선형 예시 답은 이 R 이다. 복습: 정의 10.4.2, 정의 10.4.3.

유제 10.4.6 해설 읽는 방향을 바꾸면

새 질의 제공자는 Z 이므로 질의 투영은 2×2 다. 새 K/V 제공자는 H 이므로 두 투영 모두 3×2 다. 새로운 Q 는 3×2, K/V 는 2×2, S/A 는 3×2, O 는 3×2 다. 직접 반환되는 정보는 Z 의 세 위치를 보강한다. Z 의 입력 폭 2 와 값 폭 2 가 같으므로 항등 출력 사상도 가능하다.

기존 $W_Q : 3 \times 2$ 는 폭 2 의 Z 에 곱할 수 없다. 기존 매개변수의 이름만 바꾸어 방향을 뒤집을 수 없다는 뜻이다. 별도 학습한 투영이나 조건을 만족하는 새 수치를 정해야 한다. H 는 이번 뒤집힌 연산에서 조건 공급자가 되며, 양쪽을 모두 갱신하려면 두 방향의 연산과 순서/동시성 계약을 따로 설계해야 한다. 복습: 예제 10.4.6.

유제 10.4.7 해설 원문 마지막 위치를 닫으면

두 B 행 모두 $[1, 1, 0]$ 이다. 첫 행 분모는 $2 + 1 = 3$, 둘째는 $1 + 3 = 4$ 다. 따라서

$$A = \begin{bmatrix} 2/3 & 1/3 & 0 \\ 1/4 & 3/4 & 0 \end{bmatrix}, \quad O = \begin{bmatrix} 4/3 & 1 \\ 1/2 & 9/4 \end{bmatrix}.$$

두 요청의 Q, 허용된 K/V, B 가 그대로이고 변경한 열의 입력과 계산 결과가 함수의 유한성/표현 범위 계약을 만족하면 차단 열 2 의 K/V 는 허용 분모나 집계에 들어가지 않아 O 가 유지된다. 여기서 Z 에 다른 연산이 먼저 섞이는 경로는 없다. 열 2 를 다시 열면 계수는 양수이며 K/V 의 변경이 출력에 들어갈 수 있다. 우연한 상쇄나 동일 값은 가능해도 보편적 불변은 없다. 복습: 정리 10.4.2 및 10.3 국소 불변 조건.

독립 연습 해설

연습문제 10.4.1 해설 세 역할의 실제 출처

A 는 Self 다. 요청·제공·반환 위치가 모두 X 이며, B 의 행/열은 X 의 요청/제공 위치다. B 모듈은 Cross 다. H 가 요청하고 Z 가 제공하며, 반환되는 O 의 행들은 H 의 위치다. 이 모듈의 Mask 행/열은 H/Z 다. 같은 문자 B 를 모듈 이름과 Mask 에 쓰더라도 실제 대상을 구별해야 한다.

'Z 에 A 를 곱한다' 는 표현은 AV 에서 A 가 제공 위치를 합해 요청 위치의 출력을 만든다는 점을 놓친다. 출력은 $m \times d_v$ 여서 Z 의 n 개 행에 직접 대응하지 않는다. Z 를 갱신하려면 Z 가 질의를 제공하는 별도 읽기나 다른 갱신 식이 필요하다. 복습: 정의 10.4.1, 정의 10.4.2, 정리 10.4.1.

연습문제 10.4.2 해설 입력과 매개변수의 축

$W_Q/W_K : 4 \times 3$, $W_V : 4 \times 2$ 다. $Q/K : 5 \times 3$, $V : 5 \times 2$, $S/A : 5 \times 5$, $O : 5 \times 2$ 다. $R : 2 \times 4$ 면 $OR : 5 \times 4$ 로 입력 폭을 맞출 수 있다. 첫 투영의 한 셀은 입력 행의 4 좌표를 합하므로 W 의 첫 축이 4 여야 한다.

위치 수 5 는 투영 전후 행 수로 남는다. 5×3 의 W 를 쓰면 5×4 와 내적 축이 맞지 않는다. 길이가 달라져도 입력 폭이 같은 한 동일 W 를 위치별로 적용할 수 있다는 점이 이 구별의 장점이다. 복습: 예제 10.4.1.

연습문제 10.4.3 해설 세 위치의 전체 Self 계산

$L = \ln 2$ 라 쓰면 Q=$[1, 2, 0]^\top$, K=$[L, 2L, 0]^\top$, V=$[3, 6, 0]^\top$ 다. 비교 폭 1 이므로 scaling 은 1 이다.

$$S = \begin{bmatrix} L & 2L & 0 \\ 2L & 4L & 0 \\ 0 & 0 & 0 \end{bmatrix}, \quad A = \begin{bmatrix} 2/7 & 4/7 & 1/7 \\ 4/21 & 16/21 & 1/21 \\ 1/3 & 1/3 & 1/3 \end{bmatrix}.$$

분모는 7,21,3 이고 $O = [30/7, 36/7, 3]^\top$ 다. 요청 0 에는 위치 0 이 6/7, 다른 위치 1 이 24/7, 위치 2 가 0 을 더한다. 다른 위치 1 의 기여가 실제로 0 이 아니므로 자기 값 3 의 복사와 다르다. 위치 2 의 입력이 0 이어도 그 요청의 점수는 모두 0 이어서 다른 두 값을 읽고 출력 3 을 얻는다. 입력 0 과 출력 0 을 혼동하지 말자. 복습: 예제 10.4.2, 예제 10.4.3.

연습문제 10.4.4 해설 같은 집합의 표현 갱신

위치 2 의 비율은 $[2, 3, 6]/11$ 이다. 기여는 $[4/11, 0]$, $[0, 9/11]$, $[12/11, 18/11]$ 이므로 합은 $[16/11, 27/11]$ 이다. 원래 $x_2 = [1, 1]$ 에 더하면 $[27/11, 38/11]$ 이다. 위치 0 의 첫 좌표 기여 4/11 와 위치 1 의 둘째 좌표 기여 9/11 가 다른 위치에서 들어온 부분이다.

O 는 집계 정보이고 X+O 는 이 문제에서 지정한 새 표현이다. 전체 모델이 언제나 이 단순 덧셈만 수행하는 것은 아니다. 출력 사상·정규화·다음 층에 따라 후속 표현은 달라진다. 복습: 예제 10.4.3, 정의 10.4.3.

연습문제 10.4.5 해설 투영이 같은 특별한 경우

같은 X 에 같은 W 를 곱하므로 Q=K=V 다. 그러나 본문의 서로 다른 W_Q, W_K, W_V 는 Self 이면서 수치가 다르므로 등식은 필수가 아니다. 조건을 만족한 한 특별한 예를 정의 전체로 확대하면 안 된다.

두 위치의 반례에서 S=[[1, 2], [2, 4]] 는 대칭이지만 $A_{01} = e^2/(e + e^2) = e/(1 + e), A_{10} = e^2/(e^2 + e^4) = 1/(1 + e^2)$ 로 다르다. Softmax 의 분모가 행마다 달라 대칭 점수도 대칭 비율을 보장하지 않는다. Q=K 라고 정보를 양방향 같은 비율로 교환하는 것은 아니다. 복습: 예제 10.4.2와 행별 Softmax.

연습문제 10.4.6 해설 허용 위치만의 문맥화

Causal 에서 위치 1 은 열 0·1 만 읽는다. 점수 $[0, \ln 3]$ 의 지수는 [1, 3] 이라 A=[1/4, 3/4, 0], O=[1/2, 9/4] 다. 자기 위치 1 만 허용하면 A=[0, 1, 0], O=[0, 3] 다.

둘 다 세 투영의 출처가 X 라 Self 다. 그러나 후자는 해당 행에서 다른 위치의 직접 정보를 전혀 집계하지 않는 접근 정책이다. 전자는 과거 위치 0 의 정보를 [1/2, 0] 만큼 반영한다. 모듈 분류와 특정 정책 아래의 정보 혼합 정도를 별도로 말해야 한다. 복습: 예제 10.4.4.

연습문제 10.4.7 해설 길이와 폭이 모두 다른 설계

Q 는 H, K/V 는 Z 에서 만든다. $W_Q : 6 \times 3, W_K : 5 \times 3, W_V : 5 \times 2$ 다. $Q : 4 \times 3, K : 7 \times 3, V : 7 \times 2, S/A/B : 4 \times 7, O : 4 \times 2, R : 2 \times 6$ 이다. $H + OR$ 은 4×6 이다.

요청 수는 H 의 행 수 4 다.7 은 각 요청이 비교할 조건 제공 위치 수다. 모든 실제 Z 를 허용하므로 B 는 전부 True 이고, Z 에 패딩이 있다면 해당 열만 닫는다. 수행의 핵심은 우연히 행렬곱이 되는 임의 배정이 아니라 H 의 요청이 Z 를 읽는 요구를 만족하는 출처 배정이다. 복습: 정리 10.4.1, 유제 10.4.5.

연습문제 10.4.8 해설 새로운 수치의 Cross 계산

$Q=[1, 2]^\top$, $K=[0, L, 2L]^\top$, $V=[0, 4, 8]^\top$ 다. S/A 는

$$S = \begin{bmatrix} 0 & L & 2L \\ 0 & 2L & 4L \end{bmatrix}, \quad A = \begin{bmatrix} 1/7 & 2/7 & 4/7 \\ 1/21 & 4/21 & 16/21 \end{bmatrix}.$$

첫 출력은 $0 + 8/7 + 32/7 = 40/7$, 둘째는 $0 + 16/21 + 128/21 = 48/7$ 이다. O 는 2×1 로 H 의 두 요청에 대응한다. 세 제공 위치가 모두 허용되고 계수도 양수지만 첫 값이 0 이라 직접 수치 기여는 0 이다. Z 의 새 표현을 직접 반환하지 않으며, 함수는 H 가 사용할 집계 두 개를 반환한다. 복습: 예제 10.4.5.

연습문제 10.4.9 해설 폭이 맞아도 출처가 틀릴 수 있다

K 를 H 에서 만들면 비교한 열은 H 의 위치인데 집계한 V 의 열 대응은 Z 의 위치가 된다. 우연히 두 행수가 같아도 의도한 Z 의 키–값 대응이 아니다. 고칠 부분은 `k=z@wk` 이며 `q=h@wq; v=z@wv` 는 유지한다.

H=Z 인 한 입력에서는 잘못된 K 도 정상 K 와 같아 출력 비교가 통과한다. H 를 고정하고 Z 를 독립적으로 바꾼 다음 K/V/S/A 를 확인해야 한다. 단, 특정 변화가 W_K 의 영공간에 들어갈 수 있으므로 기대 변화가 있는 방향을 골라야 한다. 복습: 본문 구현의 실제 피연산자와 심화문제 10.4.3.

연습문제 10.4.10 해설 두 방향으로 조건을 교환하기

H 가 Z 를 읽는 방향는 $W_Q : 3\times 2$, $W_K : 2\times 2$, $W_V : 2\times 4$ 이며 S/A=2×3, O=2×4, R=4×3 다. Z 가 H 를 읽는 방향는 $W_Q : 2\times 2$, $W_K : 3\times 2$, $W_V : 3\times 4$ 이며 S/A=3×2, O=3×4, R=4×2 다. 각각 H 와 Z 를 직접 보강한다.

원래 A 는 각 행의 합이 1 이지만 각 열의 합은 일반적으로 1 이 아니다. 대표 A 의 첫 열 합은 $2/5+1/7 = 19/35$ 다. 따라서 A^{T} 첫 행의 합도 19/35 여서 둘째 방향의 정상 가중치가 될 수 없다. 둘째 방향은 새 Q/K 점수와 그 요청별 분모를 계산해야 한다. 만약 첫 갱신 뒤 두 번째 연산을 한다면 K/V 가 원래 H 인지 새 H 인지도 설계에서 정해야 한다. 복습: 유제 10.4.6.

연습문제 10.4.11 해설 숫자만으로 이름을 붙일 수 있는가?

가능하다. Self 구성의 한 예는 X=$[[1,0],[0,1]]$, $W_Q = W_K = I$, $W_V = [2,8]^{\mathsf{T}}$ 다. 첫 요청만 로그에 남기면 주어진 Q/K/V 가 나온다. Cross 구성은 별도 H=$[[1,0]]$, Z=$[[1,0],[0,1]]$ 에서 같은 투영 수치를 쓰면 된다. 전자는 X 의 첫 위치, 후자는 별도 H 의 첫 위치를 보강한다.

따라서 투영 전 배열의 출처 식별, 요청 위치와 반환 위치의 대응, K/V 의 제공 위치 대응을 기록해야 한다. 배열의 메모리 주소가 다르더라도 X 의 복사본일 수 있으므로 의미상의 출처도 필요하다. 수치 로그만으로는 그 배정을 복원할 수 없다. 복습: 예제 10.4.7.

연습문제 10.4.12 해설 직접 값 경로와 전체 입력 효과

첫 변화는 $(1/5)[7,-7] = [7/5,-7/5]$, 둘째는 $(3/7)[7,-7] = [3,-3]$ 다. R 은 $[a,b]\mapsto[a,b,a-b]$ 이므로 U 의 변화는 $[7/5,-7/5,14/5]$, $[3,-3,6]$ 이다. H 를 고정하면 예시 H^{new} 의 변화도 이 U 의 변화와 같다.

실제 z_1 이 바뀌면 K 를 통한 점수와 비율도 달라질 수 있다. 이 식만 적용하려면 변경 후에도 Q/K/B 가 같고 V 의 변화가 지정한 한 행의 델타와 같아야 한다. 그 조건이 없으면 A 의 변화에 따른 다른 항이 필요하다. 복습: 정리 10.4.2, 심화문제 10.4.2.

연습문제 10.4.13 해설 Cross 의 패딩 열

B 는 두 행 모두 $[True, True, False]$, active=$[True, False]$ 다. 첫 요청은 $[2/3,1/3,0]$ 으로 출력 $[4/3,1]$ 을 얻는다. 둘째는 비활성 계약으로 A 행과 O 행 모두 0 이다. 따라서 O=$[[4/3,1],[0,0]]$ 다.

둘째 행의 계수 합은 0 이어서 확률분포의 평균이 아니다. 계산하지 않을 요청에 지정한 별도 반환이다. 첫 요청처럼 유효한 행의 허용 키가 전부 없으면 본문 함수는 ValueError 를 낸다. 패딩이라고 거짓 표시하여 오류를 숨기지 말고, 허용된 실제 조건을 공급하거나 별도 빈 조건 처리를 설계해야 한다. 복습: 유제 10.4.7,10.3 빈행 계약.

연습문제 10.4.14 해설 두 시계로 정하는 접근 관계

각 자료 도착 시각이 요청 시각 이하인지 비교한다. $[1,4,6]\le 4$ 와 $[1,4,6]\le 5$ 모두 $[1,1,0]$ 이므로

$$B=\begin{bmatrix}1&1&0\\1&1&0\end{bmatrix},\quad A=\begin{bmatrix}2/3&1/3&0\\2/3&1/3&0\end{bmatrix},\quad O=\begin{bmatrix}4\\4\end{bmatrix}.$$

2×3 의 단순 tril 은 첫 행을 $[1,0,0]$ 으로 만들어 이미 시각 4 에 도착한 자료 열 1 을 놓친다. 그 잘못된 첫 출력은 2 다. 두 목록의 배열 번호가 아니라 실제 시각을 비교해야 한다. Cross 에도 접근 제한이 필요할 수 있지만 일반적인 원문/번역 위치를 같은 시계로 취급해서는 안 된다. 복습: 본문의 접근 제약 설명과 10.3 원래 위치 비교.

연습문제 10.4.15 해설 원문 열을 무조건 삼각형으로 닫는 오류

원문이 모두 처음부터 제공된다면 모든 요청이 세 실제 원문 위치를 읽어도 이 경로에서 미래 번역 정답을 읽은 것이 아니다. B 는 $[[1,1,1],[1,1,1]]$ 로 둘 수 있다. 번역 위치와 원문 위치 사이에 $j \le i$ 라는 제약을 무조건 넣으면 두 언어의 길이/정렬이 다를 때 필요한 원문까지 버린다.

원문이 순차 도착하거나 특정 요청에서 일부 자료를 금지한다면 실제 도착/권한 관계로 별도 B 를 만든다. 미래 번역 토큰의 문제는 Decoder 쪽 입력–예측 대상 이동과 Causal Self-attention, 그리고 H 를 생성하는 다른 경로에서 검사해야 한다. Cross 의 원문을 여는 것이 잘못된 H 내부 누출까지 고치지는 못한다. 복습: 예제 10.4.4, 예제 10.4.5와 10.3 다층 보장 경계.

연습문제 10.4.16 해설 제공자 순서를 바꾸기

새 제공자 순서는 원래 2,0,1 이다. 따라서 새 K 는 원래 k_2, k_0, k_1 순, 새 V 는 $[[2,3],[2,0],[0,3]]$ 다. 원래 열 2 를 닫았으므로 새 B 의 두 행은 $[0,1,1]$ 이고, A 는

$$A' = \begin{bmatrix} 0 & 2/3 & 1/3 \\ 0 & 1/4 & 3/4 \end{bmatrix}.$$

곱하면 O 는 원래 마스크 적용 출력 $[[4/3,1],[1/2,9/4]]$ 그대로다. Q 는 유지하고 K/V/Mask 열을 함께 옮겨야 같은 제공자가 같은 계수를 받는다.

V 만 옮기고 모든 열 허용 A 의 첫 행 $[2/5,1/5,2/5]$ 를 유지하면 $\frac{2}{5}[2,3]+\frac{1}{5}[2,0]+\frac{2}{5}[0,3]=[6/5,12/5]$ 다. 원래 $[8/5,9/5]$ 와 달라 키–값 대응 오류가 드러난다. 값이 모두 같으면 우연히 오류가 감춰질 수 있으므로 한 출력 일치만으로 대응을 보증하지 않는다. 복습: 심화문제 10.4.1.

연습문제 10.4.17 해설 NumPy 실행과 실제 결과 대조

`sources.py` 에서 `example_inputs` 로 배열을 받고 Self 와 Cross 를 호출한다. 실제 Self O 의 세 행은 각각 $[1.6,1.8]$, $[1.142857\ldots, 2.571429\ldots]$, $[1.454545\ldots, 2.454545\ldots]$ 이며 Cross O 는 첫 두 행이다. 모든 중간값은 예제 10.4.2·예제 10.4.5의 행렬과 대조한다. 부동소수점 비교에는 `np.testing.assert_allclose` 로 예를 들어 atol/rtol=2×10^{-13} 을 사용한다.

예시 반환은 다음과 같다.

$$X + O = \begin{bmatrix} 13/5 & 9/5 \\ 8/7 & 25/7 \\ 27/11 & 38/11 \end{bmatrix}, \qquad H + OR = \begin{bmatrix} 13/5 & 9/5 & 4/5 \\ 8/7 & 25/7 & -3/7 \end{bmatrix}.$$

호출 전 `x_before=x.copy(); h_before=h.copy()` 를 저장하고 호출 후 `assert_array_equal` 로 입력 보존을 확인한다. 표현을 새 배열로 반환하는 것과 입력을 제자리 수정하는 것을 구별한 시험이다.

출력 일치·shape·입력 보존만으로 올바른 출처가 증명되지는 않는다. 이 예제는 일부 수치가 같도록 구성했기 때문에 호출에 실제로 `cross_attention(h,x,uq,wk,wv)` 가 전달됐는지 확인하고, 다음 문제처럼 Z 만 바꾸는 시험도 필요하다. 제공자의 Python 변수명 x 는 원래 수치를 공유한 것일 뿐, Cross 호출에서의 의미 역할은 Z 다. 복습: 본문 구현, 예제 10.4.7.

연습문제 10.4.18 해설 제공자만 바꾸는 실험

새 $k_2 = [2\sqrt{2}\ln 2, \sqrt{2}\ln 3]$, 새 $v_2 = [4, 3]$ 이다. H 가 그대로라 Q 는 유지된다. 첫 S 행은 $[\ln 2, 0, \ln 4]$ 로 바뀌어 A=[2, 1, 4]/7 이고 O=[20/7, 15/7] 다. 둘째 S 행은 $[0, \ln 3, \ln 3]$ 그대로여서 A=[1, 3, 3]/7 이다. 값의 첫 좌표가 바뀌었으므로 O=[2, 18/7] 다.

열 2 를 닫으면 두 실험 모두 A=[[2/3, 1/3, 0], [1/4, 3/4, 0]], O=[[4/3, 1], [1/2, 9/4]] 다. Q 와 허용 K/V/B 가 유지되고 다른 혼합 경로가 없어서 그렇다. 전체 자료를 유한성 검사하는 함수이므로 차단 열에도 NaN 을 넣으면 '유지' 대신 오류가 난다. 유한 입력이라도 점수/출력이 표현 범위를 넘는 변경은 거부될 수 있다.

실험 코드의 한 대안은 다음과 같다. 반환 사전에서 Q/K/V/S/A/O 를 차례로 비교한다. 값만 비교하거나 무조건 모든 배열이 달라야 한다고 판정하지 말자.

solution_sources.py | learning-source/solution_sources.py | Python | L1-L11 (11 줄)
source revision: sources-source-v0.1

```python
""" 독립 연습의 출처/순열/조건 변경 실험."""
import numpy as np
from sources import cross_attention


def compare_providers(h, z, z_new, wq, wk, wv, allowed):
    """ 같은 요청·정책에서 제공자만 바꾸어 중간값을 비교한다."""
    before = cross_attention(h, z, wq, wk, wv, allowed)
    after = cross_attention(h, z_new, wq, wk, wv, allowed)
    return {name: (a, b) for name, a, b in
            zip(["Q", "K", "V", "S", "A", "O"], before, after)}
```

복습: 정리 10.4.2와 본문 demo. 다른 구현도 같은 출처 고정·변경 분리·중간값·기대 출력·거부 조건을 확인하면 허용한다.

연습문제 10.4.19 해설 갱신 방향을 거꾸로 쓰는 코드

A 는 2 × 3 이고 H 는 2 × 3 이라 `a@h` 는 안쪽 축 3/2 가 달라 계산되지 않는다. 올바른 집계는 $O = AV$, 여기서 V=ZW_V 는 3 × 2 이고 O 는 2 × 2 다. R : 2 × 3 을 두어 $H^{\text{new}} = H + OR$ 로 반환한다.

길이와 폭까지 맞아 코드가 실행되는 경우에도 H 를 값으로 읽으면 원문 조건 Z 의 값을 집계한 것이 아니다. 또한 Z 를 갱신하는 대입은 반환 대상을 뒤집는다. 학습 중에는 이 정상 Cross 의 gradient 가 H/Z 와 투영 매개변수로 전달될 수 있지만, 그것이 순방향에서 Z 의 새 위치 표현을 반환했다는 뜻은 아니다. 복습: 예제 10.4.6.

연습문제 10.4.20 해설 문서·질문·응답 슬롯

첫 단계는 T 가 Q, D 가 K/V 의 출처다. W_Q : 5 × 2, W_K : 4 × 2, W_V : 4 × 4, A=3 × 6, O=3 × 4, R=4 × 5 다. $T^{\text{new}} = T + OR$ 로 3 × 5 를 얻는다.

둘째 단계는 U 가 Q, 새 T^{new} 가 K/V 의 출처다. W_Q : 3×2, W_K : 5×2, W_V : 5×4, A=2×3, O=2×4, R=4 × 3 이며 U^{new} : 2 × 3 을 반환한다. 두 단계 모두 Cross 이며, 문서 D 의 6 개 새 표현을 자동 반환하지 않는다. 두 슬롯이 문서 내용을 간접적으로 참고하는 경로는 D→ 새 T→ 새 U 다.

T 의 세 위치를 먼저 Self 로 문맥화하는 추가 설계도 가능하지만 요구한 두 인터페이스를 대신할 수는 없다. 질문 갱신에 원래 T 를 residual 로 더할지 다른 반환 함수를 쓸지는 명시하면 대안으로 허용한다. 복습: 정의 10.4.2, 정의 10.4.3.

연습문제 10.4.21 해설 같은 자연어, 다른 표현 출처

첫 경우는 서로 다른 Encoder 의 표현 집합 사이를 읽는 Cross 다. 같은 문장이라는 원자료의 동일성이 현재 표현 집합의 동일성을 뜻하지 않는다. 둘째는 하나의 X 에서 세 역할을 만들므로 구조상 Self 다. 내용이 여러 문서에서 왔다는 사실만으로 그 모듈이 Cross 가 되지는 않는다.

문서별로 독립 처리가 필요하면 각 위치의 문서 식별자를 기록하고 $B_{ij} = [\text{doc}(i) = \text{doc}(j)]$ 를 둔다. 필요하면 Causal/패딩 조건도 AND 한다. 이어 붙인 X 에서 모든 열을 열면 서로 다른 문서 내용이 섞일 수 있다. 이 판단은 출처 경계를 어떻게 모듈 입력으로 구성했는지에 근거하며, 문자열이 같은가만으로 내릴 수 없다. 복습: 정의 10.4.1, 예제 10.4.7.

연습문제 10.4.22 해설 빈 조건 집합을 처리하는 설계

조건 길이 0 이면 각 요청의 허용 집합도 공집합이다. 지수 합의 분모가 0 이고 합 1 을 갖는 분포가 없으므로 본문의 비어 있지 않은 행렬 계약은 이를 거부한다.

한 대안은 조건 없음 상태를 명시하고 이 하위 연산을 건너뛰어 H 를 그대로 반환하는 것이다. 이것은 Attention 분포를 만든 결과가 아니며 후속 모델이 이 경우를 처리하도록 학습/사용 계약을 정해야 한다. 다른 대안은 '검색 결과 없음' 을 나타내는 실제 별도 조건 벡터 하나를 제공하는 것이다. 이때 Z 는 길이 1 이고 그 키/값을 허용해 정상 집계할 수 있지만, 그 벡터의 의미와 학습 방법을 정해야 하며 없는 근거를 있다고 주장해서는 안 된다.

명시적 0 집계와 유효성 표지를 반환하는 별도 설계도 가능하다. 핵심은 유효한 요청을 패딩처럼 숨기지 않고 빈 조건의 의미를 드러내는 것이다. 오류를 상위 호출자에게 전달해 검색을 다시 시도하는 처리도 타당하다. 복습:10.3 의 유효 빈행 계약과 정의 10.4.2.

심화문제 해설

심화문제 10.4.1 해설 순열에 따른 Self 와 Cross 의 대응

Cross 에서 $K' = PZW_K = PK$, $V' = PV$ 이고 Q 는 그대로다. 따라서 $S' = QK^{\top}P^{\top}/\sqrt{d_k} = SP^{\top}$ 이다. B 도 같은 열 순열이므로 허용 위치들의 점수/분모가 대응한다. 각 행의 Softmax 는 열을 옮겨도 대응 비율만 옮겨져 $A' = AP^{\top}$ 이다. 그러므로 $O' = A'V' = AP^{\top}PV = AV = O$ 다. 이는 제공자 목록의 표현 순서를 바꾼 것이지 제공 내용을 바꾼 것이 아니다.

Self 에서는 $Q' = PQ, K' = PK, V' = PV$ 이므로 $S' = PSP^{\top}$ 이다. B 도 $PBP^{\top}$ 로 행/열을 함께 옮겼으므로 행별 정규화에서 $A' = PAP^{\top}$ 다. 따라서 $O' = PAP^{\top}PV = PO$ 다. 입력을 옮긴 만큼 요청 출력도 옮겨진다. 대응된 active 가 있다면 그것도 P 에 따라 옮겨야 한다.

원래 위치 신호를 입력에 다시 붙이거나 고정 tril 을 새 배열 순서에 적용하면 위 전제를 만족하지 않을 수 있다. 예를 들어 순서를 뒤집고 동일 tril 을 재사용하면 원래 과거/미래가 뒤집히므로 $B' = PBP^{\top}$ 가

아니다. 새 위치 신호가 원래 입력과 함께 옮겨진다는 조건, 또는 원래 위치로 정책을 다시 구성한다는 조건을 명시해야 한다. 복습: 연습문제 10.4.16와 10.3 재배열 반례.

심화문제 10.4.2 해설 조건 변화가 출력에 들어오는 두 경로

점은 $\epsilon = 0$ 에서의 미분이다. Q 는 고정이고 K/V 는 선형 투영이므로 $\dot{K} = EW_K, \dot{V} = EW_V$ 다. 따라서 $\dot{S} = Q\dot{K}^\top/\sqrt{d_k}$ 다. 허용 집합 J_i 를 고정하면 몫의 미분으로, 허용 셀에서

$$\dot{A}_{ij} = A_{ij}\left(\dot{S}_{ij} - \sum_{t\in J_i} A_{it}\dot{S}_{it}\right)$$

를 얻고 차단 셀의 $\dot{A}_{ij}$ 는 0 이다. 이 식의 합은 0 이라 A 행의 합 1 을 유지한다. 이제 곱을 미분하면

$$\dot{O} = \dot{A}V + A\dot{V}, \qquad \dot{o}_i = \sum_{j\in J_i} \dot{A}_{ij}v_j + \sum_{j\in J_i} A_{ij}\dot{v}_j.$$

첫 항은 K 변경 → 점수 → 비율의 경로이고 둘째는 V 변경 → 집계의 경로다. 정리 10.4.2만 적용하면 첫 항을 빠뜨린다. $EW_K = 0$ 인 방향처럼 K 가 유지되는 조건에서는 첫 항이 0 이지만, 일반 E 에 그렇다고 둘 수 없다. Mask 나 허용 집합 자체가 바뀌는 경우는 고정 집합 미분의 전제 밖이며 별도 분석이 필요하다.

검산하려면 중심차분 $[O(Z + hE) - O(Z - hE)]/(2h)$ 를 여러 작은 h 에서 도출식과 비교한다. 반올림 때문에 h 를 무한히 작게만 하는 것이 최선은 아니다. 본 실습 검증은 $h = 10^{-5}$ 의 작은 비퇴화 사례에서 두 경로를 각각 계산하고 합을 대조한다. 이 수치 확인이 일반 미분 증명을 대신하지 않는다. 복습:10.2 Softmax 미분,10.3 고정 Mask 미분.

심화문제 10.4.3 해설 출처 오류를 잡는 검증 설계

한 설계는 H=[[1, 0], [0, 1]], Z=[[0, 1], [1, 0]], $W_Q = W_K = I$, $W_V = \mathrm{diag}(2, 3)$ 로 놓는 것이다. H/Z 가 다르므로 정상 K 는 Z 이고 잘못된 K 는 H 가 되어 직접 대조할 수 있다. V 도 정상은 [[0, 3], [2, 0]], 오류는 [[2, 0], [0, 3]] 로 구별된다. H=Z 인 기준 하나만 썼다면 두 오류가 숨겨진다.

K 경로의 분리 실험에는 입력 폭 3 을 쓰고 W_K = [[1, 0], [0, 1], [0, 0]], W_V = [[0], [0], [1]] 로 둘 수 있다. Z 의 첫 좌표만 바꾸면 K 가 변하고 V 는 유지된다. 같은 Q 에서 적어도 한 행의 상대 점수가 달라지고 제공 값들이 서로 다르도록 Z 의 셋째 좌표를 정한다. 그때 A/O 의 예상 변화를 계산해, K 를 H 에서 잘못 만든 구현이 Z 변경을 놓치는지 확인한다.

V 경로는 반대로 Z 의 셋째 좌표만 바꾸면 K/S/A 가 유지되고 V/O 만 변한다. Q/K/B 를 고정한 변화량은 해당 열의 계수 × 델타다. V 를 H 에서 잘못 만든 구현은 이 양성 대조에 반응하지 않는다. Q 는 두 실험 모두 고정이어야 한다. shape·정상 배열과 중간값 대조·변경에 대한 반응을 함께 확인하며, 모든 입력을 0 으로 만드는 함수 같은 결함을 출력 불변 시험만으로 통과시키지 않는다.

위 수치와 다른 설계도 (1) H/Z 를 독립 변경하고, (2) K/V 경로를 분리하며, (3) 비퇴화한 기대 변화를 명시하고, (4) 실제 입력 피연산자를 확인하고, (5) 유한한 테스트의 범위를 설명하면 허용한다. 출처 오류를 탐지한 기술 시험은 독자의 학습효과 검증과 별개다. 복습: 연습문제 10.4.9, 연습문제 10.4.18.

이해 확인 해설

같은 입력이라는 말 첫 위치의 Q/K/V 는 각각 $[1,0]$, $[\sqrt{2}\ln 2, 0]$, $[2,0]$ 로 다르다. Self 를 결정하는 것은 세 투영의 출처 X 다. 반대로 수치가 같아도 서로 다른 집합에서 투영해 얻었을 수 있어 Self 라고 확정할 수 없다. 질문, 예제 10.4.1와 연습문제 10.4.11을 참고하자.

Mask 가 있으면 그렇지 않다. H 가 질의를, 별도 Z 가 키/값을 제공하는 구조는 Cross 그대로다. Mask 는 그 H–Z 쌍 중 어느 열을 읽을지 제한한다. 출처 배정과 접근 정책은 독립적으로 확인한다. 질문, 예제 10.4.4을 복습하자.

원문은 바뀌지 않는가? 그렇게 확대할 수 없다. 이번 순방향 연산의 집계는 H 의 위치별로 반환되지만 Z 는 다른 모듈에서 갱신될 수 있다. 학습에서 Z 를 생성한 매개변수로 gradient 가 전달되는 일도 별개다. '이번 식에 Z 의 직접 반환 대입이 없다' 는 국소적인 관찰을 유지하자. 질문, 예제 10.4.6을 참고하자.

길이가 같으면 결정할 수 없다. Q/K/V 가 투영되기 전 같은 표현 집합이었는지 별도 집합이었는지 알아야 한다. 길이·폭·수치의 일치는 가능한 우연 또는 설계 결과이며 출처의 증명이 아니다. 질문, 예제 10.4.7과 연습문제 10.4.11을 복습하자.

실행 성공과 인터페이스 실행 성공은 내적 축과 유한 수치 등의 계약을 확인할 뿐이다. H 가 Z 를 읽으려면 K/V 를 Z 에서 만들어야 한다. K 를 H 에서 만들었으면 의도한 제공자를 비교하지 않은 것이다. Z 만 바꾸는 중간값 시험과 코드의 실제 피연산자 확인이 필요하다. 질문, 연습문제 10.4.9로 돌아가자.

10.5 여러 Head 를 독립적으로 계산하고 결합하기 — 해설

어디서 답이 달라졌는지 단계별로 찾자. 입력 출처와 투영을 확인한 뒤, 각 Head 의 비교 폭으로 scaling 하고 허용 열만 정규화한다. 그다음 V 의 좌표별 가중합, 동일 요청 행의 Concat, 대응하는 W_O 의 행 순서를 검사한다. 수치만 맞아도 축과 출처 설명이 빠졌다면 본문의 도해에 자기 계산을 다시 표시해 보자. 설계 문제는 주어진 요구·shape·접근 조건을 만족하는 대안을 허용한다.

유제 해설

유제 10.5.1 해설 다른 폭의 두 Head

Head1 은 $W_Q : 7\times2, W_K : 4\times2, W_V : 4\times3, Q : 3\times2, K : 5\times2, V : 5\times3, S/A : 3\times5, O : 3\times3$ 이다. Head2 는 $W_Q : 7\times1, W_K : 4\times1, W_V : 4\times2, Q : 3\times1, K : 5\times1, V : 5\times2, S/A : 3\times5, O : 3\times2$ 다. 두 D 의 shape 도 S 와 같다.

두 O 의 공통 축은 요청 행 3 이다. 마지막 축에 이어 붙이면 C 는 3×5, 최종 폭 6 을 위한 W_O 는 5×6, Y 는 3×6 이다. 입력 폭 7 이나 제공 수 5 를 Head 수 2 로 나눈 숫자는 계산에 필요 없다. 복습: 정의 10.5.1, 정의 10.5.2.

유제 10.5.2 해설 제공 위치의 기여로 검산하기

요청 0 의 세 기여는 $(2/5)2 = 4/5$, $(1/5)1 = 1/5$, $(2/5)1 = 2/5$ 다. 합은 7/5 다. 요청 1 의 기여는 $2/3, 1/3, 1/3$ 으로 합 4/3 이다. 같은 V 라도 요청에 따라 Q 와 K 로 만든 A 행이 달라지므로 집계 결과가 달라진다.

요청 1 의 점수 0 을 차단이라고 생각하면 모든 기여를 없애는 오류가 생긴다. 점수 0 의 지수는 1 이며 세 위치가 모두 허용되어 균등 분포가 된다. 복습: 예제 10.5.3.

유제 10.5.3 해설 음수 점수도 허용된 위치다

요청 1 의 위치 2 점수는 $-\ln 3$, 지수는 1/3, 전체 지수 합은 $1+3+1/3 = 13/3$ 이다. 따라서 비율은 1/13, 값이-4 이므로 기여는-4/13 이다. 이 위치를 닫으면 허용 지수는 1 과 3, 분모 4 이며 A 행은 $[1/4, 3/4, 0]$ 다. 새 출력은 $(-1)/4 + 9/4 = 2$ 다.

차단 전 20/13 에서 차단 후 2 로 달라졌다. 차단은 단순히-4/13 을 빼는 것만이 아니라 나머지 허용 계수를 다시 정규화한다. 복습: 예제 10.5.4,10.3 의 허용 분모.

유제 10.5.4 해설 순서와 폭을 유지하는 출력 변환

C 는 3×2, 새 W_O 는 2×3 이므로 Y 는 3×3 이다. 첫 행 $[7/5, -2/3]$ 에서

$$\tilde{y}_0 = [2(7/5) - 2/3,\ 2/3,\ 7/5] = [32/15, 2/3, 7/5].$$

두 Head 가 제공한 값 좌표의 총수 2 와 최종 좌표 수 3 은 다르다. W_O 가 두 입력 좌표를 세 선형 조합으로 만들었다. 출력 폭이 커졌다고 독립 정보의 수까지 늘었다고 결론 내리면 안 된다. 예를 들어 셋째 좌표는 첫 Head 값의 복사이며 첫째는 그 두 배에서 둘째 최종 좌표를 뺀 것이다. 복습: 정의 10.5.3.

유제 10.5.5 해설 Head 별 변환의 기여

첫 Head 는 $[-1,2]R_1 = [-1,4]$, 둘째는 $[4]R_2 = [-4,4]$ 이므로 Y 는 $[-5,8]$ 이다. Concat $[-1,2,4]$ 에 행이 $[1,0],[0,2],[-1,1]$ 인 W_O 를 곱해도 $[-1-4,4+4] = [-5,8]$ 이다.

둘째 Head 출력을 0 으로 만들면 새 Y 는 $[-1,4]$ 이고 변화는 $[4,-4]$ 다. 제거한 원출력은 스칼라 4 지만 최종 변화는 출력 좌표의 벡터다. 원출력과 출력 변환 후 기여를 혼동했다면 정리 10.5.1을 복습하자.

유제 10.5.6 해설 값 폭이 다른 순서 바꾸기

원래 C 는 $[1,2,3]$, 출력은 $10+200+3000 = 3210$ 이다. Head2 를 먼저 붙이면 $C' = [3,1,2]$ 다. 기존 W_O 를 그대로 곱하면 $30+100+2000 = 2130$ 으로 틀린다.

대응 좌표 순서는 0 기반 $[2,0,1]$ 이므로 $W'_O = [1000,10,100]^{\mathsf{T}}$ 다. 새 결과는 $3000+10+200 = 3210$ 으로 보존된다. Head 번호 순열은 두 원소지만 실제 입력 좌표 순열은 세 원소다. Head1 의 두 좌표를 함께 옮겨야 한다. 복습: 정리 10.5.2.

유제 10.5.7 해설 한 Head 에서만 닫힌 패딩

요청 1 에서 Head1 은 원래 점수가 모두 0 이므로 열 2 를 닫으면 비율 $[1/2,1/2,0]$, 출력 $(2+1)/2 = 3/2$ 다. Head2 를 열어 두면 출력 20/13 이 그대로라서

$$y_1 = [3/2,20/13]W_O = [-1/26,59/13].$$

두 Head 모두 닫으면 Head2 의 비율은 $[1/4,3/4,0]$, 출력 2 이고 $y_1 = [3/2,2]W_O = [-1/2,5]$ 다. 앞의 경우 열 2 의 V2 를 δ 만큼 바꾸면 최종 변화는 $(\delta/13)[-1,1]$ 이므로 패딩의 영향이 남는다. 두 Head 모두 닫고 요청과 다른 허용 자료가 고정되어야 이 직접 경로가 막힌다. 복습: 예제 10.5.8.

독립 연습 해설

연습문제 10.5.1 해설 두 Head 의 새로운 전체 계산

X 는 2×1, 여섯 W 는 1×1 이다. $L=\ln 2$ 로 놓으면

$$Q_1=[1,0]^{\top},\quad K_1=[L,0]^{\top},\quad V_1=[3,0]^{\top},$$
$$Q_2=[-1,0]^{\top},\quad K_2=[L,0]^{\top},\quad V_2=[6,0]^{\top}.$$

비교 폭 1 이라 각 $D_r=S_r$ 다.

$$S_1=\begin{bmatrix}L & 0\\ 0 & 0\end{bmatrix},\quad A_1=\begin{bmatrix}2/3 & 1/3\\ 1/2 & 1/2\end{bmatrix},\quad O_1=[2,3/2]^{\top},$$
$$S_2=\begin{bmatrix}-L & 0\\ 0 & 0\end{bmatrix},\quad A_2=\begin{bmatrix}1/3 & 2/3\\ 1/2 & 1/2\end{bmatrix},\quad O_2=[2,3]^{\top}.$$

첫 Head 의 첫 행 지수는 $[2,1]$, 둘째 Head 는 $[1/2,1]$ 이다. 첫 요청의 두 O 가 우연히 2 로 같아도 A 와 V 는 다르다. 모든 Q/K/V/O 는 2×1, D/S/A 는 2×2 다. 마지막으로

$$C=\begin{bmatrix}2 & 2\\ 3/2 & 3\end{bmatrix},\quad Y=C\begin{bmatrix}2 & -1\\ 1 & 1\end{bmatrix}=\begin{bmatrix}6 & 0\\ 6 & 3/2\end{bmatrix}.$$

C/W_O/Y 는 모두 2×2 다. Y 의 둘째 행 첫 좌표는 $2(3/2)+3=6$ 이다. 첫 요청의 같은 Head 출력만 보고 독립 계산이 없다고 판단하지 말자. 복습: 정의 10.5.1, 예제 10.5.5.

연습문제 10.5.2 해설 세 Head 의 서로 다른 폭

요청 수 2, 제공 수 4 는 모든 Head 에서 같다. 투영과 출력은 다음과 같다.

Head	W_Q, W_K, W_V	Q/K/V	D/S/A	O
1	$5\times 1, 7\times 1, 7\times 2$	$2\times 1, 4\times 1, 4\times 2$	2×4	2×2
2	$5\times 3, 7\times 3, 7\times 1$	$2\times 3, 4\times 3, 4\times 1$	2×4	2×1
3	$5\times 2, 7\times 2, 7\times 4$	$2\times 2, 4\times 2, 4\times 4$	2×4	2×4

값 폭의 합은 $2+1+4=7$ 이다. 따라서 C 는 2×7, W_O 는 7×5, Y 는 2×5 다. 일반식에서 입력 폭을 Head 수로 나누지 않았으므로 가능하다. 특정 균등 분할 구현만 사용한다면 그 구현의 제약은 따로 확인해야 한다. 복습: 예제 10.5.1.

연습문제 10.5.3 해설 Scaling 폭 바꾸기

새 Q/K 는 3×2, D 는 원래 D 의 $\sqrt{2}$ 배다. 비교 폭 2 이므로 $S'_r = D'_r/\sqrt{2} = D_r = S_r$ 다. V/B 가 같으므로 A/O/C/Y 도 원래와 같다. 이 구성은 비교 폭 변경 시 scaling 을 실제 계산에 넣어야 한다는 예다.

K 를 보정하지 않으면 $S'_r = S_r/\sqrt{2}$ 다. Head1 요청 0 의 지수는 $[2^{1/\sqrt{2}}, 1, 2^{1/\sqrt{2}}]$ 이므로 $t = 2^{1/\sqrt{2}}$ 라 두면 A 행은 $[t, 1, t]/(2t+1)$ 이다. 원래 $[2, 1, 2]/5$ 와 같지 않다. 복습: 식 (10.5.1)와 10.2 scaling.

연습문제 10.5.4 해설 실제 Concat 과 출력 변환

각 요청의 좌표들을 옆으로 놓으면

$$C = \begin{bmatrix} 1 & 2 & 5 \\ 3 & 4 & 6 \end{bmatrix}, \quad Y = \begin{bmatrix} 1+10 & 2-5 \\ 3+12 & 4-6 \end{bmatrix} = \begin{bmatrix} 11 & -3 \\ 15 & -2 \end{bmatrix}.$$

C 는 2×3, W_O 는 3×2, Y 는 2×2 다. 최종 첫 좌표는 Head1 첫 좌표와 Head2 의 두 배, 둘째는 Head1 둘째 좌표에서 Head2 를 뺀 것이다. 원출력의 폭은 2 와 1 이어서 수학적 덧셈은 정의되지 않는다. NumPy broadcasting 이 실행된다는 사실은 원래 연산의 동등성 근거가 아니다. 복습: 정의 10.5.2, 정리 10.5.1.

연습문제 10.5.5 해설 같은 평균, 다른 최종 출력

두 평균은 모두 1/2 이다. 원래 출력은 $[1,0]W_O = [1,2]$, $[0,1]W_O = [-1,1]$ 로 다르다. 평균만 입력받는 결정적 함수 f 는 같은 입력 1/2 에 같은 결과를 내야 한다. 서로 다른 두 Y 를 동시에 내야 하므로 모순이다.

이는 평균이 Head 구별을 잃을 수 있다는 반례다. 모든 평균 연산이 무의미하다는 주장이 아니라 일반 W_O 와 같지 않다는 뜻이다. $R_r = T/h$ 인 특별한 구성은 심화 1 에서 다룬다. 복습: 정리 10.5.1 뒤 반례.

연습문제 10.5.6 해설 Head 의 수와 출력의 폭

각 Head 의 Q/K 는 9×3, V/O 는 9×2, A 는 9×9 다. W_Q/W_K 는 10×3, W_V 는 10×2 다. C 는 9×8, W_O 는 8×10, Y 는 9×10 이다.

각 Head 의 투영 전 입력은 같은 9×10 이다. 입력을 10/4 좌표로 자른 것이 아니다. 균등 분할만 지원하는 API 라면 입력/내부 투영 폭의 정의, `embed_dim` 과 Head 수의 나눗셈 조건, 별도 K/V 입력 폭 지원, 출력 폭 제약을 문서와 실제 shape 로 확인해야 한다. 이 문제의 일반 연산이 가능하다는 것과 특정 API 가 그대로 구현해 준다는 것은 별개다. 복습: 예제 10.5.1.

연습문제 10.5.7 해설 Head 만 교환한 결과

각 행의 원래 두 수를 a,b 라 쓰면 새 Concat 은 $[b, a]$ 다. 고정 W_O 를 곱하면 $[b-a, 2b+a]$ 가 되므로

$$Y^{\text{wrong}} = \begin{bmatrix} -31/15 & 1/15 \\ 8/39 & 172/39 \\ -271/65 & -269/65 \end{bmatrix}.$$

예를 들어 요청 2 의 둘째 좌표는 $2(-36/13) + 7/5 = (-360 + 91)/65 = -269/65$ 다. W_O 의 두 행을 함께 바꾸면 모든 행에서 $[a-b, 2a+b]$ 로 원래 Y 가 된다. Concat 의 **열**을 옮겼고 요청 행은 그대로다. 최종 Y 의 좌표가 단순 교환된 결과도 아니다. 복습: 예제 10.5.7, 정리 10.5.2.

연습문제 10.5.8 해설 블록 폭이 다른 순열

원래 C 는 $[1, 2, 3, 4, 5]$, 출력은 $1 + 20 + 300 + 4000 + 50000 = 54321$ 이다. 새 C 는 $[4, 5, 1, 2, 3]$ 이고 대응 좌표 순서는 $[3, 4, 0, 1, 2]$ 다. 따라서

$$W'_O = [1000, 10000, 1, 10, 100]^{\mathsf{T}}.$$

곱은 $4000 + 50000 + 1 + 20 + 300 = 54321$ 이다. Head3 의 두 좌표, Head1 의 두 좌표, Head2 의 한 좌표라는 구간을 이동한다. W_O 를 새 Head 번호 세 개로만 인덱싱하면 다섯 입력 좌표 중 두 개를 버린다. 복습: 정리 10.5.2.

연습문제 10.5.9 해설 순서만 바꾸어도 항상 보존되는 조건

원래 출력은 $aR_1 + bR_2$, 교환 후는 $bR_1 + aR_2$ 다. 그 차는 $(b-a)(R_1 - R_2)$ 이므로 모든 a,b 에서 같으려면 $R_1 = R_2$ 가 필요충분하다. 필요성은 $a = 0, b = 1$ 을 넣어 얻고, 충분성은 두 행이 같으면 합이 $(a+b)R_1$ 임에서 나온다.

a=b 인 한 입력에서는 어떤 두 R 이라도 차가 0 이다. 이 한 사례로 모든 입력의 보존을 결론 내릴 수 없다. ‘Head 순서는 임의’ 라는 말은 매개변수와 좌표 대응도 함께 바꿀 때의 재표현을 뜻한다. 복습: 정리 10.5.2의 고정 W_O 조건.

연습문제 10.5.10 해설 독립 Head 인데 같은 출력

각 Head 에서 유효 행의 계수 합은 1 이다. 따라서 $o_{r,i} = \sum_j A_{r,ij} c = c \sum_j A_{r,ij} = c$ 다. 서로 다른 A 라도 출력은 c 로 같다. 예를 들어 두 위치에서 $A_1 = [1/4, 3/4]$, $A_2 = [3/4, 1/4]$, 값은 모두 5 이면 둘 다 5 다.

이 성질은 Q/K 투영의 일치나 매개변수 공유를 요구하지 않는다. 서로 다른 값 행렬도 우연히 같은 가중합을 만들 수 있어 상수 V 는 충분조건일 뿐 필요조건은 아니다. 비활성 질의는 계수 합 0·출력 0 이라는 별도 계약이므로 c 가 아닌 0 을 반환한다. 복습: 정의 10.5.1, 구현 부록의 비활성 계약.

연습문제 10.5.11 해설 하나로 묶은 투영과 공유 투영

첫 블록의 열 u 에서 $(H[W_1|W_2])_{iu} = \sum_t H_{it}(W_1)_{tu} = (HW_1)_{iu}$ 다. 둘째 블록도 열의 오프셋을 빼면 같은 식으로 HW_2 가 된다. 따라서 두 배열은 좌표별로 같다.

두 W 의 원소는 별개 매개변수다. 실행을 한 번의 큰 곱으로 묶어도 공유가 아니다. 같은 HW 를 복사하면 두 Q 가 같아지지만 독립 투영의 일반 경우를 구현하지 않는다. 다만 다른 K/V/Mask 때문에 Q 가 같아도 A/O 는 다를 수 있다. 투영 오류의 진단은 중간값과 매개변수 배정을 함께 봐야 한다. 복습: 구현의 축 설명.

연습문제 10.5.12 해설 Multi-head Cross 인터페이스

두 질의 투영은 5×2, 두 키 투영은 4×2, 값 투영은 각각 $4\times1, 4\times3$ 이다. Q 는 각각 3×2, K 는 6×2, V 는 $6\times1, 6\times3$ 이다. 각 A 는 3×6, O 는 $3\times1, 3\times3$, C 는 3×4, W_O 는 4×5, Y 는 3×5 다.

Q 는 H, K/V 는 Z 에서 온다. H 의 세 질문 위치가 문서의 여섯 위치를 읽고 결과도 H 쪽으로 돌아간다. 이름은 Multi-head Cross-attention 이다. 출처와 Head 수는 동시에 지정하는 서로 다른 선택이다. 문서가 처음부터 모두 제공되었다면 실제 여섯 열을 모두 허용할 수 있고, 도착 제약이 있으면 별도 B 를 구성한다. 복습: 예제 10.5.8.

연습문제 10.5.13 해설 두 Head 의 Causal 계산

요청 0 에서는 각 A 행이 $[1,0,0]$ 이므로 O 는 2 와-1, Y 는 $[2,-1]W_O=[3,3]$ 이다. 요청 1 에서는 Head1 의 A 행이 $[1/2,1/2,0]$ 로 O=3/2, Head2 는 $[1/4,3/4,0]$ 로 O=2 다. Y 는 $[3/2-2,3+2]=[-1/2,5]$ 다.

Head2 만 모두 열면 요청 0 의 A2 는 $[1/3,1/3,1/3]$ 이고 O2=-2/3 이다. Y 는 $[2,-2/3]W_O=[8/3,10/3]$ 이다. 요청 0 이 미래 위치 1·2 의 V2 를 읽는 경로가 열렸다. 미래 위치의 K2 도 분모와 비율을 바꿀 수 있다. 다른 Head 가 올바르게 닫혀 있어도 이 경로를 제거하지 못한다. 복습: 예제 10.5.8.

연습문제 10.5.14 해설 Head 별 허용 집합

Head1 은 지수 1,2 만 남아 $A_1=[1/3,2/3,0]$, $O_1=(1+10)/3=11/3$ 이다. Head2 는 지수 1,4 만 남아 $A_2=[1/5,0,4/5]$, $O_2=(1+36)/5=37/5$ 다. C 는 $[11/3,37/5]$, Y 는 $11/3-37/5=-56/15$ 다.

값 2 를 9 에서 10 으로 바꾸면 Head1 은 불변, Head2 는 4/5 증가해 41/5 다. 최종 Y 는 4/5 감소하여 $-68/15$ 가 된다. Q/K/B 를 고정한 투영 후 값 변경이라는 조건이 필요하다. 실제 입력 Z 의 변경은 K 도 바꿀 수 있으므로 비율까지 다시 계산해야 한다. 복습:10.4 고정 비율 변화와 출처와 접근 경로.

연습문제 10.5.15 해설 패딩을 모든 Head 에서 닫기

두 B 의 모든 행은 $[True, False]$ 다. 유효 요청에서 각 A 는 $[[1,0],[1,0]]$ 이고 Head1 의 O 는 $[3,3]^\top$, Head2 는 $[6,6]^\top$ 다. 각 C 행은 $[3,6]$, Y 행은 $[12,3]$ 이다. 요청 1 의 Q 가 0 이어도 유일한 허용 키의 계수는 1 이다.

active 를 $[True, False]$ 로 바꾸면 두 A/O 의 둘째 행과 최종 Y 의 둘째 행은 0 이다. 비활성 질의 0 은 확률 분포가 아니다. 유효 행까지 모든 키를 닫으면 Softmax 분모가 정의되지 않으므로 이 구현은 ValueError 로 거부한다. 의미 있는 대체 자료나 별도 반환 계약 없이 0 을 정상 Attention 이라고 부르지 않는다. 복습: 정의 10.5.1와 10.3 빈 허용 집합.

연습문제 10.5.16 해설 제공자 변경의 불변 조건

H 와 투영·B 를 고정하고 Z 의 t 만 바꾸면 해당 $k_{r,t}, v_{r,t}$ 만 바뀐다. 요청 i 의 허용 집합에 t 가 없는 모든 Head 에서는 점수의 허용 항·분모·집계가 모두 그대로다. 따라서 각 $o_{r,i}$ 와 $y_i=\sum_r o_{r,i}R_r$ 가 불변이다. 유한 입력과 고정 허용 집합, 다른 경로가 없다는 조건을 쓴다.

한 Head 라도 t 를 열었다고 반드시 Y 가 바뀌지는 않는다. 반례로 해당 Head 의 $R_r=0$ 이고 다른 Head 는 t 를 닫으면 그 변화가 Y 에 들어오지 않는다. 반대로 두 제공 위치·한 요청에서 Q=0 을 유지하고 값이 $[0,v_t]$, 그 Head 의 $R_r=[1]$ 이면 t 를 허용할 때 Y 는 $v_t/2$ 다. v_t 가 0 에서 2 로 바뀌면 Y 는 0 에서 1

로 변한다. Q/K 경로와 V 경로가 분리되는 입력/투영을 택하면 실제 Z 변경으로도 구성할 수 있다. 복습: 출처와 접근 경로와 10.4 입력 변화의 직접/간접 경로.

연습문제 10.5.17 해설 잘못 결합한 코드 수정

올바른 코드는 다음과 같다.

실행 결과 | Text

```
joined = np.concatenate(outputs, axis=1)  # (m, 2*v)
result = joined @ wo                      # wo: (2*v, d_out)
```

`axis=0` 은 $(2m, v)$ 로 요청 행 수를 늘린다. 같은 요청에서 두 Head 의 좌표를 결합한 배열이 아니다. 평균은 (m, v) 라 실행은 가능하지만 원래 Concat 의 두 좌표 묶음을 구별하지 못한다. 일반적인 R_1, R_2 대신 같은 $T/2$ 를 쓰는 특수 조건에서만 평균 뒤의 T 로 대체할 수 있다. 복습: 정리 10.5.1, 구현의 축 설명.

연습문제 10.5.18 해설 실행되지만 순서가 틀린 reshape

stack 은 $(2, 2, 1)$ 이며 축 순서는 Head–요청–값이다. 메모리 순서의 숫자는 $[1, 2, 3, 4]$ 라 단순 `reshape(2,2)` 는 $[[1, 2], [3, 4]]$ 가 된다. 올바른 C 는 요청 0 에 $[1, 3]$, 요청 1 에 $[2, 4]$ 를 놓은 $[[1, 3], [2, 4]]$ 다.

`stacked.transpose(1,0,2).reshape(2,2)` 로 요청–Head–값 순서로 옮긴 뒤 합치거나, 바로 `np.concatenate([o1,o2],axis=1)` 을 사용한다. 두 배열의 shape 가 모두 2×2 여도 좌표 의미가 다르다. 복습: 정의 10.5.2와 코드의 축 설명.

연습문제 10.5.19 해설 Q/K 와 W_O 의 오류 진단

Head1 의 비교 폭이 2 와 3 으로 달라 내적이 정의되지 않는다. K 를 5×2 로 고치면 A 는 3×5, O1 은 3×4 다. O2 는 3×2 이므로 C 는 3×6 이다. 따라서 폭 7 의 출력을 위한 W_O 는 6×7 이어야 하며 Y 는 3×7 이다. 원래 4×7 는 첫 Head 폭만 받은 오류다.

이 로그는 요청 3·제공 5 의 구조를 보이지만 실제 Q/K 투영 전 배열과 선택한 요청의 범위가 없다. 전체 Self 에서 요청 일부만 뽑은 기록일 수도 있어, 출처를 확정하려면 실제 입력 배정과 부분 선택 여부가 필요하다. 복습: 정의 10.5.1,10.4 의 출처와 수치 구별.

연습문제 10.5.20 해설 Learning Source 로 오류를 드러내기

`demo_heads.py` 는 Q/K/V/S/A/O/C/Y 를 출력한다. 대표 Q1/2 의 첫 행은 1 과 0, V1/2 는 $[2, 1, 1]^\top$ 와 $[-1, 3, -4]^\top$ 다. A1/2 와 최종 Y 는 본문 분수값을 별도 기준으로 비교한다. Head2 에 Head1 투영을 복사하면 O2 도 O1 이 되어 C 의 두 열이 같아지고 $Y = [0, 3O_1]$ 이다. shape 는 원래와 같다.

Head 만 교환하면 독립 7 의 잘못된 Y 가 나오고, 함께 옮기면 원래 Y 다. Mask 변형은 요청 0 의 Causal 정답 $[3, 3]$ 을 기준으로 두 Head 의 차단 셀 0 도 따로 검사한다. 미래 행 2 만 바꾸는 실험에서는 두 Head 모두 Causal 이면 요청 0 이 불변, 둘째 Head 를 열면 바뀌는 양성 대조를 확인한다. 단순 최종 shape 는 이 세 의미 오류를 모두 놓친다. `verify_heads.py` 의 독립 Decimal 경로·Fraction 정답·순열 시험은 서로 다른 실패를 검사한다. 복습: 구현의 축 설명.

연습문제 10.5.21 해설 새 인터페이스 설계와 검증

Q 는 R, K/V 는 M 에서 만든다. Head1 의 W_Q, W_K, W_V 는 $7\times3, 4\times3, 4\times2$, Head2 는 $7\times1, 4\times1, 4\times3$ 이다. Q1/2 는 $2\times3, 2\times1$, K1/2 는 $5\times3, 5\times1$, V1/2 는 $5\times2, 5\times3$ 이다. 두 B/A 는 2×5 다. 양쪽 Head 에 동일한 최소 정책을 적용하면

$$B_1 = B_2 = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 1 & 1 & 0 \end{bmatrix}.$$

시각 2 에서는 0/1 자료만, 시각 4 에서는 네 실제 자료 모두 도착했다. 패딩 4 는 시각과 무관하게 닫는다. O 는 $2\times2, 2\times3$, C 는 2×5, W_O 는 5×7, Y 는 2×7 이며 R 의 두 위치에 반환한다.

무작위 유한 가중치로 실행한 뒤 각 A 의 차단 셀이 정확히 0 이고 유효 행합이 1 인지, 모든 허용 집합이 비어 있지 않은지 검사한다. M 의 패딩 행을 바꿔도 Y 가 같아야 한다. 시각 3/4 자료만 바꾸면 첫 요청은 불변이며 둘째는 변할 수 있다. Concat 의 구간을 각 O 와 exact 대조하고, $CW_O = O_1R_1 + O_2R_2$ 및 Head·Mask·출력 행 구간 동시 순열 보존도 검사한다. 특정 무작위 입력에서 허용 자료 변경의 출력이 같을 수 있으므로 중간 K/V 의 변화와 양성 대조도 확인한다. 복습: 예제 10.5.8, 정리 10.5.2.

연습문제 10.5.22 해설 여러 Head 만으로 순서가 생기는가?

모든 Head 에서 $Q'_r = PQ_r, K'_r = PK_r, V'_r = PV_r$ 다. 따라서 $S'_r = PS_rP^\top$ 이다. 전부 허용하거나 B 도 $PB_rP^\top$ 로 옮기면 행/열 순열이 각 정규화 분모의 항을 보존하여 $A'_r = PA_rP^\top$ 다. $O'_r = PA_rP^\top PV_r = PO_r$, 요청별 Concat 이므로 $C' = PC$, 끝으로 $Y' = PCW_O = PY$ 다.

Head 수를 늘려도 각 단계가 같은 대응을 따르므로 이 성질은 사라지지 않는다. 고정 Causal Mask 를 그대로 쓰면 일반 P 에 대해 B 가 대응하지 않아 증명의 조건이 깨진다. Mask 의 허용 방향과 별도 위치 신호는 다른 계산 요소다. 다음 절의 질문은 내용뿐인 비교에 위치·상대 거리 정보를 어디서 어떻게 넣는가다. 복습:10.4 순열 심화와 출처와 접근 경로.

심화 해설

심화문제 10.5.1 해설 평균으로 대체할 수 있는 정확한 조건

충분성은 모든 $R_r = T/h$ 를 대입해 $\sum_r O_r R_r = (\sum_r O_r/h)T$ 로 정리하면 된다. 필요성을 보이려면 임의의 Head s 하나만 남기고 다른 O 를 0 으로 둔다. 그러면 모든 O_s 에 대해 $O_s(R_s - T/h) = 0$ 이다. 한 행에 표준기저 벡터들을 차례로 넣으면 $R_s - T/h$ 의 모든 행이 0 이어야 한다. s 가 임의이므로 모든 r 에서 조건이 필요하다.

실제 모델이 가능한 O 들을 예를 들어 $O_1 = O_2$ 로 제한하면 필요성 증명의 '하나만 임의로 남기기' 를 할 수 없다. 이 경우 서로 다른 R 도 같은 제한 집합에서 동등할 수 있다. 본문의 일반 연산 동등성과 특정 모델·입력 집합의 동등성을 구별해야 한다. 복습: 정리 10.5.1.

심화문제 10.5.2 해설 서로 다른 폭의 Head 순열 구현

값 폭 $[2,1,3]$ 의 좌표 구간은 $[0,1]$, $[2]$, $[3,4,5]$ 다. 새 Head 순서 $[2,0,1]$ 에 대응하는 좌표 순서는 $[3,4,5,0,1,2]$ 다. `wo[order]` 는 세 행만 뽑으므로 총 여섯 입력 좌표와 맞지 않는다.

solution_heads.py | learning-source/solution_heads.py | Python | L1-L13 (13 줄)
source revision: heads-source-v0.1

```python
"""Head 별 값 폭이 달라도 대응 좌표를 함께 옮기는 해설 코드."""
import numpy as np


def reorder(heads, masks, wo, order):
    if sorted(order) != list(range(len(heads))):
        raise ValueError("order 는 모든 Head 를 한 번씩 포함해야 한다")
    widths = [np.asarray(t[2]).shape[1] for t in heads]
    offsets = np.cumsum([0] + widths)
    coords = np.concatenate([np.arange(offsets[r], offsets[r+1])
                             for r in order])
    return ([heads[r] for r in order], [masks[r] for r in order],
            wo[coords, :])
```

예를 들어 원래 `multi_head(h,z,heads,wo,masks)` 와 이 함수로 받은 새 heads/masks/wo 의 최종 Y 를 `assert_allclose` 로 비교한다. 실수 연산은 합 순서가 바뀌어 마지막 자리 오차가 날 수 있으므로 적절한 허용오차를 쓴다. 투영·Mask 묶음을 같이 옮겨야 기존 O 자체가 재배열되고, 그 뒤의 입력 좌표 행들도 대응해야 한다. `verify_heads.py` 는 서로 다른 값 폭을 포함한 생성 사례에 이 검사를 실행한다. 복습: 정리 10.5.2.

심화문제 10.5.3 해설 출력 변환의 보존 한계

$v = [-1,-1,1]$ 이면 $vW_O = [-1+1,-1+1] = [0,0]$ 이다. 따라서 $C_1 = [0,0,0]$, $C_2 = [-1,-1,1]$ 은 다르지만 Y 는 모두 $[0,0]$ 이다. 또는 임의의 C 에 v 를 더해도 Y 가 같다. 행 벡터의 오른쪽 곱 기준으로 v 는 이 선형사상의 영공간에 속한다.

Concat 은 Head 들의 좌표를 순서대로 그대로 담지만 W_O 는 그중 구분을 잃게 할 수 있다. 여기서는 입력 폭 3 에서 출력 폭 2 로 가는 선형사상이 모든 실수 입력에 대해 일대일일 수 없다. D 가 출력 폭보다 작거나 같아도 행 rank 가 부족하면 복원이 안 된다. 일대일인 경우 대수적으로 좌표를 복원할 가능성과 학습된 좌표의 언어적 의미를 해석하는 일은 별개다. 복습: 정의 10.5.2, 정의 10.5.3와 선형대수의 영공간·rank.

짧은 이해 확인 해설

같은 입력, 다른 축 요청 수는 11 이다. Head 는 3 벌이며 각각 X 의 전체 폭 6 에서 투영할 수 있다. 비교/값 폭을 2 로 택할 수는 있지만 원래 입력의 두 좌표만 읽는다는 조건은 아니다. W 의 영이 아닌 원소가 모든 입력 좌표에 걸쳐 있으면 각각을 사용할 수 있다. 질문으로.

계산과 언어적 기능 교육용 투영을 사람이 정했고 언어 자료로 훈련하거나 기능을 평가하지 않았다. 서로 다른 A 라는 사실은 서로 다른 읽기 비율의 증거이며 문법 역할의 증거는 아니다. V 가 상수이거나 서로 다른 합이 우연히 같으면 O 가 같을 수도 있다. 질문으로.

Concat 과 최종 변환 Concat 은 $[7/5, -2/3]$ 로 두 입력 좌표를 유지한다. 합은 스칼라 $11/15$ 이며 어느 값이 어느 Head 에서 왔는지 보존하지 않는다. Y 에서 복원 가능한지는 W_O 의 rank 와 가능한 입력 집합에 달려 있다. 대표 W_O 는 determinant 가 3 이라 역행렬이 있지만, 일반 W_O 는 차원 축소나 rank 부족으로 일대일이 아닐 수 있다. 질문으로.

한 입력과 모든 입력 두 값이 같으면 교환이 C 를 바꾸지 않으므로 어느 W_O 에서도 그 입력의 Y 는 같다. 다른 입력에서는 두 값이 달라질 수 있다. 모든 가능한 C 의 보존은 $(P - I)W_O = 0$ 을 요구하며 한 번의 우연한 같음으로 이를 증명하지 못한다. 질문으로.

실행 성공과 좌표 의미 행 방향 Concat 은 6×1 이며 원래 요청 3 개의 각 행에 두 Head 를 담지 않는다. 이 배열에 맞는 W_O 는 마지막 폭 1 만 받아 각 행을 따로 변환할 뿐, 원래 같은 요청의 두 Head 를 결합하지 못한다. 예를 들어 첫 행은 Head1 요청 0 만 포함하고 Head2 요청 0 은 네 번째 행에 있다. 별도의 올바른 재배열 없이 W_O shape 만 바꿔서는 원래 함수가 되지 않는다. 질문으로.

10.6 위치와 순서를 Attention 에 반영하기 — 해설

내용 벡터와 위치 목록을 먼저 분리하자. 가산은 투영 전, 편향은 scaling 뒤, 회전은 Q/K 투영 뒤에 들어간다. 점수 분자의 부호·폭을 확인한 뒤 허용 집합의 지수 합으로 비율을 만들고, 대응하는 V 행을 집계한다. 설계 문제에서는 같은 요구를 만족하는 다른 규약도 허용하지만 규약의 부호·배치·조건을 전체 계산에서 일관되게 유지해야 한다. 각 풀이 끝의 복습 안내로 돌아가 틀린 중간 단계부터 다시 계산하자.

유제 해설

유제 10.6.1 해설 두 종류의 순열 주장

원래 O 는 $[10/3, 18/5]^\top$ 이고 교환 뒤는 $[18/5, 10/3]^\top$ 이다. 두 숫자가 다르므로 $O' = O$ 는 틀리고 $O' = PO$ 가 맞다. 출력이 원래 내용 행을 따라 이동했다.

Causal 에서 요청 0 은 배열 첫 제공 행만 읽는다. 원래 첫 값은 2, 교환 뒤 첫 값은 4 이므로 출력은 2→4 다. 원래 Causal 의 요청 1 은 두 키를 읽어 18/5 이므로 그 출력을 교환한 첫 행과도 다르다. Mask 를 고정하면 순열에 따라 허용 관계가 옮겨지지 않는다. 출력 불변과 등변을 혼동하거나 Causal 을 전부 허용한 증명에 넣는 오류를 피하자. 복습: 정리 10.6.1, 예제 10.6.1.

유제 10.6.2 해설 값 경로의 변화

Q/K 는 첫 두 입력 좌표만 읽는다. e 의 셋째 좌표 변화는 두 투영의 0 행에 곱해져 사라지므로 S/A 도 유지된다. 값 투영은 셋째 좌표를 읽으므로 $V' = [2, 6, 8]^\top$ 다. A 의 키 1 계수만큼 각 출력이 증가한다.

$$O' = \begin{bmatrix} 23/4 + 1/4 \\ 28/5 + 2/5 \\ 13/2 + 1/6 \end{bmatrix} = \begin{bmatrix} 6 \\ 6 \\ 20/3 \end{bmatrix}.$$

요청 2/키 2 의 원래 비교 내용은 둘 다 $[1, 0]$, 위치 성분도 둘 다 $[1, 0]$ 이며 scaled M 은 첫 두 좌표에서 LI_2 다. 네 항은 L, L, L, L 로 합 4L 이다. 위치–위치 항만 보면 네 항 중 하나만 센다. 복습: 식 (10.6.3), 예제 10.6.2.

유제 10.6.3 해설 e 의 내적과 가산 후 점수

폭 2 에서 $e_p = [\sin p, \cos p]^\top$ 다. 두 내적은 모두 $\cos 1$ 이다. 하지만 가산한 내용이 $x = [1, 0]$ 이면 분자는

$$(x + e_p)^\top (x + e_t) = 1 + \sin p + \sin t + \cos(p - t).$$

(0,1) 의 scaled 점수는 $(1+\sin 1+\cos 1)/\sqrt{2} \approx 1.6842$ 이고, (2,3) 은 $(1+\sin 2+\sin 3+\cos 1)/\sqrt{2} \approx 1.8319$ 다. 위치–위치 항은 같지만 내용–위치/위치–내용 항이 달라졌다. ‘상대 변위가 같음’ 만으로 가산 전체의 보존을 추론하지 말자. 복습: 정리 10.6.2, 식 (10.6.3).

유제 10.6.4 해설 부호와 접근 관계

올바른 $\delta = [1, -1]$, 편향 $[\ln 3, \ln 2]$ 다. 원점수 0 에 더하면 지수 3 과 2 이므로 A 는 $[3/5, 2/5]$, O 는 $6/5 + 16/5 = 22/5$ 다. 반대 부호를 표에 그대로 넣으면 A 는 $[2/5, 3/5]$, O 는 $28/5$ 다.

올바른 Causal 은 키 위치 0 만 허용하므로 A 는 $[1, 0]$, O 는 2 다. 편향의 크기가 아니라 접근 관계가 키 2 를 닫는다. 반대 부호를 사용하는 대안 자체는 가능하지만 $\tilde{b}(u) = b(-u)$ 로 표도 바꾸어야 한다. 복습: 정의 10.6.3, 예제 10.6.4.

유제 10.6.5 해설 길이와 상대 방향

회전 전 두 길이는 1, 내적은 0 이다. q 는 그대로이고 k 를 90 도 돌리면 $k' = [-1, 0]^{\mathsf{T}}$ 이므로 내적은-1 이다. 두 길이는 여전히 1 이다. 둘 모두 90 도 돌리면 $q' = [0, 1]^{\mathsf{T}}, k' = [-1, 0]^{\mathsf{T}}$ 이어서 내적 0 이 유지된다.

직교성의 내적 보존은 같은 R 을 양쪽에 적용했을 때다. 서로 다른 R 의 곱은 일반적으로 I 가 아니라 상대각 회전이다. 복습: 정리 10.6.3, 식 (10.6.10).

유제 10.6.6 해설 방향 교차항을 놓치지 않기

$a = \sqrt{2}\ln 2$ 라 두자. 회전 전 q 는 $[1, 0]$, 두 키는 $[0, a]$, $[a, 0]$ 다. scaled 점수 $[0, L]$ 의 지수는 1 과 2, A 는 $[1/3, 2/3]$, O 는 $1 + 6 = 7$ 이다.

첫 키를 90 도 돌리면 $[-a, 0]$, 둘째는 위치 0 이라 그대로다. 회전 후 점수는 $[-L, L]$, 지수 $[1/2, 2]$ 이므로 A 는 $[1/5, 4/5]$, O 는 $(3 + 36)/5 = 39/5$ 다. 상대각을 반대로 하면 첫 키가 $[a, 0]$ 이 되어 점수 $[L, L]$, A 는 $[1/2, 1/2]$, O 는 6 이다. 두 번째 항 $(bc - ad)\sin\phi$ 의 부호가 달라진 결과다. 복습: 식 (10.6.11), 예제 10.6.6.

유제 10.6.7 해설 같은 수학과 다른 저장 순서

Interleaved 의 첫 쌍 $(1, 2)$ 는 90 도에서 $(-2, 1)$, 둘째 $(3, 4)$ 는 0 도에서 그대로여서 결과는 $[-2, 1, 3, 4]$ 다. Split-half 를 같은 원시 배열에 적용하면 쌍 $(1, 3)$ 이 $(-3, 1)$ 로 변하고 $(2, 4)$ 는 유지되어 $[-3, 2, 1, 4]$ 가 된다.

입력을 $[1, 3, 2, 4]$ 로 재배치하면 Split-half 의 첫 쌍은 원래 $(1, 2)$, 둘째는 $(3, 4)$ 다. 결과 $[-2, 3, 1, 4]$ 를 역순열로 돌리면 $[-2, 1, 3, 4]$ 다. 주파수와 투영 좌표도 이 쌍에 맞추어야 동등하다. 같은 원시 배열에 다른 쌍을 적용한 결과를 무조건 동등하다고 판단하지 말자. 복습: 예제 10.6.7, 여러 좌표 쌍은 서로 다른 속도로 회전한다.

유제 10.6.8 해설 위치를 동반한 재배열

순서 2→0→1 의 원래 키 위치는 $[2, 0, 1]$, 값은 $[8, 2, 5]^{\mathsf{T}}$ 이다. 회전 키는 $[[-a, 0], [a, 0], [0, a]]$, 요청 1 의 회전 q 는 $[0, 1]$ 이므로 scaled 점수는 $[0, 0, L]$ 이다. 올바른 Causal 은 [False, True, True] 다. A 는 $[0, 1/3, 2/3]$, O 는 4 다. 원래 비율의 열만 같은 순서로 바뀌었다.

위치까지 새 배열 순서 $[0, 1, 2]$ 로 덮어쓰면 첫 키의 원래 미래 위치 2 를 과거 0 이라고 부르고, 마지막 키의 원래 과거 1 을 미래 2 라고 부른다. 회전 키도 $[[a, 0], [0, a], [-a, 0]]$ 로 잘못 계산한다. Causal 도 잘못 만들면 A 는 $[1/3, 2/3, 0]$ 다. 이 경우 O 는 우연히 4 로 같지만, 금지된 값 8 을 읽고 허용된 값 5 를

누락했다. 출력 하나만 검사해서는 오류를 놓친다. 복습: Position 과 Mask 를 함께 사용하는 방법,10.3 의 원래 위치와 배열 인덱스.

독립 연습 해설

연습문제 10.6.1 해설 새로운 순열 계산

$L = \ln 2$, $a = \sqrt{2L}$ 에서 $Q = I_2$, $K = aI_2$, $V = \mathrm{diag}(2, 3)$ 다. $S = LI_2$, 지수 행은 $[2, 1]$ 과 $[1, 2]$ 이므로

$$A = \begin{bmatrix} 2/3 & 1/3 \\ 1/3 & 2/3 \end{bmatrix}, \qquad O = \begin{bmatrix} 4/3 & 1 \\ 2/3 & 2 \end{bmatrix}.$$

교환하면 Q/K/V 행이 각각 바뀌고 $S' = PSP^{\mathsf{T}} = S$, $A' = PAP^{\mathsf{T}} = A$ 다. 이 예제의 S/A 대칭은 특별한 수치 성질이다. V 행이 바뀌어 $O' = PO = [[2/3, 2], [4/3, 1]]$ 다. 합은 둘 다 $[2, 3]$, 첫 출력은 다르다. S/A 가 우연히 같다는 이유로 V 정렬을 생략해서는 안 된다. 복습: 정리 10.6.1.

연습문제 10.6.2 해설 가정과 후속 연산

공유 FFN 은 각 행에 같은 f 를 적용하므로 $f(PX) = Pf(X)$ 로 등변성을 보존한다. 고정 Causal 은 허용 관계가 임의 순열을 따라 바뀌지 않아 보존 증명이 일반적으로 성립하지 않는다. 행마다 다른 W_Q 를 고정해 쓰면 $Q(PX) = PQ(X)$ 부터 실패할 수 있다.

위치 정보를 이미 가진 H 를 통째로 옮겨 같은 Attention 에 넣으면 그 Attention 은 여전히 H 의 행순열에 대해 등변이다. 그러나 내용에 붙은 위치 정보도 함께 옮긴 실험이며, '내용을 새 실제 위치에 배정하고 위치 벡터를 다시 만든다' 는 실험과 다르다. Attention 이전 경로가 순서를 알 수 없다는 뜻도 아니다. 출력 행의 합은 순열 불변이며 첫 행 선택은 등변 배열에서 특정 위치를 고르는 추가 연산이다. 여기서 모델 전체가 순서를 사용할 수 있는지를 판정하려면 입력 생성과 모든 경로를 보아야 한다. 복습: 위치 표지가 없는 계산의 조건.

연습문제 10.6.3 해설 좌표 쌍 번호와 주파수

주파수는 $[1, 10000^{-1/3}, 10000^{-2/3}] \approx [1, 0.046416, 0.002154]$ 다. 위치 2 의 각도는 각 주파수의 2 배이므로

$$e_2 = [\sin 2, \cos 2, \sin(2 \cdot 10000^{-1/3}), \cos(2 \cdot 10000^{-1/3}), \sin(2 \cdot 10000^{-2/3}), \cos(2 \cdot 10000^{-2/3})].$$

x 와 더하면 짝 좌표는 위 sin 값에 1 을 더하고 홀 좌표는 cos 그대로다. 첫 r 에 1 을 넣으면 첫 주파수가 1 대신 $10000^{-1/3}$ 이 되어 가장 빠른 쌍을 빠뜨린다. 표/코드에서 0 기반을 선언한 이유다. 반올림 오차를 허용하되 정확한 식과 좌표 순서는 같아야 한다. 복습: 정의 10.6.2.

연습문제 10.6.4 해설 네 항과 직접 내적

$M = \mathrm{diag}(2, 1)$ 이다. 내용–내용은 $1(4) + 2(-1) = 2$, 내용–위치는 $1(2) + 2(0) = 2$, 위치–내용은 $0(4) + 1(-1) = -1$, 위치–위치는 0 이다. 합 3 을 $\sqrt{2}$ 로 나누어 $3/\sqrt{2}$ 를 얻는다.

직접 가산한 q 는 $[1, 3]^{\mathsf{T}}$, k 는 $[6, -1]^{\mathsf{T}}$ 여서 내적 $6 - 3 = 3$ 이다. 가산 전 내적 2 에서 1 증가했는데 위치–위치 항은 0 이다. 실제 변화는 두 혼합 항 $2 - 1$ 에서 나왔다. 복습: 식 (10.6.3).

연습문제 10.6.5 해설 어떤 투영이 위치를 읽는가?

가산 전 Q=1,K=2,V=[4, 5] 다. 가산 후 표현은 [1, 3, 5] 이며 Q=1,K=3,V=[6, 8] 이다. Q 는 첫 좌표만 읽고 그 e 좌표가 0 이라 유지된다. K 는 둘째 좌표의 위치 증가 1 을 읽고, V 는 둘째/셋째 증가를 사용한다.

‘위치 가산은 모든 투영을 반드시 바꾼다’ 도 틀리고 ‘Q/K 만 바꾼다’ 도 틀리다. 실제 투영과 가산 벡터의 대응으로 판단해야 한다. 복습: 정의 10.6.1.

연습문제 10.6.6 해설 상대 위치가 같은 Absolute 점수

(0,1) 에서는 $(1+0)(1+1)=2$, (1,2) 에서는 $(1+1)(1+2)=6$ 이다. 네 항은 첫 경우 $[1,1,0,0]$, 둘째 $[1,2,1,2]$ 다. 위치 차-1 은 같아도 개별 e 가 달라져 혼합 항과 위치–위치 항이 바뀐다.

임의 학습 표는 sin/cos 쌍으로 정의되지 않았으므로 그 내적을 cos 변위의 합으로 자동 바꿀 수 없다. 실제 표에서 우연히 같은 내적이 나오더라도 모든 위치의 항등식 증거는 아니다. 복습: 정리 10.6.2, 무엇을 함께 옮겨야 같은 점수가 유지되는가?.

연습문제 10.6.7 해설 위치 목록을 먼저 대조하기

편향 전 두 행은 $[L, 0, -L]$ 이다. 비율은 [4/7, 2/7, 1/7], 출력은 22/7 이다. 상대 위치와 편향은

$$\Delta = \begin{bmatrix} 1 & -1 & -2 \\ 3 & 1 & 0 \end{bmatrix}, \qquad T = L\Delta.$$

편향 뒤 S 는 $L[[2,-1,-3],[4,1,-1]]$ 다. 첫 행 지수는 $[4, 1/2, 1/8]$, 둘째는 $[16, 2, 1/2]$ 이며 둘째가 첫째의 4 배다. 두 A 행은 모두 $[32/37, 4/37, 1/37]$, 두 출력은 $[32+16+10]/37 = 58/37$ 이다.

요청 위치만 2 증가했지만 선형 b 때문에 같은 행 상수 2L 만 추가되어 비율이 같다. 점수가 달라도 비율이 같을 수 있는 유용한 사례다. 복습: 정의 10.6.3, 연습문제 10.6.9.

연습문제 10.6.8 해설 거리와 방향

signed 편향의 지수는 4 와 1, A 는 [4/5, 1/5], O 는 $(8+8)/5 = 16/5$ 다. 부호를 지우면 두 지수 모두 4, A 는 [1/2, 1/2], O 는 5 다. 가까운 과거와 미래를 다르게 다루려던 의도가 사라졌다.

방향을 구별하지 않는 편향도 의도적인 설계가 될 수 있다. 그러나 주어진 signed 요구를 구현한 것과는 다르다. 복습: 예제 10.6.4.

연습문제 10.6.9 해설 행 상수의 소거

허용 집합 J_i 에서

$$\frac{e^{S_{ij}+c}}{\sum_{t\in J_i} e^{S_{it}+c}} = \frac{e^{c}e^{S_{ij}}}{e^{c}\sum_{t\in J_i} e^{S_{it}}} = A_{ij}.$$

J 를 유지해야 하며 유효 빈행에는 분모 자체가 정의되지 않는다. 차단 열은 끝까지 0 이다. 예를 들어 점수 $[0,0]$ 에 $[0,\ln 2]$ 를 더하면 A 가 $[1/2,1/2]$ 에서 $[1/3,2/3]$ 로 바뀐다. 상수 편향 불변을 열마다 다른 편향에 확대하지 말자. 복습: Relative Position Bias 는 점수를 직접 바꾼다,10.2 의 Softmax 이동 성질.

연습문제 10.6.10 해설 내용에 의존하는 상대 키 항

첫 q 에서 추가 분자는 $[2,0]\cdot[0,3]=0$, 추가 scaled 점수는 0 이다. 둘째 q 에서는 6, scaled 추가는 $6/\sqrt{2}=3\sqrt{2}$ 다. 같은 상대 위치라도 q 에 따라 달라지므로 위치에만 의존하는 b 하나가 두 값을 모두 맞출 수 없다.

Shaw 형태는 선택한 상대 값 벡터도 집계에 넣을 수 있어 $\sum_j A_{ij}(v_j+a_{ij}^V)$ 다. 본문의 scalar bias 구현은 AV 만 사용한다. 상대 위치라는 상위 이름만 같다고 서로 다른 점수/값 식을 합치지 말자. 복습: Relative Position Bias 는 점수를 직접 바꾼다와 Shaw 원문 미주.

연습문제 10.6.11 해설 회전 방향과 행배열

0/90/180/-90 도의 결과는 $[3,-2]$, $[2,3]$, $[-3,2]$, $[-2,-3]$ 이며 길이 제곱은 모두 13 이다. 행벡터를 $R(\pi/2)$ 에 오른쪽 곱하면 $[-2,-3]$ 으로 -90 도 회전이 된다. 요구된 열벡터 Rz 의 좌표를 행에 저장하려면 $z_{\text{row}}R^{\top}$ 다.

길이만 검사하면 두 방향 모두 보존되어 오류를 잡지 못한다. 알려진 90 도 좌표와 부호를 함께 검사한다. 복습: 정의 10.6.4.

연습문제 10.6.12 해설 새 RoPE 의 전 계산

$a=\sqrt{2}L$ 라 쓰자. 요청 1 의 $R(\pi/2)$ 는 q 를 $[-1,1]^{\top}$ 로 만들고, 키 위치 0/2 의 I 와 $R(\pi)$ 는 두 키를 $[a,0]^{\top}$, $[-a,0]^{\top}$ 로 만든다. 원래 점수는 $[L,L]\cdot$A=$[1/2,1/2]\cdot$O=4 였다.

회전 후 분자는 $[-a,a]$, S 는 $[-L,L]$ 이다. 지수 $[1/2,2]$ 의 합 5/2 로부터 A=$[1/5,4/5]$, O=$1/5+28/5=29/5$ 다. 상대각은 각각 $-\pi/2,+\pi/2$ 여서 직접 상대식으로 같은 분자를 얻는다. 쌍의 비교 폭 2 를 값 폭 1 로 바꾸어 나누지 말자. 복습: 식 (10.6.10), 예제 10.6.6.

연습문제 10.6.13 해설 부호가 드러나는 내용

정답은 $R(\pi/2)[0,1]^{\top}=[-1,0]^{\top}$ 이므로 분자-1 이다. 반대 부호는 $R(-\pi/2)[0,1]^{\top}=[1,0]^{\top}$ 이므로 1 이다. scaled 점수라면 각각 $\mp1/\sqrt{2}$ 다.

q=k 일 때 $bc-ad=0$ 이라 점수가 cos 항만 갖는다. cos 는 짝함수여서 부호를 뒤집어도 같은 숫자를 만들 수 있다. 독립 검산에는 sin 교차항이 0 이 아닌 내용을 포함해야 한다. 복습: 식 (10.6.11).

연습문제 10.6.14 해설 같은 상대 위치와 다른 회전 벡터

위치 $[7,8,9]$ 에서 Q' 의 행은 $[0,-1]$, $[1,0]$, $[0,1]$, K' 는 각각 a 배다. 원래 회전 Q/K 와 다르지만 각 쌍의 상대각은 유지되어 S/A/O 는 대표 예제 그대로다.

요청 0 만 위치 1 로 바꾸면 키 0/1/2 와의 S 행은 $[0,L,0]$, A 는 $[1/4,1/2,1/4]$, O 는 5 다. 다른 요청 행은 그대로다. q/k·주파수·폭·좌표 배치 고정이 점수 보존 조건이고, A/O 까지 말하려면 허용 집합과 V 도 유지해야 한다. 복습: 정리 10.6.4.

연습문제 10.6.15 해설 전체 폭의 scaling

요청 1 에서 두 쌍 모두 90 도여서 $q' = [0, 1, -2, 0]^\top$ 이다. 키 2 에서는 두 쌍 모두 180 도여서 $k' = [0, -1, -1, 0]^\top$ 이다. 내적은 $-1 + 2 = 1$, scaled 점수는 1/2 다.

상대각 90 도로 첫 쌍의 내적-1, 둘째 2 를 구해도 같다. 전체 비교 좌표가 4 개이므로 분모는 $\sqrt{4} = 2$ 다. 쌍별로 $\sqrt{2}$ 로 나누면 다른 총점이 된다. 복습: 예제 10.6.7, 여러 좌표 쌍은 서로 다른 속도로 회전한다.

연습문제 10.6.16 해설 원 주파수에서도 가능한 반례

둘째 쌍은 내용이 0 이므로 점수에 기여하지 않는다. 분자는 cos(변위), 전체 폭 4 의 scaled 점수는 $\cos 3/2 \approx -0.494996$, $\cos 4/2 \approx -0.326822$ 다. 거리 3→4 에서 증가했다.

반박되는 주장은 '모든 내용에서 개별 점수가 반드시 단조 감소한다' 다. 특정 주파수 합에 대한 상계·거리 구간의 경향·특정 실험의 결과를 이 두 수치로 전부 부정했다고 말할 수는 없다. 그 주장의 수학적 대상과 가정을 따로 확인한다. 무제한 길이의 성능 보장도 이 항등식에서 나오지 않는다. 복습: 예제 10.6.8와 감쇠 미주.

연습문제 10.6.17 해설 위치 정보와 Causal 의 결합

허용 행은 [1, 0, 0], [1, 1, 0], [1, 1, 1] 이다. 첫 행은 A=[1, 0, 0], O=2 다. 둘째 허용 점수 0/L 의 지수 1/2 로부터 A=[1/3, 2/3, 0], O=4 다. 셋째는 [1/7, 2/7, 4/7]·O=44/7 이다.

유한 점수-100 은 수학적으로 양의 지수를 만든다. 따라서 전부 허용하면 키 2 의 계수는 양수이며 엄밀히 차단한 것과 다르다. 특정 자료형에서 지수가 0 으로 underflow 하거나 출력 변화가 표시되지 않아도 접근 금지 계약을 구현한 증거는 아니다. 복습: Position 과 Mask 를 함께 사용하는 방법,10.3 의 금지와 낮은 점수.

연습문제 10.6.18 해설 원래 좌표가 사라진 경우

$c = 0, s = 1$ 의 정확한 90 도 기준으로 첫 줄은 x0=-2, 둘째는 새 x0 를 써서 x1=-2 를 만든다. 정답 $[-2, 1]$ 과 다르다. 실제 cos(pi/2) 의 작은 잔여값은 별도 부동소수점 오차다.

실행 결과 | Text

```
original = x.copy()
x[0] = c*original[0] - s*original[1]
x[1] = s*original[0] + c*original[1]
```

새 배열에 두 결과를 쓰는 것도 허용된다. `np.cos/np.sin` 의 입력은 rad 이며 90 도는 pi/2 다. 정수 배열이면 소수 좌표가 잘릴 수 있으므로 일반 회전에는 float 배열을 사용한다. 복습: Position 과 Mask 를 함께 사용하는 방법의 `rope` 원본.

연습문제 10.6.19 해설 축을 바꿨지만 부호는 유지된 코드

올바른 delta 는 $[[2, -1, -2], [5, 2, 1]]$ 이고 shape 는 2×3 이다. 문제의 코드는 shape3×2, 원소 $[[2, 5], [-1, 2], [-2, 1]]$ 을 만든다. 이것은 올바른 delta 의 전치다.

따라서 **주어진 코드에서는 전치만으로 축과 값이 모두 복구**된다. pQ-pK 의 부호는 이미 맞다. 만약 `kp[:,None]-qp[None,:]` 였다면 전치 후에도 부호가 반대이므로 음수를 취하거나 표를 반대로 정의

해야 한다. 오류가 있다고 가정해 부호까지 임의로 뒤집지 말자. QK^{T} 에서 첫 축은 요청 2, 둘째는 제공 3 이다. 복습: 정의 10.6.3.

연습문제 10.6.20 해설 출력과 중간 배열을 함께 검사

키 순서 2→0→1 에서 K/V/키 위치가 함께 옮겨진다. 회전 K 의 행과 S/A 의 열도 같은 순열을 따른다. Q 행은 유지되므로 최종 O 는 그대로다. 비율 열을 원래 순서로 되돌려 전 셀을 비교하고 차단 계수 0 도 확인해야 한다.

올바른 Mask $[0, 1, 1]$ 을 쓰되 RoPE 에 잘못된 새 키 위치 0/1/2 를 넣으면 요청 1 의 S 는 $[0, L, 0]$, 허용 비율은 $[0, 2/3, 1/3]$ 다. 값 $[8, 2, 5]$ 를 곱해 O=3 으로 달라진다. Mask 도 잘못 바꾼 경우 O 가 우연히 4 였던 유제와 구별한다.

solution_position.py | learning-source/solution_position.py | Python | L1-L15 (15 줄)
source revision: position-source-v0.1

```python
""" 독립 연습의 재배열: K/V 와 실제 위치를 같은 순서로 옮긴다."""
import numpy as np
from position import comparison_inputs, rotary_attention
from sources import project
from masking import causal_allowed

x, wq, wk, wv, _, p, _ = comparison_inputs()
q, k, v = project(x, wq), project(x, wk), project(x, wv)
order = np.array([2, 0, 1])
allowed = causal_allowed(p, p[order], np.ones(3, dtype=bool))
_, _, scores, weights, output = rotary_attention(
    q, k[order], v[order], p, p[order], [np.pi/2], allowed)
print(" 재배열된 키의 원래 위치", p[order])
print(" 비율", weights)
print(" 출력", output)
```

이 발췌는 원래 위치를 동반한 올바른 재배열의 실행이다. 복습: 유제 10.6.8, Position 과 Mask 를 함께 사용하는 방법.

연습문제 10.6.21 해설 회전 부분과 전체 비교 폭

Interleaved 는 $(0, 1), (2, 3), (4, 5)$, Split-half 는 $(0, 3), (1, 4), (2, 5)$ 다. 폭 5 부분 회전은

$$\widehat{R}(p) = \operatorname{diag}(R(p\theta_0), R(p\theta_1), 1)$$

로 정의할 수 있다. 마지막 좌표의 내적 $q_4 k_4$ 를 회전 두 쌍의 내적 합에 더한 뒤 $\sqrt{5}$ 로 나눈다.

제공 함수는 전체 짝수 회전만 계약으로 두었으므로 폭 5 를 `ValueError` 로 거부한다. 사용자가 원하는 부분 회전은 별도 명시 함수로 구현해야 한다. 홀수 폭을 조용히 잘라 내거나 마지막 좌표를 빠뜨리면 내용 점수까지 손실된다. 복습: 여러 좌표 쌍은 서로 다른 속도로 회전한다.

연습문제 10.6.22 해설 로그가 보여 주는 계산 지점

A 는 Absolute 가산이다. X/E 의 대응 위치와 같은 폭·행, 세 투영의 출처와 V 의 변화 여부를 검사한다. B 는 점수 추가 방식이다. T 가 같은 상대 위치의 함수/구간 표에서 왔는지 확인해야 Relative Bias 라고 식별할 수 있다. 임의 행렬 T 는 일반 점수 보정일 수 있다. δ 부호와 scaled 뒤 가산·허용 정규화를 검사한다.

C 는 위치별 회전 구조다. 그것이 RoPE 인지는 2 차원 쌍의 블록·위치에 비례하는 각도·Q/K 의 대응 주파수와 배치를 확인해야 한다. 임의 직교행렬만으로 상대 위치식이 보장되지는 않는다. 세 경로 모두 Mask·값 대응·Head 별 폭/구성을 따로 확인한다. 추가 구성은 각각 절대 표/함수, 편향 표/함수, 회전 주파수/쌍 배치다. 복습: 세 경로를 같은 관점으로 읽기.

연습문제 10.6.23 해설 방법 도입과 출력 변화

Absolute 에서는 e 가 모든 사용 투영의 영공간에 있으면 가산 표현이 달라도 Q/K/V 는 그대로다. 혹은 가산 후 V 를 포함해 모든 값이 같은 c 로 유지되면 A 가 달라도 O=c 다. 어떤 조건을 썼는지 밝혀야 한다.

Bias 에서 모든 허용 열에 같은 b 를 더하면 S 가 바뀌어도 A/O 가 유지된다. RoPE 에서는 모든 Q/K 에 같은 회전각이 적용되면 내적이 유지되고, 내용이 0 이면 위치를 달리 돌려도 그 셀 점수는 0 이다. 모든 V 행이 같거나 키 하나만 허용되면 A 의 변화가 출력 변화로 이어지지 않는다. 키 하나인 경우라도 Absolute 가 그 V 를 바꾸면 출력은 바뀔 수 있으므로 방법별 직접 경로를 빠뜨리지 말자. 여러 올바른 반례를 허용한다. 복습: 예제 10.6.7, 세 경로를 같은 관점으로 읽기.

연습문제 10.6.24 해설 새 Cross 의 세 경로

$L = \ln 2, a = \sqrt{2L}$ 로 쓰자. 값을 별도 공급했으므로 세 계산 모두 $V = [2, 8]^\top$ 다. Absolute 가산 뒤의 배열은

$$q = [1, 1]^\top, \qquad K = a \begin{bmatrix} 1 & 0 \\ 1 & 2 \end{bmatrix}$$

다. 점수 $[L, 3L]$·지수 2/8 에서 A=[1/5, 4/5], O=34/5 다.

Bias 에서는 원래 점수 $[L, L]$, delta=$[1, -1]$ 라서 S=$[2L, 0]$, A=[4/5, 1/5], O=16/5 다. RoPE 에서는 q'=[0, 1], 두 k'=$[a, 0], [-a, 0]$ 이므로 S=[0, 0], A=[1/2, 1/2], O=5 다.

함께 1 이동하면 Absolute 의 q 는 [1, 2], 키는 a 배의 [1, 1], [1, 3] 이라 S=$[3L, 7L]$ 다. A=[1/17, 16/17], O=130/17 로 바뀐다. Bias 의 delta 와 RoPE 의 상대각은 유지되어 앞의 S/A/O 가 같다. 값 고정은 이 문제의 인터페이스 조건이다. 같은 Z 행을 공유 W_V 에 넣어 서로 다른 값 2/8 을 만들었다고 주장하지 않는다. 일반 Absolute 에서 V 도 가산 표현에서 만들면 값 변화까지 계산해야 한다. 복습: 정의 10.6.1, 정리 10.6.4.

선택적 심화 해설

심화문제 10.6.1 해설 블록별 증명과 주파수 일치

블록대각 행렬의 전치/곱은 블록별로 계산된다. 따라서 각 r 에서 $R(p\theta_r)^\top R(t\theta_r) = R((t-p)\theta_r)$ 이며 이를 모으면 전체 상대식이다. t=p 면 모든 블록이 I 여서 직교성·길이 보존이 성립한다. 상대 위치 유지 →S 유지, 허용 집합 유지 →A 유지, V 유지 →O 유지 순서로 증명한다.

Q 와 K 의 주파수가 각각 θ_Q, θ_K 이면 상대각은 $p_K\theta_K - p_Q\theta_Q$ 다. 함께 c 이동하면 $c(\theta_K - \theta_Q)$ 가 더 생긴다. 예를 들어 q=k=$[1, 0], \theta_Q = \pi/2, \theta_K = \pi$ 에서 위치 (0,0) 의 내적은 1, (1,1) 은 0 이다. 상대 위치 0

이 같아도 달라졌다. 전체 모델이나 길이에 따른 주파수 변경을 고정 주파수 증명에 넣지 말자. 복습: 정리 10.6.3, 정리 10.6.4.

심화문제 10.6.2 해설 순열로 구현하는 Split-half

Split-half 입력 배열은 $[a_0, \dots, a_{m-1}, b_0, \dots, b_{m-1}]$ 이다. 인접 쌍 구현에 넣으려면 순열 $[0, m, 1, m+1, \dots, m-1, 2m-1]$ 로 $[a_0, b_0, \dots]$ 를 만든다. 회전 결과를 역순열로 돌린다. Q/K 에 같은 좌표 순열을 적용하면 내적은 보존된다. 원래 인접 배열을 Split-half 배열로 저장하려면 순서 $[0, 2, \dots, 1, 3, \dots]$ 를 사용한다.

solution_position.py | learning-source/solution_position.py | Python | L18-L28 (11 줄)
source revision: position-source-v0.1

```python
def split_half(x, p, theta):
    """Split-half 저장 순서를 인접 쌍으로 옮겨 기존 회전을 재사용한다."""
    from position import rope
    from sources import matrix
    x = matrix(x)
    d = x.shape[1]
    if d % 2:
        raise ValueError("Split-half 의 전체 회전 폭은 짝수여야 한다")
    order = np.array([i for r in range(d//2) for i in (r, r+d//2)])
    inverse = np.argsort(order)
    return rope(x[:, order], p, theta)[:, inverse]
```

폭 4 의 $[1, 2, 3, 4]$·주파수 $[\pi/2, 0]$ 를 재배치 없이 돌리면 인접 결과 $[-2, 1, 3, 4]$ 와 Split-half 결과 $[-3, 2, 1, 4]$ 가 다르다. 함수는 홀수 폭을 거부한다. 별도 검증에서 무작위 q/k 의 동등한 재배치·역배치와 내적까지 대조한다. 입력을 재배치하고 투영의 좌표는 그대로라고 가정하는 설명은 불완전하다. 복습: 유제 10.6.7, 여러 좌표 쌍은 서로 다른 속도로 회전한다.

심화문제 10.6.3 해설 내적 항등식의 적용 범위

Sinusoidal 의 $e_{p+c}^{\top} e_{t+c}$ 는 $\sum_r \cos((p-t)\omega_r)$ 이므로 원래와 같다. $W_Q = W_K = I$ 에서 내용을 고정했을 때 가산 후 전체 점수가 같은 필요충분조건은 나머지 두 혼합 항 변화가 서로 상쇄하는 것이다.

$$x_p^{\top}(e_{t+c} - e_t) + (e_{p+c} - e_p)^{\top} x_t = 0.$$

폭 2·같은 x=[1, 0] 에서 이 식은 sin(p+c)+sin(t+c)-sin p-sin t=0 이다. (0,1)→(2,3) 에서는 성립하지 않아 scaled 점수가 약 1.6842→1.8319 로 바뀐다. 일반 투영 M 에서는 위치–위치 항도 단순 내적 항등식과 다를 수 있어 그 변화까지 포함한 네 항의 합을 검사해야 한다.

RoPE 는 내용 벡터에 e 를 가산하지 않는다. 점수는 고정 q/k 사이에 상대 회전 한 개를 넣은 식이며, 위치 이동 뒤 그 행렬 자체가 같아져 점수가 보존된다. 혼합 가산 항을 없다고 선언하는 대신 두 방법의 실제 식을 비교하자. 복습: 정리 10.6.2, 식 (10.6.10).

짧은 이해 확인의 답과 이유

입력에 이미 순서가 있다면 결론이 나오지 않는다. H 가 만드는 경로에 순서가 이미 들어 있을 수 있고 Attention 은 그 내용을 사용한다. H 의 행을 통째로 바꾼 등변성과 새 순서의 입력에서 H 를 다시 계산한 결과를 구별해야 한다. 원래 위치를 함께 옮긴 것인지도 확인한다. 복습: 위치 표지가 없는 계산의 조건, 질문으로.

절대 위치의 오해 가산된 표현이 V 투영에 들어가면 V 도 바뀔 수 있다. e 의 값 투영이 0 인 특별 경우만 그대로다. Sinusoidal e 의 내적은 cos 변위의 합이므로 상대 변위 관계가 존재한다. 그러나 cos3<cos4 이므로 모든 거리에서 단조 감소하지 않는다. 일반 학습 표에 이 항등식을 적용할 수는 없다. 복습: 예제 10.6.2, 정리 10.6.2. 질문으로.

같은 거리의 의미 같은 signed delta 면 같은 편향을 받지만 내용 내적과 비교 폭도 고정해야 같은 점수가 된다. 비율에는 같은 행의 다른 키 점수와 허용 집합까지 필요하다. 절댓값 거리만 같으면 방향도 다를 수 있다. 복습: 예제 10.6.4. 질문으로.

회전과 내적 같은 R 에는 $(Rq)^\top(Rk) = q^\top k$ 가 성립한다. 서로 다른 위치에는 $q^\top R(p_Q\theta)^\top R(p_K\theta)k = q^\top R((p_K - p_Q)\theta)k$ 다. 상대각이 0 이 아닌 경우 보존 보장은 없다. q=[1, 0], k=[0, 1] 의 한쪽 90 도 회전이 반례다. 복습: 정리 10.6.3. 질문으로.

배열 인덱스와 위치 보존하지 않는다. 행 0/1/2 는 저장 위치,7/3/5 는 원래 시퀀스 위치다. V 를 같은 저장 순서로 맞추어도 Q/K 의 회전 각도가 잘못되면 비교 점수는 다른 계산이다. 키 원래 위치 목록을 함께 넘겨야 한다. 허용 관계도 실제 위치로 만든다. 복습: 유제 10.6.8. 질문으로.

어디까지 보장하는가? 점수 보존은 고정 내용/주파수/배치 조건의 국소 성질이다. 다른 Mask 면 분모와 허용 기여가, 다른 V 면 집계가 달라질 수 있다. 다른 입력과 여러 층의 다른 경로까지 모두 같다고 도출할 수 없다. S→A→O 각각의 추가 조건을 명시해야 한다. 복습: 정리 10.6.4. 질문으로.

10.7 Attention 출력을 Transformer 블록으로 연결하기 — 해설

답을 볼 때 먼저 각 하위 함수가 읽은 표현을 확인하자. MHA 의 입력·반환과 첫 Residual 합은 다른 객체다. LN 은 한 행의 특징 통계를 사용하고 FFN 은 그 입력의 특징을 변환한다. Pre-LN 에서는 정규화 한 가지와 정규화 전 합산 경로가 다르다. 계산이 막히면 틀린 첫 단계로 돌아가고, 최종 숫자만 맞추려고 이후 연산을 바꾸지 말자. 반올림은 표시 단계에서만 한다.

유제 해설

유제 10.7.1 해설 반환 폭과 대응 행

C 의 행 [a, b] 는 $[a, b, a-b]$ 로 반환된다. 따라서 M=[[2, 1, 1], [-1, 3, -4]], X+M=[[3, 3, 1], [2, 2, -2]] 다. C 의 폭 2 는 X 의 폭 3 과 다르며 최종 출력 투영을 먼저 수행해야 한다.

둘째 요청의 행을 첫 요청에 배정하면 요청에 맞춘 집계가 잘못 전달된다. O_1 만 마지막 축에 방송하면 한 Head 의 스칼라를 세 모델 좌표에 반복해서 더한 다른 함수가 된다. 같은 shape/행 대응과 정의한 W_O 가 모두 필요하다. 복습: 예제 10.7.1, 예제 10.7.2.

유제 10.7.2 해설 통계·Scale·Shift

μ=4, 분산 8/3, 분모 $\sqrt{3}$, z=[-2/$\sqrt{3}$, 0, 2/$\sqrt{3}$] 이다. γ/β 뒤 출력은 [-2/$\sqrt{3}$, 1, 2/$\sqrt{3}$-1], 평균 0 이다. **이 문제에서는 우연히** 0 이며 모든 좌표별 γ/β 에서 0 이라는 결론은 아니다. 가운데 z 가 0 이라 γ_2=2 가 그 좌표에 영향을 주지 않았다.

[9, 11, 13] 은 원입력에 7 을 더한 것이다. 평균만 11 로 달라지고 중심화 좌표·분산·z·LN 출력은 같다. 반면 입력에 따른 매개변수가 바뀌었다면 이 조건을 사용할 수 없다. 복습: 정의 10.7.2, 정리 10.7.2.

유제 10.7.3 해설 활성화 전후

[a, b, c]=[0, 1, -1] 이므로 z=[-1, 2.5, 1, -1.5], h=[0, 2.5, 1, 0] 이다. 둘째 선형 변환 뒤 f=[0.6, 0.55, 1.55] 다. Bias 도 포함해야 한다.

반대로 z 를 그대로 둘째 변환에 넣으면 $zW_2 + b_2 = [0.85, 0.55, 1.30]$ 이고 이 값은 모두 양수라 마지막 ReLU 뒤에도 같다. 올바른 f 와 다르다. ReLU 를 적용한 **중간 좌표**가 달라졌기 때문이다. FFN 매개변수와 해당 입력 행이 고정되고 위치 간 혼합이 없으면 다른 행의 변경은 이 f 를 바꾸지 않는다. 복습: 예제 10.7.7.

유제 10.7.4 해설 함수 입력으로 순서 진단

첫 코드에서 MHA 가 $LN_1(X)$ 를 읽는 지점부터 Post-LN 정의와 다르다. 올바르게는 `m=MHA(X)` 이며 나머지 `u=LN1(X+m); y=LN2(u+FFN(u))` 를 유지한다. MHA 앞 LN_1 은 불필요한 한 번 추가된 호출이 아니라 Q/K/V 의 수치와 이후 반환을 바꾸는 호출이다.

Pre-LN 의 둘째 식은 `y=u+FFN(LN2(u))` 다. Residual 왼쪽은 u 이고 FFN 입력만 $LN_2(u)$ 다. u 까지 정규화한 값으로 덮어쓰지 않는다. 복습: 정의 10.7.4, 정의 10.7.5.

유제 10.7.5 해설 둘째 요청의 끝까지 계산

Head1 기여는 (1/2)2 = 1, (1/2)1 = 1/2 로 합 3/2 다. Head2 는 (1/17)1 = 1/17, (16/17)0 = 0 으로 합 1/17 이다. M=[3/2, 1/17, 49/34], R_1=[3/2, 35/17, 83/34] 다. 평균 2, 중심화 [-1/2, 1/17, 15/34], 분산 259/1734, 분모 $\sqrt{259/1734 + 0.01} \approx 0.399207$ 이다.

U 약 [-1.252485, 0.147351, 1.105134]. 첫 FFN 변환은 [-0.147351, -0.457783, 1.399837, -1.899837], h=[0, 0, 1.399837, 0] 이다. 따라서 f 약 [0.799918, -0.899918, 0.3], R_2 약 [-0.452567, -0.752567, 1.405134]. R_2 평균 1/15, 분산 약 0.910748, LN_2 반환 약 [-0.541119, -0.853763, 1.394882] 다.

마지막 LN 에 F 만 주면 둘째 Residual 이 이어 온 U 를 빠뜨린다. FFN 의 보강 정보와 갱신된 표현을 혼동한 것이다. 복습: 예제 10.7.8.

유제 10.7.6 해설 두 가지 입력을 분리하기

첫 LN_1 입력 =[1, 0, 2], 출력 =[0, -ρ, ρ] 약 [0, -1.215661, 1.215661]. MHA 반환 약 [0.607831, -0.138808, 0.746638]. 원래 X 행과 합한 U 약 [1.607831, -0.138808, 2.746638] 다. LN_2 입력은 U, 출력 B 약 [0.170137, -1.296561, 1.126423]. FFN 반환 F 약 [0.264931, -0.2, 0.135069] 다.

올바른 Y=U+F 약 [1.872762, -0.338808, 2.881707]. 잘못된 B+F 약 [0.435069, -1.496561, 1.261492] 이며 두 반환의 차이는 U-B 다. 정규화한 가지가 FFN 의 조건을 정하지만 기존 합산 경로를 그 가지로 교체하지 않는다. 복습: 예제 10.7.9와 두 경로 도해.

유제 10.7.7 해설 비활성 행과 후속 연산

첫 합 0, $LN_1(0)$=0 이다. FFN 이 [1, 0, -1] 을 반환하므로 둘째 합도 [1, 0, -1]. 평균 0, 분산 2/3 이어서 최종 LN 출력은 [ρ, 0, -ρ] 약 [1.215661, 0, -1.215661] 이다. 비활성 MHA 의 0 출력을 전체 Block 출력 0 으로 승계할 수 없다.

최종 반환에서 query-valid 게이트를 곱해 패딩 행을 0 으로 만드는 방법이 가능하다. 다음 Block 의 키 Mask 에서도 패딩 키를 제외한다. 게이트를 더 이른 지점에 넣는 대안은 Bias/LN Shift 등 후속 비영 경로가 다시 생기는지 검사해야 한다. 복습: 예제 10.7.10.

이해 확인 해설

직접 경로의 의미 F(x)=-x 이면 y=0 이므로 서로 다른 모든 입력이 같은 반환이 된다. 직접 x 가 더해져도 상쇄가 가능하다. 미분 가능한 경우 Jacobian 은 I+J_F 지만 J_F=-I 면 0 이다. 직접 경로는 모든 정보의 복원과 모든 조건의 기울기 보장이 아니다. 질문으로. 복습: 정의 10.7.1, 심화문제 10.7.1.

ε 와 γ/β z 분산은 $\sigma^2/(\sigma^2+\varepsilon)$ 로 1 보다 작다. 최종 평균은 좌표별 γ/β 때문에 일반적으로 0 이 아니다. 같은 좌표의 입력은 모두 z=0 이 되어 β 로 반환되므로 상수의 크기를 구별하지 못한다. 질문으로. 복습: 정리 10.7.1, 예제 10.7.5.

Position-wise 한 행의 특징을 가중합하여 새 특징을 만드는 것이 좌표 혼합이다. 다른 행을 읽어 섞는 것이 위치 혼합이다. FFN 자체는 앞의 혼합만 하지만 입력이 이미 Attention 정보를 담았다면 그 정보도 변환된다. 질문으로. 복습: 정의 10.7.3.

반환 위치 Pre-LN 은 정규화 전 U 와 FFN 반환을 더한 값을 반환한다. 평균 0 은 일반적으로 성립하지 않는다. 스택 마지막의 별도 LN 은 그 모델의 마지막 경로이고 각 Block 내부에 있는 연산으로 소급되지 않는다. 질문으로. 복습: 정의 10.7.5.

첫 차이와 성능 MHA 입력이 달라진다. X 대신 $LN_1(X)$ 를 쓰고 같은 투영으로 다시 계산해야 한다. MHA 출력이 우연히 동일한 특수 경우는 가능하지만 조건 없이 복사할 수 없다. 반환 좌표의 크기는 과제 성능 지표가 아니고 학습/평가 근거가 필요하다. 질문으로. 복습: 대표 두 완전 계산과 Xiong 외의 초기화·실험 미주.

Causal 의 전제 초기 행부터 허용 범위 정보만 담았다는 가정이 필요하다. 모든 추가 연산도 위치별이어야 한다. 전역 평균이나 다른 입력 생성/조건 출처는 Mask 밖의 경로를 열 수 있다. 질문으로. 복습: 정리 10.7.3.

독립 연습 해설

연습문제 10.7.1 해설 새 Post-LN 의 전체 계산

먼저 투영과 집계를 계산하고 모델 폭으로 반환한다. $L = \ln 2$ 라 두면 Q=[2, 0]^{T}, K=[2L, 0]^{T}, V=[[2, 1], [0, 3]] 다. 비교 폭 1 이므로

$$S = \begin{bmatrix} 4L & 0 \\ 0 & 0 \end{bmatrix}, \quad A = \begin{bmatrix} 16/17 & 1/17 \\ 1/2 & 1/2 \end{bmatrix}, \quad O = \begin{bmatrix} 32/17 & 19/17 \\ 1 & 2 \end{bmatrix}.$$

단일 Head 라 C=O 다. 출력 투영 후

$$M = \begin{bmatrix} 16/17 & 19/34 & -13/34 \\ 1/2 & 1 & 1/2 \end{bmatrix}, \quad R_1 = \begin{bmatrix} 50/17 & 53/34 & -13/34 \\ 1/2 & 2 & 5/2 \end{bmatrix}.$$

첫 평균 70/51 약 1.372549, 중심화 [80/51, 19/102, -179/102], 분산 약 1.858324 이다. 둘째 평균 5/3, 중심화 [-7/6, 1/3, 5/6], 분산 13/18 약 0.722222 다. 각 행에 ε=0.04 를 더한 분산의 제곱근으로 나눈다.

$$U \approx \begin{bmatrix} 1.138504 & 0.135197 & -1.273702 \\ -1.336306 & 0.381802 & 0.954504 \end{bmatrix}.$$

새 W_1 의 좌표식은 $[a + c - 0.5, -a + b + 0.25]$ 다. 따라서

$$Z \approx \begin{bmatrix} -0.635197 & -0.753307 \\ -0.881802 & 1.968108 \end{bmatrix}, \quad H \approx \begin{bmatrix} 0 & 0 \\ 0 & 1.968108 \end{bmatrix},$$

$$F \approx \begin{bmatrix} 0 & 0.1 & -0.1 \\ 0 & 1.084054 & 0.884054 \end{bmatrix}, \quad R_2 \approx \begin{bmatrix} 1.138504 & 0.235197 & -1.373702 \\ -1.336306 & 1.465856 & 1.838558 \end{bmatrix}.$$

첫 위치 모든 ReLU 좌표가 0 이어도 b_2 는 남는다. F=0 으로 놓으면 Bias 를 빠뜨린 것이다. 마지막 통계는 평균 [0, 0.656036], 분산 [1.079522, 2.007865] 이며

$$Y \approx \begin{bmatrix} 1.076015 & 0.222288 & -1.298303 \\ -1.392237 & 0.565897 & 0.826340 \end{bmatrix}.$$

첫 행을 끝까지 손계산하고 둘째 행을 함수로 대조하는 접근도 가능하지만 요청된 두 행의 중간값은 모두 남겨야 한다. 복습: 예제 10.7.8, 정의 10.7.3.

연습문제 10.7.2 해설 γ/β 가 있는 실제 두 순서

Post-LN. MHA 입력 =X, Q=[1, 2]^{T}, K=[3L, 0]^{T}, V=X 다.

$$S = L\begin{bmatrix}3 & 0\\ 6 & 0\end{bmatrix},\quad A=\begin{bmatrix}8/9 & 1/9\\ 64/65 & 1/65\end{bmatrix},\quad O=\begin{bmatrix}10/9 & 8/3\\ 66/65 & 192/65\end{bmatrix}.$$

C=O, M=O/ 2 약 [[0.555556, 1.333333], [0.507692, 1.476923]]. 첫 합 R_1 약 [[1.555556, 4.333333], [2.507692, 1.476923]]. LN_1 통계는 평균 [2.944444, 1.992308], 분산 [1.929012, 0.265621] 이다. 중심화한 좌표를 각 분모로 나눈 z 는 [[-0.940887, 0.940887], [0.717738, -0.717738]] 다. **여기에 γ/β 를 적용**하면

$$U\approx\begin{bmatrix}-0.440887 & 1.881775\\ 1.217738 & -1.435476\end{bmatrix}.$$

FFN 입력은 U 다. 좌표 [a, b] 의 첫 변환은 [a+b-0.5, -a+b+0.25], 둘째 변환은 [h_0+0.2, -h_1-0.1] 이다.

$$Z\approx\begin{bmatrix}0.940887 & 2.572662\\ -0.717738 & -2.403214\end{bmatrix},\quad H\approx\begin{bmatrix}0.940887 & 2.572662\\ 0 & 0\end{bmatrix},$$

$$F\approx\begin{bmatrix}1.140887 & -2.672662\\ 0.2 & -0.1\end{bmatrix},\quad R_2\approx\begin{bmatrix}0.7 & -0.790887\\ 1.417738 & -1.535476\end{bmatrix}.$$

LN_2 통계는 평균 [-0.045444, -0.058869], 분산 [0.555686, 2.180369], z 약 [[0.830485, -0.830485], [0.947172, -0.947172]]. γ/β 뒤 반환은

$$Y_{\text{post}}\approx\begin{bmatrix}1.330485 & -1.660970\\ 1.447172 & -1.894344\end{bmatrix}.$$

Pre-LN. 먼저 X 의 평균은 [2, 1], 분산은 [1, 1], 정규화 좌표는 [[-2/$\sqrt{5}$, 2/$\sqrt{5}$], [2/$\sqrt{5}$, -2/$\sqrt{5}$]]. γ/β 뒤 MHA 입력은

$$T\approx\begin{bmatrix}-0.394427 & 1.788854\\ 1.394427 & -1.788854\end{bmatrix}.$$

Q=T 의 첫 열, K=L·T 의 둘째 열, V=T 다. 따라서

$$Q\approx[-0.394427, 1.394427]^{\mathsf{T}},\quad K\approx[1.239939, -1.239939]^{\mathsf{T}},$$

$$S\approx\begin{bmatrix}-0.489066 & 0.489066\\ 1.729005 & -1.729005\end{bmatrix},\quad A\approx\begin{bmatrix}0.273263 & 0.726737\\ 0.969469 & 0.030531\end{bmatrix},$$

$$O\approx\begin{bmatrix}0.905600 & -0.811200\\ -0.339812 & 1.679624\end{bmatrix},\quad M=O/2\approx\begin{bmatrix}0.452800 & -0.405600\\ -0.169906 & 0.839812\end{bmatrix}.$$

U=X+M 약 [[1.452800, 2.594400], [1.830094, 0.839812]]. LN_2(U) 통계는 평균 [2.023600, 1.334953], 분산 [0.325813, 0.245165] 다. z 약 [[-0.752217, 0.752217], [0.703646, -0.703646]] 에 γ/β 를 적용하면 FFN 입력은

$$B \approx \begin{bmatrix} -0.252217 & 1.504435 \\ 1.203646 & -1.407292 \end{bmatrix}.$$

여기서도 γ/β 를 빠뜨리면 입력이 다르다.

$$Z \approx \begin{bmatrix} 0.752217 & 2.006652 \\ -0.703646 & -2.360937 \end{bmatrix}, \quad H \approx \begin{bmatrix} 0.752217 & 2.006652 \\ 0 & 0 \end{bmatrix},$$

$$F \approx \begin{bmatrix} 0.952217 & -2.106652 \\ 0.2 & -0.1 \end{bmatrix}, \quad Y_{\text{pre}} = U + F \approx \begin{bmatrix} 2.405017 & 0.487748 \\ 2.030094 & 0.739812 \end{bmatrix}.$$

이 둘째 합 뒤 추가 LN 은 없다. 첫 차이는 T 를 MHA 입력으로 삼는 지점이며 Q/K/V 부터 결과가 달라졌다. FFN 도 다른 입력을 받는다. 마지막 반환 위치까지 다르므로 단순히 최종 행에 LN 만 붙인 비교가 아니다. 복습: 정의 10.7.4, 정의 10.7.5. 실행의 새 조건은 `solution_block.py` 에서 재현할 수 있다.

연습문제 10.7.3 해설 Residual 인터페이스

C 는 3×3, W_O 는 3×4 여야 한다. 첫 출력 =[2+3, -1-3, 2, -1+6]=[5, -4, 2, 5], 첫 합 =[6, -2, 2, 4] 다. O_2 는 3×1 로 방송될 수 있지만 그 스칼라를 모든 좌표에 반복하는 연산이며 정해진 Concat·출력 투영을 대신하지 않는다. 동일 요청행 유지도 필요하다. 복습: 예제 10.7.2.

연습문제 10.7.4 해설 LN 의 모든 항

μ=5, 중심화 [-3, 0, 3], 분산 6 이다. ε=3 이므로 분모 3, z=[-1, 0, 1]. γ/β 뒤 y=[0, 0, -0.5], 평균 =-1/6 이다. 정규화 좌표 z 와 affine 출력 y 를 같은 통계라고 두면 틀린다. 복습: 정리 10.7.1, 예제 10.7.4.

연습문제 10.7.5 해설 ε 의 위치

μ=2, σ^2=1. ε=0.25 면 y=[-2/√5, 2/√5], 분산 4/5. ε=3 이면 y=[-0.5, 0.5], 분산 1/4 다. 분모를 $\sqrt{\sigma^2+\varepsilon}$=1.25 로 쓰면 y=[-0.8, 0.8] 이고 올바른 약 ±0.894427 과 다르다. ε 는 분산에 더한 뒤 제곱근을 취한다. 복습: 식 (10.7.3).

연습문제 10.7.6 해설 분산 0 과 폭 1

첫 입력은 μ=7, σ^2=0, z=0, 출력 β=[1, 2, -3] 이다. 폭 1 도 μ=9, σ^2=0, 출력 [-2]. ε=0 이면 0/0 이다. 모든 좌표가 같은 서로 다른 입력은 같은 β 로 반환되어 구별할 수 없다. γ 가 0 이거나 음수여도 중심화가 0 인 결론은 같다. 복습: 예제 10.7.5.

연습문제 10.7.7 해설 축 오류

잘못된 열 통계는 μ=[5.5, 8.5], σ^2=[20.25, 30.25] 다. 출력 약 [[-0.993884, -0.995893], [0.993884, 0.995893]]. 올바른 행 통계는 μ=[2, 12], σ^2=[1, 4], 출력 약 [[-0.894427, 0.894427], [-0.970143, 0.970143]]. shape 는 같지만 첫 행 둘째 좌표 부호부터 다르다.

열 평균은 둘째 위치의 값을 포함하므로 그 행이 바뀌면 첫 위치 통계도 바뀐다. `axis=-1, keepdims=True` 는 각 행의 통계를 그 행의 d 좌표에만 방송한다. 복습: 예제 10.7.6.

연습문제 10.7.8 해설 FFN 세 함수

$z=xW_1$=[-1, -3]. 올바른 h=[0, 0], f=b_2=[-1, 1]. 활성화 생략은 zW_2+b_2=[1, -4]. 마지막에만 ReLU 면 [1, 0]. 세 결과는 다르다. 중간 특징의 비선형 선택과 최종 출력의 비선형 제한을 바꾸어 쓰면 다른 함수가 된다. 복습: 정의 10.7.3, 유제 10.7.3.

연습문제 10.7.9 해설 행별/배치 계산

H=[[1, 0], [0, 3]], F=[[1, -1], [0, 6]]. 각각 [1, 0] 과 [0, 3] 에 같은 W_2 를 곱한 결과와 정확히 같다. 둘째 입력만 바뀌면 첫 FFN 출력은 유지된다. Batch 를 추가해도 마지막 특징 폭 2 만 변환하고 앞의 (b, n) 축을 유지한다. 단 Block/MHA 의 이 절 구현은 Batch 미지원이므로 FFN 지원을 전체 Block 지원으로 확대하지 않는다. 복습: 구현 계약.

연습문제 10.7.10 해설 혼합 순서 진단

A 는 MHA 입력 $LN_1(X)$, 첫 합 $U=X+MHA(LN_1(X))$, FFN 입력 U, 마지막 LN_2 입력 $U+FFN(U)$ 다. Pre-LN 첫 갱신과 Post-LN 마지막 갱신을 섞었다. Post 로 고치려면 MHA 입력 X, 첫 합 뒤 LN_1 을 추가해 U 를 만들고 마지막을 유지한다. Pre 로 고치려면 FFN 입력 $LN_2(U)$, 반환 $U+FFN(LN_2(U))$ 로 바꾼다.

B 는 MHA 입력 X, $U=LN_1(X+MHA(X))$, FFN 입력 $LN_2(U)$, 반환 $U+FFN(LN_2(U))$ 다. Post 의 첫 갱신과 Pre 의 둘째 갱신이다. Post 로는 `y=LN2(u+FFN(u))`, Pre 로는 첫 식을 `u=X+MHA(LN1(X))` 로 바꾼다. 혼합 구조가 무조건 금지라는 뜻은 아니다. 다만 두 기준식 중 하나라고 부르면 수식과 구현이 맞지 않는다. 복습: 두 Block 정의.

연습문제 10.7.11 해설 합산 경로를 바꾼 오류

MHA=0 이면 올바른 첫 U=X=[1, 3], 잘못된 첫 $U=LN_1(X)=[-2/\sqrt{5}, 2/\sqrt{5}]$ 다. 이미 다르다. 둘째 FFN 도 0 인 대안을 고르면 Pre-LN 최종 반환이 각각 그 U 라 완전한 반례가 된다. Residual 경로의 표현과 하위 함수에 주는 표현을 바꾸면 동일 연산이 아니다. 복습: 정의 10.7.5.

연습문제 10.7.12 해설 affine 합성의 조건

항등 활성화에서는 $FFN=x(W_1W_2)+(b_1W_2+b_2)$ 다. Bias b_1 도 둘째 변환에 통과한다. 폭 1 ReLU 사례는 f(x)=max(0, x). 만약 모든 x 에 ax+b 와 같다면 x=0 에서 b=0, x=1 에서 a=1 이다. 그러나 x=-1 에서는 affine 값-1 과 ReLU 값 0 이 다르다. 각 부호 영역 안에서 affine 일 수 있는 것과 전역 하나의 affine 인 것은 다르다. 복습: 정의 10.7.3.

연습문제 10.7.13 해설 불변과 정보 손실

새 평균 μ+c 를 빼면 중심화 좌표가 원래와 같고 분산/분모/affine 출력도 같다. 다른 평균의 입력들이 같은 출력으로 가므로 입력 평균을 반환만으로 찾을 수 없다. 규모 변화에서는 LN([-1, 1])=[-1/√2, 1/√2], LN([-2, 2])=[-2/√5, 2/√5] 로 다르다. ε 가 고정되면 분산과 함께 같은 비율로 확대되지 않는다. 복습: 정리 10.7.2.

연습문제 10.7.14 해설 패딩도 Residual 경로를 가진다

p 평균 0.5, 중심화 [1.5, -1.5], 분산 2.25, 분모 √2.5 다. B=[3/√10, -3/√10] 약 [0.948683, -0.948683]. H=[0.948683, 0], F 약 [1.448683, -0.5], Y 약 [3.448683, -1.5] 다. 마지막에 해당 요청의 유효성 게이트를 적용해 0 으로 만들 수 있다. 다음 MHA 에서도 패딩 키를 제외한다. 패딩을 0 으로 만든 것만으로 Softmax 분모에서 자동 제외되지는 않는다. 복습: 예제 10.7.10.

연습문제 10.7.15 해설 두 층과 귀납법

첫 층의 0 행은 {0}, 1 행은 {0, 1} 에만 의존한다. 둘째 층 위치 1 은 그 두 행을 읽으므로 가능한 초기 집합도 {0, 1}. 더 높은 층에서는 허용 $j \le i$ 의 표현이 j 이하에만 의존한다는 귀납 가정으로 합집합이 i 이하에 남음을 보이면 된다. Residual/LN/FFN 도 같은 i 행 안에서 계산한다.

전체 시퀀스 평균을 빼면 위치 2/3 의 값이 위치 1 의 반환에 들어갈 수 있어 전제가 깨진다. Causal MHA 하나만 확인한 증명으로는 부족하다. 실제 의존성이 특정 매개변수에서 상쇄될 수 있어도 허용 경로가 열렸다는 진단은 유지한다. 복습: 정리 10.7.3.

연습문제 10.7.16 해설 입력 생성부터 검사하기

Pre-LN 은 두 반환 가지가 0 이면 $Y_0=X_0=[s, 0, 1]$ 이므로 누출이 직접 남는다. Post-LN 은 $LN_2(LN_1(X_0))$ 다. s=0 이면 첫 좌표의 중심화 값은-1/3, s=2 이면 1 이다. 두 LN 모두 γ=1/β=0 이고 분모는 양수이므로 두 번째 LN 까지 첫 좌표 부호가 유지된다. 따라서 서로 다른 미래 s 가 다른 Y_0 를 만든다.

수정은 미래 s 를 초기 0 행에 넣는 생성 경로를 제거하고 허용된 과거/현재 정보로만 초기 표현을 구성하는 것이다. LN 이나 더 엄격한 키 Mask 를 붙이는 것으로 그 입력 경로를 대신 고칠 수 없다. 복습: 예제 10.7.10.

연습문제 10.7.17 해설 Causal 의 첫 요청

Post 첫 요청은 키 0 만 읽는다. $O_1=2$, $O_2=1$, M=[2, 1, 1], 첫 합 =[3, 1, 3]. Pre 첫 요청도 키 0 만 읽지만 출처는 T 다. $O_1=ρ$, $O_2=0$, M=[ρ, 0, ρ], 첫 합 =[1+ρ, 0, 2+ρ]. 원래 전부 허용한 결과를 그대로 사용할 수 없다.

초기 첫 행이 고정되고 미래 행만 바뀌면 첫 요청 Q 와 허용 K/V 가 그대로다. 행별 LN·FFN·Residual 도 그 첫 행만 처리하므로 뒤 반환이 유지된다. 미래를 초기 첫 행에 미리 섞었거나 전역 연산이 있다면 이 논증은 성립하지 않는다. 복습: 정리 10.7.3.

연습문제 10.7.18 해설 설계 대안과 판정 기준

가능한 계약 하나는 C:n×5, W_O:5×5, W_1:5×7, b_1:7, W_2:7×5, b_2:5 다. LN 마다 γ/β:5, 마지막 특징 축, ε=1e-5 등의 명시적 양수를 사용한다. Head 마다 Mask:n×n, 요청 active:n, Block 입력/반환:n×5, ReLU

FFN 으로 정한다. 두 Head 비교 폭 d_k 는 서로 달라도 각 Head 안 Q/K 폭이 같고 자기 $\sqrt{d_k}$ 로 scaling 하면 된다.

단일 시퀀스 지원으로 정하고 Batch 는 외부 반복, active 는 MHA 반환만 0, 패딩 최종 반환은 필요하면 별도 게이트, 비유한/중간 overflow 거부, 입력 비변경으로 명시할 수 있다. 다른 양의 ε, 유효성 처리, Batch 구현도 허용하되 수식·shape·접근/반환 정책이 일관되고 조용한 방송이 없어야 한다. 특정 수치 하나만 정답은 아니다. 복습: 구현 계약, 예제 10.7.2.

연습문제 10.7.19 해설 keepdims 가 필요한 이유

μ 는 shape(n,) 이다. X:(n, d) 에 바로 빼면 마지막 d 축과 n 을 맞추려 하므로 n≠d 이면 일반적으로 방송 오류다. n=d=2 에서는 우연히 실행되지만 μ=[2, 12] 가 **열 방향**으로 방송된다. 잘못된 중심화는 [[-1, -9], [8, 2]], 올바른 중심화는 [[-1, 1], [-2, 2]] 다.

`mu=X.mean(axis=-1, keepdims=True)` 는 (n, 1), 분산도 (n, 1) 로 유지한다. Batch 에서는 (b, n, 1) 이므로 각 사례의 각 위치에만 방송된다. flatten 하여 통계를 내면 다시 다른 연산이다. 복습: 정의 10.7.2.

연습문제 10.7.20 해설 지원과 정의의 경계

ε=0 은 이 구현의 양수 계약 위반이며 특히 분산 0 에서는 수학적으로 0/0 이다. 모든 비상수 벡터에서도 수학 정의가 없다는 뜻은 아니다. 복소수는 이 실수 정의/구현의 범위 밖, NaN 은 유한 실수 계약 위반이다. M 의 폭 1 은 exact shape 계약 위반이며 방송 실행은 새 연산이다. 유효 요청의 빈 허용 집합은 Attention 확률분포를 만들 수 없다. 비활성 요청의 0 계수는 별도 계약이다.

3 차원 Block 입력은 지원 범위 제외다. LN/FFN 은 그런 Batch 를 처리할 수 있어도 기존 MHA 는 2 차원만 지원한다. 차단 열 NaN 도 배열곱/0×NaN 에서 오염을 일으킬 수 있으므로 현재 구현은 모든 Q/K/V 를 유한하게 요구한다. 키 유효성으로 제외할 패딩은 유한 값으로 만들고 Mask 도 적용한다. 복습: 구현 계약.

연습문제 10.7.21 해설 동일 조건의 참조 비교

검토표에는 LN 마지막 축·분산 ddof/ε/γ/β, W 저장의 전치, 각 투영과 모든 Bias, 비교 폭 scaling, ReLU 위치, Dropout 상태/확률, True 가 허용인지 금지인지/Mask shape/비활성 요청, Pre/Post 기준식·마지막 LN 포함 여부를 넣는다. 입력 dtype/정밀도와 허용오차도 기록한다.

입력과 첫 MHA 입력부터 Q/K/V/S/A/O/C/M, 첫 합/LN, FFN Z/H/F, 둘째 합/마지막 LN 을 순서대로 대조한다. 최초 차이의 조건을 고친 뒤 뒤값을 다시 계산한다. 설정이 다른 결과의 차이는 구현 오류 증거가 아니다. 대안의 표 형식은 자유지만 위 조건의 누락 여부로 자기평가한다. 복습: 구현 계약와 두 완전 계산.

연습문제 10.7.22 해설 구현 대조와 양성 오류

가능한 새 입력은 [[-0.5, 2, 1], [3, -1, 0.25]] 이며 대표 매개변수를 사용한다. `solution_block.py` 의 아래 보충 함수가 두 정상 trace 와 LN_2 생략 오류를 재현한다. 먼저 정상 결과를 수식과 대조하고 오류에서 무엇을 재사용해도 되는지 결정한다. 첫 MHA/첫 합까지는 그대로다. FFN **입력부터** U 와 $LN_2(U)$ 가 달라지고 이후 Z/H/F 와 반환이 달라진다. 오류로 계산한 F 를 정상 trace 에 끼워 넣지 않는다.

solution_block.py | learning-source/solution_block.py | Python | L41-L57 (17 줄)
source revision: block-source-v0.1

```python
def diagnose_missing_ln():
    """ 연습 22: 새로운 입력으로 정상 두 trace 와 LN₂ 생략을 대조한다."""
    from block import example_inputs, feed_forward, residual
    inputs = list(example_inputs())
    inputs[0] = np.array([[-.5, 2., 1.], [3., -1., .25]])
    post, pt = post_ln(*inputs)
    pre, rt = pre_ln(*inputs)
    wrong_update, wrong_ffn = feed_forward(rt["u"], *inputs[3])
    wrong = residual(rt["u"], wrong_update)
    print(" 연습 22 Post 반환", post, sep="\n")
    print(" 연습 22 Pre 반환", pre, sep="\n")
    print(" 오류 FFN 입력", rt["u"], sep="\n")
    print(" 오류 첫 선형", wrong_ffn["linear"], sep="\n")
    print(" 오류 반환", wrong, sep="\n")
    assert not np.allclose(rt["ffn_input"], rt["u"])
    assert not np.allclose(pre, wrong)
    return pt, rt, wrong
```

정상 Post 반환은 [[-0.540191, -0.854485, 1.394676], [0.508714, 0.858111, -1.366825]], 정상 Pre 반환은 [[0.475907, 0.159802, 2.307802], [2.397460, 0.197490, 0.339677]] 이다. 오류 반환은 [[1.282634, 0.167854, 1.493023], [2.581454, 0.341807, 0.300000]] 로 달라진다. 다른 입력도 허용한다. 자기평가는 원입력 비변경, shape/축·FFN 의 중간값·두 합·반환과 식의 대응, 오류의 최초 단계, 최종 차이를 드러내는 양성 대조를 기준으로 한다. 오류의 최종 변화가 0 인 입력도 가능하며 그것만으로 두 함수의 동등성을 주장하지 않는다. 복습: 예제 10.7.9, 구현 계약.

선택적 심화 해설

심화문제 10.7.1 해설 직접 경로와 Jacobian

열벡터 Jacobian 규약에서 $J_y = I + J_F(x)$ 다. Post 의 한 갱신에서는 $J_y = J_{\mathrm{LN}}(x + F(x))(I + J_F(x))$. Pre 의 한 갱신에서는 $J_y = I + J_F(\mathrm{LN}(x))J_{\mathrm{LN}}(x)$ 다. 연쇄법칙의 곱 순서는 실제 함수 입력에 맞춰야 한다. 여러 하위 갱신/층의 Jacobian 은 그 순서로 곱해진다.

F(x)=-x 면 첫 기본 Residual 의 Jacobian0, F(x)=cx 이면 (1+c)I 다. 큰 c 와 반복 갱신은 큰 규모를 만들 수 있다. 따라서 I 항이 있다고 전체 곱의 수치 안정성을 보장하지 않는다. LN 도 모든 방향 정보를 보존하는 함수가 아니다. ReLU 경계에서는 고전 미분 가능성을 별도로 다룬다. 이 도출은 초기화 조건의 연구 결과를 대신하지 않는다. 복습: Residual 정의·LN 이동 불변과 Xiong 외의 초기화·실험 미주.

심화문제 10.7.2 해설 Block 의 순열 등변성

앞 절의 공유 투영 MHA 는 MHA(PX)=P MHA(X) 다. 공유 LN 은 행별 함수라 LN(PX)=P LN(X), 공유 FFN 도 FFN(PX)=P FFN(X). 대응 행 덧셈은 P(A+B)=PA+PB 다. Post 의 두 식에 차례대로 대입하면 $U' = PU, Y' = PY$ 다. Pre 도 정규화 가지와 합산 가지 각각에 같은 항등식을 적용하면 동일하게 Y'=PY 다.

Causal Mask 를 배열에 고정하면 X 순열에 따라 허용 관계가 같이 PBP^{T} 로 옮겨지지 않아 MHA 등변성의 가정이 깨진다. 언어 의미나 과제 정답을 보존한다는 주장은 이 대수 성질과 다른 대상이다. 실제 입력에 위치가 있으면 그 생성 경로도 조건에 포함해야 한다. 복습: 10.6 절의 순열 정리, 정리 10.7.3.

심화문제 10.7.3 해설 조건을 지킨 연구 읽기

단순화한 이론은 단일 Head·투영/FFN 폭 d, Q/K 초기 0 으로 균등 Attention, Gaussian 초기화/입력과 고정 LN Scale1/Shift0 등의 조건을 사용한다. 정리 1 은 명시한 hidden norm 의 집중 조건과 도함수 조건 아래 마지막 FFN W_2 의 초기화 기울기 규모를 다룬다. 전체 현대 모델의 임의 학습 시점/모든 매개변수/모든 설정에 대한 무조건 보장이 아니다.

실험은 번역과 BERT 사전학습 등의 지정 설정에서 배치·학습률/Warm-up 조건을 비교한다. 정리의 조건, 실제 과제/설정, 관찰된 학습 변화, 자신의 추가 추측을 네 칸으로 나누면 경계를 드러낼 수 있다. Xiong 외의 초기화·실험 미주의 원문 locator 를 사용하라. 논문의 마지막 스택 LN 을 빠뜨리고 동일 모델 실험이라고 주장하는 것도 피한다.

실험 계획은 입력 자료/분할·모델 크기·매개변수 초기화 규칙·seed·활성화·Bias·Mask·Dropout·optimizer·학습률/스케줄·평가 지표·여러 반복과 계산 예산을 명시한다. 배치 순서만 독립 변인인지, Warm-up 도 비교 변인인지 구분하고 실패를 포함해 보고한다. 실제 실행 없는 계획은 실험 결과가 아니다. 다른 합리적 통제 계획도 허용하며 연구 claim 을 조건 밖으로 확대하지 않는지를 기준으로 평가한다. 복습: 두 계산의 비교의 본문과 참고문헌.

10.8 Encoder 와 Decoder 의 정보 요구 및 구조 선택 — 해설

구조를 고르기 전에 예측 시점의 입력을 다시 쓰자. 요청 행과 제공 열, 입력 Token 과 감독 Target 를 구별하고 실제 출처를 따라가면 세 이름을 혼동하지 않는다. 계산은 투영 → 점수 → 허용 열 정규화 → 값 집계 → 출력 투영 →Residual/LN/FFN 순서로 한다. 표시된 소수는 반올림된 값이므로 가능한 한 분수·정확한 식 또는 실행 원본으로 다음 단계를 계산한다.

유제 해설

유제 10.8.1 해설 셋째 제공 위치를 제외하기

첫 점수는 [L, 0, 2L] 이지만 허용 집합은 {0, 1} 이다. 지수 [2, 1] 의 분모 3 을 사용해 A_0=[2/3, 1/3, 0] 이고

$$O_0 = \frac{2}{3}[1, 0, 2] + \frac{1}{3}[0, 2, 1] = [2/3, 2/3, 5/3].$$

셋째 열을 0 으로 만든 뒤 원 분모 7 을 그대로 쓰면 합이 1 이 아니므로 틀리다. 패딩 열은 분모에서도 빠져야 한다. 비활성 셋째 Query 는 별도로 A/O 를 0 으로 반환할 수 있다. 그러나 Z_2 가 비영이면 Residual 이 남고, LN 의 β·FFN 의 b 도 값을 만들 수 있다. 최종 0 이 필요하면 명시적 최종 게이트를 쓰며 다음 Block 의 키 유효성도 유지한다. 복습: 예제 10.8.1, 유제 10.8.1, 10.7 절의 패딩 사례.

유제 10.8.2 해설 입력과 예측 위치

입력은 [BOS, 가, 나, 다], Target 는 [가, 나, 다,EOS] 다. 행 0 은 BOS→ 가, 행 1 은 BOS/가 → 나, 행 2 는 BOS/가/나 → 다, 행 3 은 BOS/가/나/다 →EOS 로 연결된다. 허용표는 4×4 대각선을 포함한 하삼각형이다.

정답을 같은 행에 넣으면 행 i 의 Query 와 Value 및 Residual 이 그 정답을 읽는다. 삼각형의 대각선도 그 복사 경로를 허용한다. 대각선이 올바른지는 Mask 모양만으로 알 수 없고 입력–Target 계약을 함께 봐야 한다. 복습: 정의 10.8.4, 유제 10.8.2.

유제 10.8.3 해설 상수 출력을 배제하기

행 1 은 Q=0 이어서 허용 두 열의 점수도 0 이고 A=[1/2, 1/2, 0] 이다. 변경 전 O=[1/2, 1, 3/2]. 과거 행 0 을 [-2, 1, 4] 로 바꾸면 O=[-1, 3/2, 5/2] 다. 허용 정보를 읽는 값 집계가 실제로 반응한다.

항상 0 을 반환하는 함수는 미래 변경 불변에는 통과하지만 이 기대 양성 대조를 만족하지 않는다. 다만 어떤 올바른 매개변수에서는 특정 입력 변화가 우연히 투영/상쇄로 사라질 수 있다. 따라서 반응이 예상되는 구체적 사례를 독립 정답과 비교해야 한다. “매 Token 변화에 항상 모든 출력이 변해야 한다” 를 새 수학적 조건으로 만들지 않는다. 복습: 예제 10.8.5, 유제 10.8.3.

유제 10.8.4 해설 두 유효한 답변 생성 구성

한 유효한 Encoder–Decoder 답은 [문서,SEP, 질문] 을 Encoder 에 넣어 E 를 만들고 Decoder 에는 [BOS, 이미 알려진 답변] 을 주는 것이다. Encoder 의 유효 위치끼리 전체 접근을 허용한다. Decoder Self 는 출력 입력 위치 이하만 읽고 Cross 의 각 요청은 E 의 유효 열 전체를 읽는다. Self 의 Q/K/V 는

Decoder 자체 표현, Cross Q 는 Self 이후 H, K/V 는 E 다. Decoder 반환의 마지막 행이 다음 답변 Token 을 예측한다.

Decoder-only 대안은 `[문서,SEP, 질문,SEP,BOS, 답변 Prefix]` 한 시퀀스다. 모든 Self 는 기본 Causal 관계를 사용한다. 마지막 답변 입력 위치의 Query 는 앞쪽 조건과 알려진 출력 전부를 읽는다. 별도 E/Cross 는 없고 조건 위치 표현도 같은 스택에 있다. 조건 위치는 뒤 답변을 읽지 못한다. 답변 정답은 감독으로만 사용하고 입력에는 이동한 Prefix 를 제공한다.

두 답 모두 요구를 만족한다. Encoder–Decoder 는 각 원문 위치가 전체 조건의 문맥을 반영할 수 있고, 기본 Causal Decoder-only 의 조건 첫 위치는 뒤 조건을 읽지 못한다. 조건 Prefix 내부만 전체 접근을 허용하는 변형은 조건/생성 경계를 별도로 명시하면 허용 대안이다. 성능·비용은 이 출처표만으로 비교할 수 없다. 복습: 예제 10.8.6, 유제 10.8.4.

유제 10.8.5 해설 일부 원문만 도착한 경우

첫 요청은 원 점수 [L, 0,L] 중 0/1 열만 허용하므로 A_0=[2/3, 1/3, 0], O_0=[4/3, 2/3] 이다. 둘째 요청은 원문의 세 위치 모두 허용되므로 A_1=[1/7, 4/7, 2/7], O_1=[6/7, 10/7] 그대로다. 행마다 제공 가용성이 다를 수 있으며 요청 수와 원문 수를 비교하는 삼각형과는 다른 정책이다.

하지만 E_0/E_1 이 전체 원문을 읽었다면 첫 요청도 E 를 통해 아직 도착하지 않은 원문 2 를 간접적으로 읽는다. 입력 전체로 만들어진 E 를 출처 검토 없이 '시점 1 에서 가용' 이라 표시하면 안 된다. 도착한 부분만 인코딩하거나 Encoder 에서도 시간별 의존성을 제한해야 한다. 복습: 예제 10.8.8, 유제 10.8.5.

유제 10.8.6 해설 둘째 Decoder 행의 전체 반환

$O_c \approx [-0.267571, 0.110194]$ 를 W_O^c 에 곱하면 M_c 의 셋째 좌표는 $(O_0 - O_1)/2$ 다. 따라서 M_c 약 [-0.267571, 0.110194, -0.188882]. H 약 [-1.085304, -0.155043, 1.240347] 에 더한 R_2 는 [-1.352875, -0.044850, 1.051465] 다.

평균 약 -0.115420, 분산 0.965965 이므로 분모는 $\sqrt{1.065965}$ 다. 중심화 좌표를 나누면 U 약 [-1.198555, 0.068351, 1.130203] 이다. ReLU 는 [0, 0.068351, 1.130203], FFN 은 그 1/4 인 [0, 0.017088, 0.282551]. R_3 약 [-1.198555, 0.085439, 1.412754] 다.

R_3 평균 0.099880, 분산 1.136593, LN_3 분모 $\sqrt{1.236593}$ 를 사용하여 Y_1 약 [-1.167633, -0.012986, 1.180619] 를 얻는다. 반환 행 $Y_1 = [a, b, c]$ 의 세 좌표로 쓰면 점수는 $[a + c/2, b, -a + c]$ 이므로 [-0.577324, -0.012986, 2.348253]. 이 행은 입력 y_1 에 대응하며 다음 y_2 를 예측한다.

E 의 둘째 행은 원문 위치 1 이고 반환의 둘째 행은 출력 입력 위치 1 이다. 길이가 달라도 같은 번호라는 이유로 더할 수 없다. 이 사례에서는 폭은 우연히 같지만 위치 대응이 다르므로 E 에 더하면 직접 갱신 대상 계약을 위반한다. 복습: 예제 10.8.10, 유제 10.8.6.

유제 10.8.7 해설 초기 입력 생성 경로의 수정

전체 평균에 미래 D_2 가 포함되어 $\tilde{D}_0$ 와 $\tilde{D}_1$ 을 바꾼다. 요청 0 에서는 Q 경로와 Residual 직접 경로, 자기 K/V 경로에 미래 정보가 들어간다. 요청 1 에서는 자기 표현과 과거로 읽는 오염된 행 0 을 통해서도 들어온다. 금지 열 2 의 Mask 를 바르게 두어도 우회 경로가 남는다.

한 수정은 전체 평균을 제거하고 D_i 의 Token/위치 표현만 쓰는 것이다. 다른 수정은 $\widetilde{D}_i = D_i + (i+1)^{-1} \sum_{r \le i} D_r$ 로 바꾸는 것이다. 후자는 허용 Prefix 를 한 번 더 혼합하는 새 입력 설계이며 첫 수정과 수치가 같을 필요는 없다. 초기 의존성이 허용 범위 안이어서 이후 Causal 귀납 조건을 만족할 수 있다.

미래 행 2 만 바꿔 앞 요청 0/1 이 유지되는지 확인하고, 행 1 의 허용 과거 0 을 바꿔 독립 계산상 기대되는 O/Y 변화도 확인한다. 상수 0 은 후자를 실패하므로 제외한다. 복습: 예제 10.8.11, 유제 10.8.7.

이해 확인 해설

이름과 허용표 패딩·권한 밖 세그먼트가 있으면 Encoder 도 그 열을 제외해야 한다. Cross 의 셋째 제공 열이 유효하고 이미 가용하다면 요청 2 행이라는 이유로 막지 않는다. 두 축은 서로 다른 위치 집합이다. 질문으로. 복습: 정의 10.8.2.

구조와 학습 목표 Bidirectional 은 접근 정책이다. 분류·위치별 감독 등 다른 목표도 설계할 수 있다. 예시 MASK 입력에는 정답 사과를이 Token 입력에 그대로 들어가지 않고 감독에만 있으므로 직접 복사하지 않는다. 실제 BERT 의 전체 MLM 입력 변형을 MASK-only 예시와 동일시하지 않는다. 질문으로. 복습: 예제 10.8.3과 BERT 미주.

병렬 학습 행 0 의 허용 집합은 {BOS} 뿐이다. 행 2 의 y_2 는 배열에 있어도 읽지 못한다. 같은 Token 값의 반복은 서로 다른 위치의 공급 시점을 합치지 않는다. 시퀀스 위치와 입력 이동이 기준이다. 질문으로. 복습: 정의 10.8.4.

반환하는 행 O 는 요청 H 의 두 행에 대응한다. E 는 세 K/V 제공 위치다. 제공 위치 3 행을 반환하려면 세 요청으로 정의한 다른 연산이 필요하다. 이번 O 를 새 Encoder 표현이라고 부르면 요청/갱신 대상이 뒤집힌다. 질문으로. 복습: 정의 10.8.6.

비활성 요청 O=0 은 Attention 반환 계약이다. Residual 입력 D 가 비영이거나 LN β·FFN Bias 가 비영이면 후속 표현이 0 일 필요가 없다. 패딩을 다음 층의 키로 허용하면 그 값이 활성 요청에 전달될 수 있다. 최종 게이트와 key_valid 를 별도로 관리한다. 질문으로. 복습: 10.7 절과 실습 계약.

선택의 이유 Decoder-only 도 원문을 Prefix 에 먼저 넣어 조건부 생성할 수 있다. Encoder-only 가 현재 완성 입력 표현만 반환한다면 순서별 출력 입력·미래 차단·Token Readout·생성 반복 계약을 추가해야 한다. 그 추가 구조가 무엇인지 설명해야 하며 이름만으로 생성 경로가 생기지 않는다. 질문으로. 복습: 예제 10.8.12.

독립 연습 해설

연습문제 10.8.1 해설 새 조건의 전체 구조

보고서 내용과 질문을 [보고서 1, 보고서 2, 보고서 3, 질문] 의 네 개 교육용 위치로 표현하는 답을 택하자. 실제 여러 Token 보고서는 더 많은 행을 쓰지만 역할은 같다. Token/센서 입력 투영과 위치 표지를 반영하여 Z:4×d_E 를 만든다. 정답 레이블·미래 답변은 Z 생성에 사용하지 않는다. Encoder Self 의 Q/K/V 는 같은 Z 또는 직전 Encoder 반환에서 나오고 B_enc 는 4×4 전부 1 이다. 행별 Residual/LN/FFN 뒤 E:4×d_E 를 반환한다.

현재 답변 입력이 [BOS,y1] 이면 D:2×d_D 다. Self 허용표는 [[1, 0],[1, 1]], Cross 는 2×4 전부 1 이다. Self Q/K/V 는 D, Cross Q 는 Self 갱신 뒤 H, K/V 는 E 다. Cross 비교 폭을 d_k, 값 폭을 d_v 로 두고 O:2×d_v 를 W_O:d_v×d_D 로 반환한다. Decoder 후속 LN/FFN 뒤 Y:2×d_D 가 나온다. 마지막 Y_1 의 Readout 은 다음 y_2 를 예측한다.

질문을 별도 조건으로 인코딩하여 보고서 E 와 이어 붙이는 대안도 허용한다. 그 경우 제공자의 길이·각 표현의 생성 과정·질문과 보고서 사이 정보 교환 여부를 다시 명시해야 한다. 판정 기준은 가용 입력, 미래 차단, 요청/제공 출처, 반환 shape, 질문 조건화, 실제 예측 위치의 여섯 요소다. 한 가지 구조명을 맞힌 것만으로 수행을 충족하지 않는다. 복습: 연습문제 10.8.1, 예제 10.8.12, 예제 10.8.10.

연습문제 10.8.2 해설 세그먼트의 전체 접근

허용표는

$$B = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}, \qquad \text{active} = [1, 1, 1, 0].$$

위치 0 의 Q 는 자기 표현, 허용 K/V 는 문서 A 의 0/1 행이다. Self 이므로 투영 전 전체 출처 집합은 같지만 허용 관계가 문서 경계를 제한한다. 전부 1 은 문서 B 와 패딩을 읽게 한다. 단순 tril 은 위치 0 이 같은 완성 문서 A 의 뒤 위치 1 을 못 읽고 위치 2 는 문서 A 를 읽게 하므로 두 요구를 모두 위반한다. 비활성 마지막 행은 정상 확률분포의 빈행이 아니라 별도 0 계약이다. 복습: 연습문제 10.8.2, 정의 10.8.2.

연습문제 10.8.3 해설 두 키만 읽는 Encoder

S_0=[L, 0, 2L] 이지만 허용 지수는 2/4 다. A_0=[1/3, 0, 2/3] 이고

$$O_0 = [5/3, 2/3, 2/3], \quad M_0 = [5/6, 1/3, 1/3], \quad R_{1,0} = [11/6, 1/3, 7/3].$$

평균 3/2, 중심화 [1/3, -7/6, 5/6], 분산 13/18 이다. 첫 LN 은 이 중심화 벡터를 $\sqrt{13/18 + 0.1} = \sqrt{37/45}$ 로 나눈 값, 약 [0.367607, -1.286626, 0.919018] 이다.

같은 층의 모든 Q/K/V 입력 Z 가 고정되고 행별 정규화라면 다른 요청의 B 행 변경은 첫 요청의 계산에 직접 영향을 주지 않는다. 그러나 다른 요청의 반환을 다음 층의 키로 읽으면 다음 층에서는 영향을 줄 수 있다. 한 층과 스택 의존성을 구별한다. 복습: 연습문제 10.8.3, 예제 10.8.2.

연습문제 10.8.4 해설 유효 평균만 사용하기

유효 평균 r=[2, 0, 1] 이고 점수는 [3, 0] 이다. 둘째 점수는 r_1-r_2+1=0 이다. 패딩까지 포함하면 r'=[14/3, 10/3, 4], 점수는 [26/3, 1/3] 이다. 같은 첫 범주가 선택되어도 점수 계산은 달라졌으며 다른 매개변수에서는 결정도 바뀔 수 있다.

패딩 반환값이 0 이더라도 분모를 3 으로 쓰면 유효 평균과 다르다. 유효 행 수 2 를 사용해야 한다. 특별한 분류 Token 은 한 설계이며 유효 풀링이나 별도 Readout 도 가능하다. 복습: 연습문제 10.8.4, 예제 10.8.3.

연습문제 10.8.5 해설 이동 오류와 첫 빈행

잘못된 입력 행 0 의 7 은 행 0 의 Target7 과 같은 정답 위치다. 자기 Q/V 와 Residual 경로를 통해 그 값을 읽는다. 동일 오류가 행 1/2 에서도 반복된다. 수정 입력은 [0, 7, 8], Target 는 [7, 8, 9]. 허용 입력은 행 0:{0}→7, 행 1:{0, 7}→8, 행 2:{0, 7, 8}→9 다. 대각선 허용은 이 계약에서는 정상이다.

정답 입력을 그대로 두고 대각선만 금지하면 행 0 은 모든 키가 차단된다. 유효 첫 예측의 Softmax 분모가 0 인 문제가 생기며 Query/Residual 은 여전히 자기 정답을 담는다. 모든 누출 경로를 해결하지 못한다. 입력 이동으로 문제의 시작점부터 고쳐야 한다. 복습: 연습문제 10.8.5, 정의 10.8.4.

연습문제 10.8.6 해설 미래와 과거의 다른 시험

행 1 Q=0 이므로 S_1=[0, 0, 0]. 허용열 0/1 에서 A_1=[1/2, 1/2, 0], O_1=[1/2, 1, 3/2] 다. 미래 행 2 변경은 허용 V 와 Q 를 바꾸지 않아 O_1 이 같다.

허용 과거 0 을 [3, 0, 0] 으로 바꾸어도 행 1 Q=0 이므로 가중치는 같다. O_1 은 $([3,0,0]+[0,2,1])/2 = [3/2,1,1/2]$ 로 바뀐다. 미래 시험은 금지 경로 차단, 과거 시험은 정상 집계 보존과 상수 구현 배제를 확인한다. 시험이 보는 것은 지정 입력의 출력이며 일반 Causal 보장은 정리의 전제와 증명으로 얻는다. 복습: 연습문제 10.8.6, 예제 10.8.5.

연습문제 10.8.7 해설 원래 위치를 복원해서 비교하기

제공 열 순서가 원래 [2, 0, 1] 이므로

$$B = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}.$$

A 의 열도 기존 [0, 1, 2] 에서 [2, 0, 1] 로 옮기고 V 를 같은 순서로 옮긴다. 합은 같은 원래 위치별 쌍의 합이라 O 가 보존된다. K 와 V 중 하나만 옮기면 점수가 가리키는 값이 달라진다.

배열 tril 은 첫 요청이 첫 열인 미래 위치 2 를 읽고 정상 위치 0 인 둘째 열을 놓친다. 둘째 요청도 미래 2 를 허용하며 과거/현재 위치 1 을 놓친다. 위치와 배열의 차이를 정책과 출처 대응 양쪽에서 고쳐야 한다. 복습: 연습문제 10.8.7, 10.3 절의 재배열 사례.

연습문제 10.8.8 해설 이미 제공된 Prefix 의 마지막 행

생성 입력 `[BOS,y1]` 은 2 행이며 마지막 행 1 은 다음 y_2 를 예측한다. 학습 4 행의 행 0 허용 집합은 {BOS} 뿐이다. y_3 는 입력 행 3 에 있지만 Mask 가 차단하고, 초기 입력과 모든 후속 행별 연산도 그 정보를 우회 공급하지 않아야 한다.

학습은 모든 입력값이 메모리에 있어도 요청마다 접근을 제한한다. 생성에서는 아직 선택하지 않은 뒤 Token 자체가 입력에 없다. 병렬 학습 출력 4 개가 서로 같은 가용 정보를 읽는 것은 아니다. 복습: 연습문제 10.8.8, 예제 10.8.4.

연습문제 10.8.9 해설 각 축의 역할

W_Q:5×2, W_K:3×2, W_V:3×6 이다. Q:4×2, K:7×2, V:7×6, S/A:4×7, O:4×6. W_O:6×5, M:4×5 이고 H 에 더한다.

O:4×6 을 E:7×3 에 더하면 행/폭이 모두 다르고 요청/제공 대응도 틀린다. Q=EW_Q 는 3 과 5 의 곱 폭이 안 맞고, 차원이 우연히 맞도록 다른 행렬을 쓰더라도 E 의 7 개 행이 요청으로 바뀌어 Decoder4 개 요청을 갱신하는 연산이 아니다. shape 와 출처 두 가지를 모두 검사한다. 복습: 연습문제 10.8.9, 정의 10.8.6.

연습문제 10.8.10 해설 새로운 직사각형 Cross 전 계산

L=ln2 라 두면

$$Q=\begin{bmatrix}1 & 1\\ 2 & 0\end{bmatrix},\quad K=\sqrt{2}L\begin{bmatrix}0 & 1\\ 1 & 0\\ 1 & 1\end{bmatrix},\quad V=\begin{bmatrix}-1 & 1\\ 1 & 2\\ 0 & 3\end{bmatrix}.$$

Q/K 의 각 내적을 $\sqrt{2}$ 로 나누면

$$S=\begin{bmatrix}L & L & 2L\\ 0 & 2L & 2L\end{bmatrix}.$$

허용 지수는 첫 행 [2, 2, 4], 둘째 [1, 4, 4] 다. 따라서

$$A=\begin{bmatrix}1/4 & 1/4 & 1/2\\ 1/9 & 4/9 & 4/9\end{bmatrix},\quad O=\begin{bmatrix}0 & 9/4\\ 1/3 & 7/3\end{bmatrix}.$$

첫 반환의 첫 좌표는 $-1/4+1/4+0=0$ 이고 둘째는 $1/4+2/4+3/2=9/4$ 다. 둘째 반환의 두 좌표는 각각 $-1/9+4/9=1/3$, $1/9+8/9+12/9=7/3$ 이다. $W_O=I_2$ 라 M=O 이며

$$R_2=H+M=\begin{bmatrix}1 & 13/4\\ 7/3 & 7/3\end{bmatrix}.$$

첫 평균 17/8, 중심화 [-9/8, 9/8], 분산 81/64. ε=1/4 를 더한 분모는 $\sqrt{97/8}$ 이므로

$$U = \begin{bmatrix} -9/\sqrt{97} & 9/\sqrt{97} \\ 0 & 0 \end{bmatrix} \approx \begin{bmatrix} -0.913812 & 0.913812 \\ 0 & 0 \end{bmatrix}.$$

둘째 행은 상수라 평균 7/3, 분산 0 이고 중심화 0 이다. ε>0 이라 정상 0 반환이다. 두 출력 행은 두 Decoder 요청에 대응하며 세 Encoder 제공 행을 직접 갱신하지 않는다. 현재 조건 E 는 주어진 Encoder 출력이고 이번 문제에서 원문 →Encoder 계산은 요청하지 않았다. 복습: 연습문제 10.8.10, 예제 10.8.7.

실행 원본의 아래 함수는 같은 문제를 Q/K/V 부터 LN 통계까지 재현한다.

solution_architectures.py | learning-source/solution_architectures.py | Python | L1-L26 (26 줄)
source revision: architectures-source-v0.1

```python
""" 새 독립 Cross/Encoder 변형의 수치 풀이를 재현한다."""
import numpy as np
from architectures import full_allowed, exact_cross, parameters
from sources import cross_attention, project
from block import layer_norm, residual


def problem_cross():
    """ 독립 문제 10/11: 주어진 E, 두 요청·세 제공, LN 까지."""
    h = np.array([[1.,1.],[2.,0.]])
    e = np.array([[0.,1.],[1.,0.],[1.,1.]])
    wq = np.eye(2); wk = np.sqrt(2.)*np.log(2.)*np.eye(2)
    wv = np.array([[1.,2.],[-1.,1.]])
    results = {}
    for name, mask in [(" 전체",full_allowed(2,np.ones(3,bool))),
                       (" 잘못된 _ 삼각형",np.tri(2,3,dtype=bool))]:
        trace = cross_attention(h,e,wq,wk,wv,mask)
        r = residual(h,trace[-1])
        u, norm = layer_norm(r,np.ones(2),np.zeros(2),.25)
        results[name] =
    ↪  dict(q=trace[0],k=trace[1],v=trace[2],s=trace[3],a=trace[4],o=trace[5],r=r,u=u,norm=norm)
    return results


def main():
    np.set_printoptions(precision=6,suppress=True)
    for name, trace in problem_cross().items():
```

연습문제 10.8.11 해설 원문 기여를 제거한 오류

첫 행은 키 0 만 허용하므로 A_0=[1, 0, 0], O_0=[-1, 1]. 둘째 허용 점수는 [0, 2L] 이라 A_1=[1/5, 4/5, 0], O_1=[3/5, 9/5] 다. 올바른 첫 [0, 9/4] 와 둘째 [1/3, 7/3] 와 다르다.

원문 2 의 V=[0, 3] 은 둘째 좌표에 정상 기여하는데 두 요청 모두에서 사라졌다. 원문 1 도 첫 요청에서 제거됐다. 완성 원문은 이미 제공된 조건이므로 번역 미래 Target 차단과 무관한 손실이다. 출력 Self 에는 Causal 을 유지하고 Cross 는 유효 원문 전체를 허용해야 한다. 복습: 연습문제 10.8.11, 예제 10.8.8.

연습문제 10.8.12 해설 E 의 의존성도 시점을 지켜야 한다

도착 시간만 비교한 Cross 관계는 [[1, 0, 0],[1, 1, 1]] 이다. 그러나 시점 5 이후 양방향으로 만든 E_0 는 원문 1/2 에도 의존할 수 있다. 시점 1 요청 →E_0 의 K/V→ 미래 원문 2 라는 간접 경로가 있다. 열 0 의 번호가 과거라는 것만으로 안전하지 않다.

한 유효 수정은 시점 1 에는 도착 원문 0 만 Encoder 에 주어 $E^{(1)}$ 을 만들고, 시점 6 에는 세 원문으로 $E^{(6)}$ 을 만드는 것이다. Cross 가 그 시점에 실제 계산된 E 를 읽게 한다. 다른 답은 원문 시간의 Causal

Encoder 를 써 E_0 가 원문 0 만 읽도록 하고 Cross 를 도착 관계로 제한하는 것이다. 각 가용 표현의 의존 집합이 허용 시점에 포함되는지 설명해야 한다. 복습: 연습문제 10.8.12, 정리 10.8.2.

연습문제 10.8.13 해설 요청과 제공의 역전

잘못된 Q 는 E 의 3 개 원문 행을 요청으로 만들고 K/V 는 H 의 2 개 출력 행을 제공자로 만든다. O 는 3 행으로 돌아와 원문 요청에 대응한다. 이는 반대 방향의 다른 Cross 이며 Decoder2 행 갱신이라 부를 수 없다.

올바른 W_Q:3×2, W_K:2×2, W_V:2×1, Q:2×2, K:3×2, V:3×1 이다. S/A:2×3, O:2×1, W_O:1×3 으로 M:2×3 을 만든다. A 를 전치하면 행 정규화와 요청 뜻이 바뀌며 V 출처도 바로잡지 못한다. 출처 투영부터 다시 해야 한다. 복습: 연습문제 10.8.13, 정의 10.8.6.

연습문제 10.8.14 해설 우회 경로와 허용 정보

D_2 가 전체 평균에 들어가 $\widetilde{D}_0$ 를 바꾸면 첫 경로는 Q/K/V→Self 집계 →Y_0, 둘째는 Residual 의 직접 입력 →LN/FFN→Y_0 다. 요청 1 도 오염된 과거 행 0 을 읽을 수 있다. Mask 의 금지 열 2 와 독립적인 경로다.

전체 평균을 제거하면 초기 행 i 는 위치별 D_i 만 읽는다. Causal 평균으로 바꾸면 행 i 가 0…i 를 추가 집계하므로 다른 유효 설계다. 입력 이동과 위치 정보가 올바르고 후속 모든 함수가 행별/Causal 이면 두 방식 모두 미래를 차단한다. 정상 과거가 없어지는 수정은 피한다.

검사는 원 입력 고정/미래 2 만 변경 → 행 0/1 불변, 과거 0 만 변경 → 행 1 에서 독립 계산이 예측한 변화라는 두 대조로 한다. Q=0 인 행 1 과 비영 값 투영을 고르면 과거 변경이 반드시 해당 예제 O 에 드러나기 쉬워 반응 시험을 설계할 수 있다. 상수 0 은 예상된 O 의 수치도, 양성 변화도 못 맞춰 탈락한다. 복습: 연습문제 10.8.14, 예제 10.8.11, 정리 10.8.1.

연습문제 10.8.15 해설 패딩·빈행·후속 0 을 분리하기

첫 요청의 허용 점수 [L, 0] 에서 A_0=[2/3, 1/3, 0], O_0=[4/3, 2/3]. 둘째 요청은 비활성이므로 A_1=[0, 0, 0], O_1=[0, 0] 이며 확률분포라고 부르지 않는다.

활성 첫 요청을 전부 차단하면 허용 지수 합이 0 이므로 이 실습에서는 ValueError 다. 임의 균등/NaN/0 을 정상 Softmax 로 반환하면 안 된다. 빈 조건을 다루려면 별도 null 제공자 또는 하위 연산 생략 등의 계약을 새로 정의해야 한다.

비활성 O=0 뒤 H=[1, 0, 2] 를 그대로 더하면 Residual 은 H 다. γ=1, β=0, ε=0.1 의 LN 은 [0, -1/$\sqrt{(2/3+0.1)}$, 1/$\sqrt{(2/3+0.1)}$] 로 비영이다. FFN Bias 가 있으면 0 입력에서도 비영이 될 수 있다. 패딩 최종 게이트와 키 제외가 별도로 필요하다. 복습: 연습문제 10.8.15, 실습 계약.

연습문제 10.8.16 해설 허용 정보와 정의한 모델의 일치

Z 가 허용된 원문 Token/위치만 읽었다면 미래 출력 누출이 없을 수 있다. 그러나 정의한 인터페이스가 Encoder 반환 E 를 제공하기로 했다면 Z 를 넣은 코드는 그 인터페이스를 구현하지 않았다. E 에는 Encoder Self 와 Residual/LN/FFN 의 문맥 변환이 들어가고 Z 에는 그 변환이 없다.

올바른 구현은 E=Encoder(Z) 를 계산한 뒤 K=EW_K,V=EW_V 다. Z 를 직접 조건으로 쓰는 별도 Cross 설계도 명시적으로 선택할 수 있지만, 그것을 Encoder Block 출력이라고 부르거나 같은 모델이라고 주장해서는 안 된다. 그 구조의 요구 충족과 성능은 따로 판단한다. 복습: 연습문제 10.8.16, 예제 10.8.2.

연습문제 10.8.17 해설 동일 기능을 만족하는 다른 경로

Encoder–Decoder 에서는 `[계약서,SEP, 질문]` 을 Token/위치 표현으로 변환하고 유효 조건 전체를 읽는 Encoder 로 E 를 만든다. Decoder `[BOS, 답변 Prefix]` 는 Causal Self 와 전부 허용 유효 E Cross 를 읽는다. H 가 Q, E 가 K/V 이고 마지막 Decoder 행의 점수가 다음 답변 Token 을 예측한다. 정답 전체를 E 에 넣지 않는다.

Decoder-only 에서는 `[계약서,SEP, 질문,SEP,BOS, 답변 Prefix]` 를 하나의 시퀀스로 둔다. Self Q/K/V 가 그 스택의 같은 표현 집합에서 나오며 기본 Causal 관계를 적용한다. 조건은 생성 위치보다 앞에 있어 마지막 답변 요청이 모든 유효 계약서/질문 Token 을 읽을 수 있다. 학습 Target 도 한 위치 이동하고 답변 감독과 입력을 분리한다. 과제에 따라 손실을 답변 부분에만 적용하는 추가 학습 계약을 둘 수 있으나 이 문제의 구조 설명에 전체 손실 도출은 필요 없다.

기본 Decoder-only 의 계약서 첫 행은 뒤 계약서 내용을 읽지 못한다. Encoder E 의 각 원문 행은 전체 허용 조건을 읽을 수 있다. Prefix 내부 전체 접근 변형은 허용 가능한 제 3 안이지만 미래 출력 → 조건 경로를 막는 Block 관계를 명시해야 한다. 우위를 주장하려면 같은 과제·자료·매개변수/비용 기준·평가 방식 등 실제 비교 조건과 결과가 필요하다. 복습: 연습문제 10.8.17, 예제 10.8.6, 예제 10.8.12.

연습문제 10.8.18 해설 분류를 읽는 위치 바꾸기

`[문서 Token 들, 분류용 입력 위치]` 를 두고 마지막 위치의 표현에 두 범주 Readout 을 달 수 있다. 마지막 위치는 Causal 관계에서도 앞 문서 전부와 자기 입력을 읽는다. 실제 분류 정답을 그 입력 Token 으로 주지는 않는다. 분류용 Token 은 요청을 표시하는 입력이다.

첫 문서 행이 뒤 문서를 읽지 못하는 것은 그대로다. 그래서 Encoder 의 모든 행이 양방향 문맥을 반영하는 구조와 동일하지 않다. 그러나 단일 분류 출력의 정보 요구는 마지막 위치에서 충족할 수 있다. Readout·감독 설계와 실제 학습이 추가로 필요하며 접근 가능성만으로 정확한 분류를 보장하지 않는다. 복습: 연습문제 10.8.18, 구조 선택.

연습문제 10.8.19 해설 세 단정의 교정

Encoder-only 는 Bidirectional 표현을 만드는 구조이며 MLM 이라는 목표와 같지 않다. 입력 `[나는,MASK, 좋아한다]` 와 별도 Target= 사과를은 한 교육용 MLM 예시다. 분류 레이블을 감독으로 주는 다른 학습도 가능하다. BERT 의 실제 MLM 전체 변형과 구별한다.

Decoder-only 는 `[지시, 원문,SEP,BOS, 출력 Prefix]` 에서 다음 출력을 예측하여 조건부 생성할 수 있다. 원문이 생성보다 앞에 있고 미래 정답을 사용하지 않으면 된다. Cross 가 반드시 필요한 것은 아니다.

Encoder–Decoder 는 출처/스택/인터페이스의 구분이며 LN 배치까지 자동 고정하지 않는다. 원 Transformer 의 Post-LN 과 T5§2.1 의 하위 연산 입력 정규화·가산 편향 없는 변형을 구별할 수 있다. GPT-2 보고서의 입력 LN/스택 마지막 LN 은 별도 Decoder-only 대표 사례다. 이 차이에서 보편적 우위를 추론하지 않는다. 복습: 연습문제 10.8.19, 정의 10.8.5와 각 미주.

연습문제 10.8.20 해설 코드 축과 출처 수정

Q=H@wq, K=E@wk, V=E@wv 다. 점수는 m×n. 허용 열만 행별 최대를 빼고 exp 한 뒤 마지막 제공 열 축 `axis=1` 로 분모를 계산한다. O=A@V 로 m×d_v 를 반환한다. `A.T@V` 는 일반적으로 곱이 성립하지 않고 요청/제공 축도 틀린다.

이 실습의 기존 함수로 명료하게 고치면 다음과 같다. 함수 내부는 핵심 연산이 드러난 구현이고 고수준 모델 API 가 아니다.

실행 결과 | Text

```
q = H @ wq
k = E @ wk
v = E @ wv
scores, a, o = masked_attention(q, k, v, allowed, active)
```

`masked_attention` 은 Softmax 전에 허용 열을 고르고 활성 빈행은 거부한다. 동일 길이/폭이라 잘못된 코드가 우연히 실행돼도 Q 요청이 E 에서 나오는 의미 역전과 열별 정규화 오류는 남는다. shape 가 맞는 것과 구조가 맞는 것은 별도다. 복습: 연습문제 10.8.20, 10.3 절의 원본, 정의 10.8.6.

연습문제 10.8.21 해설 통합 경로를 복원하기

첫 오류는 Self 갱신 뒤 H 대신 초기 D 로 Cross Q 를 만드는 것이다. Post-LN 계약의 요청은 H 이고, 같은 투영이어도 Q 수치가 달라진다. 둘째 오류는 Cross M 을 Encoder E 에 더하는 것이다. M 은 Decoder 요청 수 2 행, E 는 원문 제공 3 행으로 shape 가 다르고 반환 위치도 다르다.

올바른 원문 경로는 C+P 에서 Z 를 만들고 Encoder 의 Self·Residual·LN·FFN 을 거쳐 E 를 얻은 뒤 Cross 의 K/V 로 투영하는 것이다. Prefix 경로는 D 의 Causal Self 반환을 D 에 더하고 LN_1 을 적용하여 H 를 얻은 뒤 Cross 의 Q 로 투영한다.

Cross O 를 W_O 로 모델 폭에 반환한 M_c 를 H 에 더하고 LN_2 로 U 를 만든다. U 의 FFN 반환을 U 에 더하고 LN_3 로 Y 를 얻는다. 마지막 Y 행의 W_t 점수가 다음 Token 을 예측한다.

이 Forward 호출에서 Cross 는 E 를 제자리 갱신하지 않는다. 하지만 다른 Encoder 호출이나 학습의 매개변수 갱신은 E 를 바꿀 수 있다. 영원히 고정이라는 주장은 틀리다. 복습: 연습문제 10.8.21, 예제 10.8.9, 예제 10.8.10.

연습문제 10.8.22 해설 한 연산에서 스택으로

위치 축 LN 은 현재 행 통계에 미래 행을 포함하여 Mask 밖 혼합 경로를 만든다. 한 Attention 의 불변 시험이 맞아도 그 다음 함수가 미래를 읽으면 전체 출력은 안전하지 않다. 마지막 특징 축의 행별 LN 과 위치별 FFN 으로 고치고 전역 Pooling 을 출력 위치에 잘못 되돌려 넣지 않는다.

귀납 가정은 초기 D_i 가 허용 Prefix 만 읽음, 모든 Self 가 원래 위치 기준 Causal/패딩 정책을 지킴, Cross E 가 허용 조건만으로 만들어짐, 모든 추가 연산이 새 금지 출처를 만들지 않음, 매개변수/위치/접근 정책이 비교 조건에서 고정됨이다. 이 가정으로 각 층의 허용 의존 집합을 증명한다.100 개 수치 시험은 특정 구현과 유한 사례의 오류 탐지이며 가정 없는 실수 전체 증명은 아니다. 복습: 연습문제 10.8.22, 정리 10.8.1, 정리 10.8.2.

심화 해설

심화문제 10.8.1 해설 의존 집합의 합성 상한

한 Self 층의 행 i 에 대해

$$\mathcal{D}_i^{(\ell+1)} \subseteq \mathcal{D}_i^{(\ell)} \cup \bigcup_{j:B_{ij}=1} \mathcal{D}_j^{(\ell)}$$

가 상한이다. Q 는 자기 행 의존 집합을, K/V 는 허용 제공 행 의존 집합을 읽고, 점수/정규화/값 집계는 그 합집합 밖의 입력을 새로 만들지 않는다. Residual 의 자기 행도 포함한다. 행별 LN/FFN 은 같은 집합의 함수를 적용하므로 상한을 확대하지 않는다.

Cross 를 연결하면 현재 요청의 의존 집합 $\mathcal{H}_i$ 에 $\bigcup_{j:B^c_{ij}=1} \mathcal{E}_j$ 를 합친 것이 상한이다. Encoder E 가 완성 허용 원문만 읽으면 조건 x 와 출력 Prefix 의 합집합을 얻는다. Causal Self 에서 초기 $\mathcal{D}_i^{(0)} \subseteq \{D_0, \dots, D_i\}$ 이면 모든 허용 j≤i 의 집합도 그 안이라 귀납이 닫힌다.

스트리밍에서 열 0 만 열어도 $\mathcal{E}_0$ 에 미래 원문 2 가 들어 있으면 그 정보가 합집합에 남는다. 제공 위치 번호만 제한하지 말고 제공 표현의 의존 집합을 검사해야 한다. 위 식은 포함관계이며 등식이나 비영 영향 보장이 아니다. 영 투영·상쇄·정규화가 실제 영향을 제거할 수 있다. 복습: 심화문제 10.8.1, 정리 10.8.1, 연습문제 10.8.12.

심화문제 10.8.2 해설 Prefix 내부 전체 접근의 경계

조건 0–3 과 생성 입력 4–6 을 구분하면

$$B = \begin{bmatrix} 1 & 1 & 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 1 & 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 1 & 1 & 1 & 1 \end{bmatrix}.$$

입력 행 5 가 y_1 이므로 그 반환이 y_2 를 예측한다. 조건 행은 초기부터 조건만 담고 모든 층에서 생성 열 4–6 을 읽지 않는다. 따라서 다음 층 조건도 생성 정답으로 오염되지 않는다. 생성 행 i 는 조건 전체와 생성 입력 4…i 에만 의존한다. 행별 후속 함수라는 가정하에 두 집합을 함께 귀납한다.

전 7×7 양방향이면 행 5 가 입력 행 6 의 y_2 를 직접 읽는다. 첫 층에서 조건 행도 y_2 를 섞으면 다음 층 행 5 가 조건을 통해 우회해서도 읽는다. 조건 내부의 전체 접근은 생성 정답과의 전체 접근을 뜻하지 않는다. 복습: 심화문제 10.8.2, 관련 설명, 심화문제 10.8.1.

심화문제 10.8.3 해설 순차 조건의 유효한 두 설계

완성 원문 번역은 모든 원문이 처음부터 허용된다는 조건이 있다. 이 과제는 다르다. 미래 기록을 Encoder 입력에 주면 E 가 그 기록에 의존하고 Cross 가 전부 허용하면 현재 예측으로 전달된다. 출처는 시간별 실제 가용 입력이어야 한다.

첫 설계는 예측 시점 t 에 도착/권한이 확인된 기록만 Encoder 에 넣어 $E^{(t)}$ 를 새로 만든 뒤, Decoder `[BOS, 이미 생성된 보고서]` 의 Causal Self 와 해당 E 의 유효 키 Cross 를 연결한다. 도착한 기록 내부의 Bidirectional 접근은 허용될 수 있으나 세그먼트 권한 R 을 적용한다. 패딩 키는 제외하고 비활성 Query 최종값의 사용도 명시한다. E 가 어떤 시점/입력으로 생성됐는지 함께 저장하는 실험 계약이 필요하다.

둘째 설계는 도착한 기록을 구분자와 시간 표지로 Decoder-only 조건 Prefix 앞에 넣고 보고서 입력을 뒤에 놓는다. 예측마다 실제 허용 기록과 출력 Prefix 로 입력을 구성한다. 단일 Causal 관계 또는 조건 Prefix 내부만 전체 접근하는 관계를 명시하고, 미래 출력이 조건 행에 역으로 들어가지 못하게 한다. 새 기록을 과거 출력 사이에 단순 삽입할 때는 위치/출처 계약이 바뀌므로 같은 계산이라고 주장하지 않는다.

두 설계는 가용 기록·출력 Prefix 만 사용하면 유효할 수 있다. 첫 구조는 별도 조건 표현 E, 둘째는 한 시퀀스의 조건 표현을 쓰며 원문 각 행의 의존성도 다르다. 시간별 미래 불변과 도착한 기록/허용 과거 변경 양성 시험을 함께 설계한다. 임상 정확도·안전성을 검증한 답으로 확대하지 않는다. 판정 기준은 가용성, 의존성, 권한/패딩, 입력–Target 분리, 요청/반환, 대안 비교의 설명이다. 복습: 심화문제 10.8.3, 연습문제 10.8.12, 연습문제 10.8.17.

10.9 다음 토큰 계산과 KV Cache 재사용

해설을 읽는 방법

새 항목 계산에서는 먼저 레이어 입력을 정하고 N→ 투영 → 과거 결합 →Attention→Residual/FFN→ 다음 레이어 순서로 진행하자. 유효성 판단에서는 주소 $(\ell, r, p, K/V)$ 를 붙이고 생성 경로가 바뀌는 최초 지점을 찾는다. 계산이 틀린 위치를 표시한 뒤 본문의 해당 설명으로 돌아가고, 해설을 가려 다시 풀어 보자. 소수는 여섯 자리로 표시한다. 재현 코드는 그 표시값을 다음 단계 입력으로 사용하지 않는다.

유제 10.9.1 해설

문제. 입력은 $H_0^{(0)} = [1, 0]$, 첫 레이어 N 반환은 $[1, -1]/\sqrt{5}$ 다. Head 별 $q = k = (1/\sqrt{5}, -1/\sqrt{5})$, $v = (2/\sqrt{5}, -4/\sqrt{5})$ 다. 허용 Key 가 하나라 두 가중치는 1 이고 C 는 $[0.894427, -1.788854]$ 다. $CW_O = [0.894427, -0.894427]$ 을 원래 h 에 더한다.

$$R_0^{(1)} = [1.894427, -0.894427].$$

그 합에서 평균 0.5, 좌표 편차 약 $[1.394427, -1.394427]$ 를 구한다. 분산은 약 1.944427 이며 N 반환은 약 $[0.812635, -0.812635]$ 다. ReLU 활성도 두 양의 좌표 $[0.812635, 0.812635]$ 여서 F 는 $[0.506317, 0.103159]$ 다. 따라서

$$H_0^{(1)} = [2.400745, -0.791268], \qquad N(H_0^{(1)}) = [0.847402, -0.847402].$$

둘째 레이어 Head1 의 $k = 0.847402, v = 1.694804$, Head2 의 $k = -0.847402, v = -3.389609$ 다. K/V 는 첫 레이어 반환을 정규화한 **둘째 레이어 입력 출처**에서 얻었다. F 에 N(h) 를 재사용하면 Attention 반환이 FFN 입력에 반영되지 않아 이 Block 식과 다르다. 복습: Block 계약, 길이 2 계산.

유제 10.9.2 해설

문제. 각 레이어에서 Head1 K 는 2×2, V 는 2×1 이고 Head2 K 는 2×1, V 는 2×2 다. 위치 4 를 처리한 뒤 각각 $3 \times 2, 3 \times 1, 3 \times 1, 3 \times 2$ 다. 새 Query 는 Head1 1×2, Head2 1×1 이며 각 점수/비율은 1×3 이다.

각 출력은 1×1, 1×2 라 Concat 은 1×3 이다. W_O 는 3×2 여서 모델 폭 2 로 반환한다. 두 레이어의 배열은 각각 따로 보관한다. Head 가 둘이라는 이유로 K 와 V 의 폭을 모두 2 로 맞추거나 값 폭을 비교 폭으로 나누는 오류를 피하자. 복습: Cache 주소.

유제 10.9.3 해설

문제. 과거 Cache 는 대표 예제의 레이어 1 위치 0/1 이고 새 입력만 $h = [0.2, 1]$ 이다. 평균 0.6, 분산 0.16 이므로 $z = [-0.4, 0.4]/\sqrt{1.16}$ 다. 그 결과를 두 투영에 곱한다. 새 K/V 를 미리 주어진 표에서 복사한 것이 아니다.

Head	새 Q	새 K	새 V
1	`[-0.371391]`	`[-0.371391]`	`[-0.742781]`

Head	새 Q	새 K	새 V
2	[0.371391]	[0.371391]	[1.485563]

Head	점수	비율	Head 출력
1	[-0.166091, 0.152406, 0.137931]	[0.268071, 0.368613, 0.363316]	[-0.332626]
2	[-0.166091, 0.152406, 0.137931]	[0.268071, 0.368613, 0.363316]	[0.665252]

Head1 의 과거 K/V 뒤에 새 K/V 를 붙인다. 새 Query 는 원위치 2 라 세 Key 를 모두 읽는다. Head2 의 Q/K 는 반대 부호, V 는 -2 배여서 이 특수 사례의 점수·비율은 같다. 두 Head 출력에서 C 를 만들고 W_O 를 적용한다. M 은 원래 [0.2, 1] 에 더한다. R 에 N 을 적용해 F 의 입력 U 를 얻고 F 반환은 R 에 더한다.

단계	새 한 행
입력 h	[0.200000, 1.000000]
N(h)	[-0.371391, 0.371391]
C	[-0.332626, 0.665252]
M	[-0.332626, 0.332626]
R	[-0.132626, 1.332626]
U=N(R)	[-0.590993, 0.590993]
ReLU 활성	[0.000000, 0.000000]
F(U)	[0.100000, -0.100000]
반환	[-0.032626, 1.232626]

다음 레이어에 넘기는 것은 이 마지막 반환 전체다. 첫 K 나 N(h) 를 넘기는 답은 틀리다. 복습: 새 첫 레이어.

유제 10.9.4 해설

문제. 과거는 대표의 레이어 2 K/V 다. 앞 유제의 첫 반환을 h 로 삼아 둘째 레이어 N 과 투영부터 다시 한다.

Head	새 Q	새 K	새 V
1	[-0.534626]	[-0.534626]	[-1.069251]
2	[0.534626]	[0.534626]	[2.138502]

Head	점수	비율	Head 출력
1	[-0.453043, 0.224429, 0.285824]	[0.197533, 0.388921, 0.413547]	[-0.433934]
2	[-0.453043, 0.224429, 0.285824]	[0.197533, 0.388921, 0.413547]	[0.867867]

단계	새 한 행
입력 h	[-0.032626, 1.232626]
N(h)	[-0.534626, 0.534626]
C	[-0.433934, 0.867867]
M	[-0.433934, 0.433934]
R	[-0.466560, 1.666560]
U=N(R)	[-0.729503, 0.729503]
ReLU 활성	[0.000000, 0.000000]
F(U)	[0.100000, -0.100000]
반환	[-0.366560, 1.566560]

새 최종 반환에 고정 Readout 을 적용해 다음 Token 점수를 얻는다. 과거 0/1 항목은 그대로이고 두 레이어의 각 K/V 에 이 유제에서 얻은 새 행을 붙인다.

레이어·Head·원위치	K	V
1·1·0	[0.447214]	[0.894427]
1·1·1	[-0.410365]	[-0.820729]
1·1·2	[-0.371391]	[-0.742781]
1·2·0	[-0.447214]	[-1.788854]
1·2·1	[0.410365]	[1.641459]
1·2·2	[0.371391]	[1.485563]
2·1·0	[0.847402]	[1.694804]
2·1·1	[-0.419787]	[-0.839573]
2·1·2	[-0.534626]	[-1.069251]
2·2·0	[-0.847402]	[-3.389609]
2·2·1	[0.419787]	[1.679146]
2·2·2	[0.534626]	[2.138502]

각 Head shape 는 3×1 이다. Full 실행에서는 세 위치를 모두 계산하지만 마지막 위치의 위 전 중간값은 증분과 같다. 실습 `CACHE_SOLUTIONS.json` 의 반올림 전 값으로 대조한다. 복습: 둘째 레이어, 동등성.

유제 10.9.5 해설

문제. 비교할 원위치가 `[4,1,3]` 이고 요청 위치가 3 이므로 허용 행은 `[False,True,True]` 다. 원위치 1 이 비활성이면 `[False,False,True]` 다. 배열 번호 0/1/2 에 삼각형을 그리는 답은 원위치를 잃는다.

K 만 옮기면 가중치가 생성된 출처와 V 출처가 맞지 않는다. 예를 들어 첫 열이 위치 4 K 인데 첫 V 가 위치 1 V 라면 위치 4 의 점수로 위치 1 내용을 집계한다. 올바른 재배열은 K/V 와 원위치·유효 표지를 같은 순열로 움직인다. 복습: 한 행 Mask.

유제 10.9.6 해설

문제. 첫 입력 z 가 위치와 무관하고 고정돼 있다는 조건이 주어졌다. 회전 전 $\bar{k}$ 는 같은 z 와 W_K 에서 생성돼 유지된다. 회전 후 K 는 위치 1 의 $[0,1]$ 에서 위치 2 의 $[-1,0]$ 으로 다시 회전해야 한다. 같은 레이어 V 는 직접 회전하지 않고 입력도 같아 유지된다.

다음 레이어 V 는 조건부다. 변경된 Q/K 로 집계가 바뀌면 첫 Block 반환과 다음 N 입력이 바뀐다. 그 반환이 같다는 항등식 또는 수치 생성원을 확인해야 한다. 회전 전 K 를 저장한 경우에도 원위치 metadata 를 갱신해야 하며, 회전 전 값이 상위 레이어에서 같다는 추가 보장 없이 재회전만 해서는 안 된다. 복습: RoPE 계약.

유제 10.9.7 해설

문제. 레이어 1 Head2 의 W_V 만 바뀌었다. 위치 0/1/2 모두에 대해 레이어 1 Head1 K/V 와 Head2 K 는 유지된다. Head2 V 세 항목은 직접 재계산 대상이다. Q/K 가 같으므로 비율 자체는 같다. 바뀐 V 가 그 비율로 집계되어 M 과 반환을 바꿀 수 있다.

레이어 2 의 두 Head K/V 는 모든 위치에서 첫 반환을 다시 확인해야 한다. 대표 W_O 에서는 Head2 출력 변화가 둘째 출력 좌표로 전달된다. 위치 0 도 한 Key 의 **바뀐** V 를 읽으므로 W_Q 변경에서의 보존 예외가 없다. 변화된 V 가 실제 0 이거나 그 변화가 출력 투영에서 제거된다는 별도 항등식이 있다면 해당 위치의 반환 유지와 이후 항목 재사용을 확인할 수 있다. 복습: K/V 변경.

이해 확인의 해설

이해 확인 1 질문 위치. 존재하지 않는다. y2 를 선택한 뒤 위치 2 의 Embedding/위치 표현을 만들고 첫 레이어 N→Q/K/V→Attention→ 두 Residual/FFN→ 첫 반환을 계산해야 한다. 그 반환을 둘째 N/투영에 넣어 V 를 얻는다. 선택된 토큰이라는 정보는 입력 Token ID 를 정할 뿐 이미 처리된 K/V 를 만들지 않는다.

이해 확인 2 질문 위치. (1) 기존 초기 Token/위치가 유지된다. (2) 기존 요청은 미래를 읽지 않아 같은 허용 K/V 를 사용한다. (3) N/FFN/Residual 은 고정된 위치별 함수다. 이 셋으로 첫 반환이 유지되고 그 반환이 둘째 입력이므로 레이어 귀납이 이어진다. 초기 입력만 같다는 말은 중간 Attention 이 미래를 읽지 않는다는 조건을 빠뜨린다.

이해 확인 3 질문 위치. 첫 K 의 생성원은 $N(H_2^{(0)})$ 이고 둘째 K 의 생성원은 $N(H_2^{(1)})$ 다. 같은 W_K 에 곱해도 입력이 `[0.099504,-0.099504]` 와 `[0.323438,-0.323438]` 로 달라 새 K 도 다르다. 위치뿐 아니라 레이어 주소가 필요하다.

이해 확인 4 질문 위치. 결론 내릴 수 없다. Readout 이 0 이면 잘못된 내부 반환도 같은 0 Logit 을 만든다. 출력 투영이 어떤 Head 오류의 변화량을 영공간으로 없애도 최종 결과가 같을 수 있다. 새 K/V·점수·비율·Head 출력부터 비교해야 하고, 공유 구현 밖의 별도 기준도 필요하다.

이해 확인 5 질문 위치. 일반적으로 부족하다. W_Q 또는 FFN 변경은 첫 K/V 를 유지해도 첫 반환을 바꾸어 둘째 K/V 를 바꿀 수 있다. 유지 예외는 W_Q 만 바꾼 위치 0 의 단일 Key 집계, 또는 Readout 만 바꿔 내부 경로를 그대로 둔 경우다. 출력이 같은가를 생성원으로 확인한다.

이해 확인 6 질문 위치. 처리 후 Prefix 길이가 100 이고 모든 유효 Key 를 읽는 요청이라면 100 개다. Query 행 수 1 과 Key 열 수 100 을 구별한다. 과거 K/V 를 다시 투영하지 않아도 저장된 값을 읽어 새 점수와 가중합을 만든다. Attention 행렬을 줄이는 별도 방법과 Cache 재사용을 같은 주장으로 쓰지 않는다.

독립 연습 상세 해설

연습문제 10.9.1 해설

문제. 앞 계산의 입력은 위치 0 BOS·위치 1 y1 이고 마지막 반환은 y2 점수를 만든다. 선택 직후 Cache 는 0/1 이다. 위치 2 에 y2 를 넣고 두 레이어를 처리한 뒤 Cache 가 0/1/2 가 되며 마지막 반환은 y3 점수를 만든다. Teacher Forcing 에서는 y2 가 정답 입력으로 이미 준비돼 있어 세 행을 함께 처리할 수 있지만 각 행은 Causal 허용 집합만 읽는다. 'y2 예측 시점에 y2 의 K/V 사용' 은 정답 입력을 미리 읽는 오류다. 복습: 시점.

연습문제 10.9.2 해설

문제. 위치 0/1 의 초기 표현·N·Q/K/V, 기존 허용 Key 비교·Softmax·V 집계, C/W_O·Residual·N/FFN·반환을 다시 한다. 둘째 레이어에서도 같은 첫 반환을 받아 이 경로를 반복한다. 첫 레이어 입력 같음과 Causal 접근, 위치별 후속 함수가 첫 반환 보존을 만들고 이것이 둘째 입력 보존을 만든다.

새 요청은 새 표현으로 Q 와 Attention Weight 를 새로 만든다. 과거 요청을 다시 계산하지 않으므로 과거 Q/비율 전체는 기본 Cache 에 필요하지 않다. 이것은 과거 Q 를 별도 저장하는 최적화를 금지하는 말이 아니며, 새 Q 를 과거 Q 로 대체하는 행위를 정당화하지도 않는다. 복습: Full 계산, 정의.

연습문제 10.9.3 해설

문제. 각 레이어 Head1 은 K 5×2, V 5×1, Head2 는 K 5×4, V 5×3 다. 한 레이어 원소는 $5(2+1+4+3) = 50$, 세 레이어는 150 이다. 새 토큰당 $3(2+1+4+3) = 30$ 개 증가한다. Batch2 이면 300 개다. Batch metadata·메모리 객체를 제외한 K/V payload 원소 수다. 두 Head 폭이 달라 하나의 고정 마지막 축으로 묶지 않는다. 복습: 주소와 shape.

연습문제 10.9.4 해설

문제. 새 K 는 $[1, -1]I = [1, -1]$, 새 V 는 $1 \cdot 1 + (-1) \cdot 2 = -1$ 이다. 제공 K 는 세 행, V 는 $[2, 4, -1]^{\mathsf{T}}$ 다. $d_k = 2$ 이므로 raw 내적 $[1, 2, -1]$ 을 $\sqrt{2}$ 로 나눈다.

점수·비율·출력은 다음과 같다.

$$S = [0.707107, 1.414214, -0.707107],$$
$$A = [0.305695, 0.619985, 0.074320],$$
$$o = [3.017011].$$

허용 세 지수의 합으로 나눈 비율을 해당 순서의 V 와 곱한다. 새 V 가 음수여도 Softmax 비율이 음수인 것은 아니다. scale 을 1 로 하거나 Softmax 를 비교 좌표 축에 적용하는 답은 틀리다. 복습: 증분 식.

연습문제 10.9.5 해설

문제. 첫 레이어 새 Query 는 $q = 0.099504$ 다. 올바른 과거 K 를 곱한 두 점수는 $[0.044499, -0.040833]$ 다. 둘째 레이어 K 를 넣으면 다음처럼 바뀐다.

잘못된 두 과거 점수는 $[0.084320, -0.041770]$ 이며 새 위치 점수는 여전히 0.009901 이다.

새 Key 는 첫 레이어에서 만든 것이므로 서로 다른 레이어 출처가 하나의 제공 집합에 섞인다. 같은 shape 라는 것은 같은 생성원의 보장이 아니다. Head 를 교환하면 첫 Query 가 둘째 K 를 읽고 둘째 V 를 집계한다. 이 대표의 대칭성에서는 일부 점수 관계가 단순해 보여도 값 배율과 W_O 슬롯이 다르므로 반환이 달라진다. `verify_cache.py` 는 shape 검사를 우회한 실제 잘못된 계산도 비교한다. 복습: 레이어 전달.

연습문제 10.9.6 해설

문제. 지수는 1 과 2 이므로 비율은 $[1/3, 2/3]$ 다. 출력은 $2/3 + 16/3 = 6$ 이다. V 만 바꾸면 $8/3 + 4/3 = 4$ 다. K/V/위치를 함께 교환하면 비율도 $[2/3, 1/3]$ 으로 옮겨져 같은 6 이 된다. 원위치에 따른 Mask 도 같은 순열로 바꾸어야 한다. 복습: Mask 와 대응.

연습문제 10.9.7 해설

문제. 올바른 행은 `[True,True,True]`, 배열 첫 행에 `np.tril` 을 적용한 행은 `[True,False,False]` 다. 원위치 4 요청을 배열 행 0 으로 바꿔 생각한 오류다. 위치를 0 으로 다시 시작하면 Absolute 의 P 가 바뀌고, RoPE 의 Q/K 회전도 R(0) 을 쓰며, 원위치 비교는 과거 1/3/4 를 모두 미래로 볼 수 있다. 세 오류는 서로 다른 계산 단계이므로 하나만 수정해서 나머지를 해결했다고 보지 않는다. 복습: 한 행 오류, 위치.

연습문제 10.9.8 해설

문제. 제공 Cache 는 원위치 1/3 의 각 레이어별 K/V 이며 대표 예제의 Cache 를 쓰지 않는다. 새 Token1 의 Embedding $[1, -1]$ 에 $P_4 = [0, 0.8]$ 을 더하면 $h = [1, -0.2]$ 다. 첫 N 의 평균 0.4, 분산 0.36 이므로 기본 정규화는 $[0.514496, -0.514496]$ 이다. 첫 $\gamma = [1, 0.8]$ 를 곱해 $z = [0.514496, -0.411597]$ 를 얻는다.

Head1 의 직접 투영은 $q = [z_1, 0.5z_1 + z_2]$, $k = [0.5z_1 + z_2, z_2]$, $v = z_1 - z_2$ 다. Head2 는 $q = 0.5z_1 + z_2$, $k = z_1 - 0.5z_2$, $v = [z_1 + 0.5z_2, z_2]$ 다. 두 Head 의 scale 은 각각 $\sqrt{2}$ 와 1 이며 점수는 둘 다 원위치 1/3/4 의 세 열이다.

Head	새 Q	새 K	새 V
1	`[0.514496, -0.154349]`	`[-0.154349, -0.411597]`	`[0.926092]`
2	`[-0.154349]`	`[0.720294]`	`[0.308697, -0.411597]`

Head	점수	비율	Head 출력
1	`[0.014137, 0.013636, -0.011231]`	`[0.336197, 0.336028, 0.327775]`	`[-0.466224]`
2	`[0.139949, 0.134989, -0.111176]`	`[0.360623, 0.358839, 0.280538]`	`[-0.188032, 0.250709]`

Head1 출력 한 좌표와 Head2 출력 두 좌표를 Head1 뒤 Head2 의 좌표 순서로 결합한다. W_O 첫 행은 Head1 슬롯, 둘째/셋째 행은 Head2 두 슬롯에 대응한다. 원래 h 에 M 을 더한 R 을 N2 에 넣고 FFN 을 실행한다.

단계	새 한 행
입력 h	[1.000000, -0.200000]
N(h)	[0.514496, -0.411597]
C	[-0.466224, -0.188032, 0.250709]
M	[-0.340869, 0.156693]
R	[0.659131, -0.043307]
U=N(R)	[0.331375, -0.331375]
ReLU 활성	[0.331375, 0.000000, 0.000000]
F(U)	[0.066275, 0.050000]
반환	[0.725406, 0.006693]

둘째 입력은 이 최종 $H^{(1)}$ 다. 둘째 N1 에서는 $\gamma = [0.9, 1]$ 을 사용한다. 첫 레이어의 z 나 K 를 복사하지 않는다. 같은 Head 투영이어도 입력이 달라 두 번째 새 K/V 가 달라진다.

Head	새 Q	새 K	새 V
1	[0.304365, -0.186001]	[-0.186001, -0.338183]	[0.642548]
2	[-0.186001]	[0.473456]	[0.135273, -0.338183]

Head	점수	비율	Head 출력
1	[-0.011466, -0.011361, 0.004448]	[0.331549, 0.331584, 0.336867]	[-0.876910]
2	[0.227008, 0.224935, -0.088063]	[0.366614, 0.365855, 0.267532]	[-0.218060, 0.545151]

단계	새 한 행
입력 h	[0.725406, 0.006693]
N(h)	[0.304365, -0.338183]
C	[-0.876910, -0.218060, 0.545151]
M	[-0.423034, 0.305284]
R	[0.302372, 0.311978]
U=N(R)	[-0.004803, 0.004803]
ReLU 활성	[0.000000, 0.004803, 0.009606]

단계	새 한 행
F(U)	`[-0.000961, 0.052401]`
반환	`[0.301411, 0.364379]`

둘째 FFN 의 ReLU 이전 세 좌표는 $[U_1, U_2, -U_1 + U_2]$ 다. 이 사례에서는 첫 좌표가 음수라 0 이고 두 번째/세 번째는 양수다. 최종 반환은 `[0.301411,0.364379]` 이고 Readout 은 `[0.301411,0.364379,0.062968]` 이다.

레이어·Head·원위치	K	V
1·1·1	`[0.194295, 0.518119]`	`[-1.165767]`
1·1·3	`[0.187409, 0.499756]`	`[-1.124451]`
1·1·4	`[-0.154349, -0.411597]`	`[0.926092]`
1·2·1	`[-0.906708]`	`[-0.388589, 0.518119]`
1·2·3	`[-0.874573]`	`[-0.374817, 0.499756]`
1·2·4	`[0.720294]`	`[0.308697, -0.411597]`
2·1·1	`[0.479469, 0.871762]`	`[-1.656347]`
2·1·3	`[0.475091, 0.863802]`	`[-1.641223]`
2·1·4	`[-0.186001, -0.338183]`	`[0.642548]`
2·2·1	`[-1.220466]`	`[-0.348705, 0.871762]`
2·2·3	`[-1.209322]`	`[-0.345521, 0.863802]`
2·2·4	`[0.473456]`	`[0.135273, -0.338183]`

각 레이어의 Head1 은 K 3×2, V 3×1, Head2 는 K 3×1, V 3×2 다. 총 24 개 스칼라이며 새 항목은 8 개다. 기존 원위치 1/3 의 모든 K/V 는 추가 전후 같은 배열 값으로 보존된다. Full Prefix 가 만든 마지막 h/z/Q/K/V/점수/비율/출력/C/M/R/U/활성/F/반환/Readout 과 위 모든 값을 대조한다. 여러 폭은 Head 내부 비교와 출력 Concat 에서 각각 처리되므로 하나의 Block 에 연결된다.

흔한 오류는 Head1 에도 scale1 을 쓰는 것, 원위치 4 를 배열 행 0 으로 읽는 것, 세 좌표 C 에 대표의 2×2 W_O 를 적용하는 것, 둘째 N 의 gamma 를 첫 gamma 로 복제하는 것이다. 복습: Block 계약, 증분 식. 해설용 `solution_cache.py` 와 `demo_cache.py` 로 반올림 전 대조를 할 수 있다.

연습문제 10.9.9 해설

문제. 각 레이어에서 h/z 는 1×2, 새 Head1 Q/K 는 1×2·V 1×1, Head2 Q/K 1×1·V 1×2 다. 점수/비율은 1×3, Head 출력은 1×1/1×2, C 1×3, M/R/U/F/반환은 1×2 다. FFN 활성은 1×3 이고 Readout 은 1×3 이다. Full 배열의 마지막 행과 이 모든 배열을 대조하고 과거 Cache 의 전체 보존도 검사한다.

공통 `layer` 가 Softmax 축을 잘못 잡아도 두 실행이 같은 오류를 낼 수 있다. 별도 스칼라 함수는 내적·허용 지수 합·V 집계를 각각 구현해 최초 차이를 찾게 한다. 유한 시험의 성공은 일반 귀납 증명과 별개다. 복습: 동등성, 코드.

연습문제 10.9.10 해설

문제. 첫 레이어 위치 1 의 초기 입력은 $[0.2, 2]$ 로 달라져 N 과 두 Head K/V 를 재계산한다. 위치 0/2 의 첫 K/V 는 자신의 Token/위치가 같아 유지한다. 첫 반환의 위치 1/2 는 바뀐 과거를 읽으므로 둘째 레이어 두 Head 의 위치 1/2 K/V 는 재계산 대상이다. 둘째 위치 0 은 유지된다.

변경 뒤 둘째 레이어 위치 2 의 Head1 K/V 는 [0.166623] / [0.333246] 다. Head2 K/V 는 [−0.166623] / [−0.666492] 다. 기존 Head1 K/V [0.323438] / [0.646876] 와 비교하자.

이 실제 계산에서는 첫 K/V 위치 2 가 그대로이지만 둘째 K/V 위치 2 는 위 새 값으로 달라진다. 첫 레이어 Cache 보존 여부만으로 다음 레이어 판단을 끝낼 수 없는 반례다. 숫자가 같다는 우연만으로 새로운 계약에서 모든 입력의 보장을 주장하지 않는다. 복습: Token 변경.

연습문제 10.9.11 해설

문제. 허용 집합을 유지하면 첫 레이어 위치 1 만 초기 P 가 바뀌어 K/V 직접 재계산 대상이고 위치 0/2 첫 K/V 는 유지된다. 둘째 레이어는 위치 0 유지, 위치 1/2 는 바뀐 첫 반환의 영향을 확인한다.

순서까지 바뀌면 원위치 비교에서 기존 Query 가 읽던 Key 집합도 달라질 수 있다. 위치 0 이 변경 Key 를 새로 읽는다면 그 반환부터 영향이 난다. Token 별 P 뿐 아니라 위치 순서, 실제 허용 집합, Key 유효성을 새로 제공해야 정확한 범위를 정할 수 있다. 기존 표의 p<a 보존을 새 순서에 그대로 대입하지 않는다. 복습: 위치 계약, 유효성 표.

연습문제 10.9.12 해설

문제. 반시계 회전이므로 위치 0 은 `[2,1]`, 위치 1 은 `[-1,2]`, 위치 2 는 `[-2,-1]` 이다. 회전 전 바탕 표현과 투영이 같다면 $\bar{k}$ 를 유지해 새 위치 회전을 적용한다. 회전 후 옛 K 는 그대로 재사용하지 않는다. 같은 레이어 V 는 입력 z 가 같다는 조건에서 유지된다.

상위 입력이 바뀌면 $\bar{k}$ 자체도 달라질 수 있으므로 옛 회전 후 K 를 풀어 다시 돌리는 것만으로 현재 K 를 만들 수 없다. 다음 레이어 V 도 바뀐 입력에서 새로 투영해야 할 수 있다. 복습: 회전 전후 계약.

연습문제 10.9.13 해설

문제. 레이어 1 K/V 는 모든 Head·위치에서 유지된다. 레이어 2 위치 0 은 모든 Head K/V 가 유지된다. 위치 0 의 Softmax 는 $e^s/e^s = 1$ 이라 어떤 유한 새 점수에서도 같은 V 를 집계한다. 고정 W_O 와 위치별 후속 함수의 입력도 같다.

위치 1/2 는 변경된 Head1 Q 가 여러 K 를 비교해 상대 점수를 바꿀 수 있다. 대표 1.7 배 변형의 실제 계산은 레이어 2 항목의 변화를 보이며 그 입력을 다시 계산해야 한다. 일반 매개변수에서는 점수가 같거나 영공간 때문에 반환이 유지될 수도 있으므로 그 조건을 확인하면 더 좁게 재사용할 수 있다. 복습: W_Q 사례.

연습문제 10.9.14 해설

문제. W_K 변경: 레이어 1 Head1 K 전체는 재계산, 그 Head V·Head2 K/V 는 유지. Q 는 유지되나 점수/비율이 바뀔 수 있다. 위치 0 은 가중치 1·V 유지라 둘째 위치 0 은 유지한다. 둘째 위치 1/2 의 모든 Head K/V 는 입력 생성원을 재검토한다.

W_V 변경: 레이어 1 Head1 V 전체는 재계산, K 전체·Head2 V 유지. 비율은 그대로지만 전달 내용이 바뀐다. 위치 0 도 바뀐 V 를 읽어 둘째 위치 0 에 보존 예외가 없다. 상위 두 Head 가 모두 같은 바뀐 첫 반환을 입력으로 쓰므로 Head1 만 영향을 받는다는 답은 틀리다. 복습: K/V 투영 사례.

연습문제 10.9.15 해설

문제. 레이어 1 K/V 는 W_O 와 FFN 보다 앞에서 생성되므로 전부 유지된다. W_O 변경은 M/R 을, FFN 변경은 F 와 마지막 합을 바꿀 수 있다. 그 반환을 받는 레이어 2 N1/K/V 는 영향받은 위치마다 확인해야 한다.

추가 조건의 예는 변경된 Head Concat 차이 ΔC 가 고정 W_O 에서 $\Delta C W_O = 0$ 인 경우다. W_O 자체를 바꿨다면 같은 C 에 대해 $C\Delta W_O = 0$ 도 반환 보존의 한 조건이다. FFN 도 주어진 U 에서 새 F(U)= 옛 F(U) 가 항등적으로 유지되면 반환이 같다. 실제 사용 입력 또는 전체 계약 범위에 대해 어느 보장인지 명시한다. 복습: 생성원 그래프.

연습문제 10.9.16 해설

문제. N1 의 gamma/beta 는 Attention 입력 z 를 바꿔 Q/K/V 에 직접 들어간다. 모든 Head·위치에서 영향이 가능한 직접 재계산 대상이다. N2 gamma 는 K/V 생성 뒤의 FFN 입력 U 에 들어가므로 첫 K/V 는 유지되고 첫 반환/둘째 K/V 를 재검토한다.

z 변화가 W_K 의 영공간에 있다면 해당 K 변화는 0 일 수 있다. V 도 유지하려면 $\Delta z W_V = 0$ 를 별도로 확인해야 한다. Q 또는 다른 Head 가 변해 반환이 달라질 수 있어 이 한 셀 보존을 상위 전체 보존으로 확대하지 않는다. 복습: 두 N 의 역할, 판정표.

연습문제 10.9.17 해설

문제. 기존 위치 2 의 Mask 변경은 첫 K/V 전부를 유지하지만 첫 위치 2 Attention/반환을 재계산한다. 둘째 K/V 의 직접 생성 입력은 위치 2 만 달라질 수 있어 위치 0/1 은 유지하고 위치 2 는 재검토한다. 셋째 레이어가 있다면 둘째 반환 중 바뀐 위치 2 를 읽는 요청들로 다시 퍼질 수 있다. 현재 Prefix 가 0/1/2 뿐이면 둘째 위치 2 가 해당 요청이다.

새 위치 3 의 접근만 바꾸면 기존 요청의 경로는 그대로라 두 레이어 과거 K/V 를 모두 유지한다. 위치 3 의 새 첫 K/V 를 생성해 정한 `{1,2,3}` 으로 집계하고 그 반환으로 둘째 새 K/V 를 만든다. 새 항목은 아직 과거에 없었으므로 '새 Mask 와 무관하니 완성된 둘째 새 V 를 재사용' 할 수는 없다. 복습: 유효성 표.

연습문제 10.9.18 해설

문제. 아래에서 $B^{KV}_{\ell,P}$ 는 레이어 ℓ, 두 Head 모두, 위치 집합 P 의 K 와 V 를 함께 뜻한다. $B^{K}_{1,P}$ 는 두 Head 의 K 만이고 $V_{1,2,P}$ 는 레이어 1 Head2 의 V 다. 이 묶음 주소를 명시해 24 개 셀을 빠짐없이 판정한다.

변경	재사용	직접 재계산	추가 확인/후속 재계산	새 추가
Token1	$B^{KV}_{1,\{0,2\}}, B^{KV}_{2,\{0\}}$	$B^{KV}_{1,\{1\}}$	$B^{KV}_{2,\{1,2\}}$	없음
Head2 W_V	레이어 1 모든 K·Head1 모든 V	$V_{1,2,\{0,1,2\}}$	$B^{KV}_{2,\{0,1,2\}}$	없음
N2	$B^{KV}_{1,\{0,1,2\}}$	첫 FFN/반환	$B^{KV}_{2,\{0,1,2\}}$	없음

변경	재사용	직접 재계산	추가 확인/후속 재계산	새 추가
기존 Query2 Mask	$B^{KV}_{1,\{0,1,2\}}, B^{KV}_{2,\{0,1\}}$	첫 요청 2 Attention/반환	$B^{KV}_{2,\{2\}}$	없음
Readout	두 레이어의 24 셀 전부	Token 점수만	없음	없음
새 입력	두 레이어의 24 셀 전부	새 입력 경로	새 입력의 레이어 전달	두 레이어·두 Head 새 K/V

'직접 재계산' 열의 FFN/반환은 K/V 저장 셀이 아닌 후속 연산임을 명시했다. Cache 셀에서 보면 N2/Mask 변경은 레이어 1 의 직접 무효 셀이 없다. 추가 확인 영역은 항등식으로 반환이 유지됨을 입증하면 유지할 수 있으나 근거 없이 유지하지 않는다. 모두 비운다는 답은 확실히 보존되는 셀을 구별하지 못한다. 복습: 항목 유효성.

연습문제 10.9.19 해설

문제. 같은 고정 `[BOS,y1]` 의 두 레이어 표현 생성원은 Readout 에 의존하지 않아 Cache 는 유효하다. 반환을 새 Readout 에 적용해 점수는 다시 계산한다. 선택된 y2 가 달라지면 다음 위치 2 초기 입력부터 다르므로 그 위치의 K/V 를 서로 공통으로 재사용할 수 없다. 두 실행의 공통 앞부분 위치 0/1 은 Causal 조건 아래 유지된다. 복습: Readout 변경.

연습문제 10.9.20 해설

문제. 위치 0/1 의 내용과 위치·모델·접근 계약은 같으므로 두 레이어의 그 Cache 를 공유할 수 있다. 위치 2 는 b/c 가 달라 초기 표현부터 재계산해야 한다. 같은 길이는 같은 shape 만 보장한다. 상위 위치 2 입력은 앞부분과 자기 Token 을 거친 반환이라 자기 내용만 같은 일부 토큰을 찾아도 전체 상위 생성원 같음을 보장하지 않는다. 복습: 다른 Prefix.

연습문제 10.9.21 해설

문제. 위치 1 이 패딩이면 활성 요청 2 의 행은 `[True,False,True]` 다. 이 실습의 비활성 Query Attention 은 0 이지만 R=h 이고 다음 F(N(h)) 를 더하므로 최종 반환 0 은 일반적으로 아니다. Key 유효성과 Query 활동 상태는 다른 축이다.

다른 Dropout 표본은 같은 결정적 함수 가정을, 시퀀스 전체 평균은 위치별 N 가정을 깨뜨린다. 정밀도 변경은 실수 수학의 함수 관계를 부정하지 않아도 실제 부동소수점 숫자의 일치를 보장하지 않는다. 동일 deterministic inference 규약으로 대조해야 한다. 미래 변경 불변만 검사하면 상수 0 모델도 통과하므로 허용 과거 변경 반응의 양성 대조도 추가한다. 복습: Mask, 증명 조건.

연습문제 10.9.22 해설

문제. Prefill4 를 제외하면 길이 5/6 을 처리한다. Full 활성 쌍은 $5 \cdot 6/2 + 6 \cdot 7/2 = 15 + 21 = 36$, 증분은 5+6=11 이다. 각 Head 의 비교이며 레이어/Head 수를 곱하면 대표 모델에서 144 와 44 다. dense 원 내적 셀을 센다면 25+36=61 로 별도 계산한다.

최종 길이 6 Cache 는 $8 \cdot 6 = 48$ 개 float64 스칼라, payload384 바이트다. 마지막 한 요청은 6 개 Key 를 읽으며 새 N/투영/FFN, Cache 증가·읽기·교육 구현의 복사 비용이 남는다. 실측하지 않은 wall-clock 가속률을 36/11 로 주장하지 않는다. 복습: 비용의 조건.

선택적 Deep 해설

심화문제 10.9.1 해설

문제. 먼저 기존 위치에 대해 레이어 귀납을 한다. 고정 Token/위치로 초기 표현이 같고, 같은 이전 표현에서 N/투영이 같으며 Causal 허용 집합이 변하지 않는다. 같은 Q/K/V·허용 집합에서 Attention 이 같고 위치별 후속 함수에서 반환이 같다. 이를 L 번 반복해 모든 기존 K/V 보존을 증명한다.

이후 새 위치의 별도 레이어 귀납을 한다. 초기 입력은 Full/Incremental 에서 같고, 첫 레이어 새 투영과 과거 제공 집합은 같다. 같은 새 집계/후속 반환을 얻어 다음 레이어 새 입력도 같다. L 번 후 Readout 도 같다. 두 귀납은 '과거 보존' 과 '새 계산 일치' 라는 서로 다른 결론을 만든다.

반례로 $N_{\text{seq}}(h)_p = h_p - \frac{1}{n}\sum_j h_j$ 를 쓰자. 두 행 $[0, 2]$ 의 첫 반환 입력은 -1 이지만 미래 10 을 붙이면 첫 값은 -4 다. Causal Attention 이전에 초기 과거 표현이 이미 미래에 의존한다. 분산까지 쓰지 않아도 가정 위반이 드러난다. 복습: 두 정리.

심화문제 10.9.2 해설

문제. Token a 변경은 초기 $H_a^{(0)}$ 부터 바꾸어 레이어 1 K/V 위치 a 에 직접 닿는다. 첫 Attention 의 요청 $p \geq a$ 가 그 Key/Value 를 읽을 수 있어 첫 반환 범위는 $p \geq a$ 다. 레이어 2 K/V 는 그 범위의 입력에서 생성되고, 이후 레이어도 기본 Causal 아래 $p \geq a$ 를 잠재적 영향 범위로 유지한다. p<a 는 유지된다.

레이어 1 Query a 의 Mask 만 바꾸면 레이어 1 K/V 자체는 전부 유지한다. 바뀐 첫 집계와 반환은 위치 a 뿐이다. 레이어 2 K/V 의 직접 변경 범위도 위치 a 뿐이다. 그러나 레이어 2 Attention 의 $p \geq a$ 가 그 바뀐 K/V 를 읽어 레이어 2 반환은 $p \geq a$ 로 퍼질 수 있다. 따라서 레이어 3 K/V 에서 그 넓어진 범위가 나타난다. K/V 생성 전·후의 시점을 나눈 것이 한 레이어 차이의 이유다.

이 범위는 영향이 가능한 구조상 영역이다. 투영 0·값 같음·단일 Key 또는 영공간은 실제 영향 일부를 제거할 수 있다. 특정 숫자 같은 결과와 모든 입력의 생성 계약 보장을 구별한다. 복습: 그래프.

심화문제 10.9.3 해설

문제. 초기 내용은 위치와 독립이고 Absolute 또는 다른 위치 효과는 없다고 가정한다. 주파수는 고정이며 동시 이동은 순서와 허용 관계를 보존한다. 기존 레이어 입력이 같으면 바탕 q/k/v 가 같고

$$R(p+c)^{\top} R(j+c) = R(j-p) = R(p)^{\top} R(j)$$

라 모든 허용 점수와 비율이 같다. V 도 같아 집계·Residual·위치별 후속 함수·반환이 같다. 초기 단계에서 시작해 모든 레이어에 귀납한다. 회전 후 Key 는 $k'_p = \bar{k}_p R(p+c)^{\top} = k_p R(c)^{\top}$ 여서 일반적으로 좌표가 바뀐다. 회전 전 K 와 V 는 유지될 수 있으나 회전 후 Cache 는 새 좌표로 변환해야 한다.

한 위치만 옮기면 그 위치와 다른 위치 사이 j-p 가 바뀐다. 허용 집합을 유지해도 상대 점수가 달라져 상위 바탕 K/V 가 달라질 수 있다. V 가 직접 회전하지 않는다고 전 레이어 보존을 주장하지 않는다. 실습 RoPE 변형은 동시 이동의 V 불변과 국소 이동의 상위 V 변화를 각각 비교한다. 복습: RoPE 위치 계약.

계산을 다시 실행하기

`solution_cache.py` 는 유제의 새 입력부터 최종 반환까지와 일부 독립 과제의 별도 입력을 계산한다. `demo_cache.py` 는 연습문제 8 과 같은 새 통합 모델의 과거 Cache·Full/Incremental 전 중간값을 저장한다. 실행 함수 반환을 읽을 때도 어떤 입력을 넣었는지와 어느 레이어의 과거를 읽었는지 확인하자.

solution_cache.py | learning-source/solution_cache.py | Python | L1-L19 (19 줄)
source revision: cache-source-v0.1

```python
""" 유제와 독립 과제의 수치 풀이. 문제 입력에는 새 항목의 정답을 넣지 않는다."""
from pathlib import Path
import json
import numpy as np
from kv_cache import example_model, transfer_model, full_prefix, incremental, serial, attention

def guided():
    """ 새 입력 계약을 먼저 정한 뒤 과거 Cache 와 두 레이어를 계산한다."""
    model = example_model()
    model["embedding"][2] = [0., 1.]
    _, _, past, _ = full_prefix(model, [0, 1], [0, 1])
    h, logits, updated, trace = incremental(model, [0, 1], [0, 1], 2, 2, past)
    return dict(h=h, logits=logits, updated=updated, trace=trace), past


answer, past = guided()
answers = dict(유제=answer)
new_k = np.array([[1., -1.]]) @ np.eye(2)
new_v = np.array([[1., -1.]]) @ np.array([[1.], [2.]])
```

문제 8 의 새 Cache 를 만든 뒤 문제 18 의 변경안을 별도로 적용해 보자. 같은 파일의 수치 일치를 확인하는 일과 변경 계약에서 재사용을 보장하는 일은 서로 다르다. 생성원 설명을 먼저 쓰고 수치로 반례와 유지 조건을 확인하는 순서가 도움이 된다.

10.10 Efficient Attention 의 비용과 정보 경로 — 상세 해설

본문의 유제·독립 연습·심화와 이해 확인을 모두 다룬다. 비용을 비교할 때 포함한 연산을 먼저 쓰고, 그래프는 제공 → 요청 방향과 층 번호를 함께 표시하자. 출력이 다르면 Mask·정규화·특징맵·누적 범위 중 어느 조건이 달라졌는지 확인한다.

유제 해설

유제 10.10.1 해설 문제. Causal 쌍은 $6 \cdot 7/2 = 21$ 이다. 점수 곱셈은 $21 \cdot 3 = 63$, 값 집계는 $21 \cdot 2 = 42$ 로 합 105 회다. Dense 점수 셀은 36 이며 두 행렬곱의 곱셈은 108 회와 72 회로 합 180 회다. 허용 쌍 21 을 구현의 36 셀과 혼동하면 두 경우의 차이를 놓친다.

Q/K/V 투영은 $6 \cdot 4 \cdot (3 + 3 + 2) = 192$ 회다. 이를 추가한 합은 허용 쌍 계산 297 회, Dense 계산 372 회다. Softmax·Scaling·나눗셈·출력 변환·FFN 은 제외했다. 입력 배열 폭 4 와 비교 폭 3, 값 폭 2 를 섞어 $21 \cdot 4$ 로 점수를 세는 접근은 틀리다. 비용 범위를 복습하고 한 점수의 실제 좌표 곱부터 다시 세자.

유제 10.10.2 해설 문제. 지수는 $[2, 1, 3, 4]$, Full 분모는 10 이다. 계수 $[.2, .1, .3, .4]$ 로 값 4,1,2,0 을 섞으면 $.8 + .1 + .6 = 1.5$ 다. Local 은 제공 3·4 만 허용해 지수 3·4, 분모 7, 계수 $[3/7, 4/7]$ 이며 출력 $6/7 \approx .857143$ 다.

Full 앞 두 계수만 0 으로 만들면 남은 합은 $.3 + .4 = .7$ 이고 출력은 $.3 \cdot 2 = .6$ 이다. 이것은 재정규화된 Local 결과가 아니다. 기본 점수는 같지만 분모가 바뀌었다. 사라진 직접 경로는 제공 1/2→ 요청 4 다. 같은 Q/K/V 비교를 복습하자.

유제 10.10.3 해설 문제. 폭 3 에서는 한 단계가 최대 2 칸 앞으로 전달한다. 위치 7 의 초기 의존 집합은 1 층 $\{5, 6, 7\}$,2 층 $\{3, 4, 5, 6, 7\}$,3 층 $\{1, 2, 3, 4, 5, 6, 7\}$ 다. 초기 1→7 의 최소는 $\lceil 6/2 \rceil = 3$ 이고 $1^{(0)} \to 3^{(1)} \to 5^{(2)} \to 7^{(3)}$ 가 가능하다.

모든 $W_V = 0$ 이면 Attention 반환이 0 이라 이 경로가 실제 비영 기여를 보장하지 않는다. Residual 은 자기 위치의 경로를 유지하지만 다른 초기 위치의 정보를 새로 만들지 않는다. “경로 존재” 와 “실제 기여” 를 각각 답해야 한다. 의존 집합과 영향 반례를 복습하자.

유제 10.10.4 해설 문제. 초기 2 는 $2^{(0)} \to 3^{(1)} \to 5^{(2)}$ 로 두 단계에 도달한다. 요청 5 의 직접 제공 집합에는 2 가 없어 한 단계는 불가능하다. 초기 4→ 요청 2 는 모든 합법 Edge 가 과거 → 현재로 향하므로 도달하지 못한다.

위치 3 이 미래 5 를 읽으면 마지막 층에서 요청 4 가 합법적으로 3 을 읽어도 $5^{(0)} \to 3^{(1)} \to 4^{(2)}$ 로 누출된다. 마지막 층만 Causal 로 고치는 것은 충분하지 않다. 첫 중계 표현의 정보 출처까지 제한해야 한다. Global 의 실제 층 경로를 복습하자.

유제 10.10.5 해설 문제. 요청 특징과 제공 특징의 내적은 1 과 3 이며 분모 4 다. 분자는 $1[2, -1] + 3[0, 3] = [2, 8]$ 이므로 출력 $[1/2, 2]$ 다. 비음수 특징과 양의 분모 4 가 조건을 만족하며 Value 의 음수 좌표는 허용한다.

$r = 2, d_v = 2$ 이고 외적들은 $\begin{bmatrix} 2 & -1 \\ 0 & 0 \end{bmatrix}$ 와 $\begin{bmatrix} 0 & 3 \\ 0 & 3 \end{bmatrix}$ 다. $S = \begin{bmatrix} 2 & 2 \\ 0 & 3 \end{bmatrix}$, $z = [2,1]^\top$ 다. 요청 적용은 $[1,2]S = [2,8]$, $[1,2]z = 4$ 여서 일치한다. S 는 2×2, z 는 2, 분자는 2, 분모는 스칼라다. 분모 없이 반환한 $[2,8]$ 은 정규화된 정의와 다르다. 좌표별 증명으로 돌아가 분자와 분모를 따로 확인하자.

유제 10.10.6 해설 문제. 첫 항은 $[1,1]^\top \cdot 2 = [2,2]^\top$ 다. $S_1 = [2,2]^\top, z_1 = [1,1]^\top$ 이고 요청 $[1,1]$ 의 분자 4/분모 2 로 2 다. 두 번째 항은 $[2,0]^\top \cdot 3 = [6,0]^\top$ 다. $S_2 = [8,2]^\top, z_2 = [3,1]^\top$, 요청 $[2,0]$ 의 16/6 으로 8/3 이다. 세 번째 항은 $[0,1]^\top \cdot 6 = [0,6]^\top$ 다. $S_3 = [8,8]^\top, z_3 = [3,2]^\top$, 요청 $[0,1]$ 의 8/2 로 4 다.

직접 Prefix 내적을 확인하면 두 번째 가중치는 $[2,4]$ 여서 $(2 \cdot 2 + 4 \cdot 3)/6 = 8/3$, 세 번째는 $[1,0,1]$ 여서 $(2+6)/2 = 4$ 다. 현재 항을 추가하기 전에 위치 1 을 계산하면 $S_0 = z_0 = 0$ 으로 분모 0 이다. 자기 위치 허용을 제외한 다른 규약이므로 순서를 고쳐야 한다. Prefix 정의를 복습하자.

유제 10.10.7 해설 문제. A 는 KV Cache 다. 고정 모델·입력·위치·Causal 경로 등 과거 K/V 생성원이 유지되면 원 Full Softmax 결과를 보존하며 반복 생성을 줄인다. 새 요청의 모든 과거 Key 비교는 남는다. B 는 폭 3 Sparse Local 이며 제공 집합 자체를 제한해 먼 과거의 직접 연결을 지운다. 일반적으로 원 Full 출력이 달라진다.

C 는 명시한 Kernel 의 Prefix 인자 분해다. 비음수 가중치·양의 분모·Causal 특징 생성·현재 항의 갱신 순서 아래 같은 Kernel 직접 합과 같다. 원 Softmax 와 같다는 보장은 별도다. Exact Kernel 은 원 Dense 연산을 유지하는 구현/메모리 접근 최적화이며 연결 삭제·다른 Kernel 정의와 구별한다. 실무에서 기법을 조합할 수 있어도 보장 조건을 따로 확인해야 한다. 세 방법과 Cache를 복습하자.

독립 연습 해설

연습문제 10.10.1 해설 문제. 양방향 Full 은 81 쌍이며 점수 곱셈 324 회, Value162 회, 합 486 회다. Causal 허용 쌍은 45 개이고 점수 180 회·Value90 회, 합 270 회다. Dense 점수/Value 행렬곱을 유지하면 각각 324/162 회로 486 회지만 허용 쌍은 여전히 45 개다. 허용 쌍을 세는 기준과 구현 셀을 세는 기준이 다르다.

486/270 은 이 범위의 곱셈 비이지 실행 시간 배율이 아니다. 지수·나눗셈·투영·메모리 접근·병렬화·희소 관리 등은 포함하지 않았다. 실제 실행 시간은 구현과 환경을 고정해 측정해야 한다. 비용을 복습하자.

연습문제 10.10.2 해설 문제. 제공 집합은 $\{1\}, \{1,2\}, \{1,2,3\}, \{2,3,4\}, \{3,4,5\}$ 다. Mask 는

$$B = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 & 1 \end{bmatrix}.$$

쌍 수는 $1+2+3+3+3 = 12 = 5 \cdot 3 - 3 \cdot 2/2$ 다. $w = 8$ 은 n 보다 커서 모든 과거를 허용해 15 쌍이다. $w = 1$ 은 자기 연결 5 쌍이다. $m = \min(n, w)$ 로 $nm - m(m-1)/2$ 가 모든 양의 폭을 처리한다. $w = 8$

에 $nw - w(w-1)/2$ 를 무조건 넣어 12 를 얻는 오류는 식의 조건 $n \geq w$ 를 놓친 것이다. 쌍 수 정리를 복습하자.

연습문제 10.10.3 해설 문제. 고정 폭 4 는 $E = 4n - 6$ 이므로 $\Theta(n)$ 이다. $w = \lfloor \sqrt{n} \rfloor$ 면 $nw = \Theta(n^{3/2})$ 이며 보정항 $w(w-1)/2 = \Theta(n)$ 은 더 작은 차수라 주요 산술은 $\Theta(n^{3/2})$ 다. $w = \lfloor n/2 \rfloor$ 면 $nw - w(w-1)/2 = \Theta(n^2)$ 다.

여기서 d_k, d_v 는 고정했다. 폭이 늘어나는 조건을 지운 채 “Local 은 선형” 이라고 쓰면 뒤 두 경우를 설명하지 못한다. Window 조건을 복습하자.

연습문제 10.10.4 해설 문제. Full 지수는 $[1, 3, 2, 4]$ 이고 분모 10, 계수 $[1, 3, 2, 4]/10$ 이다. 분자는 $1 \cdot 2 + 3 \cdot 0 + 2 \cdot 5 + 4(-1) = 8$ 이므로 출력 $4/5 = .8$ 이다. Local 은 위치 3·4 를 읽어 지수 2·4, 분모 6, 계수 1/3·2/3 이며 출력 $5/3 - 2/3 = 1$ 이다.

Full 계수에만 0 을 넣으면 $[0, 0, .2, .4]$, 출력 $1 - .4 = .6$ 으로 틀린다. 사라진 직접 관계는 제공 1→ 요청 4, 제공 2→ 요청 4 다. 기본 점수는 같지만 분모를 10 에서 6 으로 고쳐야 한다. V 의 음수는 Softmax 가중치 정의에 문제가 없으며 부호를 임의로 제거하면 다른 출력이다. 재정규화 예제를 복습하자.

연습문제 10.10.5 해설 문제. 모든 $v_j = c$ 이고 허용 가중치의 합이 1 이면 $o_i = \sum_j a_{ij} c = (\sum_j a_{ij}) c = c$ 다. Full/Local 은 비어 있지 않은 허용 집합의 Softmax, Kernel 은 비음수와 양의 분모 조건 아래 해당한다. 이는 특정 Value 에 대한 결과 일치다. 다른 계수 벡터가 모두 같은 Value 를 섞으면 차이가 보이지 않을 수 있다.

예를 들어 마지막 Query 점수 0, 값 1·2·3·4 를 쓰면 Full 평균 2.5 와 폭 2 Local 평균 3.5 가 다르다. Kernel 과 Softmax 는 본문의 3/3.732992 사례로도 구별된다. 상수 Value 를 유일한 동등성 시험으로 쓰지 말자. 우연 일치를 복습하자.

연습문제 10.10.6 해설 문제. 폭 2 는 $D_i^{(L)} = \{\max(1, i-L), \ldots, i\}$ 다. 위치 4 는 1 층 3·4,2 층 2·3·4,3 층 1·2·3·4 다. 위치 6 은 1 층 5·6,2 층 4·5·6,3 층 3·4·5·6 이다. 초기 1→6 은 최소 5 단계이며 1→2→3→4→5→6 이 가능하다. 미래 6→ 과거 2 는 불가능하다.

동일 층의 갱신을 연속해서 읽어 한 층에 1→6 까지 보낸다면 원래 동시 Attention 과 다른 계산이다. 세 단계 예제를 복습하고 층을 위첨자로 표시하자.

연습문제 10.10.7 해설 문제. 첫 층은 $1+2+2+2+2 = 9$ 쌍, 둘째는 $1+1+2+2+2 = 8$ 쌍이다. 모든 제공 번호가 요청 이하라 Causal 이다. 첫 의존 집합은 문제의 제공 집합과 같다. 둘째 위치별 합집합은

$$D^{(2)} = [\{1\}, \{1, 2\}, \{1, 2, 3\}, \{1, 2, 3, 4\}, \{1, 3, 4, 5\}].$$

최종 5 는 첫 3 의 1·3 과 첫 5 의 4·5 를 받는다. 초기 1 은 $1^{(0)} \to 3^{(1)} \to 5^{(2)}$ 로 도달한다. 초기 2 는 첫 2·4 에 도달하지만 둘째 5 는 그 위치들을 읽지 않아 도달하지 않는다. 둘째 층에 3→5 가 있다고 같은 층에서 2→3→5 를 한 번에 쓰는 오류를 피하자. Query 와 Residual 의 자기 경로를 더해도 이 예에서는 이미 자기 Edge 가 있어 결과가 같다. 집합 재귀식을 복습하자.

연습문제 10.10.8 해설 문제. 각 중계에서 $x > 0$ 인 상황에 ReLU$(-x)$ 를 Value 로 쓰면 반환은 0 이다. 예를 들어 첫 제공 값 $x_1 = 1$ 에 대해 $v_1 = 0$ 이고 해당 값 경로만 초기 1 을 전달하도록 만들면 이후 중계에 그 정보가 전달되지 않는다. 중계에 양의 상수 Residual 을 더해 그 입력을 양수로 유지하는 예도 가능하다. 원 초기 1 을 전달하는 다른 경로는 제외한다고 명시해야 반례가 완결된다.

그래프는 초기 1 이 최종 4 에 영향을 줄 **가능성**을 허용하지만 실제 함수의 0 영역이 그 경로의 변화를 지운 것이다. 경로가 없으면 정의한 모델의 다른 위치 간 경로가 없는 조건 아래 구조상 전달 불가능하다. 경로가 있으면 실제 비영 영향은 매개변수·입력·함수를 봐야 한다. 실제 영향 반례를 복습하자.

연습문제 10.10.9 해설 문제. 누출 경로는 $5^{(0)} \to 2^{(1)} \to 3^{(2)}$ 다. 미래 5 를 첫 중계 2 가 읽어 이미 첫 표현이 오염된다. 첫 층 위치 2 의 제공을 $\{1, 2\}$, 둘째 위치 3 의 제공을 $\{2, 3\}$ 로 고치면 초기 1→2→3 의 두 층 경로는 남고 미래 5 는 제거된다.

나머지 모든 생성원·층에서도 Causal 을 지켜야 한다. 이 두 관계만 고쳐도 다른 위치의 Bidirectional 경로가 남아 있으면 전체 모델 안전성을 결론 낼 수 없다. 초기 1→3 직접 연결을 새로 추가하는 수정도 가능하지만 문제의 중계 경로는 위처럼 보존할 수 있다. Global 누출을 복습하자.

연습문제 10.10.10 해설 문제. 제공 집합은 $\{1\}, \{1, 2\}, \{1, 2, 3\}, \{1, 2, 3, 4\}, \{3, 4, 5\}, \{3, 4, 5, 6\}$ 다. 자기 블록 안에서는 자기와 앞 위치만, 바로 앞 블록에서는 두 위치 모두 읽는다. 허용 쌍은 $1+2+3+4+3+4 = 17$ 이다.

선택한 블록은 대각 3 개와 직전 블록 2 개로 5 개다. 각 2×2 를 먼저 계산하면 20 셀이고 대각 블록의 미래 셀 3 개는 나중에 Mask 한다. 허용 17 과 실제 20 을 구별해야 한다. 블록 안도 완전 허용이라 가정하면 미래 2→1 등을 열어 Causal 조건이 깨진다. Block Sparse 설명을 복습하자.

연습문제 10.10.11 해설 문제. 내적은 2,4,1 이고 분모 7 이다. 분자는 $2[1, 2]+4[3, 0]+1[-1, 4] = [13, 8]$ 여서 출력 $[13/7, 8/7]$ 이다. 값의 두 번째 좌표까지 계산해야 값 폭 2 의 의미를 확인할 수 있다.

외적은

$$\begin{bmatrix} 1 & 2 \\ 0 & 0 \end{bmatrix}, \quad \begin{bmatrix} 3 & 0 \\ 6 & 0 \end{bmatrix}, \quad \begin{bmatrix} 0 & 0 \\ -1 & 4 \end{bmatrix}.$$

합은 $S = \begin{bmatrix} 4 & 2 \\ 5 & 4 \end{bmatrix}$, $z = [2, 3]^{\mathsf{T}}$ 다. 요청 적용은 $[2, 1]S = [13, 8]$, $[2, 1]z = 7$ 이라 같다. $r = d_v = 2$, $S : 2 \times 2$, $z : 2$, 분자 2, 분모 스칼라, 출력 2 다. 모든 좌표 곱이 가중치 비음수를 만족하고 분모 7 이다. 값 폭 2 예제를 복습하자.

연습문제 10.10.12 해설 문제. 요청 특징은 $[1, 2]$, 제공 특징은 $[1, 2], [1, 6]$ 으로 내적 5 와 13 이다. 분모 18, 분자는 $5 \cdot 4 + 13(-2) = -6$ 이므로 출력 $-1/3$ 이다. 가중치는 비음수고 분모는 양수다. 음수 Value 때문에 출력도 음수일 수 있으며 가중치 조건과 모순되지 않는다.

$S = [1, 2]^{\mathsf{T}}4 + [1, 6]^{\mathsf{T}}(-2) = [2, -4]^{\mathsf{T}}$, $z = [2, 8]^{\mathsf{T}}$ 다. 요청 분자는 $2 - 8 = -6$, 분모 $2 + 16 = 18$ 이다. 여러 Query 가 같은 상태를 쓰려면 상태는 제공 특징 $\psi(k)$ 와 Value 로만 만든다. Query 를 미리 섞은 상태는 Query 마다 다시 계산해야 하며 같은 제공 요약의 재사용 근거를 잃는다. 일반형을 복습하자.

연습문제 10.10.13 해설 문제. (a) 는 내적 0·분모 0, (b) 도 내적 0·분모 0 이라 정의되지 않는다. 비음수 특징만으로 양의 분모를 보장하지 않는다. (c) 는 가중치 $[-1, 2]$, 분모 1 로 양수지만 비음수 조건을 위반한다. 형식적인 비율을 계산하면 $(-1 \cdot 1 + 2 \cdot 3)/1 = 5$ 로 값 범위 1...3 을 벗어난다.

분모에 ε 을 추가해도 (a)/(b) 의 정보가 복원되지는 않는다. 그것은 $(\sum wv)/(\sum w + \varepsilon)$ 이라는 다른 정의이며 가중치 합 1 도 일반적으로 달라진다. 거부 또는 명시한 대체 규약이 필요하다. Kernel 조건을 복습하자.

연습문제 10.10.14 해설 문제. 쌍별 분자는 `(Phi_Q @ Phi_K.T) @ V` 다. 4×2 와 2×5 로 4×5 가중치를 만든 뒤 5×3 Value 와 곱해 4×3 을 반환한다. 인자 분자는 `Phi_Q @ (Phi_K.T @ V)` 이며 상태 S 는 2×3 이다.

$z = \Phi_K.sum(axis = 0)$ 는 특징 폭 2 를 남긴다. `axis=1` 은 각 제공 행의 좌표를 더해 길이 5 를 만들므로 요청 폭 2 와 맞지 않는다. `d = Phi_Q @ z` 는 길이 4 이고 `numerator / d[:,None]` 는 4×3 이다. 행별 분모를 열로 확장해야 각 요청의 모든 값 좌표를 같은 분모로 나눈다. 행렬 결합법칙을 복습하자.

연습문제 10.10.15 해설 문제. Identity Kernel 가중치는 1,2 이고 계수 1/3·2/3, 출력 2/3 이다. 원 Softmax 는 e, e^2 를 정규화해 계수 $1/(1+e), e/(1+e)$ 이며 출력 $e/(1+e) \approx .731059$ 다. $d_k = 1$ 이라 Scaling 은 1 이다.

Kernel 직접/인자 일치는 **같은 내적** Kernel 을 두 순서로 계산한 검사다. 그 가중치 함수 qk 가 e^{qk} 와 같다는 증명이 아니다. 분모를 빼거나 지수를 생략하면 "정확한 Softmax" 라고 부를 수 없다. 정규화 비교를 복습하자.

연습문제 10.10.16 해설 문제. 전체 외적 합은 $S = [2,0]^\top + [4,4]^\top + [0,16]^\top = [6,20]^\top, z = [2,3]^\top$ 다. 전역 출력은 요청별 $6/2 = 3, 26/5 = 5.2, 40/6 = 20/3$ 이다.

올바른 Prefix 는 $S_1 = [2,0]^\top, z_1 = [1,0]^\top$ 로 2 다. $S_2 = [6,4]^\top, z_2 = [2,1]^\top$ 에서 두 번째 요청의 분자 10/분모 3 으로 10/3 이다. 세 번째 상태는 전역 상태와 같아 20/3 이다. 뒤 상태 하나를 모든 앞 요청에 공유해서는 안 된다.

미래 $v_3 = 80$ 이면 마지막 외적은 $[0,160]^\top$ 라 전역 $S = [6,164]^\top$ 다. 잘못된 전역 앞 출력은 3 과 34 다. 첫 출력은 미래 제공 3 과 내적 0 이라 우연히 유지되지만, 둘째는 미래와 내적 2 로 바뀐다. Prefix 앞 둘은 2 와 10/3 그대로다. 하나의 앞 요청만 관찰해 "변화 없음" 이라고 결론 내리면 0 계수의 예외를 놓친다. 미래 변경 예제를 복습하자.

연습문제 10.10.17 해설 문제. 정답은 먼저 $S_1 = 3, z_1 = 1$ 을 만든 뒤 요청 1 을 적용해 3 이다. 오류 A 는 0/0 이므로 정의되지 않는다. 첫 위치를 무조건 0 으로 반환하는 보완도 문제의 Kernel 정의와 다르다.

오류 B 는 $S_1 = 6, z_1 = 1$ 로 6 을 반환한다. 분자와 분모가 같은 제공 항들을 한 번씩 세야 하며, 분자만 중복하면 계수 합 1 이 깨진다. 이전 상태를 읽어 현재 외적과 특징을 각각 한 번 더하고 그 새 상태로 출력하자. Prefix 순서를 복습하자.

연습문제 10.10.18 해설 문제. Full Causal 은 5050 쌍, Local 은 $100 \cdot 5 - 5 \cdot 4/2 = 490$ 쌍이다. 비교 폭 8 과 값 폭 4 를 합쳐 Full 곱셈 60,600 회, Local5,880 회다. Factorized 는 $2 \cdot 100 \cdot 3 \cdot 4 + 100 \cdot 3 = 2700$ 회다. Scale·지수·나눗셈·투영·특징 생성·FFN 은 제외했다.

현재 상태는 S : 3×4 의 12 개와 z 의 3 개를 합쳐 15 개 수다. Full 과거 K/V 는 $100(8+4) = 1200$ 개 수다. Prefix 상태 100 개 전부를 저장하면 1500 개 수이고 현재 상태만 유지하면 15 개다. 특징/입출력/Gradient/인덱스 등은 추가 저장이다. 이 한 항목의 수를 실제 전체 메모리나 실행 시간이라고 표현하지 않는다. 저장 범위를 복습하자.

연습문제 10.10.19 해설 문제. 전체 상태는 $S = 1+3+9 = 13, z = 3$ 이며 두 요청에 쓰면 둘 다 13/3 이다. 첫 올바른 상태는 $S_1 = 4, z_1 = 2$ 로 2, 둘째는 $S_2 = 12, z_2 = 2$ 로 6 이다. 요청별 허용 집합을 지우고 전역 합으로 바꾸면 원 연산을 보존하지 않는다.

Window 를 1·2 에서 2·3 으로 옮기면 첫 제공의 외적 1 을 빼고 셋째 외적 9 를 더한다. z 도 첫 특징 1 을 빼고 셋째 특징 1 을 더해 2 를 유지한다. 일반 특징/Value 에서는 제거할 항을 알아야 하므로 해당 항을 저장하는 비용도 고려해야 한다. Prefix 와 달리 오래된 항이 빠진다. 일반 Mask 조건을 복습하자.

연습문제 10.10.20 해설 문제. Full 의 첫 출력은 1 이다. 둘째는 점수 0·1, 분모 $1+e$, 출력 $(1+2e)/(1+e) \approx 1.731059$ 다. 셋째는 점수 0·1·2, 분모 $1+e+e^2$, 출력 $(1+2e)/(1+e+e^2) \approx .579488$ 다. Local 의 첫 둘은 같고 셋째는 제공 2·3 의 점수 1·2 로 $2e/(e+e^2) = 2/(1+e) \approx .537883$ 다.

특징은 요청 모두 $[1,2]$, 제공은 $[1,1], [1,2], [1,3]$ 다. 내적 가중치는 3,5,7 이다. Kernel Prefix 상태는 다음과 같다.

위치	$S_i^\top$	$z_i^\top$	Kernel 출력
1	$[1,1]$	$[1,1]$	3/3=1
2	$[3,5]$	$[2,3]$	13/8=1.625
3	$[3,5]$	$[3,6]$	$13/15 \approx .866667$

Full Causal 은 6 쌍, Local5 쌍이다. Kernel 의 허용 관계도 $j \le i$ 로 6 쌍이며 이 입력에서는 모든 허용 내적이 양수다. Kernel 은 그 6 쌍을 직접 만들지 않고 누적 상태로 계산한다. 곱셈은 Full $6(1+1) = 12$, Local $5(1+1) = 10$, Kernel $2 \cdot 3 \cdot 2 \cdot 1 + 3 \cdot 2 = 18$ 회다. 특징 생성 비용은 제외했다. 이 작은 예에서는 Kernel 의 곱셈 수가 더 많다.

초기 1→ 최종 3 은 Full 에 직접 1 단계, Local 에 1→2→3 의 2 단계, Kernel 에 허용 내적/누적 상태를 통한 1 단계다. 그래프 경로는 가능성을 뜻하며 매개변수·함수의 실제 비영 기여를 일반적으로 보장하지 않는다. 이 입력의 Kernel Value 경로는 양의 계수 3/15 를 갖는다.

세 방식 모두 주어진 식과 Causal 생성원 아래 미래 입력을 읽지 않는다. Local 과 Kernel 은 원 Full 출력을 보존하지 않는다. Direct/Factorized Kernel 일치는 같은 Kernel 에 대해서만 보장된다. 실제 실행 시간·학습 정확도·특정 의미의 학습 성공은 이 산술로 보장하지 않는다. 세 방법 비교와 Prefix 불변성을 복습하자.

연습문제 10.10.21 해설 문제. (a) 는 KV Cache 다. 과거 K/V 생성원과 모델/위치/접근 계약이 유지돼야 하고 새 Query 는 과거 전체를 계속 읽는다. (b) 는 Sparse 연결의 제한이다. 직접 Edge 를 지우며 다층 경로를 다시 계산해야 한다. 일반적으로 원 Full 출력이 달라진다. (c) 는 정규화 특징 Kernel 의 인자 분해/Prefix 상태다. 특징 폭·Value 폭 고정, 가중치 비음수·분모 양수, 안전한 생성원·갱신 순서가 필요하고 원 Softmax 와의 동등성은 별도다.

(d) 는 Exact Kernel 구현 최적화다. 원 Dense 연산을 유지하고 메모리 접근·계산 순서를 개선한다. 내부 구현을 이 절의 Sparse/Kernel 로 분류해서는 안 된다. 여러 기법을 조합해도 “과거 반복 생성”, “직접 읽기 집합”, “가중합 식”, “실행 구현” 의 보장은 서로 다른 근거를 가진다. 하나의 장점으로 다른 보장을 자동 상속하면 안 된다. Cache 경계를 복습하자.

연습문제 10.10.22 해설 문제. E 가 절반이라는 입력 사실에서 허용 쌍 수의 감소는 확인할 수 있다. 허용 쌍만 계산하고 폭이 같다면 점수/Value 주요 곱셈 수도 절반이다. Dense Mask 구현이면 실제 점수 셀 수는 그대로일 수 있다. 전체 메모리에는 투영 배열·반환·훈련 상태·인덱스가 있어 정확한 절반을 결론 내릴 수 없다.

실행 시간은 동일 하드웨어·정밀도·입력 길이·Batch·실제 구현·Warm-up/측정 규약을 고정한 실측이 필요하다. 정확도는 데이터/과제·학습/평가 조건과 비교 모델이 필요하다. 적절한 보고는 “이 Mask 의 허용 쌍 수는 절반이며, 해당 쌍만 계산한 주요 곱셈 범위도 절반이다. 전체 메모리·실행 시간·학습 정확도는 별도 측정이 필요하다” 다. 연구 결과를 인용한다면 “해당 논문의 명시한 과제·설정에서 관찰된 결과” 라고 범위를 쓴다. 비용의 포함/제외를 복습하자.

심화 해설

심화문제 10.10.1 해설 문제. $R_L = \sum_{\ell=1}^{L}(w_\ell - 1)$ 라 두면

$$D_b^{(L)} = \{\max(1, b - R_L), \dots, b\}.$$

기저 $L = 0$ 은 $\{b\}$ 다. 이전 층의 각 제공 $j \in [\max(1, b - w_L + 1), b]$ 가 길이 R_{L-1} 의 연속된 과거 구간에 의존하므로 그 합집합은 왼쪽 끝 $\max(1, b - (w_L - 1) - R_{L-1})$ 에서 b 까지다. 구간들이 인접 또는 겹치기 때문에 빠진 위치가 없다. 이것으로 귀납이 완결된다. 모든 폭 1 도 처리한다.

이 Local 규약에서는 결과가 폭의 합에만 의존해 순서를 바꾸어도 같은 집합이다. 일반 Graph 에서는 다르다. 길이 3 의 자기 Edge 에, Mask A 는 1→2, Mask B 는 2→3 을 추가하자. A 다음 B 면 초기 1→2→3 의 두 층 경로가 있다. B 다음 A 면 첫 층에 1 이 2 에 들어가지 않았고 둘째 3 은 자기만 읽으므로 초기 1 이 3 에 도달하지 못한다. 시간/층 순서를 지우고 두 그래프의 합집합만 보는 접근은 틀리다. 층별 재귀식을 복습하자.

심화문제 10.10.2 해설 문제. D 는 양의 분모를 대각에 둔 가역 행렬이다. 행렬곱 rank 부등식으로 $\operatorname{rank}(A) \le \operatorname{rank}(\Phi_Q \Phi_K^\top) \le r$ 다. 따라서 고정 작은 폭으로는 모든 가능한 전역 계수 행렬을 자유롭게 표현할 수 없다. 전역 접근과 계수 표현 자유도를 구별해야 한다.

Causal Mask 는 원소별로 관계를 지우며 일반적으로 같은 작은 두 행렬의 단순 곱이 아니다. $r = 1$, 모든 특징 1 인 길이 3 의 Prefix 평균은

$$A_{\text{causal}} = \begin{bmatrix} 1 & 0 & 0 \\ 1/2 & 1/2 & 0 \\ 1/3 & 1/3 & 1/3 \end{bmatrix}.$$

대각 곱 $1 \cdot (1/2) \cdot (1/3) = 1/6 \neq 0$ 이라 rank3 이다. 하지만 Prefix 누적 상태는 $r = 1$ 로도 계산된다. 상태 재사용과 최종 Causal 계수 행렬 rank 를 혼동하면 안 된다. Kernel 재배치를 복습하자.

심화문제 10.10.3 해설 문제. 미래 독립성의 기저는 0 상태다. 현재 S_i, z_i 는 이전 상태와 현재까지 허용된 특징/Value 로만 만들어지고 현재 Query 도 미래 독립이므로 출력도 미래 독립이다. 양의 분모에서 함수를 적용하는 것은 새로운 입력 의존성을 만들지 않는다. 시점 귀납과 층별 Causal 생성원 가정을 함께 적용한다.

반례로 첫 층의 $v_1 = x_1 + x_2$ 를 만들자. 두 번째 층의 위치 1 은 Prefix 항 1 만 쓰더라도 x_2 변경에 반응한다. 상태 갱신은 올바르지만 제공 항 생성원이 이미 미래를 읽었다. 반대로 항상 0 인 코드는 미래 변경에 불변이어도 특징 1·Value3 의 유일한 제공을 읽는 정답 3 과 다르다. 이 직접 합 검사와 허용 과거 Value3→5 의 출력 3→5 양성 대조가 그 코드를 거부한다. 불변성 정리를 복습하자.

심화문제 10.10.4 해설 문제. $n > 0$ 이므로 비교 부등식을 n 으로 나누면 $r(2d_v+1) < (n+1)(d_k+d_v)/2$ 다. 따라서

$$n > \frac{2r(2d_v + 1)}{d_k + d_v} - 1.$$

엄격한 부등식이므로 정수 경계의 같음에서는 더 적다고 말하지 않는다. r, d_k, d_v 를 고정하고 투영 등이 주어졌다는 비용 계약이다. 위치당 두 특징 생성의 총 곱셈 비용을 c_ϕ 라 정의하면 좌변에 c_ϕ 를 더해

$$n > \frac{2\{r(2d_v + 1) + c_\phi\}}{d_k + d_v} - 1$$

가 된다. c_ϕ 가 한 특징맵만의 비용이라면 Q/K 두 비용을 각각 더해야 한다. 폭 r 이나 생성 비용이 길이와 함께 늘어나면 조건도 함께 바뀐다. 예를 들어 $d_k = d_v = 1, r = 2, c_\phi = 0$ 이면 $n > 5$ 다. $n = 4$ 에서는 Full20 회보다 Factor24 회가 많고 $n = 6$ 에서는 Full42 회보다 Factor36 회가 적다.

이 비교는 곱셈 범위의 산술이다. 다른 출력 정의를 사용하므로 모델 정확도 보존을 판정하지 못하며 메모리 접근·오버헤드·하드웨어 병렬성을 포함하지 않아 GPU 시간도 판정하지 못한다. 비용 비교를 복습하자.

짧은 이해 확인 해설

이해 확인 1 Causal 허용 쌍은 $8 \cdot 9/2 = 36$, Dense 점수 셀은 64 다. 구현이 36 만 계산하는지 64 를 먼저 계산하는지 알아야 실제 산술을 셀 수 있다. 이 비를 시간 배율로 바로 읽을 수는 없다. 비용 범위로 돌아가 포함/제외를 쓰자.

이해 확인 2 모든 계수의 합 1 이므로 같은 값 7 을 섞으면 7 이다. 관계나 계수가 같다는 증거는 아니다. 서로 다른 Value 를 넣으면 차이가 드러날 수 있다. 우연 일치를 복습하자.

이해 확인 3 읽기 표시는 요청 4 가 제공 3 을 선택한다는 관계일 수 있지만, **정보 전달** 화살표는 3→4 다. Value3 이 요청 4 의 갱신으로 들어간다. 층을 포함하면 $3^{(\ell-1)} \to 4^{(\ell)}$ 다. 직접 연결을 복습하자.

이해 확인 4 성립하지 않는다. 폭 1 의 요청 특징 0, 제공 특징 1 이면 내적 0·분모 0 이다. 요청도 0 이 아닌 반례는 요청 $[1, 0]$, 제공 $[0, 1]$ 다. 가중치 비음수와 분모 양수는 각각 확인해야 한다. 정의 조건을 복습하자.

이해 확인 5 보장되지 않는다. 합의 범위만 제한해도 항 자체가 미래에 의존하면 누출된다. 이전 층과 Q/K/V·특징의 생성원이 같은 Causal 조건을 지켜야 한다. 불변성 정리를 복습하자.

이해 확인 6 $r = n/2$ 를 대입하면 $O(n^2 d_v + n^2)$ 다. 값 폭 고정에서도 길이에 이차다. 특징 폭의 고정 조건을 누락한 설명이 원인이다. 인자 비용을 복습하자.

다른 값 폭의 실행 자료

아래 파일은 본문의 값 폭 2 예제를 독립 실행한다. 직접 합과 인자 합이 둘 다 $[24/11, 17/11]$, $[15/10, 19/10]$, $[13/7, 12/7]$ 을 얻는지 확인하자. Prefix 는 다른 허용 집합을 쓰므로 출력이 $[2, -1]$, $[6/7, 13/7]$, $[13/7, 12/7]$ 이다.

solution_efficient.py | learning-source/solution_efficient.py | Python | L1-L16 (16 줄)
source revision: efficient-source-v0.1

```python
""" 본문과 다른 특징·값 폭의 독립 계산. CPU 에서 직접 합과 인자 합을 대조한다."""
import numpy as np
from efficient import kernel_direct, kernel_factorized, kernel_prefix, causal_mask


def solve_example():
    qf = np.array([[1., 2.], [2., 1.], [1., 1.]])
    kf = np.array([[1., 1.], [2., 0.], [0., 3.]])
    v = np.array([[2., -1.], [0., 4.], [3., 2.]])
    weights, a, direct = kernel_direct(qf, kf, v)
    s, z, factor = kernel_factorized(qf, kf, v)
    assert np.allclose(direct, factor)
    states, prefix = kernel_prefix(qf, kf, v)
    mask = causal_mask([1, 2, 3], [1, 2, 3])
    assert np.allclose(prefix, kernel_direct(qf, kf, v, mask)[2])
    return weights, s, z, direct, prefix
```

이 계산 자료는 손풀이의 대조이며 그래프 증명·학습효과·원 Softmax 동등성을 대신하지 않는다. 문제에서 요구한 비용 범위와 생략/대체/재배치를 자신의 풀이에 함께 기록하자.

10.11 전체 모델 구현과 종합 적용 — 해설

완성 숫자에 앞서 각 연산이 어떤 입력을 읽었는지 비교하자. 같은 차원의 배열이라도 생성원이 다르면 같은 객체가 아니다. 열린 설계 문제의 답은 아래 예시 하나로 제한하지 않는다. 허용 정보·출처·연산·반환을 모두 설명한 대안은 각 문제의 기준에 따라 검토할 수 있다.

유제 해설

유제 10.11.1 해설 문제. Encoder–Decoder 에서는 Encoder 의 각 활성 센서 요청이 유효 4 열을 읽고 패딩 열을 제외한다. 출력 입력은 첫 두 토큰을 예측할 때 [BOS, y_1] 이다. 둘째 요청의 Target 는 y_2 이고, Self Q/K/V 는 같은 출력 Prefix 의 해당 레이어 표현에서 만든다. Cross Q 는 현재 출력 표현, K/V 는 Encoder 반환에서 만든다. 둘째 요청의 Cross 허용 행은 센서 배열 열 순서에 맞춘 4 개의 True 와 패딩 열 False 다. 종료 기호도 Vocabulary 후보 중 하나여야 한다.

Decoder-only 는 $[s_0, s_1, s_2, s_3, \text{SEP}, \text{BOS}, y_1]$ 처럼 유효 센서만 직렬화할 수 있다. 패딩을 배열에 남겼다면 모든 출력 요청에서 해당 Key 열을 차단한다. 일반 Causal Mask 의 출력 둘째 요청은 네 센서·SEP·BOS·y_1 을 읽는다. 별도 Cross 가 필수는 아니며 Q/K/V 는 한 스택에서 나온다. 조건 구간을 양방향으로 만들려면 별도 Prefix Mask 를 정의하고 출력 미래가 조건 표현으로 되돌아가는 경로를 막아야 한다. 10.8 절에서 정보 요구와 두 출처를 복습한다.

유제 10.11.2 해설 문제. 행벡터를 각 열과 내적하면 $[1 + 2/2, -1, -1 + 2] = [2, -1, 1]$ 이다. Logit 열 0 의 A 가 최대이며 Target ID 는 1 이다. 열 번호 0 과 Token ID0=BOS 를 혼동하지 않는다. 선택 직후 입력과 Cache 는 여전히 기존 길이다. A 를 새 위치의 입력으로 처리한 뒤에야 그 위치의 레이어별 K/V 가 생기고 처리 길이가 1 증가한다. 다음 점수는 이 새 반환으로 계산한다. 10.9 절의 선택/처리 구별을 다시 확인하자.

유제 10.11.3 해설 문제. 투영 전 받는 배열 1×2×8 과 제공 배열 1×5×8 이다. 분할 후 Q 는 1×2×2×4, K/V 는 1×2×5×4 다. 두 번째 축이 Head 다. 점수/계수는 1×2×2×5 이고 각 Head 집계는 1×2×2×4 다. 위치 축을 Head 앞으로 옮기면 1×2 요청 ×2Head×4 이고 마지막 두 축을 이어 1×2×8 을 만든다. 출력 투영 뒤도 1×2×8 이다. 패딩 **제공 열**은 허용표 1×2×5 의 해당 마지막 축 열에서 False 다. 요청 2 와 제공 5 를 같은 길이라고 가정하면 Cross 반환 행을 잘못 세게 된다. 10.4 절·10.5 절을 복습한다.

유제 10.11.4 해설 문제. 첫 레이어 K/V 는 FFN 보다 앞의 $N_1(H^{(0)})$ 에서 만들어져 직접 유지된다. FFN 마지막 편향 변화는 첫 레이어 반환에 같은 변화량을 더한다. 일반적인 벡터 변화는 둘째 레이어 N_1 입력을 바꾸므로 그 K/V 와 Attention·후속 반환·Logit 이 달라질 수 있다.

예외로 모든 좌표에 같은 상수 c 를 더하면 둘째 레이어의 행 평균도 c 만큼 이동하고 분산은 같다. 그 앞 LN 출력은 같아져 둘째 레이어 K/V 가 유지될 수 있다. 하지만 둘째 레이어 Residual 직접 경로에는 그 상수 이동이 남는다. 기본 모델에서는 다음 위치별 연산 뒤 스택 마지막 LN 도 이 일률 이동을 없애 최종 Logit 까지 같을 수 있다. 이것은 해당 위치별 LN·가산 구조의 특수 불변성이다. FFN 편향 변경이면 모든 후속 K/V 가 반드시 달라진다는 주장도 과도하다. 보수적 구현은 이 예외를 분석하지 않고 매개변수 변경 Cache 를 거부한다. 10.7 절의 LN 이동 불변과 10.9 절의 생성원을 확인한다.

유제 10.11.5 해설 문제. Full 의 허용쌍은 6, Local 은 5 다. 주요 곱셈은 각각 $6(4+4) = 48$, $5(4+4) = 40$ 이다. Factorized 는 $nr(2d_v + 1) = 3 \cdot 2 \cdot 9 = 54$ 회로 여기서는 오히려 많다. 특징 생성 등 제외한 범위를

적어야 한다. 더 긴 n 에서 곱셈 수의 우열이 바뀔 수 있지만 실제 시간에는 연산 배치·라이브러리·메모리도 관여한다. 같은 특징 Kernel 의 직접/인자 합은 같아도 원 Softmax 출력 보존은 별도다. 10.10 절의 비용 범위를 복습한다.

독립 연습 해설

연습문제 10.11.1 해설 문제. 등급은 보고서 전체를 읽은 Encoder 표현을 Pooling 하거나 별도 분류 위치로 모아 등급 Readout 에 넣는 설계가 가능하다. 각 보고서 위치의 양방향 접근을 허용할 수 있다. 생성은 보고서와 앞 설명을 구별한다. Encoder–Decoder 에서는 보고서를 E 로 만들고 Causal Decoder Prefix 가 Cross 를 통해 E 를 읽는다. Decoder-only 에서는 보고서를 조건 Prefix 앞에 놓아 출력이 그것과 앞 출력을 읽게 한다. 출력 정답을 Encoder 조건에 함께 넣는 설계는 누출이다.

Encoder 하나를 분류에 썼다는 사실이 생성 이력 입력·Causal 접근·어휘 선택·반복 호출을 자동으로 제공하지는 않는다. 출력 이력을 받는 경로와 다음 토큰 감독을 추가해야 한다. 이름보다 각 예측의 입력을 명시한 답을 인정한다. 10.8 절에서 분류와 생성의 정보 요구를 복습한다.

연습문제 10.11.2 해설 문제. 입력은 [BOS, A, C], Target 는 [A, C, B] 다. 허용 입력 집합은 {BOS}, {BOS,A}, {BOS,A,C} 다. 자기 위치를 허용하는 것이 맞다. 현재 입력과 현재 Target 는 같은 Token 이 아니기 때문이다.

모든 입력에 전체 Target 평균을 더하면 첫 Query 의 입력부터 A/C/B 의 정보를 받는다. Q/K 경로뿐 아니라 Residual 직접 경로가 오염돼 올바른 삼각 Mask 도 복구하지 못한다. 각 Token 의 Embedding/Position 만 쓰거나 가용 Prefix 만의 집계를 별도로 정의하고 다시 검증한다. Target 는 Loss 에서만 사용한다. 10.3 절·10.8 절에서 전처리 누출을 확인한다.

연습문제 10.11.3 해설 문제. 비교 폭 1 이라 S=[[0, ln 3], [0, 0]] 다. 행별 지수합 4·2 를 써 A=[[1/4, 3/4], [1/2, 1/2]], O=[[1/2, 3], [1, 2]] 를 얻는다. Q 는 2×1, K 는 2×1, V 는 2×2, S/A 는 2×2, O 는 2×2 다.

Readout 결과는 첫 행 [1/2, 3, 5/2], 둘째 행 [1, 2, 1] 로 두 요청 모두 열 1 을 고른다. Attention Softmax 는 Key 두 위치에서 행별 합 1 을 만들고, 어휘 Softmax 는 Logit 의 세 후보에서 행별 합 1 을 만든다. 후자의 후보 수 3 을 앞의 제공 수 2 로 바꾸면 의미가 달라진다. 10.2 절의 두 합 축을 복습한다.

연습문제 10.11.4 해설 문제. W_Q 는 4×2 로 X 를 읽고, W_K 는 6×2·W_V 는 6×3 으로 E 를 읽는다. Q3×2, K2×2, V2×3, S/A3×2, O3×3 이다. W_O 는 3×4 라 M 은 3×4 다. 반환 행은 요청 X 의 세 요소에 대응한다. E 의 두 행은 정보를 제공했고 이 호출의 반환으로 갱신되지 않는다. 같은 폭이라도 출처 역할을 바꿀 수는 없다. 10.4 절의 Cross 를 복습한다.

연습문제 10.11.5 해설 문제. 평균 0, 분산 $(4+0+4)/3 = 8/3$, 분모 $\sqrt{11/3}$ 다. $Z = K = [2, 0, -2]/\sqrt{11/3} \approx [1.044466, 0, -1.044466]$ 다. 모든 좌표에 5 를 더하면 평균도 5 만큼 바뀌고 중심화 값·분산이 같아 K 는 유지된다. Residual 직접 경로의 원 입력은 [7, 5, 3] 으로 달라진다. K 가 같다는 사실만으로 블록 반환이 같다고 결론낼 수 없다. 10.7 절의 LN 과 Residual 을 별도로 복습한다.

연습문제 10.11.6 해설 문제. Full 은 원위치 1·2·4 가 허용돼 배열 순서 [1, 1, 0, 1] 이다. 폭 2 Local 은 원위치 3·4 중 유효 4 만 허용돼 [1, 0, 0, 0] 이다. 배열의 끝 두 열은 원위치 3·2 이므로 잘못된 허용 집합이

다. 원위치 비교와 패딩 제외를 함께 적용해야 한다. 10.3 절의 원래 위치표와 10.10 절의 Window 규약을 확인한다.

연습문제 10.11.7 해설 문제. Prefill 직후 보유 위치 0·1·2, 처리 Token3 개다. 선택 1 은 아직 없다. 다음 호출 입력은 ID1 하나와 원위치 3 이며 그 반환은 위치 4 의 다음 토큰을 예측한다. 각 레이어 기존 K/V shape1×2×3×4 에 새 1×2×1×4 를 위치 축으로 붙여 1×2×4×4 를 얻는다. 로그는 '선택 1, 아직 처리 전'과 '위치 3 처리 완료, Cache 길이 4' 를 구별해야 한다. 10.9 절를 복습한다.

연습문제 10.11.8 해설 문제. Full 의 초기 H 는 [2, 1], 잘못된 Incremental 의 H 는 [0, 1] 이다. 원위치 계약이 첫 단계부터 다르다. 이후 투영의 영공간·정규화·Readout 상쇄 때문에 Logit 이 우연히 같을 수 있으므로 Embedding/Position·K/V·Block 반환까지 검사해야 한다. 같은 입력이 보장된 동등성 정리의 전제가 깨졌다. 10.6 절·10.9 절을 복습한다.

연습문제 10.11.9 해설 문제. 올바른 순서는 $z = N_1(h) \to \mathrm{M(z)} \to r = h + M \to u = N_2(r) \to \mathrm{F(u)} \to y = r + F$ 다. 이후 스택 마지막 $N_f(y) \to \mathrm{W}$ 다. 오류는 FFN 에 정규화 전 r 를 넣고 그 합을 N_2 로 정규화한다. 이는 명시된 Pre-LN 과 다른 반환이며 마지막 LN 도 바꿨다. 입력/반환 폭이 같아도 함수 합성이 같아지지 않는다. 10.7 절에서 두 순서를 나란히 적자.

연습문제 10.11.10 해설 문제. 확인된 것은 해당 데이터·측정 모드·실행 환경에서 Loss 와 학습 데이터 예측이 개선됐다는 사실이다. 새로운 규칙·긴 길이·자연어·분포 변화 일반화는 확인되지 않았다. 같은 전체 학습 입력·Target·Loss Reduction·모드에서 갱신 전과 지정 갱신 후에 다시 계산한다. Dropout 이 있다면 평가 조건도 고정한다.

일반화는 학습에 쓰지 않은 입력·길이·규칙 등을 구별한 평가셋을 설계하고 어떤 이동을 시험하는지 명시한다. 네 시작 위상이 모두 학습에 포함됐다면 위상만 바꾼 결과를 새로운 규칙 일반화라고 부르지 않는다. 실제 언어 능력은 별도 과제와 관측이 필요하다. 본문의 학습 결과로 돌아간다.

연습문제 10.11.11 해설 문제. 위치 2 까지 $\mathrm{S}=[2,0]^\top$, $\mathrm{z}=[2,1]^\top$ 다. Query [1, 1] 의 분자 2·분모 3 이므로 출력 2/3 이다. 위치 3 의 제공 특징 [0, 1]·값 4 를 더해 $\mathrm{S}=[2,4]^\top$, $\mathrm{z}=[2,2]^\top$ 가 된다. 현재 Query [0, 1] 의 출력은 4/2=2 다.

위치 2 Query 에 이 전체 상태를 쓰면 $(2+4)/(2+2) = 3/2$ 가 되어 미래 3 의 Value 를 읽었다. 같은 Factorized 식이라도 합 범위를 틀리면 Causal 모델이 아니다. 10.10 절의 Prefix 상태를 복습한다.

연습문제 10.11.12 해설 문제. 별도 SDPA/스칼라 Attention 또는 지정 닫힌식과 대조해 0 반환을 거부한다. 유효 과거의 V 나 Token 을 바꾸어 알려진 비영 기여가 있는 조건에서 뒤 출력을 비교한다. Q/K/V·허용표·행합 1·Head 반환·Residual·레이어별 K/V 를 각각 대조한다. 학습에서는 유한 Loss·비영 Gradient/Parameter Update 와 갱신 후 재계산을 확인한다.

과거 변경 무반응이 언제나 오류는 아니다. 투영이 0, 값 변화가 영공간, 출력 변환 상쇄인 정상 모델도 가능하다. 따라서 양성 대조는 반응할 이유를 지정하거나 기준 계산과 함께 써야 한다. 불변 시험 하나를 정확성 증명으로 읽지 않는다. 10.9 절·10.10 절의 반례를 복습한다.

종합 Checkpoint 상세 해설

연습문제 10.11.13 해설 문제. 원문 배열 6 열 중 유효 5 열과 패딩 1 열이 있다. 활성 Encoder 요청마다 $[1,1,1,1,1,0]$ 을 허용한다. 패딩 요청은 제외하거나 별도 비활성 계약을 둔다. Decoder 입력 3 행의 Self 는 $[[1,0,0],[1,1,0],[1,1,1]]$ 다. Cross 는 3×6 이며 각 행이 $[1,1,1,1,1,0]$ 이다. 원문 열 번호를 Decoder 요청 번호와 비교해 원문의 뒤쪽을 막는 것은 요구에 없는 제한이다.

Decoder-only 는 유효 조건 5 개·SEP·BOS·앞 설명 2 개를 이어 놓고 각 출력 위치가 조건과 앞 출력만 읽게 한다. 일반 Causal Prefix 는 조건 앞 행이 뒤 조건을 읽지 못한다. 조건 내부 양방향을 택할 수도 있지만 그때도 조건 행이 출력 구간을 읽지 못하게 해야 미래 출력이 조건 표현을 통해 역류하지 않는다.

Encoder–Decoder E 는 조건 전체를 양방향으로 읽고 별도 스택에서 반환된다. 일반 Decoder-only 의 조건 표현은 Causal 스택에서 만들어진다. 매개변수·위치·Norm 순서까지 같다고 주어지지 않았으므로 두 K/V 를 같다고 할 수 없다. 정보 요구 충족과 함수 동일성은 다른 판정이다.

Cross W_Q : 4×2, W_K : 4×2, W_V : 4×3, Q3×2, K6×2, V6×3, S/A3×6, O3×3, W_O : 3×4, 반환 3×4 다. 패딩 열은 투영 행으로 존재해도 정규화 전에 제외한다. 10.8 절·10.4 절를 복습한다.

연습문제 10.11.14 해설 문제. Head1 의 Q/K 는 $[2,0,1]^{\mathsf{T}}$, V 는 $[4,0,2]^{\mathsf{T}}$ 다. Head2 Q/K 는 $[0,1,2]^{\mathsf{T}}$, V 는 $[0,3,6]^{\mathsf{T}}$ 다. 모두 비교 폭 1 이라 Scaling 은 1 이다.

$$S_1=\begin{bmatrix}4&0&2\\0&0&0\\2&0&1\end{bmatrix},\qquad S_2=\begin{bmatrix}0&0&0\\0&1&2\\0&2&4\end{bmatrix}.$$

Head1 의 지수 행은 $[e^4,1,e^2]$, $[1,1,1]$, $[e^2,1,e]$ 이고 각각 행합으로 나눈다. Head2 는 $[1,1,1]$, $[1,e,e^2]$, $[1,e^2,e^4]$ 다. A 의 각 행을 해당 V 와 내적해 아래 결과를 얻는다.

요청	Head1 O	Head2 O	Concat/최종 반환
0	3.701874184	3.000000000	[3.701874, 3.000000] / [5.201874, −0.701874]
1	2.000000000	4.725631148	[2.000000, 4.725631] / [4.362816, 2.725631]
2	3.150420765	5.552811277	[3.150421, 5.552811] / [5.926826, 2.402391]

Concat 의 한 행은 $[o_1,o_2]$ 로 2 좌표다. W_O 를 곱하면 $[o_1+o_2/2,-o_1+o_2]$ 다. 두 Head 를 합친 S 의 공통 Softmax 는 각각 다른 비교 좌표의 점수를 먼저 합친 새로운 계수다. 특히 첫 요청의 올바른 Head2 는 균일 평균 3 인데, 합친 점수 $[4,0,2]$ 를 쓰면 그 값이 달라진다. 독립 Head 구현이 아니다.

Cross 에서는 Q1 은 D 의 첫 열 $[1,0]^{\mathsf{T}}$, Q2 는 둘째 열 $[-1,2]^{\mathsf{T}}$ 이고 K/V 는 X 에서 유지한다. 각 Head 점수는 2×3, 집계 2×1, Concat/반환 2×2 다. X 의 세 행은 제공이고 D 의 두 요청을 갱신한다. 원 Self 의 점수 3×3 을 재사용할 수 없다. 10.5 절·10.4 절를 복습한다.

연습문제 10.11.15 해설 문제. 배열 순서 2·0·1·3 에서 요청 0 은 원위치 0 만 읽어 B 첫 행 $[0,1,0,0]$, 요청 1 은 0·1 을 읽어 둘째 행 $[0,1,1,0]$ 이다. 원점수는 $[[\ln 5,0,\ln 2,0],[0,0,0,0]]$ 다. 허용표를 Softmax 전에 적용해 A=$[[0,1,0,0],[0,1/2,1/2,0]]$, O=$[2,3]^{\top}$ 를 얻는다. 원점수의 미래 항을 작게 만드는 방식은 접근 금지와 다르다.

배열 삼각 Mask 의 첫 열은 미래 원위치 2 라 요청 0 에 Target 이후 내용을 보여 준다. 원위치와 유효 표시로 B 를 만들고 금지 점수를 $-\infty$ 로 바꾼 뒤 **허용 열만 새 분모**로 정규화한다. Softmax 뒤 0 을 곱하면 허용 계수합이 1 이 아닐 수 있다. 미래 K/V 를 바꿔도 이 두 요청의 계수와 집계·반환이 같아야 한다. Q 나 초기 표현까지 미래에 의존하면 이 조건은 더 이상 성립하지 않는다.

Target 평균을 초기 입력에 섞었다면 Query 생성원과 Residual 에 우회 경로가 남는다. 평균을 제거하거나 이미 알려진 Prefix 만으로 재정의하고 미래 불변·허용 과거 양성 대조를 다시 한다. 10.3 절·10.8 절에서 입력 생성원을 복습한다.

연습문제 10.11.16 해설 문제. 원 내적은 $2\cdot 1+1(-1)=1$ 이다. Absolute 는 $(2+i/2)(1+j/2)-1$ 을 $\sqrt{2}$ 로 나눈다. 0·1 에서 $2/\sqrt{2}=\sqrt{2}$ 이고 2·3 에서는 $(3\cdot 2.5-1)/\sqrt{2}=6.5/\sqrt{2}$ 다. 두 위치항이 각각 들어가므로 동시 이동으로 바뀐다.

Relative 는 $1/\sqrt{2}-|j-i|/3$ 라 두 배정 모두 $1/\sqrt{2}-1/3$ 이다. RoPE 는 $q^{\top}R_i^{\top}R_jk/\sqrt{2}=q^{\top}R((j-i)\pi/2)k/\sqrt{2}$ 다. 차이 1 에서 $R(\pi/2)k=[1,1]$ 이고 내적 3, 점수 $3/\sqrt{2}$ 다. 두 위치를 2 만큼 이동해도 같은 상대 회전이다.

이 식은 같은 직교 회전 규약·고정 내용벡터·동일 주파수에 대한 쌍의 내적이다. 이전 층의 내용벡터가 위치 이동으로 달라지면 최종 Attention 전체 불변은 따로 검토한다. 이 RoPE 는 Q/K 에 적용해 V 를 직접 회전하지 않지만 계수 변화로 집계가 달라질 수 있다. 위치 점수는 미래 열을 금지하지 않으므로 Mask 를 대체하지 않는다. 10.6 절의 회전 성립 조건을 복습한다.

연습문제 10.11.17 해설 문제. $R=[1.5,-0.75]$, 평균 0.375, 중심화 $[1.125,-1.125]$, 분산 1.265625 다. 분모 $\sqrt{2.265625}$ 이고 $u=[a,-a]$, $a\approx 0.747409319$ 다. FFN 첫 곱은 $[a,a]$ 여서 ReLU 후도 같고 반환 $[a/4,a/2]\approx[0.186852330,0.373704659]$ 다. 최종 y 는 $[1.686852330,-0.376295341]$ 다.

Pre-LN 의 M 입력은 $N_1(h)$ 이며 FFN 입력은 $N_2(R)$ 다. Post-LN 의 $N(h+M(h))$ 는 M 에 원 h 를 넣고 합을 정규화한 뒤 다음 하위 연산으로 넘긴다. 문제에서 주어진 $M(N_1(h))$ 값을 M(h) 의 값이라고 바꾸어 쓸 수 없다. 폭 2 가 같다는 사실은 합성 순서를 검증하지 않는다. 10.7 절에서 입력표를 다시 적는다.

연습문제 10.11.18 해설 문제. 새 ID2 의 Embedding $[1.4,0.3]$ 에 위치 2 의 $[0.2,0]$ 을 더해 $h^{(0)}=[1.6,0.3]$ 이다. 첫 레이어 평균 0.95·분산 0.4225 이므로 $z=[0.544988351,-0.544988351]$ 다. 따라서 Head1 새 q=k=0.544988351, v=1.089976701, Head2 새 q=k=−0.544988351, v=−2.179953402 다. 과거 각 Head 의 K/V 뒤에 이 행을 붙인다.

새 위치 계산	첫 레이어	둘째 레이어
N1 입력 정규화 Z	$[0.544988,-0.544988]$	$[0.782682,-0.782682]$
Head Concat	$[0.416302,-0.832604]$	$[1.108971,-2.217942]$
출력 투영 M	$[0.416302,-0.416302]$	$[1.108971,-1.108971]$
Residual R	$[2.016302,-0.116302]$	$[3.589984,-1.142918]$
N2 결과 U	$[0.729421,-0.729421]$	$[0.921133,-0.921133]$

새 위치 계산	첫 레이어	둘째 레이어
FFN 활성값	[0.729421, 0.729421]	[0.921133, 0.921133]
FFN 반환 F	[0.464710, 0.082355]	[0.560567, 0.130283]
블록 반환	[2.481012, −0.033947]	[4.150550, −1.012635]

각 층의 두 Head 는 이 예제의 부호 대칭 때문에 같은 점수 행을 가진다. 점수 행은 다음과 같다.

$$S^{(1)} \approx [0.156601250, -0.280394193, 0.297012302],$$
$$S^{(2)} \approx [0.568555794, -0.520426770, 0.612591548].$$

비교 폭 1 이라 Scaling 은 1 이며 각 행의 최대값을 뺀 지수를 행합으로 나눈다. 첫 레이어 계수 [0.357561575, 0.230975615, 0.411462810] 을 얻는다. Head1/2 의 값 배율과 부호는 다르므로 반환은 같지 않다. 첫 블록 반환 [2.481012315, −0.033946924] 가 둘째 레이어의 원 입력이다. 여기에 다시 같은 Token Embedding 을 더하지 않는다. 둘째 Z 는 [0.782682278, −0.782682278] 이고 Head1 새 K/V 는 0.782682278, 1.565364556, Head2 는 −0.782682278, −3.130729112 이다.

둘째 계수는 약 [0.419889588, 0.141317513, 0.438792899] 다. 표의 합·N/F 를 거쳐 반환 [4.150550285, −1.012634777] 을 얻는다. 마지막 추가 LN 이 **없는 이 별도 모델**의 Logit 은 [4.150550285, −1.012634777, −5.163185061] 이며 열 0 을 고른다. 학습 모델의 마지막 LN 을 이 문제에 임의로 추가하지 않는다.

각 레이어·Head Cache 는 과거 2×1 과 새 1×1 을 합쳐 3×1 이다. 과거 K/V 를 동일하게 보유하고 새 항목만 다른 값으로 추가한다. 전체 Prefix 를 2Head×2 레이어로 처음부터 계산한 마지막 반환/Logit 과 수치 허용오차 내 같다. 고정 매개변수·같은 Token/원위치·Causal 관계·위치별 N/F·Dropout 없음이 그 이유다. 다음 입력이 선택되면 아직 그 위치 Cache 는 없다.

solution_integrated.py | learning-source/solution_integrated.py | Python | L25-L42 (18 줄)
source revision: integrated-source-v0.1

```python
    old_h, old_g, past, old_trace = full_prefix(model, [0, 1], [0, 1])
    returned, logits, updated, inc = incremental(model, [0, 1], [0, 1], 2, 2, past)
    full_h, full_g, full_cache, full_trace = full_prefix(model, [0, 1, 2], [0, 1, 2])
    assert np.allclose(returned[0], full_h[-1], rtol=1e-13, atol=1e-13)
    assert np.allclose(logits[0], full_g[-1], rtol=1e-13, atol=1e-13)
    result = dict(heads=heads, joined=joined, mixed=joined@wo,
                  block=dict(h=h, mixed=mixed, r=r, u=u, active=active, f=f, returned=r+f),
                  cache=dict(past=past, old_trace=old_trace, incremental=inc,
                             returned=returned, logits=logits, updated=updated))
    (Path(__file__).resolve().parent/'SOLUTIONS_INTEGRATED.json').write_text(
        json.dumps(serial(result), ensure_ascii=False, indent=2)+'\n')
    print('새 Head 결합:', result['mixed'])
    print('새 Pre-LN 반환:', r+f)
    print('새 두 레이어 반환/Logit:', returned, logits)
    for i, c in enumerate(past['layers']):
        print('과거 층',i+1,[(h['k'].ravel().tolist(),h['v'].ravel().tolist()) for h in c['heads']])
    for i, t in enumerate(inc):
        print('새 층',i+1,'z',t['z'],'반환',t['result'],'가중치',[h['weights'] for h in t['heads']])
```

이 발췌는 별도 모델 구성·전체/증분 대조와 결과 저장 경로다. 본문의 과거 표는 같은 파일에서 전체 정밀도로 재생성한다. 10.9 절·10.7 절를 복습한다.

연습문제 10.11.19 해설 문제. 각 변경은 이전 변경을 누적하지 않는다. ‘달라질 수 있다’ 는 생성원이 달라지는 일반 판정이고 영공간·상쇄 등 예외를 함께 검토한다.

독립 변경	첫 레이어 K/V	둘째 레이어 K/V 와 이유
Token ID1 변경	위치 1 재계산 가능,0·2 의 초기 출처는 유지	위치 1·2 의 첫 반환이 바뀔 수 있어 재계산,0 은 미래 1 을 못 읽어 유지
위치 2 Absolute 변경	위치 2 재계산 가능,0·1 유지	위치 2 만 첫 반환 생성원이 바뀔 수 있어 재계산,0·1 유지
첫 W_Q 만 변경	모든 K/V 생성식 유지	Attention 반환이 달라질 수 있는 위치 1·2 재계산 가능; 단일 Key 위치 0 은 계수 1 이라 반환 유지
첫 FFN 편향 변경	모든 K/V 유지	모든 첫 반환 변화가 일반적으로 둘째 입력을 바꿈; 일률 좌표 이동은 앞 LN 에서 사라질 수 있음
요청 2 의 Key1 차단	Q/K/V 투영 자체는 모두 유지	요청 2 반환·둘째 위치 2 K/V 재계산 가능; 과거 0·1 유지
마지막 Readout 변경	모두 유지	모두 유지; Logit 만 새 행렬로 재계산

Q 나 Mask 변경은 해당 레이어 Cache 의 생성식보다 **그 Attention 반환의 후속 사용**을 통해 다음 레이어에 영향을 줄 수 있다. 위치 0 은 유일한 허용 Key 여서 Q 변경에 무관하게 계수 1 이며, 여기서 값 경로를 따로 보아야 한다. LN 이 동일 좌표 이동을 없애는 예외도 K/V 가 반드시 바뀐다는 단정을 막는다. 최소 재계산 판정은 이 수식 분석의 결과이고, 실행 인터페이스가 모든 매개변수 변경에서 Cache 를 거부하는 것은 보수적 구현 선택이다. 10.9 절의 변경 사례와 생성원을 복습한다.

연습문제 10.11.20 해설 문제. Full 마지막 지수는 $[1,2,3,4]$, 분모 10, 계수 $[1,2,3,4]/10$ 이다. 분자는 $2-2+0+16=16$ 이므로 출력 8/5 다. Local 은 3·4 만 읽어 분모 7, 계수 $[0,0,3,4]/7$, 출력 16/7 이다. Full10 쌍·Local7 쌍이며 생략은 (3,1),(4,1),(4,2) 다. 원 Full 계수에서 앞 항만 지우면 값 1.6 을 유지하지만 계수합 0.7 로 올바른 Local 이 아니다.

Kernel 마지막 계수의 분자는 $[2,1,3,5]$, 합 11 이다. Value 집계 분자는 $4-1+0+20=23$, 출력 23/11 이다. 인자 상태 $S=[10,3]^\top$, $z=[4,3]^\top$ 이고 Query $[2,1]$ 에서 $(20+3)/(8+3)=23/11$ 로 같다. 이는 주어진 Kernel 의 정확한 재배치이며 8/5 의 원 Softmax 와 다르다.

위치 2 까지만 누적하면 $S=[2,-1]^\top$, $z=[1,1]^\top$ 다. Query $[0,1]$ 는 출력 -1 을 얻는다. 원위치 1 은 허용되지만 특징 내적 0 이라 실제 기여가 없다. 전역 상태를 쓰면 3/3=1 이어서 미래 3·4 의 정보가 들어간다. Kernel 의 Causal 허용쌍은 10 개지만 양의 특징 내적 쌍은 9 개다. 허용 경로와 비영 수치 경로를 구별한다.

Full 의 1→4 는 한 단계, Local 은 최소 3 단계다. Kernel 은 마지막 특징이 첫 특징과 양의 내적 2 를 가지므로 1→4 가 직접 가능하다. Full/Local 의 Score/Value 곱셈 20/14 회, Factorized 는 $4\cdot 2(2\cdot 1+1)=24$ 회다. 직접 Kernel 을 허용쌍별 특징 내적과 Value 합으로 계산하면 $10(2+1)=30$ 회다. 여기서는 인자식이 직접 Kernel 보다 적지만 원 Softmax 보다 많다. 작은 r·n 의 비용만으로 GPU 시간 우위를 주장하지 않는다.

Cache 는 원 Full 의 투영/과거 표현 재계산을 줄이고 현재 Query 의 과거 읽기는 유지한다. Local 은 직접 관계를 지우고 Kernel 은 계수 정의를 바꾼다. 10.10 절·10.9 절의 보존 조건을 복습한다.

연습문제 10.11.21 해설 문제. 최초 오류는 1 번이다. 과거 길이 2 뒤의 실제 위치는 2 여야 하는데 0 을 썼다. 이후 2 번은 Pre-LN 투영 입력 Z 를 생략한다.3 번은 Head 축을 만들지 않아 1×2×1×4 의 Q 가 아니다.4 번은 레이어별 생성원이 다른 K/V 를 공유한다.5 번은 새 Key/Value 와 과거를 모두 포함하지 않고 Key 길이 3 에 맞는 1×3 허용표도 만들지 않는다.6 번은 요청 축을 정규화해 Key 계수를 만들지 않는다.8 번은 Post-LN 과 다른 FFN 입력을 섞었고 9 번은 스택 마지막 LN 이 없다.

수정 순서는 다음과 같다. 실제 위치 2 의 Token/Position 합 → 레이어별 $N_1(h)$→Q/K/V 투영과 Head 분할 → 해당 레이어 과거 K/V 에 새 위치 추가 → 원위치 0·1·2≤Query2 의 허용표 → 비교 폭 4 의 제곱근 $\sqrt{4} = 2$ 로 나누기 →Key 축 Softmax→Head 별 Value 집계 → 요청 축을 앞으로 옮긴 Concat→ 출력 투영 → 원 h 와 합 R→$N_2(R)$→FFN→R 와 합한 다음 레이어 h 다. 두 레이어 뒤 $N_f(h)$→Vocabulary Projection 을 적용한다.

7 번은 요청이 하나라 Head 와 그 한 위치의 펼침 순서가 우연히 맞을 수 있다. 여러 요청에서는 Head1 의 모든 위치와 Head2 의 모든 위치가 먼저 펼쳐져 올바른 요청별 Head 결합이 아니다. 따라서 `transpose(1,2).contiguous().reshape(b,n,8)` 로 명시한다.

최종 Logit 은 Readout 영공간이나 상쇄 때문에 일부 오류를 숨길 수 있다. Position/초기 H·레이어별 Q/K/V·Mask·가중치 행합·Head 순서·Residual/반환·Cache 과거 보존을 따로 대조한다. 두 요청 이상의 Concat 시험과 허용 과거 양성 대조를 포함한다. 10.5 절·10.7 절·10.9 절에서 각 출처를 다시 연결한다.

연습문제 10.11.22 해설 문제. 한 유효 답은 Encoder–Decoder 다. 조건 20 개를 양방향 Encoder 로 표현하고, 출력 입력 BOS 와 생성 Prefix 를 Causal Decoder 에 넣는다. Cross 는 모든 유효 조건을 읽어 첫 출력부터 먼 조건 단서에 접근한다. 출력 위치 p 는 이전 출력까지 담은 입력으로 다음 출력 p+1 을 예측한다. Absolute 를 선택했다면 조건/출력 위치표 길이를 각각 충분히 정하고 Full/Incremental 의 원 위치를 같게 쓴다. RoPE 를 선택했다면 회전 규약과 Key 저장 시점을 명시한다.

고정 Encoder E 와 Cross K/V 는 보관 가능하며 Self K/V 는 각 Decoder 레이어·Head 에서 따로 Append 한다. Prefill 과 선택/처리 시간을 분리하고 마지막 선택을 처리하지 않았으면 그 상태를 기록한다. 파라미터·조건·위치·Mask 변경 때 생성원을 다시 평가한다. 미래 출력/Target 를 Encoder 나 초기 전처리에 넣지 않고 미래 불변·허용 과거/조건 변경 대조를 수행한다.

정확한 Full 출력을 유지해야 한다면 Cache 와 정확한 실행 최적화를 우선 검토할 수 있다. Local 은 먼 조건 직접 읽기를 없애 요구와 충돌할 수 있다. 조건 Cross 는 Full 로 유지하고 출력 Self 만 Local 로 바꾸는 대안도 가능하지만 먼 출력 이력 경로의 변화·필요 층 수·성능 검증을 남겨야 한다. Kernel 은 조건 직접 관계를 유지할 수 있어도 계수와 학습 모델 함수가 바뀌므로 원 Softmax 동일성을 포기하고 새 과제 평가가 필요하다. 짧은 CPU 에서는 실제 시간 이득도 확인해야 한다.

Decoder-only 대안도 조건 20 개를 앞 Prefix 에 넣고 출력에서 모든 조건/과거를 읽도록 설계하면 인정한다. 조건 구간의 내부 접근·분리 기호·어휘 감독·위치 한도·Cache 생성원을 구체화해야 한다. 두 설계의 함수 동일성을 주장할 필요는 없다.

판정 기준은 (1) 각 예측의 가용 정보와 누출 경로, (2) 모든 Q/K/V·Block/Readout 출처와 shape, (3) 학습/생성 입력 이동, (4) Position·Cache 유효성, (5) 비용 범위·생략/대체 관계, (6) 수학적 대조·CPU 시간

측정·독립 과제 평가와 한계다. 구조명만 적으면 부족하다. 전 항목을 수행했다고 실제 Mastery 나 최적 설계가 입증되는 것은 아니다. 10.8 절·10.9 절·10.10 절를 복습한다.

심화 해설

심화문제 10.11.1 해설 문제. 길이 m 의 Full Causal 허용쌍은 $m(m+1)/2$ 다. 길이 1...N 을 매번 다시 계산하면 누적은 $\sum_{m=1}^{N} m(m+1)/2 = N(N+1)(N+2)/6$, 고정 Head 폭에서 $O(N^3)$ 다. Cache 로 새 Query 하나만 계산하면 단계 m 의 쌍은 m 이고 합 $N(N+1)/2$, $O(N^2)$ 다. 실제 Dense 구현은 Full 단계마다 m^2 셀을 계산할 수 있어 정확한 셀 합은 별도지만 차수는 같다.

K/V·위치별 투영/FFN 을 전체 재계산하면 위치 수 합이 $N(N+1)/2$ 이고 Cache 새 위치만 계산하면 N 이다. Cache 저장은 고정 폭·층 수에서 $O(N)$ 이다. 마지막 새 Query 의 과거 읽기는 $O(N)$ 이며 Cache 가 이를 상수로 만들지는 않는다. 마지막 선택 Token 을 처리하지 않았다면 실제 처리 길이까지의 합을 사용해야 한다. 10.9 절·10.10 절의 비용 포함 범위를 확인한다.

심화문제 10.11.2 해설 문제. 스텝 t 의 K/V 는 그때의 Token/Position·LN·투영/이전 레이어 반환·매개변수에서 나온다. 매개변수 갱신 뒤에는 같은 입력도 다른 K/V 를 만들 수 있으므로 t+1 의 Full 계산과 순방향이 달라진다. detach 는 과거 K/V 를 통해 그 생성원의 매개변수로 돌아갈 Gradient 를 끊는다. 매개변수가 우연히 K/V 에 영향을 주지 않았어도 미분 경로의 동등성을 자동 보장하지 않는다.

고정 모델의 추론에는 Gradient 가 필요 없고, Causal 미래 추가가 과거 표현을 바꾸지 않으므로 저장 재사용 정리를 쓸 수 있다. 별도 학습법이 과거 상태를 상수로 취급하거나 일부만 미분하도록 의도했다면 그 목적과 손실·Gradient 근사/절단을 따로 정의할 수 있다. 이는 일반 전체 Prefix 자동미분과 같은 학습이라고 주장할 수 없다. 10.9 절의 고정 모델 가정과 본문의 학습 경로를 복습한다.